Big Data e Ciência de Dados

Prof. André Britto de Carvalho

Introdução

- Dados
  - Fatos que podem ser gravados e que têm significado implícito.
  - Nomes, telefones, endereços, notas, etc.

Introdução

- Banco de Dados →Coleção de dados que descreve as atividades de uma ou mais **organizações** ou **empresas.**

Introdução

- Sem perceber geramos dados a todo momento
  - Uso de cartões fidelidade
  - Compras no cartão de crédito
  - Buscas na internet
  - Ida a uma hospital

Introdução

- Passado
  - Poucas companhias geravam dados
  - Consumidas por companhias, governo, ONG, pessoas

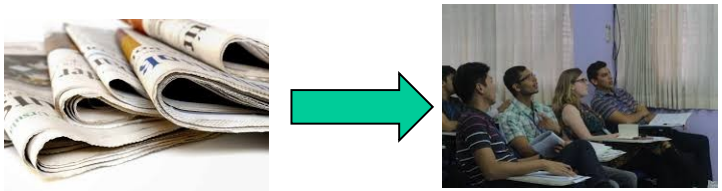

- Presente
  - Todos produzem dados
  - Todos consomem dados

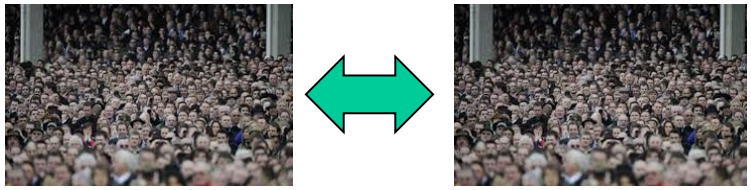

Explosão de dados

- Onde os dados são gerados
  - Dados de empresas
  - Dados do governo
  - Dados sociais
  - Dados de sensores
  - Música
  - Imagens
  - Vídeos

Fontes de dados

- Dispositivos eletrônicos
  - Smartphones
  - Logs de servidores de aplicação
    - Jogos e web sites
  - Sensores
    - Dados do clima, reservatórios de água, corpo humano
  - Imagens e vídeos
    - Monitoriamento de tráfego, vigilância.

Fontes de dados

- Atividades humanas
  - Blogs
  - Emails
  - Search and browsing
  - Redes sociais

Por que há essa explosão de dados?

- Avanços da tecnologia
  - Transmissão
  - Processamento
  - Armazenamento
- Mais, rápido e barato

Crescimento na transmissão de dados

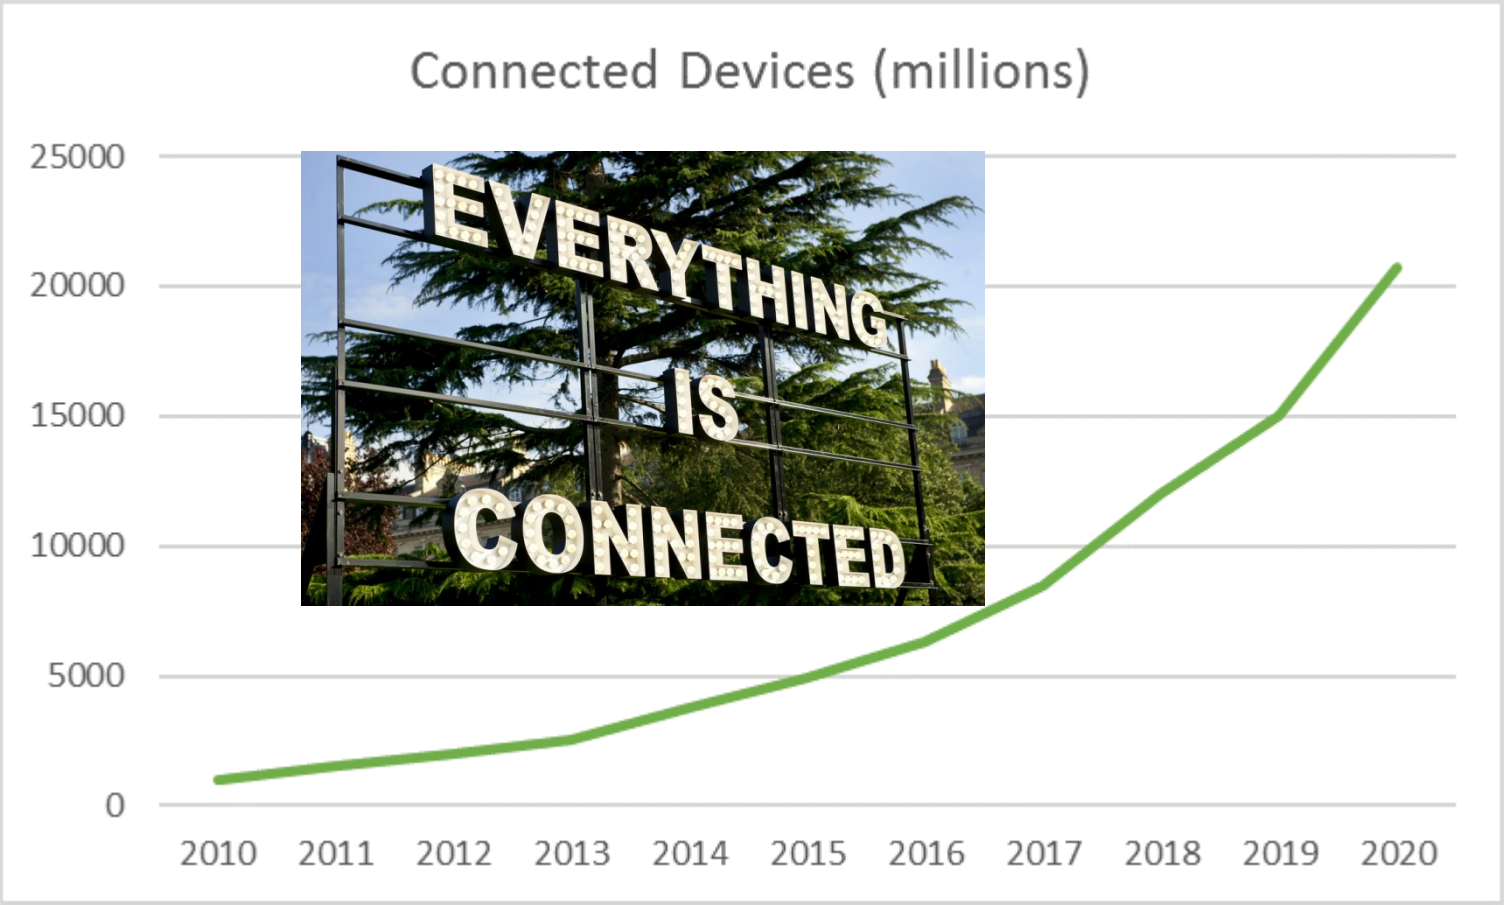

Crescimento na transmissão de dados

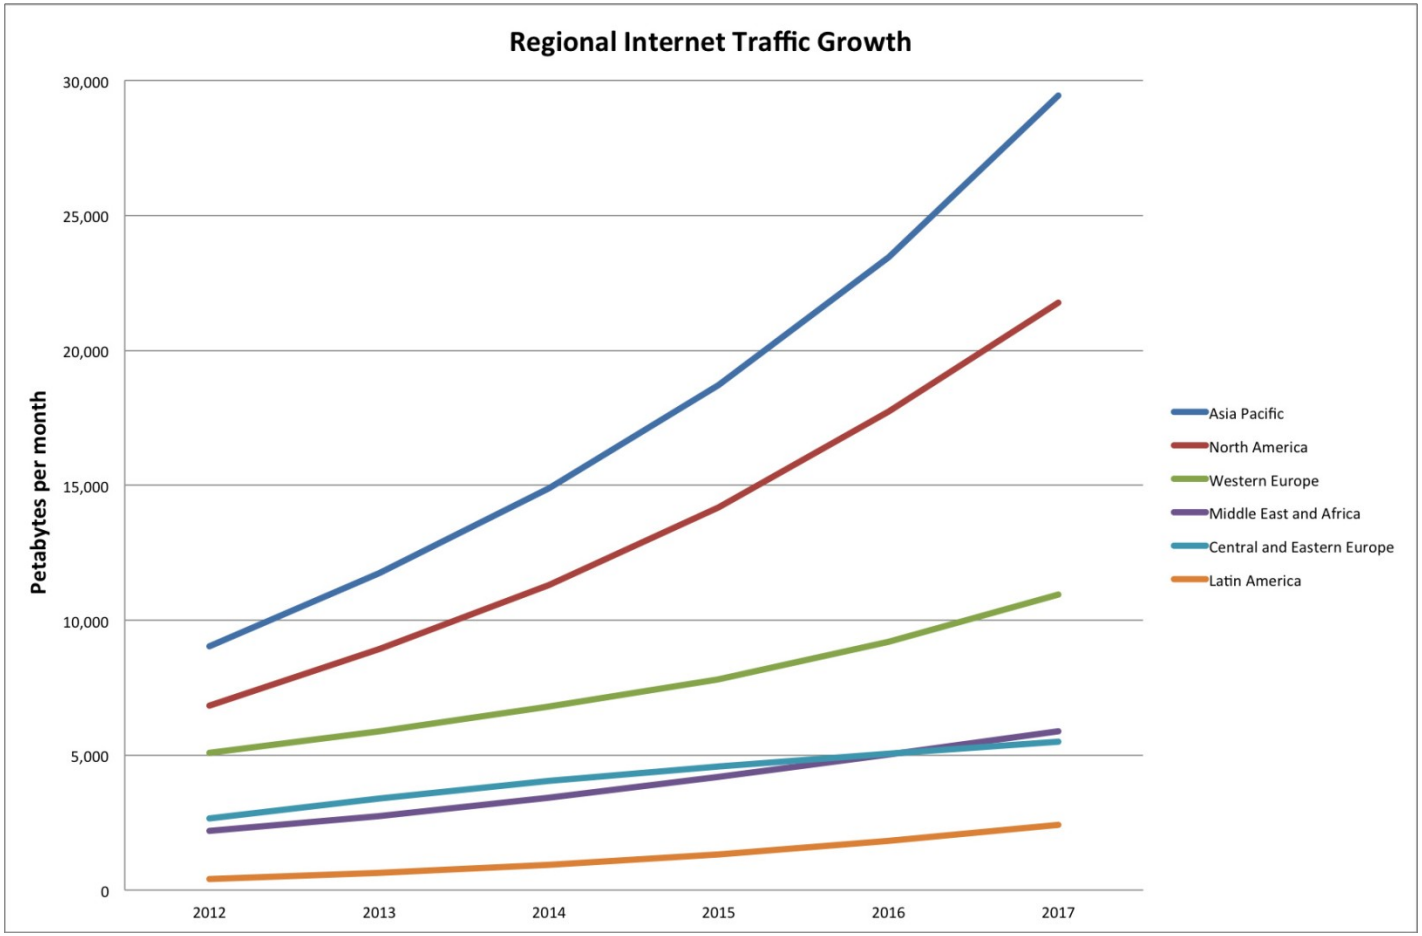

De onde os dados são gerados?

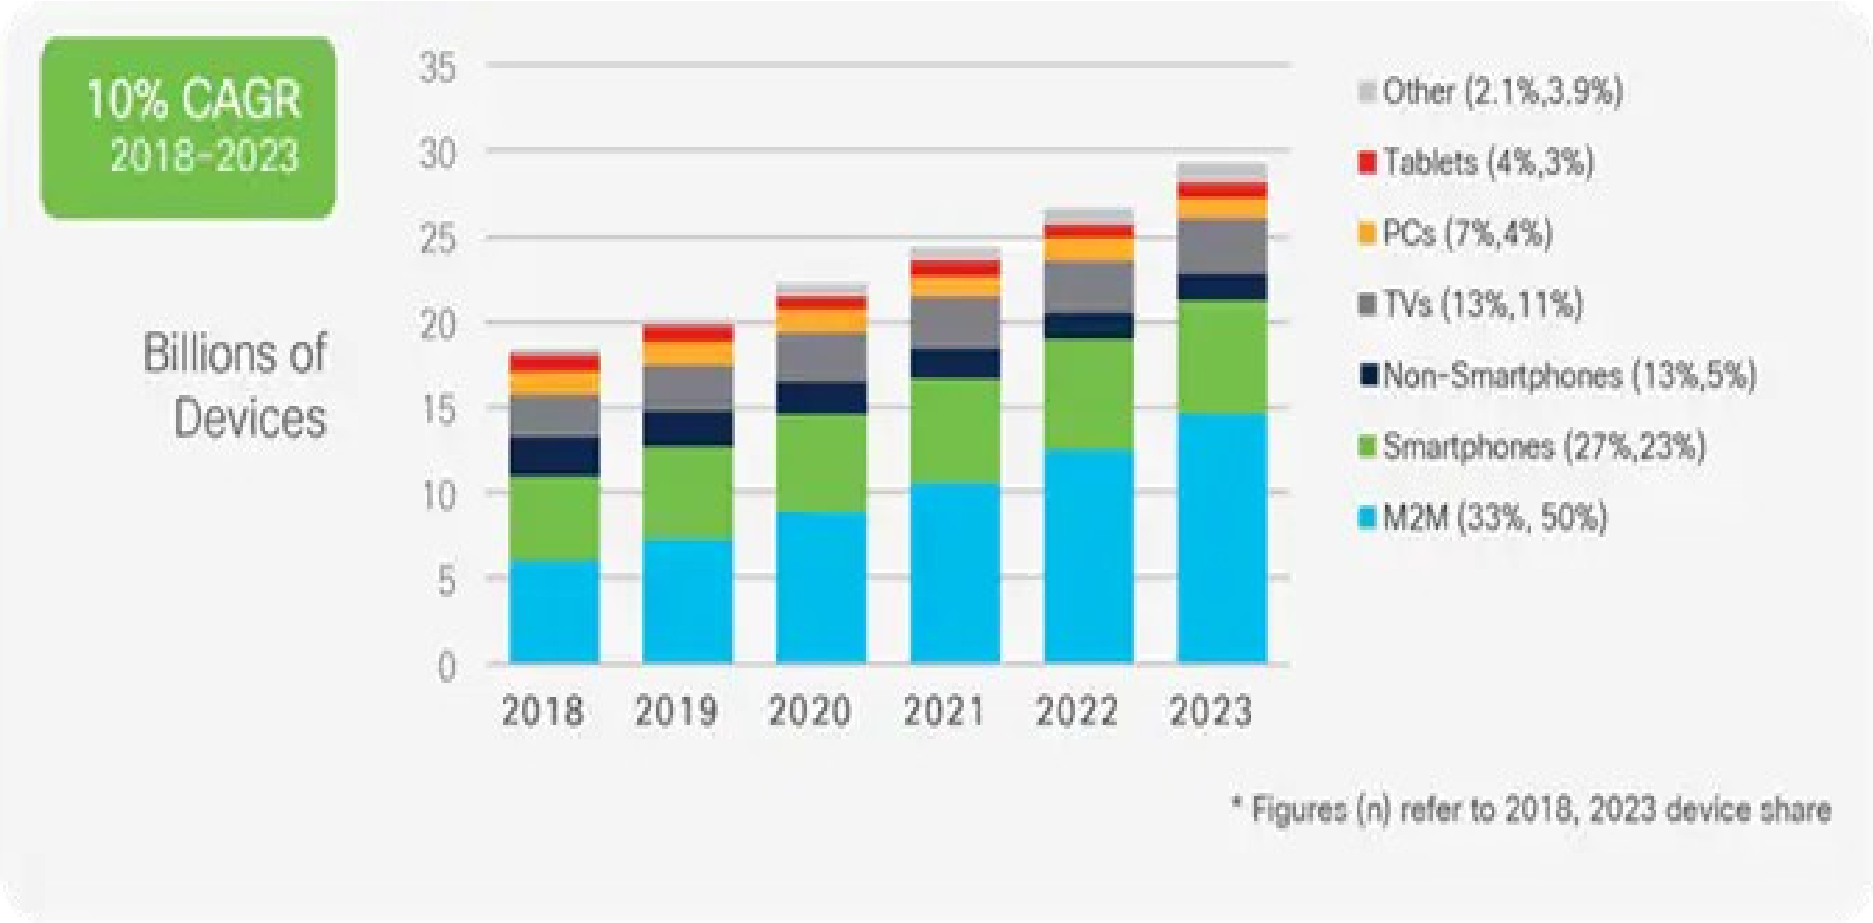

O que são esses dados?

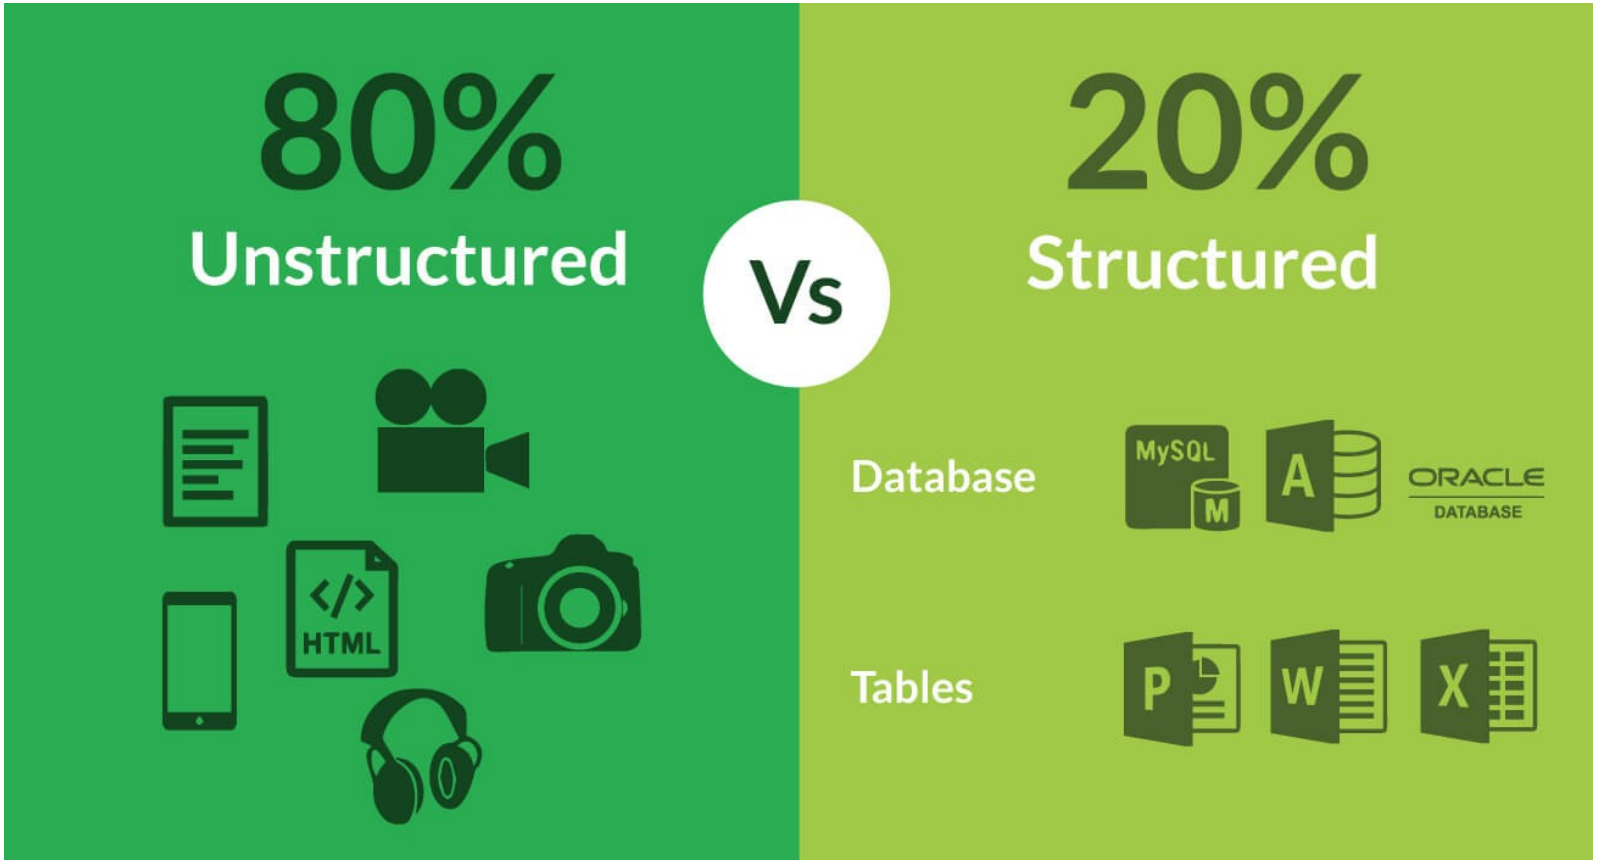

Quanto ao custo da transmissão?

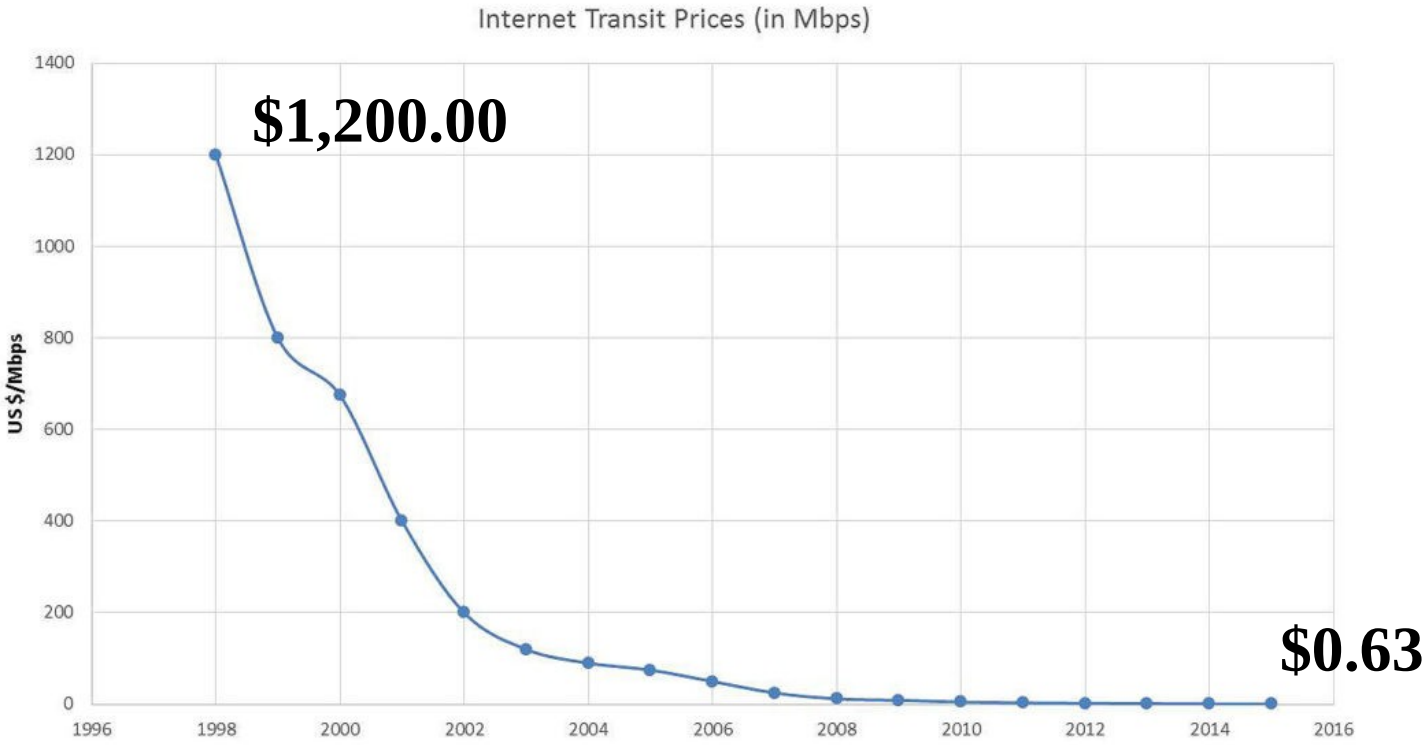

Source: DrPeering.net

Quanto ao custo de armazenamento?

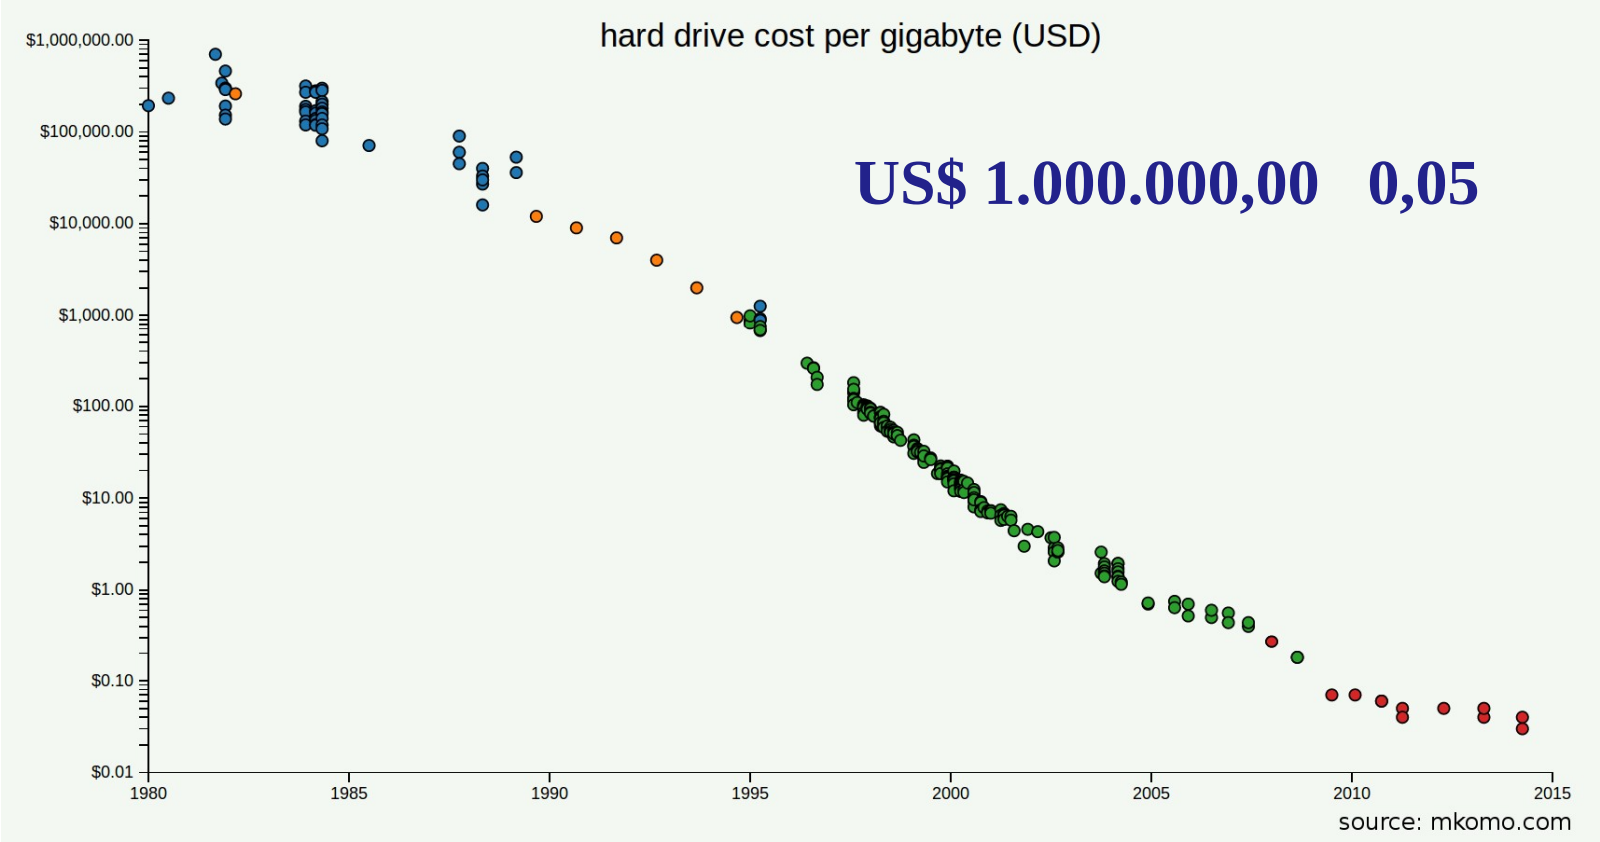

Quanto ao custo do processamento?

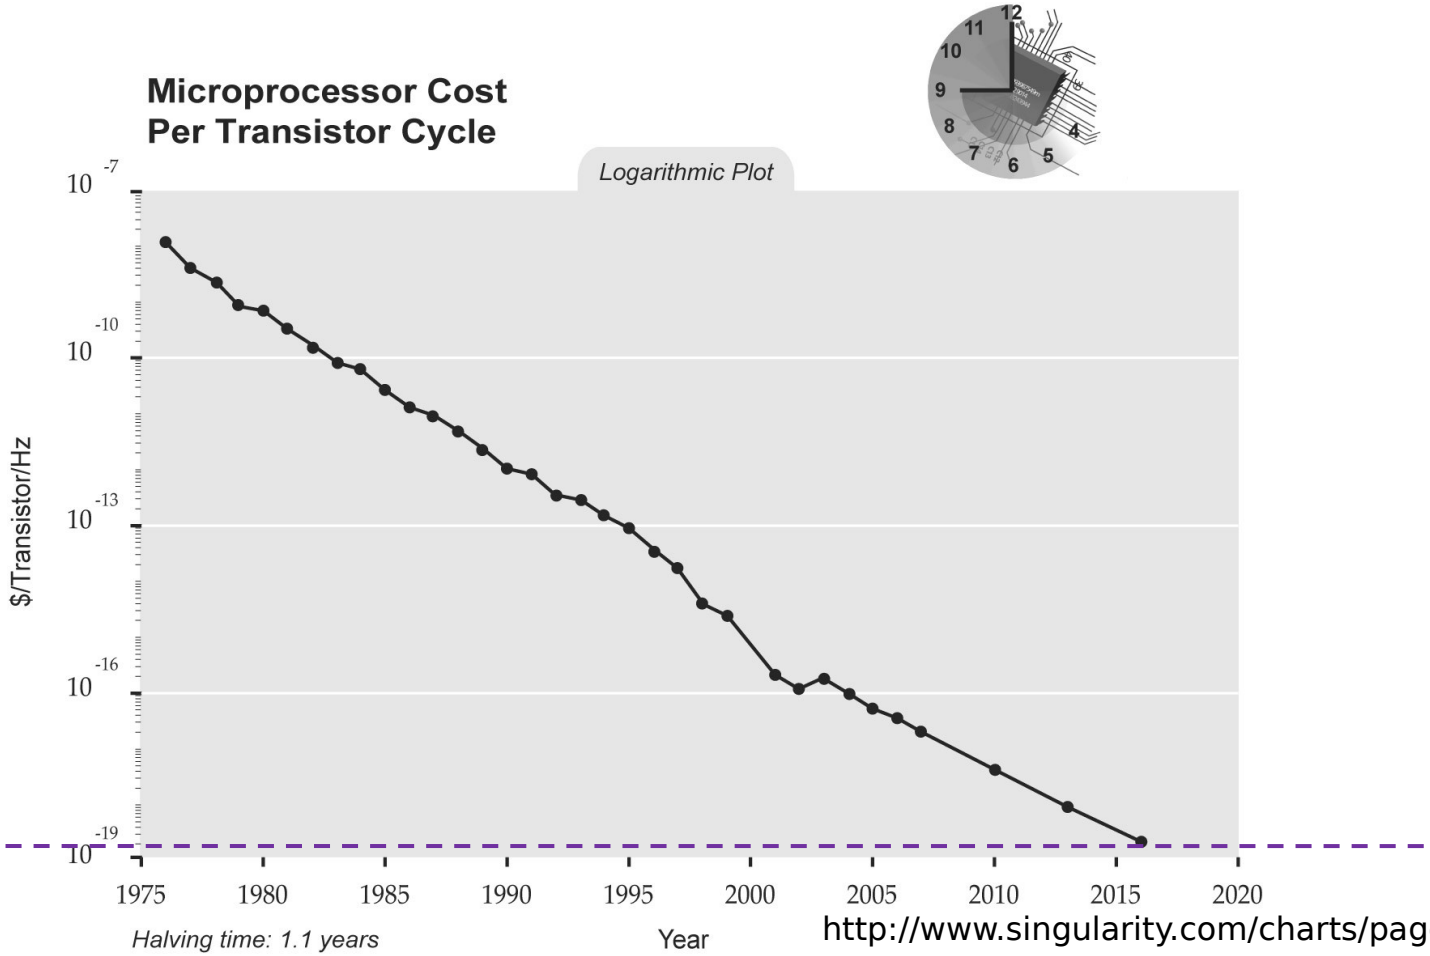

http://www.singularity.com/charts/page61.html

Big Data

approach
evidence
collect
describes
much
warehouse
related
derived
processed
scale
new
system
whether
lives
able
sources
dataset
services
systems
something
otherwise
ethical
software
use
commerce
tools
excel
small
term
smaller
social
created
opportunity
growth
across
disparate
requires
many
challenges
set
questions
amounts
storage
anything
technologies
different
aspect
later
enough
computational
size
velocity
analytics
reality
volume
possibilities
get
continues
insights
things
scope
made
solve
main
often
variety
capable
analysis
meaning
computing
techniques
collecting
maybe
technology
value
refers
diverse
decision
right
large
just
really
machine
think
world
like
need
problem
using
now
understand
particular
important
relative
relationships
means
actually
complex
help
technological
datasets
business
deal
information
society
standard
advances
capturing
processing
number
changes
way
used
analytical
definition
processes
solutions
every
tb
databases
organizations
time
products
change
decisions
fit
store
patterns
single
make
storing
buzzword
traditional
internet
methods
mean
organization
people
lot
essential
making
memory
also
issues
tool
gather
behavior
better

Big Data

- Grande **volume** de dados, gerado em alta taxa de **velocidade** e com uma larga variedade (Vs 3)
  - Volume: estruturados e não estruturados
  - Variety: diferentes fontes
  - Velocity : gerados em streams de dados cada vez mais rápidos

Big Data

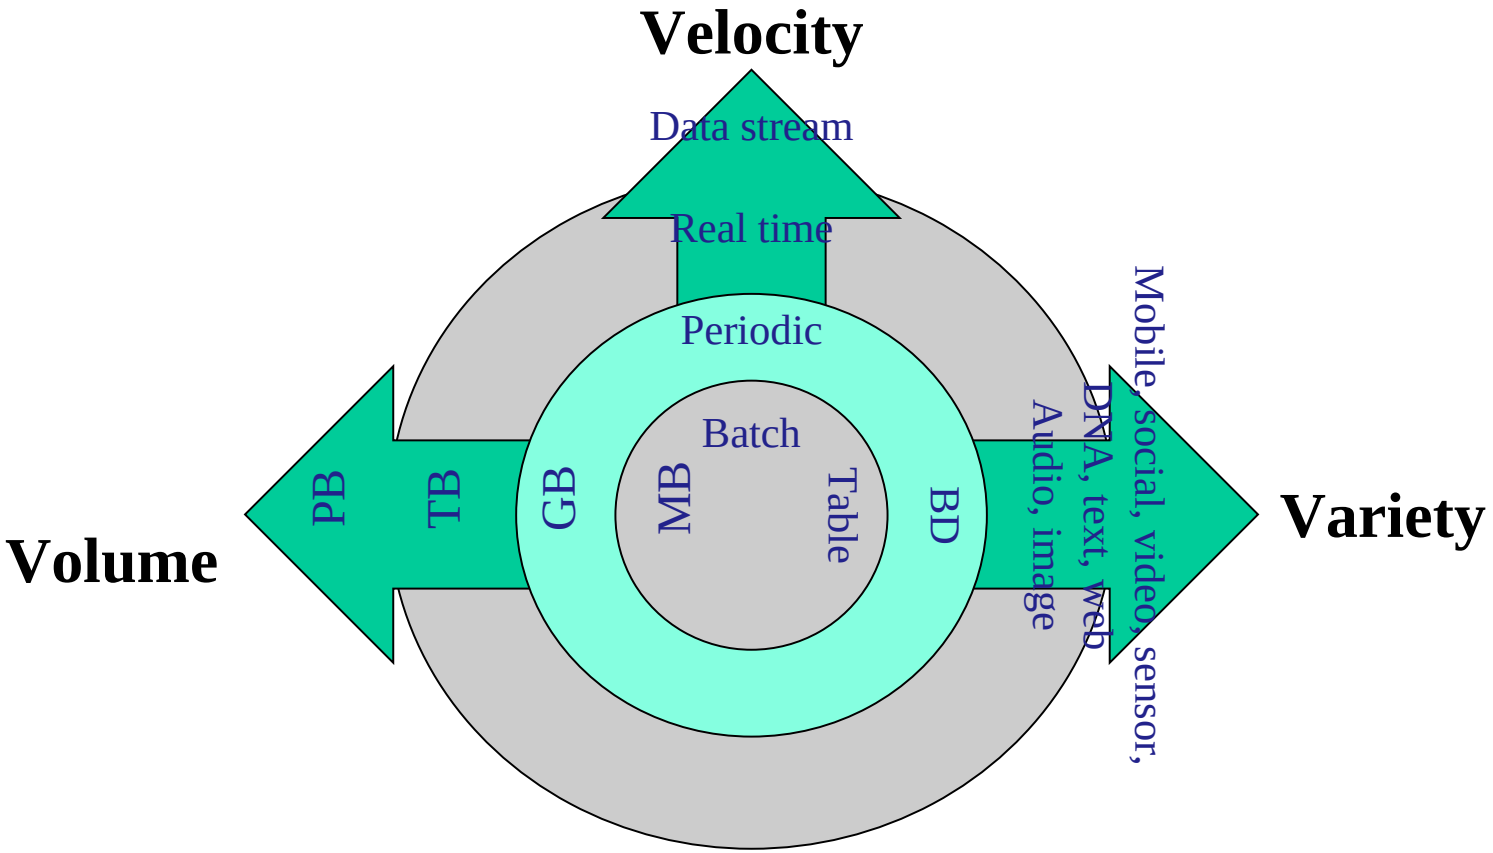
Velocity
Data stream
Real time
Periodic
Batch
Volume
PB
TB
GB
MB
Table
BD
Variety
Audio, image
DNA, text, web
Mobile, social, video, sensor,

3 Vs

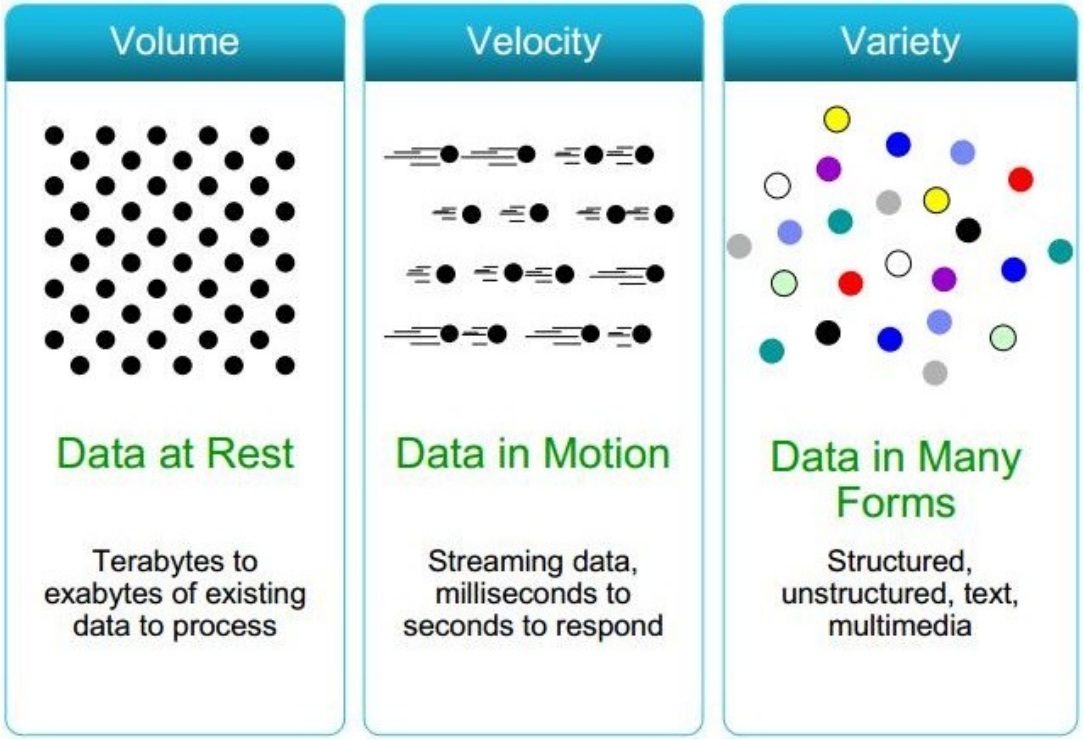
Volume
Velocity
Variety
Data at Rest
Terabytes to exabytes of existing data to process
Data in Motion
Streaming data, milliseconds to seconds to respond
Data in Many Forms
Structured, unstructured, text, multimedia

Data is money

TOP 10 RANKING CHANGES SIGNIFICANTLY...

Only three brands that appeared in the BrandZ™ Global Top 10 in 2006—Google, Microsoft, and IBM—remain in the Top 10 in 2017.

	2006	Brand Value 2006 $Mil.	2017	Brand Value 2017 $Mil.
1	Microsoft	62,039	Google	245,581
2	GE	55,834	Apple	234,671
3	Coca-Cola	41,406	Microsoft	143,222
4	中国移动 China Mobile	39,168	amazon	139,286
5	Marlboro	38,510	facebook	129,800
6	Walmart	37,567	AT&T	115,112
7	Google	37,445	VISA	110,999
8	IBM	36,084	Tencent 腾讯	108,292
9	citi	31,028	IBM	102,088
10	TOYOTA	30,201	McDonald's	97,723

Source: Kantar Millward Brown / BrandZ™ (including data from Bloomberg)

Data is money

THE TOP 100 MOST VALUABLE GLOBAL BRANDS

1 APPLE
2 GOOGLE
3 AMAZON
4 MICROSOFT
5 TENCENT
6 MCDONALD'S
7 VISA
8 FACEBOOK
9 ALIBABA
10 LOUIS VUITTON
11 NVIDIA
12 MASTERCARD
13 NIKE
14 MOUTAI
15 VERIZON
16 ARAMCO
17 COCA-COLA
18 IBM
19 ADOBE
20 INSTAGRAM
21 UPS
22 ORACLE
23 AT&T
24 YOUTUBE
25 THE HOME DEPOT
26 ACCENTURE
27 HERMÈS
28 PAYPAL
29 TESLA
30 NETFLIX
31 SAP
32 TELEKOM/T-MOBILE
33 QUALCOMM
34 INTEL
35 STARBUCKS
36 XFINITY
37 WALMART
38 DISNEY
39 MARLBORO
40 LINKEDIN
41 CISCO
42 TEXAS INSTRUMENTS
43 SALESFORCE
44 SAMSUNG
45 CHANEL
46 TCS*
47 INTUIT
48 COSTCO
49 SPECTRUM
50 L'ORÉAL PARIS
51 MEITUAN
52 AMD
53 TIKTOK
54 AMERICAN EXPRESS
55 WELLS FARGO
56 XBOX
57 RBC
58 GUCCI
59 J.P. MORGAN
60 JD
61 HDFC BANK
62 ICBC
63 HAIER
64 INFOSYS
65 VODAFONE
66 TOYOTA
67 HUAWEI
68 CHASE
69 BANK OF AMERICA
70 MERCEDES-BENZ
71 MERCADO LIBRE
72 TD
73 SIEMENS
74 SNAPCHAT
75 UNITEDHEALTHCARE
76 BMW
77 PING AN
78 DHL
79 UBER
80 COMMBANK**
81 DELL TECHNOLOGIES
82 KUAISHOU
83 ZARA
84 NTT
85 FEDEX
86 LOWE'S
87 LANCÔME
88 CHINA MOBILE
89 ADIDAS
90 TARGET
91 IKEA
92 LIC
93 BUDWEISER
94 AIA
95 KFC
96 ADYEN
97 XIAOMI
98 ALDI
99 AIRBNB
100 MORGAN STANLEY

THE TOP 10

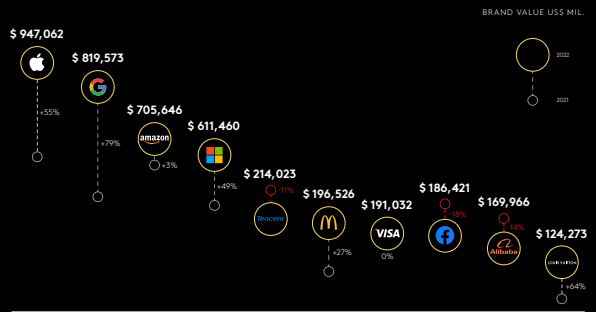

NEWCOMERS

THRESHOLD FOR ENTRY

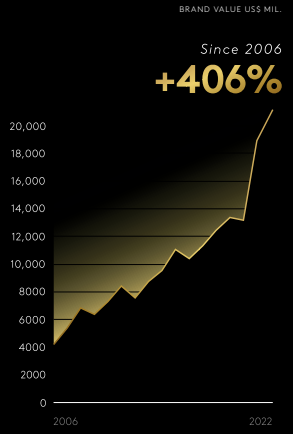

TOP 10 RISERS

		BRAND VALUE CHANGE 2022 VS. 2021	
#1	Cartier	+88%	$ 10,110 m LUXURY
#2	YouTube	+83%	$ 86,212 m MEDIA AND ENTERTAINMENT
#3	Google	+79%	$ 819,573 m MEDIA AND ENTERTAINMENT
#4	TESLA	+78%	$ 75,933 m CARS
#5	HERMÈS PARIS	+73%	$ 80,323 m LUXURY
#6	LOUIS VUITTON	+64%	$ 124,273 m LUXURY
#7	LinkedIn	+63%	$ 58,077 m MEDIA AND ENTERTAINMENT
#8	tcs TATA CONSULTANCY SERVICES	+61%	$ 50,349 m BUSINESS SOLUTIONS AND TECHNOLOGY PROVIDERS
#9	BANK OF AMERICA	+60%	$ 30,846 m BANKS
#10	J.P.Morgan	+55%	$ 37,412 m BANKS

CATEGORY COMPOSITION

	BRAND VALUE US$ MIL.	BRAND VALUE CHANGE 2022 VS. 2021
ALCOHOL	$252,325	
APPAREL	$216,595	
BANKS	$428,046	
BUSINESS SOLUTIONS AND TECHNOLOGY PROVIDERS	$2,140,844	
CARS	$230,386	
CONSUMER TECHNOLOGY	$1,095,090	
FAST FOOD	$354,177	
FOOD AND BEVERAGES	$297,102	
LUXURY	$344,355	
MEDIA AND ENTERTAINMENT	$1,477,357	
PERSONAL CARE	$206,917	
RETAIL	$830,328	
TELECOM PROVIDERS	$484,071	

** Tata Consultancy Services ** Commonwealth Bank of Australia*

KANTAR BRANDZ

Data is money

- 1 ton de ouro vale $39,289,360.00
- Através da história, por volta de 185,000 tons de ouro foram mineradas
  - $7.4 trilhões dólares
- Data G7 (Apple, Alibaba, Alphabet, Amazon, Facebook, Microsoft, Tencent) are worth $3.7 trillion (July 2017)x

Análise de dados

- Como era:
  - As técnicas de análise de dados era validadas em um número pequeno de bases da dados.
  - Predições baseadas em computadore tinham um baixa taxa de acerto

Data analysis

- Mas as predições humanas muitas vezes são piores
  - The Americans have need of the telephone, but we do not. We have plenty of messenger boys (1878)
    - William Preece, Post Office Engineering Chief
  - I think there is a world market for maybe five computers (1943)
    - IBM president Thomas Watson
  - There's no chance that the iPhone is going to get any significant market share (2007)
    - Steve Ballmer, Microsoft CEO

Consultant predictions

‘Expert’ Disruption Forecasts

In the mid-1980s AT&T hired McKinsey & Co to forecast cell phone adoption by the year 2000

THEIR (15-YEAR) PREDICTION

900,000

SUBSCRIBERS

THE ACTUAL NUMBER WAS

109 million

They were **off** by a factor of:

120x

Análise de dados

- Dados geralmente contém informação relevante
  - Uma vez analisados, podem trazer benefícios
    - Sociais, políticos e econômicos
  - Aumento do interesse em análise de dados

Ciência de Dados

- A ciência de dados é o estudo dos dados para extrair conhecimento significativo para os negócios.
- Ela é uma abordagem multidisciplinar que combina princípios e práticas das áreas de matemática, estatística, inteligência artificial e engenharia da computação para analisar grandes quantidades de dados.

Ciência de Dados

- Essa análise ajuda os cientistas de dados a fazer e responder perguntas como o que aconteceu, por que aconteceu, o que acontecerá e o que pode ser feito com os resultados.

Ciência de Dados x Analytics

- Também usadas como sinônimos
- Analytics
  - Análise de dados
  - Mais relacionada com a atividade de negócios
- Ciência de dados
  - Mais relacionada com pesquisa e inovação

Ciência de Dados

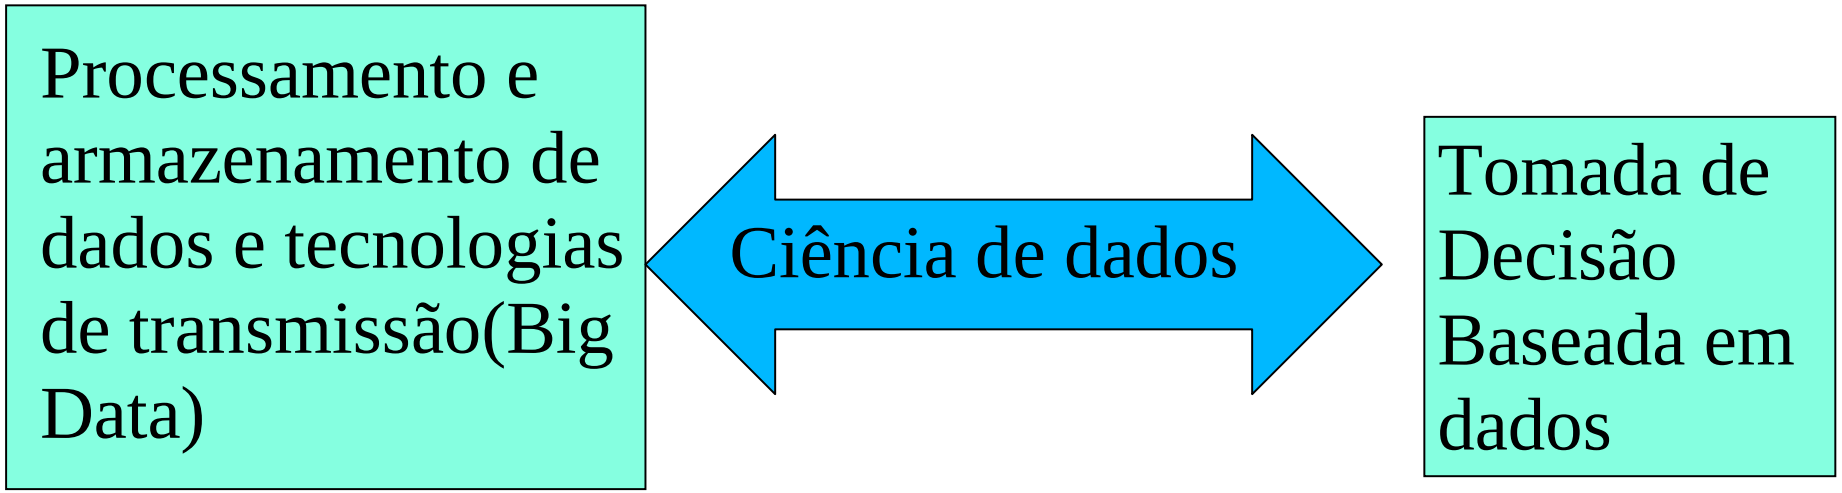

Ciência de dados

- Mineração de dados se aproxima do conceito de Ciência de Dados
  - Mas Ciência de Dados é mais amplo
- Inclui
  - Planejamento de experimentos
  - Pré-processamento
  - Modelagem
  - Avaliação

} Data Mining

Big Data x Ciência de Dados

- Muitas vezes são usadas como sinônimos
  - Ciência de dados: criação de soluções de modelagemd e dados
    - Aptos a extrair conhecimento de dados reais
  - Big Data: tecnologias para extração e gerenciamento de dados

Engenharia de Dados

- Área que trata da transformação dos dados brutos de uma empresa.
- Projetar e implementar soluções que envolvam dados, especialmente para resolver problemas de processamento de dados em tempo real e manipular quantidades massivas de dados.

Análise de dados

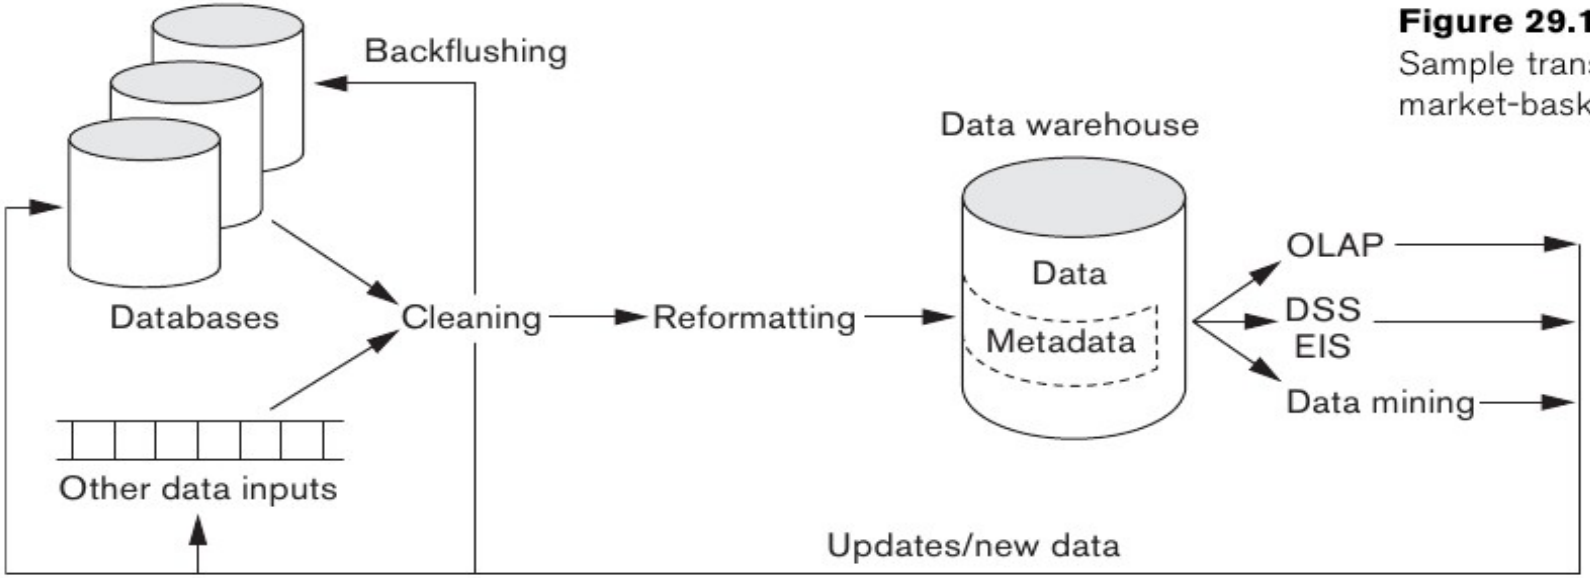

Figure 29.1
Sample transactions in market-basket model.

Referências

- ELMASRI, R; NAVATHE, S.B. **Sistemas de Banco de Dados**, Addison Wesley, 6ª Edição.
  - Capítulo 1 e 2.
- SILBERSCHATZ, A; Korth H.F.; Sudarshan S. **Sistemas de Banco de Dados**, Editora Campus, 6ª Edição.
  - Capítulo 1.
- RAMAKRISHNAN R; GEHRKE J. **Sistemas de Gerenciamento de Banco de Dados**. Mcgraw-Hill Interamericana, 3ª Edição.
  - Capítulo 1.

Material do Prof. Andre Ponce de Leon de Carvalho. USP. São Carlos