ESTAT0011 - ESTATÍSTICA APLICADA

Cleber Martins Xavier
Universidade Federal de Sergipe

Universidade Federal de Sergipe

Objetivos Gerais da Disciplina

- Introduzir ideias básicas de Probabilidade e Estatística
- Estabelecer uma linguagem comum entre o aluno e o Estatístico
- Resolver problemas práticos utilizando técnicas de Estatística
- Desenvolver técnicas de estimação com base em elementos amostrais
- Discutir e desenvolver testes de hipóteses

Programa Parte 1: Estatística Descritiva

- As fases do trabalho estatístico;
- Classificação dos dados;
- Séries estatísticas e sua representação tabular e gráfica;
- Distribuição de frequências simples e em classe e sua representação gráfica;
- Medidas de Posição: Média, Mediana e Moda;
- Medidas de Dispersão: Variância, desvio-padrão, coeficiente de variação.

Programa Parte 2: Probabilidade

- Noções de conjuntos;
- Conceitos de probabilidade: Experimento aleatório, espaço amostral e eventos;
- Eventos independentes;
- Probabilidade condicional e teorema de bayes;
- Variáveis aleatórias;
- Esperança matemática, variância e desvio-padrão;
- Distribuições discretas: Bernoulli, Binomial, Geométrica e Poisson;
- Distribuições contínuas: Uniforme, Exponencial e Normal.

Programa Parte 3: Inferência

- Conceitos iniciais de inferência;
- Distribuição da média e da proporção;
- Estimação;
- Intervalo de confiança para média e proporção;
- Testes de hipóteses para média e proporção.

Bibliografia básica

- MAGALHÃES, Marcos Nascimento; LIMA, Antônio Carlos Pedroso de. Noções de probabilidade e estatística. 7. ed. atual. São Paulo, SP: EDUSP, 2010.
- MORETTIN, Luiz Gonzaga. Estatística básica: probabilidade e inferência. São Paulo: Pearson, 2010.
- MEYER, P. L.. Probabilidade. Aplicações à Estatística. Livros Técn. Científicos, 1972.
- ROSS, Sheldon M. Probabilidade: um curso moderno com aplicações. 8. ed. Porto Alegre, RS: Bookman, 2010.

Ideia

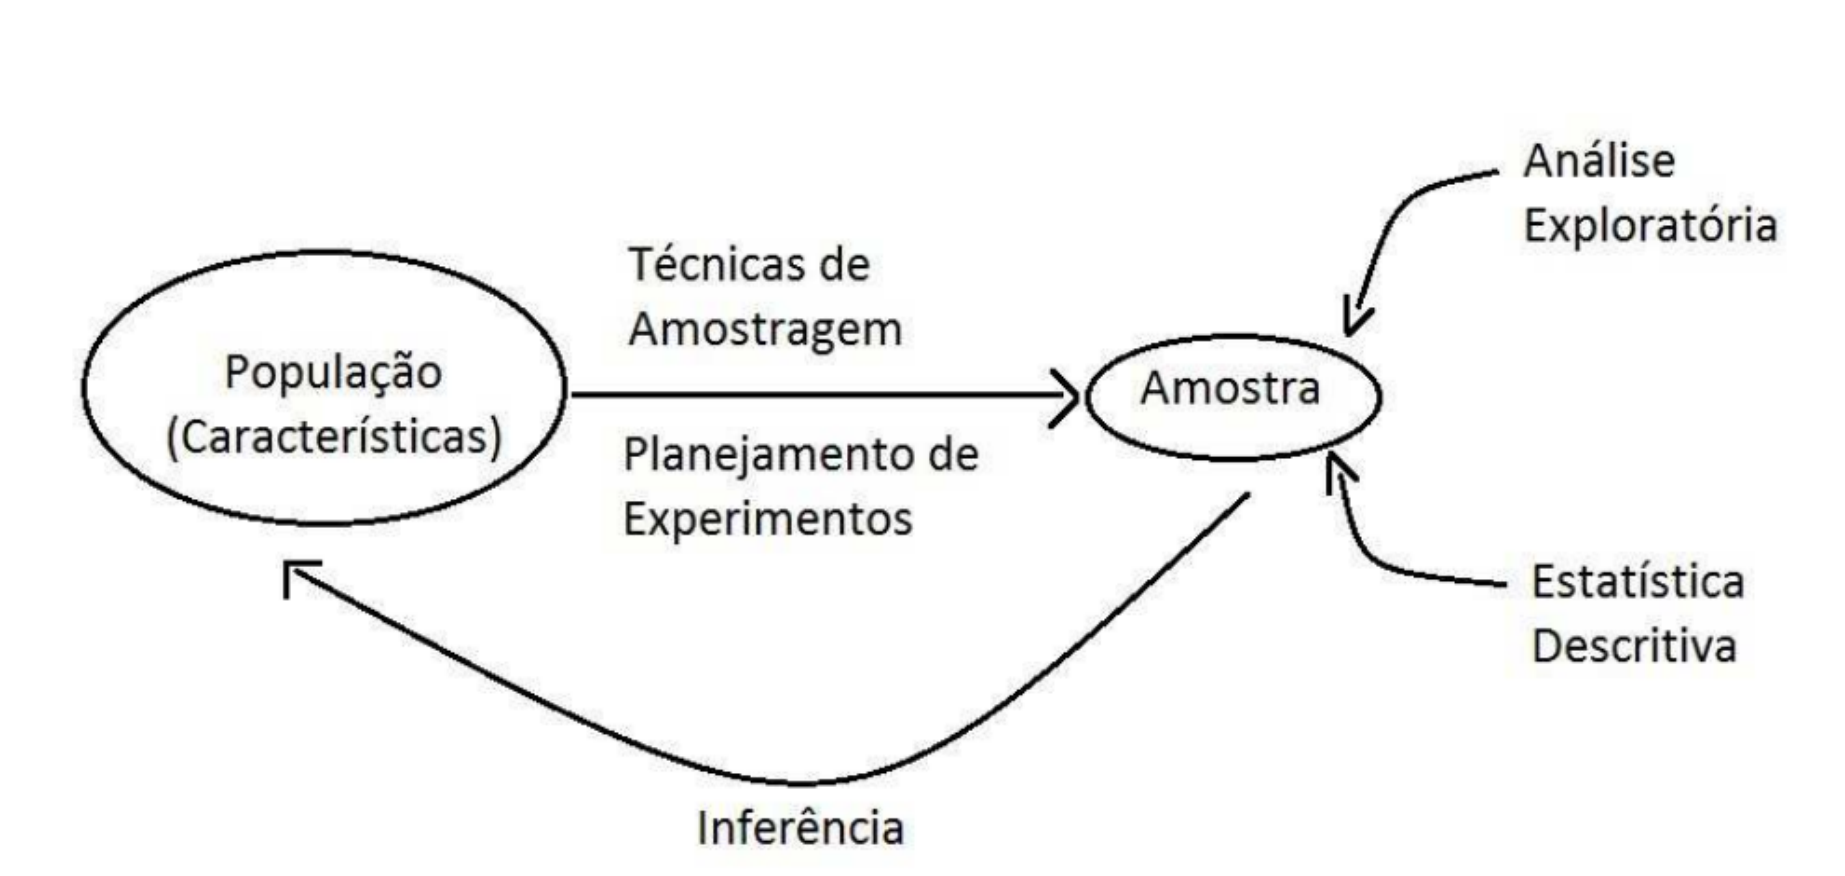
Análise
Exploratória
Técnicas de
Amostragem
População
(Características)
Amostra
Planejamento de
Experimentos
Estatística
Descritiva
Inferência

Algumas Definições

Estatística: é uma ciência baseada na **Teoria da Probabilidade**, cujo o objetivo principal é nos auxiliar a tomar decisões ou tirar conclusões em situações de incerteza, a partir dos dados.

"Estatística é um conjunto de técnicas que permite, de forma sistemática, organizar, descrever, analisar e interpretar dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento."

Marcos Magalhães

Resumo: $\boxed{\text{Estatística}} \Longleftrightarrow \boxed{\text{Incerteza}}$

Algumas Definições

População: É uma coleção completa de todos os elementos a serem estudados e que possuem certa característica comum.

Observação: A população deve ser bem definida.

Amostra: É um subconjunto de membros selecionados de uma população.

Técnicas de Amostragem

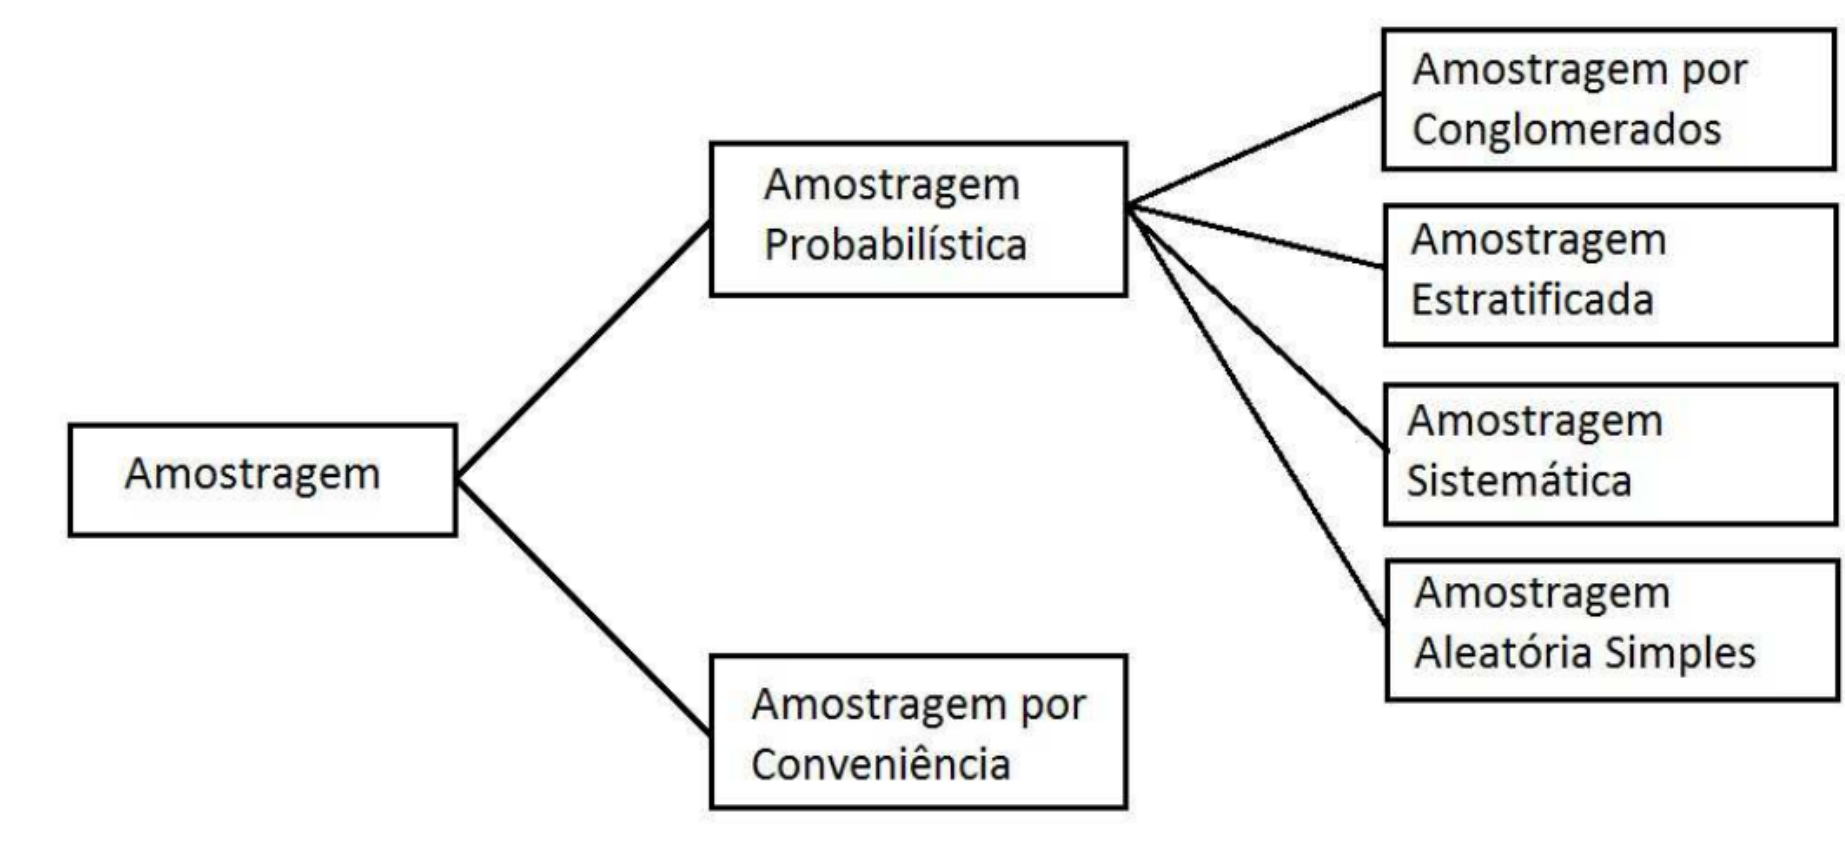

Algumas Definições

Censo: É um conjunto de dados obtidos de todos os membros da população.

Variável: Qualquer característica de interesse associada aos elementos de uma população.

Classificação de variáveis

Qualitativa
- **Nominal** (Ex: cor, sexo, estado civil)
- **Ordinal** (Ex: grau de escolaridade, classe social, porte de empresa)

Quantitativa
- **Discreta** (Ex: n° de pessoas, n° de defeitos)
- **Contínua** (Ex: peso, temperatura, preço)

Fases do método Estatístico

- Definição do Problema: fase onde o pesquisador define ou formula o problema a ser estudado;
- Planejamento: após a definição do problema esta fase consiste em se levantar informações relevantes ao estudo e como determinar o procedimento necessário para resolvê-lo;
- Coleta de dados: passo essencialmente operacional, compreendendo a coleta das informações definidas anteriormente;
- Apuração dos dados: aqui os dados são tratados para sua melhor apresentação;
- Análise e interpretação: fase onde os dados são analisados para a retirada de conclusões;

O que fazer com os dados coletados ?

Etapa inicial: Estatística descritiva/Análise exploratória

Consiste em medidas resumo (média, mediana, moda, variância, coeficiente de variação, etc.), tabelas e gráficos.

Algumas Definições

Suponha que X representa uma variável. Denota-se por $\mathbf{x} = (x_1, x_2, \ldots, x_n)$, n observações da variável X.

Desejamos conhecer o "comportamento" da varíavel X. Para isso, considere as seguintes definições:

Definições Importantes

Parâmetro: É uma medida numérica que descreve alguma característica de uma população;

Estatística ou estimador: É uma função da amostra utilizada para estimar o parâmetro;

Estimativa: É o valor numérico que a estatística assume quando avaliada nos dados observados.

Definições Importantes

Parâmetro	Estimador	Estimativa
Média populacional (μ)	média amostral ($\hat{\mu}$ ou $\bar{X}$)	$\hat{\mu}(\mathbf{x})$ ou $\bar{x}$
Variância populacional (σ^2)	Variância Amostral ($\hat{\sigma^2}$ ou S^2)	$\hat{\sigma}^2(\mathbf{x})$ ou s^2
Proporção populacional (p)	Proporção amostral ($\hat{p}$)	$\hat{p}(\mathbf{x})$

Definições Importantes

Dados Brutos: É o conjunto de observações de uma variável, apresentados da forma em que foram coletados;

Ex.: 3,7,2,1,5,7.

Rol: É o conjunto de observações de uma variável, apresentados de forma ordenada (crescente ou decrescente).

Ex.: 1,2,3,5,7,7.

Definições Importantes

Em uma notação geral, podemos denotar os **dados brutos** e o **rol** das seguintes formas:

Dados Brutos: $x_1, x_2, \ldots, x_n$

Rol: $x_{(1)}, x_{(2)}, \ldots, x_{(n)}$ tal que

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)} \quad \text{(crescente)}$$

ou

$$x_{(1)} \geq x_{(2)} \geq \cdots \geq x_{(n)} \quad \text{(decrescente)}$$

em que n representa o tamanho da amostra ou o número total de indivíduos na amostra.

Medidas Resumo

Medidas de posição: moda, média, mediana (medidas de tendência central), quantis (quartis, decis, percentis).

Medidas de dispersão: amplitude, intervalo interquartil, variância, desvio-padrão, coeficiente de variação.

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

$M_o = 3$ (Unimodal)

Ex 2- Dados: 4,1,7,4,7

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

$M_o = 3$ (Unimodal)

Ex 2- Dados: 4,1,7,4,7

$M_o = 4$ e 7 (Bimodal)

Ex 3 - Dados: 8,1,7,4,0

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

$M_o = 3$ (Unimodal)

Ex 2- Dados: 4,1,7,4,7

$M_o = 4$ e 7 (Bimodal)

Ex 3 - Dados: 8,1,7,4,0

$\nexists\ M_o$ (Amodal)

Medidas Resumo: Medidas de Posição

Média aritmética (média amostral): É a soma das observações dividido pelo número total delas.

Notação: $\bar{X}$

Descrição matemática:

$$\bar{X} = \frac{X_1 + X_2 + \cdots + X_n}{n} = \frac{\sum_{i=1}^{n} X_i}{n}$$

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

$$\bar{x} = \frac{2+3+5+3+1}{5} = 2,8$$

Desvantagem da Média amostral: Sofre influência de valores extremos (*outliers*).

Ex 2 - Dados: 0, 10, 12, 12, 16.

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

$$\bar{x} = \frac{2+3+5+3+1}{5} = 2,8$$

Desvantagem da Média amostral: Sofre influência de valores extremos (*outliers*).

Ex 2 - Dados: 0, 10, 12, 12, 16.

$$\bar{x} = \frac{0+10+12+12+16}{5} = 10$$

Ex 3 - Dados: 1, 3, 5, 6, 35

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

$$\bar{x} = \frac{2+3+5+3+1}{5} = 2,8$$

Desvantagem da Média amostral: Sofre influência de valores extremos (*outliers*).

Ex 2 - Dados: 0, 10, 12, 12, 16.

$$\bar{x} = \frac{0+10+12+12+16}{5} = 10$$

Ex 3 - Dados: 1, 3, 5, 6, 35

$$\bar{x} = \frac{1+3+5+6+35}{5} = 10$$

Medidas Resumo: Medidas de Posição

Mediana: É a observação que ocupa a posição central do conjunto de observações (amostra), quando estão ordenados de forma crescente (ou decrescente).

Notação: M_d

Como encontrar a mediana ?

Medidas Resumo: Medidas de Posição

Passo 1: Ordenar os dados, ou seja, construir o rol.

Passo 2: Encontrar a posição da mediana,

$$P = \frac{n}{2}$$

A mediana será o elemento, de tal forma que

$$M_d = \begin{cases} \frac{x_{(P)} + x_{(P+1)}}{2}, & \text{se P é inteiro} \\ x_{([P]+1)}, & \text{se P não é inteiro} \end{cases}$$

em que [P] indica a parte inteira do número P.

Ex. $[3,5] = 3$

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

Rol: 1, 2, 3, 3, 5

$P = \frac{5}{2} = 2,5 \Rightarrow M_d = x_{([2,5]+1)} = x_{(3)} = 3$

Ex 2 - Dados: 1, 3, 5, 6, 35

$P = \frac{5}{2} = 2,5 \Rightarrow M_d = x_{([2,5]+1)} = x_{(3)} = 5$

Medidas Resumo: Medidas de Posição

Quantis (quartil, decil, percentil): O quantil de ordem p ou o p-quantil, indicado por $q(p)$, sendo p uma proporção $(0 < p < 1)$, é uma medida em que $100p\%$ das observações sejam menores do que $q(p)$.

Notação: $q(p)$.

Como encontrar o quantil de ordem p ?

Medidas Resumo: Medidas de Posição

Passo 1: Ordenar os dados, ou seja, construir o rol.

Passo 2: Encontrar a posição do p-quantil,

$$P = p \cdot n$$

O quantil de ordem p ou o p-quantil será o elemento , de tal forma que

$$q(p) = \begin{cases} \frac{x_{(P)}+x_{(P+1)}}{2}, & \text{se P é inteiro} \\ x_{([P]+1)}, & \text{se P não é inteiro} \end{cases}$$

em que [P] indica a parte inteira do número P.

Medidas Resumo: Medidas de Posição

Alguns quantis e seus nomes particulares:

a) Quartis: divide o rol em 4 partes iguais.

Notação: $Q_1 = q(25\%); Q_2 = q(50\%); Q_3 = q(75\%)$

b) Decis: divide o rol em 10 partes iguais.

Notação: $D_1 = q(10\%); D_2 = q(20\%); \cdots ; D_9 = q(90\%)$

b) Percentis: divide o rol em 100 partes iguais.

Notação: $P_1 = q(1\%); P_2 = q(2\%); \cdots ; P_{99} = q(99\%)$

Medidas Resumo: Medidas de Posição

Alguns casos particulares:

$$Q_1 : 1^{\text{o}} \text{ Quartil} = P_{25} : 25^{\text{o}} \text{ Percentil}$$

$$Q_2 : 2^{\text{o}} \text{ Quartil} = M_d : \text{Mediana} = D_5 : 5^{\text{o}} \text{ Decil} = P_{50} : 50^{\text{o}} \text{ Percentil}$$

$$Q_3 : 3^{\text{o}} \text{ Quartil} = P_{75} : 75^{\text{o}} \text{ Percentil}$$

$$D_1 : 1^{\text{o}} \text{ Decil} = P_{10} : 10^{\text{o}} \text{ Percentil}$$

Medidas Resumo: Medidas de Posição

Ex 1 (Primeiro Quartil, Q_1) - Dados: 3, 2, 8, 5, 3, 7, 3, 9, 2

Medidas Resumo: Medidas de Posição

Ex 1 (Primeiro Quartil, Q_1) - Dados: 3, 2, 8, 5, 3, 7, 3, 9, 2

Rol: 2, 2, 3, 3, 3, 5, 7, 8, 9

$n = 9$ e $p = 0,25$ ou 25%

$P = n \cdot p = 9 \times 0,25 = 2,25$

$Q_1 = q(25\%) = x_{([P]+1)} = x_{([2,25]+1)} = x_{(3)} = 3$

Ex 2 (Terceiro Quartil, Q_3) - Dados: 18, 13, 12, 10, 17, 10

Medidas Resumo: Medidas de Posição

Ex 1 (Primeiro Quartil, Q_1) - Dados: 3, 2, 8, 5, 3, 7, 3, 9, 2

Rol: 2, 2, 3, 3, 3, 5, 7, 8, 9

$n = 9$ e $p = 0,25$ ou 25%

$P = n \cdot p = 9 \times 0,25 = 2,25$

$Q_1 = q(25\%) = x_{([P]+1)} = x_{([2,25]+1)} = x_{(3)} = 3$

Ex 2 (Terceiro Quartil, Q_3) - Dados: 18, 13, 12, 10, 17, 10

Rol: 10, 10, 12, 13, 17, 18

$n = 6$ e $p = 0,75$ ou 75%

$P = n \cdot p = 6 \times 0,75 = 4,5$

$Q_3 = q(75\%) = x_{([P]+1)} = x_{([4,5]+1)} = x_{(5)} = 17$

Medidas Resumo: Medidas de Dispersão

Finalidade: Encontrar um valor que resuma a variabilidade de um conjunto de dados.

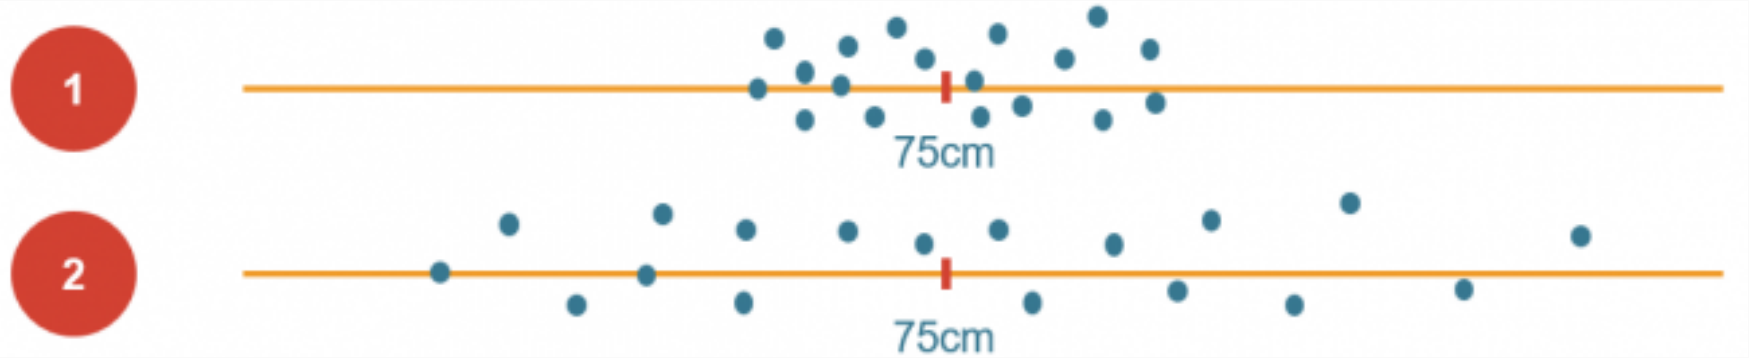

Medidas Resumo: Medidas de Dispersão

Amplitude: É a diferença entre o maior e o menor valor presentes em um conjunto de dados.

Notação: A_{mp}

$$A_{mp} = \max \ - \ \min$$

Ex. - Rol: 8, 9, 10, 13, 14

$$A_{mp} = 14 - 8 = 6$$

Medidas Resumo: Medidas de Dispersão

Amplitude ou Intervalo Interquartil: É a diferença entre o terceiro e o primeiro quartil.

Notação: d_Q

$$d_Q = Q_3 - Q_1$$

Medidas Resumo: Medidas de Dispersão

Ex. - Dados: 7, 5, 2, 9, 0, 8, 8, 2, 19, 13

Medidas Resumo: Medidas de Dispersão

Ex. - Dados: 7, 5, 2, 9, 0, 8, 8, 2, 19, 13

Rol: 0, 2, 2, 5, 7, 8, 8, 9, 13, 19

n=10, p=0.25 e p=0.75

$P = 10 \times 0.25 = 2.5$

$Q_1 = q(25\%) = x_{([P]+1)} = x_{([2.5]+1)} = x_{(3)} = 2$

$P = 10 \times 0.75 = 7.5$

$Q_3 = q(75\%) = x_{([P]+1)} = x_{([7.5]+1)} = x_{(8)} = 9$

$$d_Q = Q_3 - Q_1 = 9 - 2 = 7$$

Medidas Resumo: Medidas de Dispersão

Variância: É a soma dos quadrados dos desvios $(X_i - \mu)$ ou $(X_i - \hat{\mu})$ dividido pelo número total de elementos da amostra.

1 - Variância Populacional: A variância de uma população $X_1, ..., X_N$ de N elementos é a medida de dispersão definida como a média do quadrado dos desvios dos elementos em relação à sua média populacional μ.

Notação: σ^2

$$\sigma^2 = \sum_{i=1}^{N} \frac{(X_i - \mu)^2}{N}$$

Medidas Resumo: Medidas de Dispersão

2 - Variância Amostral: A variância de uma amostra $X_1, ..., X_n$ de n elementos é definida como a soma ao quadrado dos desvios dos elementos em relação à sua média $\overline{x}$ dividido por $(n-1)$.

Notação: $\hat{\sigma}^2$ ou S^2

$$S^2 = \sum_{i=1}^{n} \frac{(X_i - \overline{X})^2}{n-1}$$

Aqui iremos utilizar S^2 para encontrar o valor da variância.

Medidas Resumo: Medidas de Dispersão

Podemos reescrever S^2 por

$$S^2 = \frac{n\sum_{i=1}^{n} X_i^2 - \left(\sum_{i=1}^{n} X_i\right)^2}{n(n-1)}$$

OBS.: $\sum_{i=1}^{n} X_i^2 \neq \left(\sum_{i=1}^{n} X_i\right)^2$.

Medidas Resumo: Medidas de Dispersão

Ex.- Dados: 2, 3, 4, 7, 9.

Medidas Resumo: Medidas de Dispersão

Ex.- Dados: 2, 3, 4, 7, 9.

n=5

$$\overline{x} = \frac{\sum_{i=1}^{5} x_i}{5} = \frac{2+3+4+7+9}{5} = \frac{25}{5} = 5$$

$$s^2 = \sum_{i=1}^{5} \frac{(x_i - \overline{x})^2}{5-1} = \frac{(2-5)^2+(3-5)^2+(4-5)^2+(7-5)^2+(9-5)^2}{5-1} = \frac{34}{4} = 8.5$$

Medidas Resumo: Medidas de Dispersão

Desvio Padrão: é a raiz quadrada da variância.

1 - Desvio Padrão Populacional: é a raiz quadrada da variância populacional.

Notação: σ

$$\sigma = \sqrt{\sum_{i=1}^{N} \frac{(X_i - \mu)^2}{N}}$$

Medidas Resumo: Medidas de Dispersão

2 - Desvio Padrão Amostral: é a raiz quadrada da variância amostral.

Notação: $\hat{\sigma}$ ou S

$$S = \sqrt{\sum_{i=1}^{n} \frac{(X_i - \overline{X})^2}{n-1}}$$

Obs.: O desvio padrão tem a mesma unidade de medida dos dados.

Medidas Resumo: Medidas de Dispersão

Ex. - Considerando o exemplo anterior, Dados: 2, 3, 4, 7, 9.

n=5

$\overline{x} = 5$

$s^2 = 8.5$

Então, o desvio padrão amostral é

$$s = \sqrt{s^2} = \sqrt{8.5} = 2.9155$$

Medidas Resumo: Medidas de Dispersão

Coeficiente de variação: é uma medida de dispersão relativa, que descreve o desvio-padrão relativo à média.

Notação: CV ou $CV(\%)$

$$CV = \frac{\sigma}{\mu} \text{ ou } CV = \frac{S}{\overline{X}}$$

Obs.: Para expressar o coeficiente de variação em porcentagem, basta multiplicar por 100 ($CV(\%)$).

Medidas Resumo: Medidas de Dispersão

Interpretação: quanto menor o coeficiente de variação, menor é a variação dos dados

Obs.: O CV é uma medida adimensional (sem unidade de medida).

Medidas Resumo: Medidas de Dispersão

Ex.: Considere duas variáveis de interesse X e Y, com as seguintes informações:

$$X : \text{Altura} \qquad Y : \text{Peso}$$

$$\overline{x} = 1.72m \qquad \overline{y} = 68.7kg$$

$$s_x = 0.23m \qquad s_y = 12.3kg$$

Qual conjunto de dados tem maior variabilidade ?

Medidas Resumo: Medidas de Dispersão

Continuação exemplo anterior

X : Altura

$CV = \frac{0.23}{1.72} \times 100 = 13.372\%$

Y : Peso

$CV = \frac{12.3}{68.7} \times 100 = 17.904\%$

Resp.: Conjunto de dados pesos.

Tipo de Variáveis X Medidas Resumo

Variável

- **Qualitativa:** Moda
- **Quantitativa:** Moda; Média; Mediana; Quantis; Amplitude Interquartil; Variância; Desvio-Padrão; Coeficiente de Variação.

Organização dos dados

- Facilitar a leitura dos dados;
- Compreensão dos dados;
- Obter informação sobre a população;
- Fazer comparações;

Exemplo

- Número de acidentes diários em um determinado cruzamento;

0	0	0	0	0	0	2	1	0	0
0	0	0	1	0	0	0	0	0	0
1	1	1	0	0	0	1	2	1	1
0	0	1	0	0	1	1	1	1	3
0	0	1	0	0	0	1	1	0	0

Exemplo

- Prêmio da Academia: Idade dos melhores atores e atrizes

Melhores Atores									
37	48	53	20	28	21	47	26	37	27
40	62	38	34	73	31	54	56	49	74
51	35	52	34	40	63	68	35	71	31
70	21	66	17	29	72	52	63	31	62
23	42	58	26	65	50	75	48	65	64
18	17	39	67	37	72	23	29	26	45
Melhores Atrizes									
12	62	46	36	24	29	68	11	54	64
54	66	67	63	60	64	58	70	25	12
59	22	64	15	33	28	51	27	15	18
17	14	47	31	50	28	61	13	62	55
40	43	58	21	67	65	36	20	52	34
31	11	61	25	36	40	53	39	68	34

Características importantes dos dados

- **Medida Central**: Indica onde se localiza o meio do conjunto de dados;
- **Variação**: Indica quanto os valores dos dados variam entre si;
- **Distribuição**: Como os dados se distribuem de forma simétrica, assimétrica ou forma de sino uniforme;
- **Valores discrepantes** (ou *outliers*);

Ferramentas utilizadas

- Ordenação dos dados;
- Representação na forma de tabelas;
- Representação na forma de Gráficos;
- Fórmulas matemáticas para calcular grandezas;

Rol

- Ordenazação dos dados (Rol):

$$X_{(1)}, X_{(2)}, \ldots, X_{(n)}$$

- Amplitude do rol:

$$A = X_{(n)} - X_{(1)}$$

- Número de acidentes:

$$0, 0, 0, 0, 0, 0, 0, 0, \ldots, 1, 1, 1, 1, 1, 2, 2, 3$$

$n = 50$
O mínimo e o máximo: $x_{(1)} = 0$ e $x_{(n)} = 3$
Amplitude do Rol: $A_{mp} = x_{(n)} - x_{(1)} = 3 - 0 = 3$

Rol

- Idade das melhores atrizes:

$$11, 11, 12, 12, 13, 14, 15, 15, \ldots, 64, 65, 66, 67, 67, 68, 68, 70$$

$n = 60$
O mínimo e o máximo: $x_{(1)} = 11$ e $x_{(n)} = 70$
Amplitude do rol: $A_{mp} = x_{(n)} - x_{(1)} = 70 - 11 = 59$

- Idade dos melhores atores:

$$17, 17, 18, 20, 21, 21, 23, 23, \ldots, 68, 70, 71, 72, 72, 73, 74, 75$$

$n = 60$
O mínimo e o máximo: $x_{(1)} = 17$ e $x_{(n)} = 75$
Amplitude do rol: $A_{mp} = x_{(n)} - x_{(1)} = 75 - 17 = 58$

Tabela de Frequência

- **Definição**: Uma distribuição de frequência (ou tabela de frequência) lista os valores observados individualmente ou por intervalos (classes), juntamente com sua frequência (contagem).

Tabela de Frequência Simples

- Listar as observações que ocorreram;
- Número de vezes que cada observação ocorreu;

Tabela 1: Distribuição de frequência do número de acidentes.

N. de acidentes c_i	Frequência f_i
0	31
1	16
2	2
3	1
Total	50

$i = 1, 2, 3$ e 4.

Tabela de Frequência Simples

- Tabelas de distribuição de frequência absoluta (f_i);
- Tabelas de distribuição de frequência relativa (fr_i);
- Tabelas de distribuição de frequência acumulada (F_i);
- Tabelas de distribuição de frequência acumulada relativa (Fr_i).

Tabela de Frequência Simples

- f_i = número de vezes que ocorreu c_i;
- $n = \sum_{i=1}^{k} f_i$, em que k é o número de "classes";
- $fr_i = \frac{f_i}{\sum_{i=1}^{k} f_i} = \frac{f_i}{n}$ ou $fr_i(\%) = \frac{f_i}{n} \times 100$
- $F_i =$ número observações abaixo "ou igual" a c_i
- $Fr_i = \frac{F_i}{n}$ ou $Fr_i(\%) = \frac{Fr_i}{n} \times 100$

Tabela de Frequência Simples

Tabela 2: Distribuição de frequência do número de acidentes.

N. de acidentes	Frequências			
	Absoluta	Relativa	Acumulada	Acum. Relativa
c_i	f_i	fr_i	F_i	Fr_i
0	31			
1	16			
2	2			
3	1			
Total	50		-	-

$i = 1, 2, 3$ e 4 $(k = 4)$.

Tabela de Frequência Simples

Tabela 3: Distribuição de frequência do número de acidentes.

N. de acidentes	Frequências			
	Absoluta	Relativa	Acumulada	Acum. Relativa
c_i	f_i	fr_i	F_i	Fr_i
0	31	0.62	31	0.62
1	16	0.32	47	0.94
2	2	0.04	49	0.98
3	1	0.02	50	1.00
Total	50	1.00	-	-

$i = 1, 2, 3$ e 4 $(k = 4)$.

Tabela de Frequência Simples

- Média:

$$\overline{X} = \frac{c_1 f_1 + c_2 f_2 + \ldots + c_k f_k}{f_1 + \ldots + f_k} = \sum_{i=1}^{k} \frac{c_i f_i}{n}$$

em que $n = \sum_{i=1}^{k} f_i$

- Variância:

$$S^2 = \sum_{i=1}^{k} \frac{f_i (c_i - \overline{X})^2}{n-1}$$

Tabela de Frequência Simples

- Média ?
- Desvio-Padrão ?
- Mediana ?

Tabela 4: Distribuição de frequência do número de acidentes.

N. de acidentes c_i	Frequência f_i
0	31
1	16
2	2
3	1
Total	50

$i = 1, 2, 3$ e 4.

Tabela de Frequência Simples

- Média = 0,46
- Desvio-Padrão = 0,68
- Mediana = 0

Tabela 4: Distribuição de frequência do número de acidentes.

N. de acidentes c_i	Frequência f_i
0	31
1	16
2	2
3	1
Total	50

$i = 1, 2, 3$ e 4.

Tabela de Frequência por classes

Para construir uma tabela de frequência por classes:

- **Número de classes:** número de intervalos que irão agrupar os dados;
- **Limites inferiores de classes:** são os menores números de cada classe;
- **Limites superiores de classes:** são os maiores números de cada classe;
- **Pontos médios das classes:** são os pontos médios de cada intervalo que determina cada classe;
- **Amplitude de classe:** é a diferença entre os limites inferior e superior de cada classe ou a diferença entre as fronteiras de cada classe;

Tabela de Frequência por classes

- Representação das classes:
  $a \vdash b \Longrightarrow [a, b)$
  $a \dashv b \Longrightarrow (a, b]$
  $a \vdash\dashv b$ ou $a - b \Longrightarrow [a, b]$

Tabela de Frequência por classes

Qual a necessidade de construir uma distribuição de frequência por classes ?

- Tabela de frequência simples: Idade das melhores atrizes

Idade	Freq.	Idade	Freq.	Idade	Freq.	Idade	Freq.	Idade	Freq.
11	2	24	1	40	2	58	2	68	2
12	2	25	2	43	1	59	1	70	1
13	1	27	1	46	1	60	1		
14	1	28	2	47	1	61	2		
15	2	29	1	50	1	62	2		
17	1	31	2	51	1	63	1		
18	1	33	1	52	1	64	3		
20	1	34	2	53	1	65	1		
21	1	36	3	54	2	66	1		
22	1	39	1	55	1	67	2		

Tabela de Frequência por classes

Qual o número de classes (k) ideal ?

- Pode ser escolhido um k conveniente entre 5 e 20 para se usar um número inteiro;
- Exemplo: $x_{(1)} = 155, x_{(n)} = 190$
  Amplitude Rol: $A_{mp} = 190 - 155 = 35$
  Note que 35 é divisível por 5 ou por 7. Podemos optar por $k = 5$ ou $k = 7$;
- Amplitude das classes (A_c),

$$A_c = \frac{35}{5} = 7 \text{ ou } A_c = \frac{35}{7} = 5$$

Tabela de Frequência por classes

- Idade das melhores atrizes (ilustração por conveniência)

Faixa de Idade	Freq. Observada
< 11	0
11 - 22	13
23 - 39	16
40 - 55	12
56 - 67	16
68 - 70	3
70 >	0

- Neste exemplo considere a representação $\vdash\dashv$ para definir as classes;
- Observe que temos diferentes amplitudes de classes;

Tabela de Frequência por classes

- **Número de Classes:** Regra de Sturges

$$k \approx 1 + 3,33 \log_{10}(n)$$

- Amplitude do Rol: $A_{mp} = X_{(n)} - X_{(1)}$
- Amplitude das Classes: A_c

$$A_c = \frac{A_{mp}}{k}$$

Obs.: Regra do Quadrado $k = \sqrt{n}$

Tabela de Frequência por classes

Para construir uma tabela de frequência por classes:

- **Passo 1:** Ordenação dos dados $X_{(1)}, X_{(2)}, \ldots, X_{(n)}$
- **Passo 2:** Calcular a amplitude do Rol: $A_{mp} = X_{(n)} - X_{(1)}$
- **Passo 3:** Calcular o número de classes $k \approx 1 + 3,33 \log_{10}(n)$ ou $k = \sqrt{n}$
- **Passo 4:** Calcular a amplitude das classes $A_c \approx A_{mp}/k$
- **Passo 5:** Calcular os limites inferior (LI) e superior (LS) de cada classe
- **Passo 6:** Contagem das observações dentro de cada classe

Tabela de Frequência por classes

Exemplo (Idade das melhores atrizes)

- O mínimo e o máximo: $x_{(1)} = 11$ e $x_{(n)} = 70$
- Amplitude do Rol: $A_{mp} = x_{(n)} - x_{(1)} = 70 - 11 = 59$
- Número de classes: Regra de Sturges

$$k \approx 1 + 3,33 \log_{10}(60) = 6,8$$

- Devemos usar $k = 6$ ou $k = 7$?

Tabela de Frequência por classes

- Amplitude das classes:

$$k = 6 \Longrightarrow A_c \approx \frac{59}{6} = 9,8$$

$$k = 7 \Longrightarrow A_c \approx \frac{59}{7} = 8,4$$

- Vamos considerar

$$A_c = 10 \Longrightarrow k \approx \frac{A_{mp}}{A_c} = 5,9 \Longrightarrow k = 6$$

Tabela de Frequência por classes

- Representação das frequências absolutas por classes:

Idades das Atrizes Classes c_i		Freq. Absoluta f_i
$11 \vdash 21$	$[11, 21)$	11
$21 \vdash 31$	$[21, 31)$	9
$31 \vdash 41$	$[31, 41)$	11
$41 \vdash 51$	$[41, 51)$	4
$51 \vdash 61$	$[51, 61)$	10
$61 \vdash 71$	$[61, 71)$	15
Total		60

$i = 1, 2, 3, 4, 5$ e 6 $(k = 6)$.

Tabela de Frequência por classes

Também podemos obter:

- Frequência relativa: fr_i ou $fr_i(\%)$
- Frequência Acumulada: F_i
- Frequência Acumulada Relativa: Fr_i ou $Fr_i(\%)$
- Ponto médio das classes:

$$Pm_i = \frac{LI_i + LS_i}{2}$$

$i = 1, 2, \ldots, k$

Tabela de Frequência por classes

- Distribuição de frequência por classes das idades das melhores atrizes

Idades das Atrizes (Classes) c_i	Frequências				Ponto Médio Pm_i
	Absoluta f_i	Relativa fr_i	Acumulada F_i	Acum. Relativa Fr_i	
$11 \vdash 21$	11				
$21 \vdash 31$	9				
$31 \vdash 41$	11				
$41 \vdash 51$	4				
$51 \vdash 61$	10				
$61 \vdash 71$	15				
Total	60		-	-	-

$i = 1, 2, 3, 4, 5$ e 6 $(k = 6)$.

Tabela de Frequência por classes

- Distribuição de frequência por classes das idades das melhores atrizes

Idades das Atrizes (Classes) c_i	Frequências				Ponto Médio Pm_i
	Absoluta f_i	Relativa fr_i	Acumulada F_i	Acum. Relativa Fr_i	
$11 \vdash 21$	11	0.1833	11	0.1833	16
$21 \vdash 31$	9	0.1500	20	0.3333	26
$31 \vdash 41$	11	0.1833	31	0.5166	36
$41 \vdash 51$	4	0.0667	35	0.5833	46
$51 \vdash 61$	10	0.1667	45	0.7500	56
$61 \vdash 71$	15	0.2500	60	1.0000	66
Total	60	1.0000	-	-	-

$i = 1, 2, 3, 4, 5$ e 6 $(k = 6)$.

Tabela de Frequência por classes

- Média:

$$\overline{X} = \frac{Pm_1 f_1 + Pm_2 f_2 + \ldots + Pm_k f_k}{f_1 + \ldots + f_k} = \sum_{i=1}^{k} \frac{Pm_i f_i}{n}$$

em que $n = \sum_{i=1}^{k} f_i$

- Variância:

$$S^2 = \sum_{i=1}^{k} \frac{f_i (Pm_i - \overline{X})^2}{n-1}$$

Tabela de Frequência por classes

Quantis

- Encontrar a posição: $P = p \cdot n, 0 < p < 1$
- Identificar a classe que contém a P-ésima observação: $j, 1 \leq j \leq k$

$$q(p) = \frac{Ac_j(p - Fr_{\{j-1\}})}{fr_j} + LI_j \text{ ou } q(p) = \frac{Ac_j(P - F_{\{j-1\}})}{f_j} + LI_j$$

em que $Ac_j = LS_j - LI_j$

Lembrete:

$$p = 0,25 \Longrightarrow q(0,25) = Q_1$$

$$p = 0,50 \Longrightarrow q(0,50) = M_d$$

$$p = 0,75 \Longrightarrow q(0,75) = Q_3$$

Tabela de Frequência por classes

- Média? Mediana? Variância? Moda?

Tabela 5: Distribuição de frequência por classes das idades das melhores atrizes.

Idades das Atrizes (Classes) c_i	Frequências				Ponto Médio Pm_i
	Absoluta f_i	Relativa fr_i	Acumulada F_i	Acum. Relativa Fr_i	
$11 \vdash 21$	11	0.1833	11	0.1833	16
$21 \vdash 31$	9	0.1500	20	0.3333	26
$31 \vdash 41$	11	0.1833	31	0.5166	36
$41 \vdash 51$	4	0.0667	35	0.5833	46
$51 \vdash 61$	10	0.1667	45	0.7500	56
$61 \vdash 71$	15	0.2500	60	1.0000	66
Total	60	1.0000	-	-	-

$i = 1, 2, 3, 4, 5$ e 6 $(k = 6)$.

Representação Gráfica

- Gráfico de barras
- Gráfico de setores
- Gráfico de linhas
- Gráfico de pontos (dotplot)
- Histograma
- Gráfico de caixa (box-plot)

Por que utilizar gráficos ?

- O objetivo principal é produzir, no investigador ou no público em geral, uma impressão mais rápida e viva do fenômeno em estudo;
- O gráfico deve possibilitar uma correta interpretação dos valores representativos do fenômeno em estudo;
- O gráfico deve expressar a verdade sobre o fenômeno em estudo;

Gráfico em Barras (Variável Qualitativa)

- Gráfico em Barras:

Grau de Instrução	Frequência
Fundamental	12
Médio	18
Superior	6
total	36

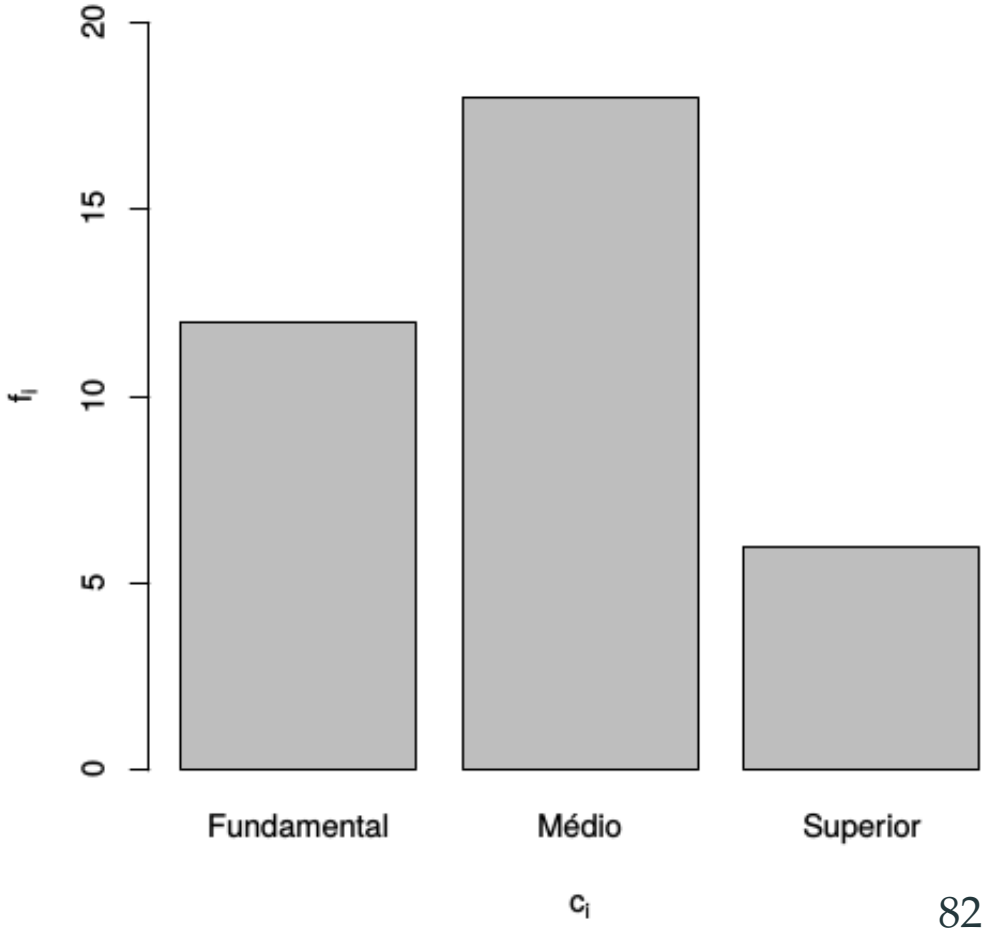

Gráfico de setores (Variável Qualitativa)

- Gráfico de setores:

Sexo	Frequência
Feminino	12
Masculino	38
total	50

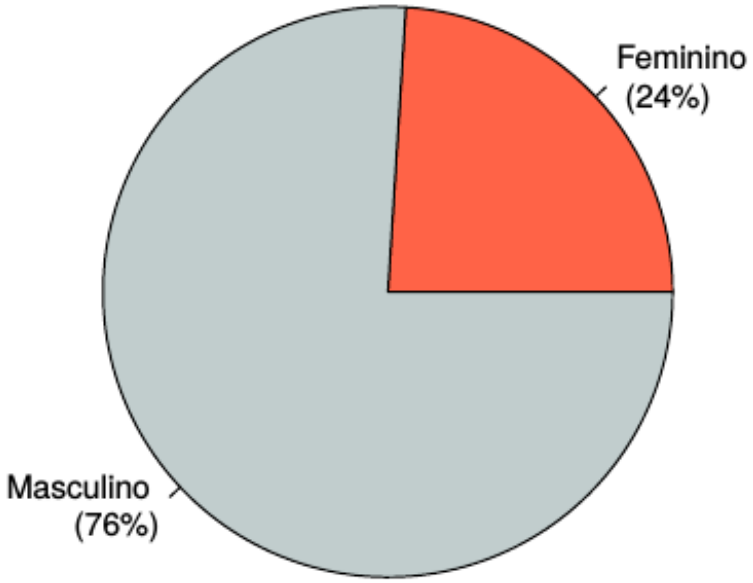

Gráfico em Barras (Variável Quantitativa)

- Distribuição de frequência simples:

N. de acidentes c_i	Frequência Absoluta f_i
0	31
1	16
2	2
3	1
Total	50

$i = 1, 2, 3$ e 4 $(k = 4)$.

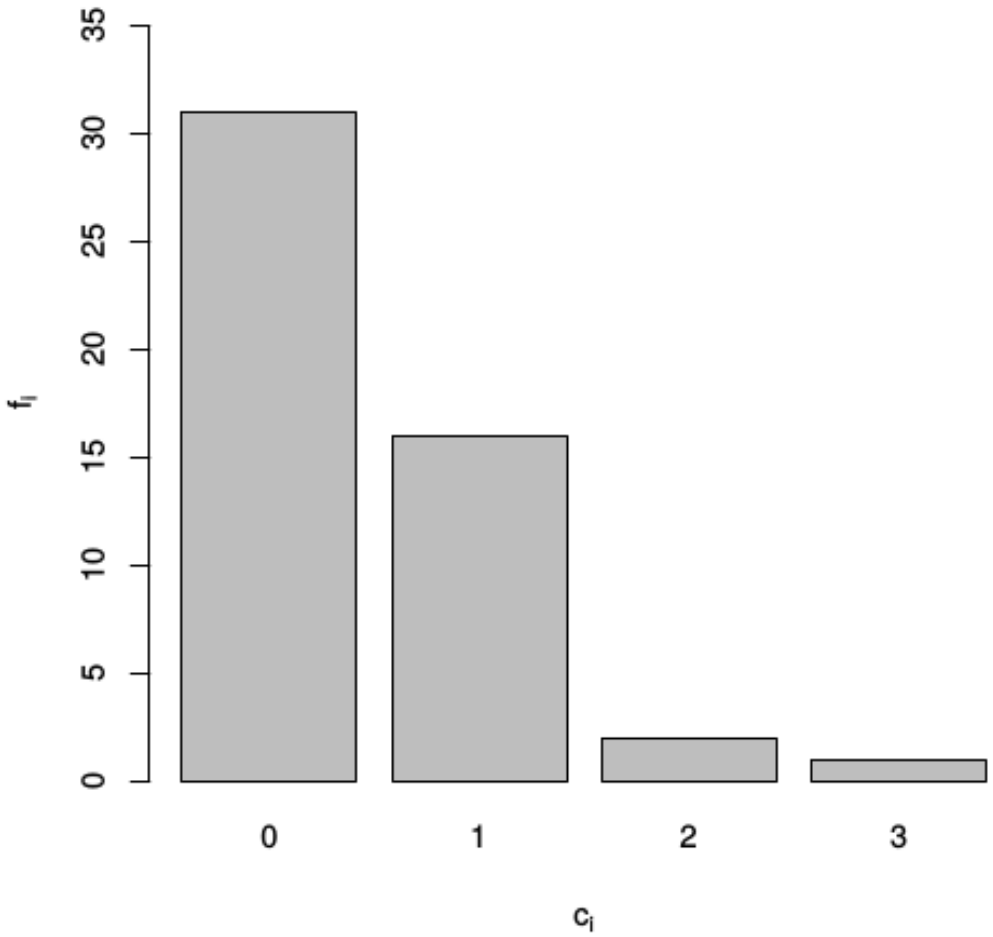

Gráfico de setores (Variável Quantitativa)

- Distribuição de frequência simples:

N. de acidentes c_i	Frequência Absoluta f_i
0	31
1	16
2	2
3	1
Total	50

$i = 1, 2, 3$ e 4 $(k = 4)$.

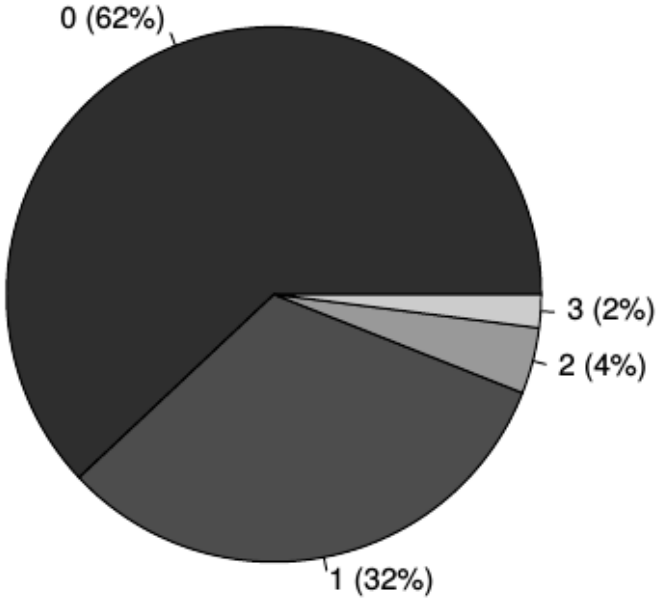

Histograma (Variável Quantitativa)

- Distribuição de frequência por classes:

Idades das Atrizes Classes c_i	Freq. Absoluta f_i
$11 \vdash 21$	11
$21 \vdash 31$	9
$31 \vdash 41$	11
$41 \vdash 51$	4
$51 \vdash 61$	10
$61 \vdash 71$	15
Total	60

$i = 1, 2, 3, 4, 5$ e 6 $(k = 6)$.

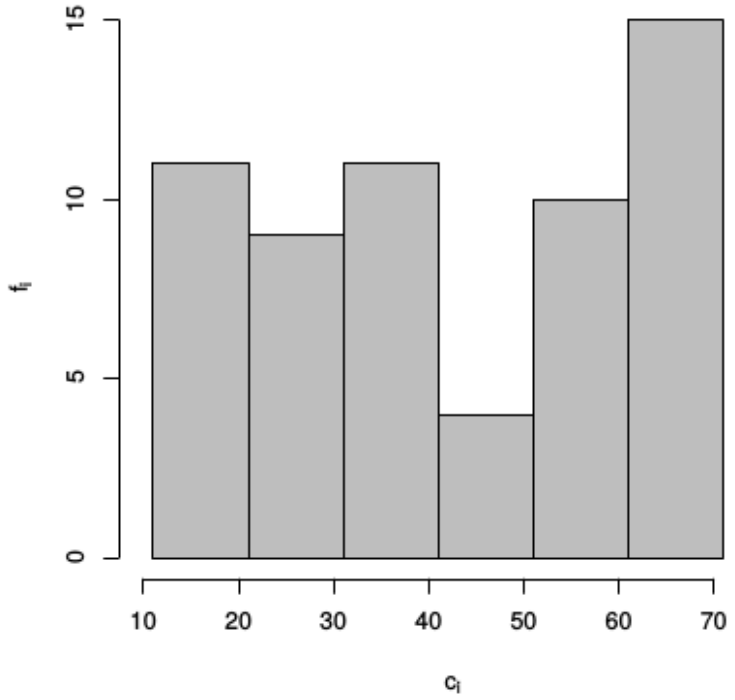

Histograma (Variável Quantitativa)

- Distribuição de frequência por classes:
- Eixo y: densidades de frequência, $d_i = \frac{fr_i}{LS_i - LI_i} = \frac{fr_i}{Ac_i}$

Idades das Atrizes (Classes) c_i	Frequências Absoluta f_i	Frequências Relativa fr_i
$11 \vdash 21$	11	0.1833
$21 \vdash 31$	9	0.1500
$31 \vdash 41$	11	0.1833
$41 \vdash 51$	4	0.0667
$51 \vdash 61$	10	0.1667
$61 \vdash 71$	15	0.2500
Total	60	1.0000

$i = 1, 2, 3, 4, 5$ e 6 $(k = 6)$.

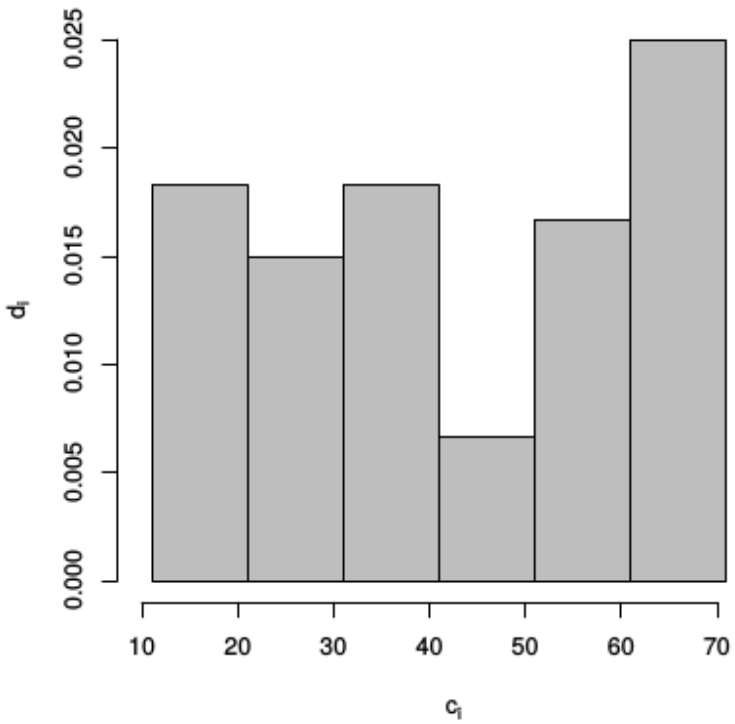

Gráfico de Linhas (Variável Quantitativa)

- São normalmente usados para controlar alterações ao longo do tempo e para facilitar a identificação de tendências ou de anomalias;

Evolução do preço de um ativo financeiro ao longo de 20 dias			
Dia 1	103,60	Dia 11	109,21
Dia 2	104,41	Dia 12	108,13
Dia 3	105,21	Dia 13	108,76
Dia 4	106,00	Dia 14	109,45
Dia 5	105,18	Dia 15	110,12
Dia 6	106,80	Dia 16	109,56
Dia 7	104,89	Dia 17	111,67
Dia 8	105,23	Dia 18	112,32
Dia 9	107,60	Dia 19	110,97
Dia 10	108,41	Dia 20	111,34

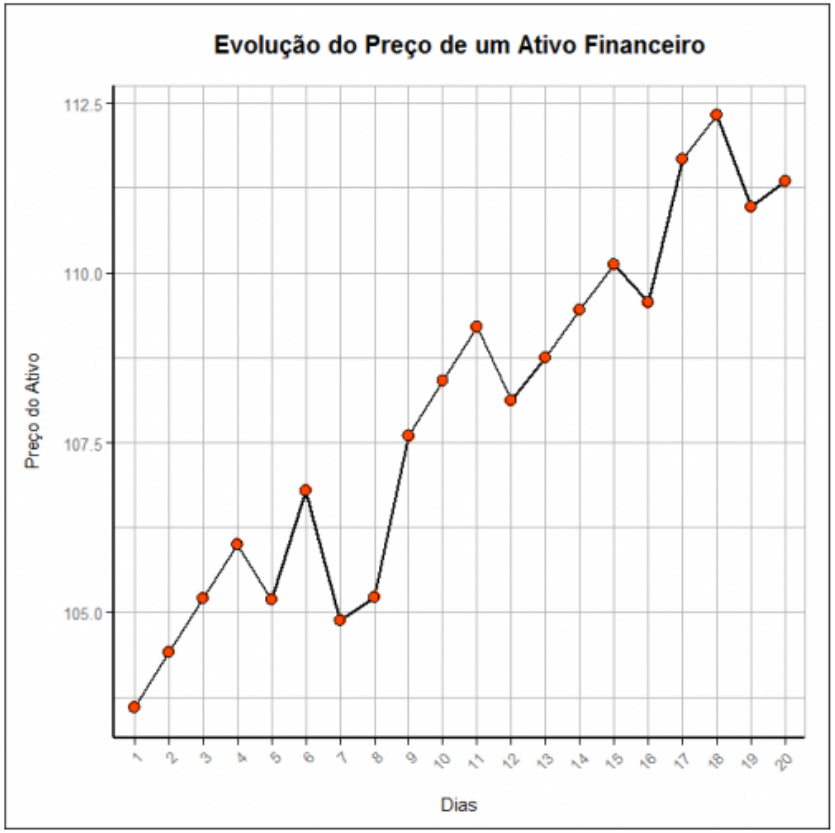

Gráfico de pontos - dotplot (Variável Quantitativa)

- Representa cada observação obtida em uma escala horizontal, permitindo visualizar a distribuição dos dados ao longo deste eixo;

A	B	C	D
3620	1910	4900	2800
4010	2100	4100	2400
4560	2210	5520	2900
2760	2030	6200	2950
3480	2090	5800	3400
2930	2230	7200	3200
3070	2060	4700	3150
3200	2050	5600	2770

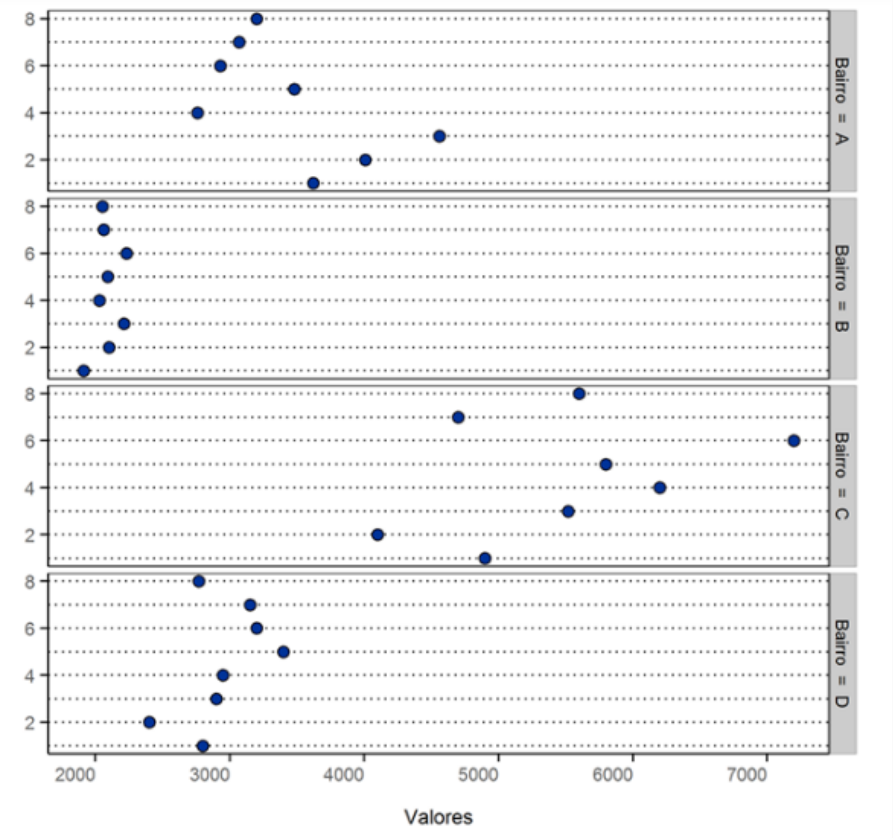

Gráfico de caixa - Boxplot (Variável Quantitativa)

Boxplot:

- Obter Q_1, Q_2 e Q_3;
- Calcular a amplitude interquartil: $d_Q = Q_3 - Q_1$;
- Calcular as cercas para identificação de outliers
  Cerca inferior: $CI = Q_1 - 1,5d_Q$
  Cerca superior: $CS = Q_3 + 1,5d_Q$
- Obter o primeiro menor valor dos dados acima da cerca inferior;
- Obter o primeiro maior valor dos dados abaixo da cerca superior;

Gráfico de caixa - Boxplot (Variável Quantitativa)

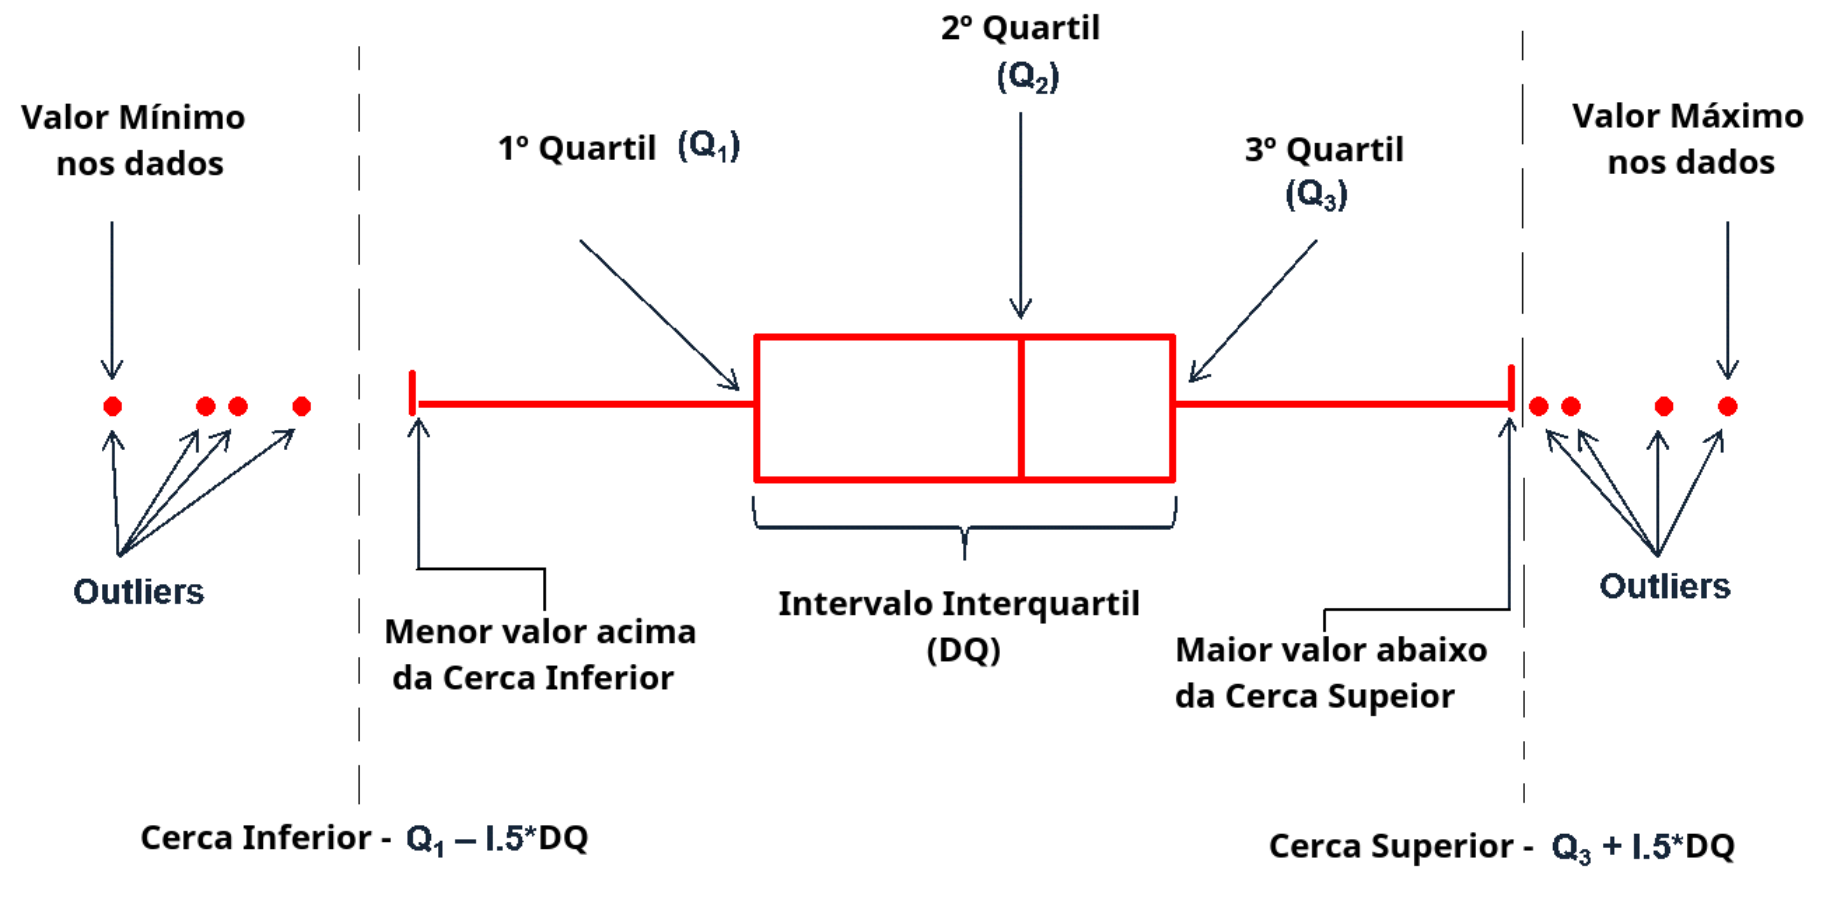

Gráfico de caixa - Boxplot (Variável Quantitativa)

Gráfico de caixa (box-plot): Idade das melhores atrizes.

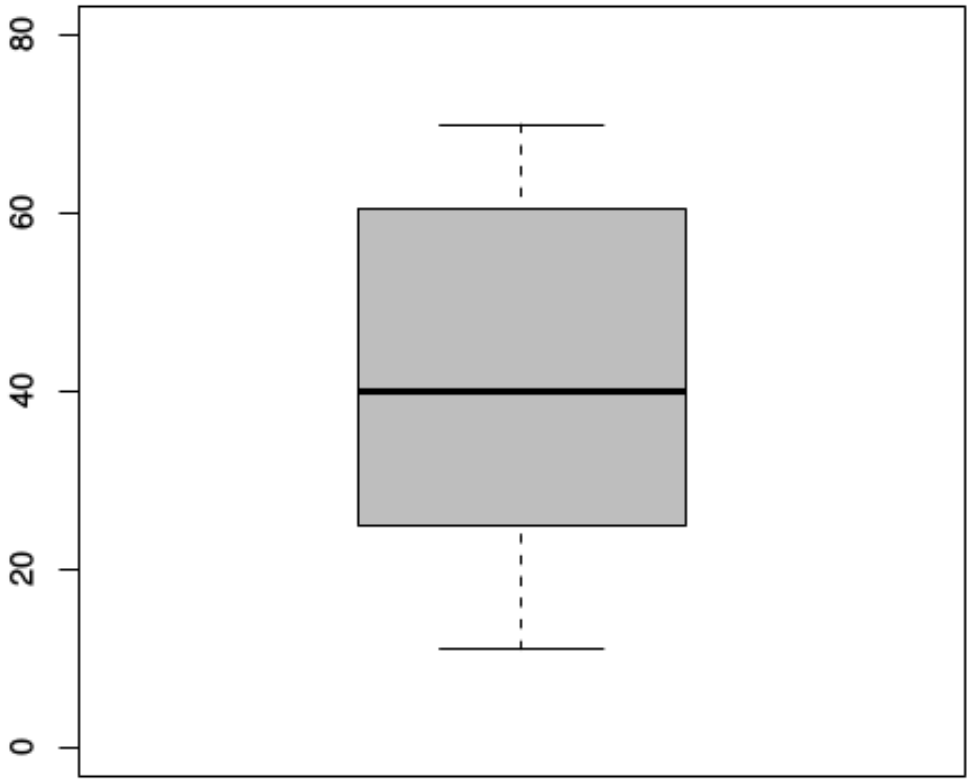

Gráfico de caixa - Boxplot (Variável Quantitativa)
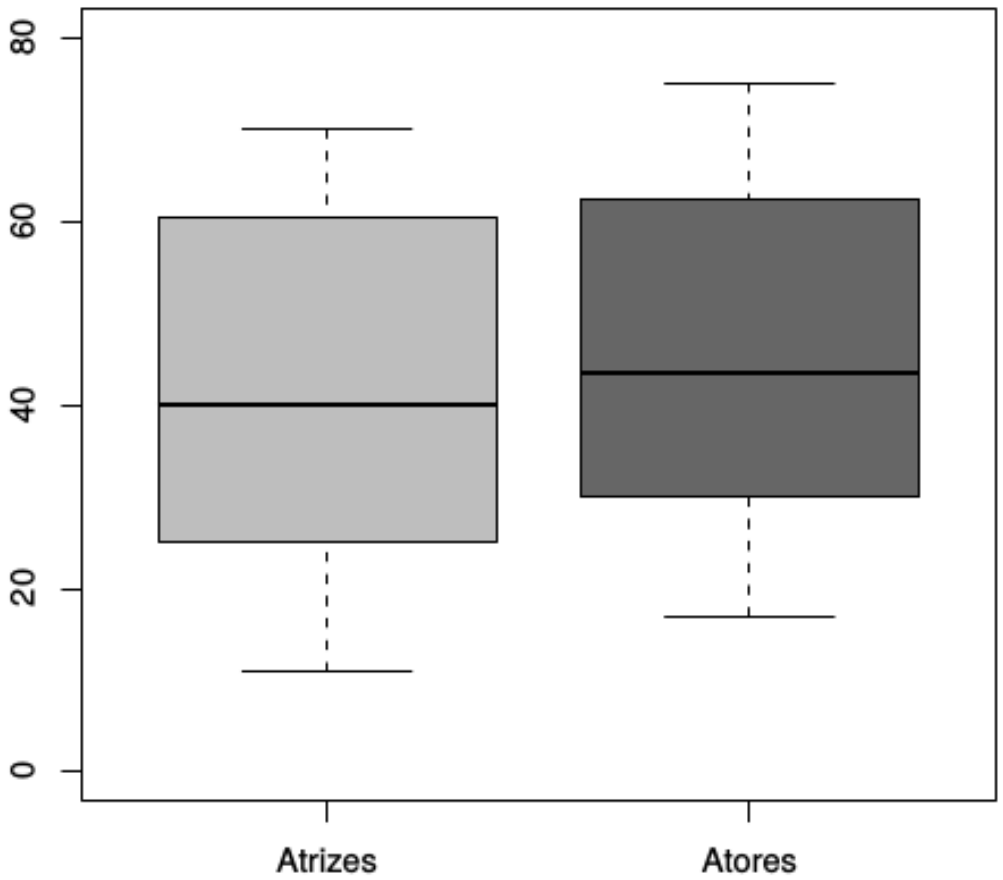
Gráfico de caixa (box-plot): Idade das melhores atrizes e melhores atores.