ESTAT0011 - ESTATÍSTICA APLICADA

Cleber Martins Xavier
Universidade Federal de Sergipe

Universidade Federal de Sergipe

Objetivos Gerais da Disciplina

- Introduzir ideias básicas de Probabilidade e Estatística
- Estabelecer uma linguagem comum entre o aluno e o Estatístico
- Resolver problemas práticos utilizando técnicas de Estatística
- Desenvolver técnicas de estimação com base em elementos amostrais
- Discutir e desenvolver testes de hipóteses

Programa Parte 1: Estatística Descritiva

- As fases do trabalho estatístico;
- Classificação dos dados;
- Séries estatísticas e sua representação tabular e gráfica;
- Distribuição de frequências simples e em classe e sua representação gráfica;
- Medidas de Posição: Média, Mediana e Moda;
- Medidas de Dispersão: Variância, desvio-padrão, coeficiente de variação.

Programa Parte 2: Probabilidade

- Noções de conjuntos;
- Conceitos de probabilidade: Experimento aleatório, espaço amostral e eventos;
- Eventos independentes;
- Probabilidade condicional e teorema de bayes;
- Variáveis aleatórias;
- Esperança matemática, variância e desvio-padrão;
- Distribuições discretas: Bernoulli, Binomial, Geométrica e Poisson;
- Distribuições contínuas: Uniforme, Exponencial e Normal.

Programa Parte 3: Inferência

- Conceitos iniciais de inferência;
- Distribuição da média e da proporção;
- Estimação;
- Intervalo de confiança para média e proporção;
- Testes de hipóteses para média e proporção.

Bibliografia básica

- MAGALHÃES, Marcos Nascimento; LIMA, Antônio Carlos Pedroso de. Noções de probabilidade e estatística. 7. ed. atual. São Paulo, SP: EDUSP, 2010.
- MORETTIN, Luiz Gonzaga. Estatística básica: probabilidade e inferência. São Paulo: Pearson, 2010.
- MEYER, P. L.. Probabilidade. Aplicações à Estatística. Livros Técn. Científicos, 1972.
- ROSS, Sheldon M. Probabilidade: um curso moderno com aplicações. 8. ed. Porto Alegre, RS: Bookman, 2010.

Ideia

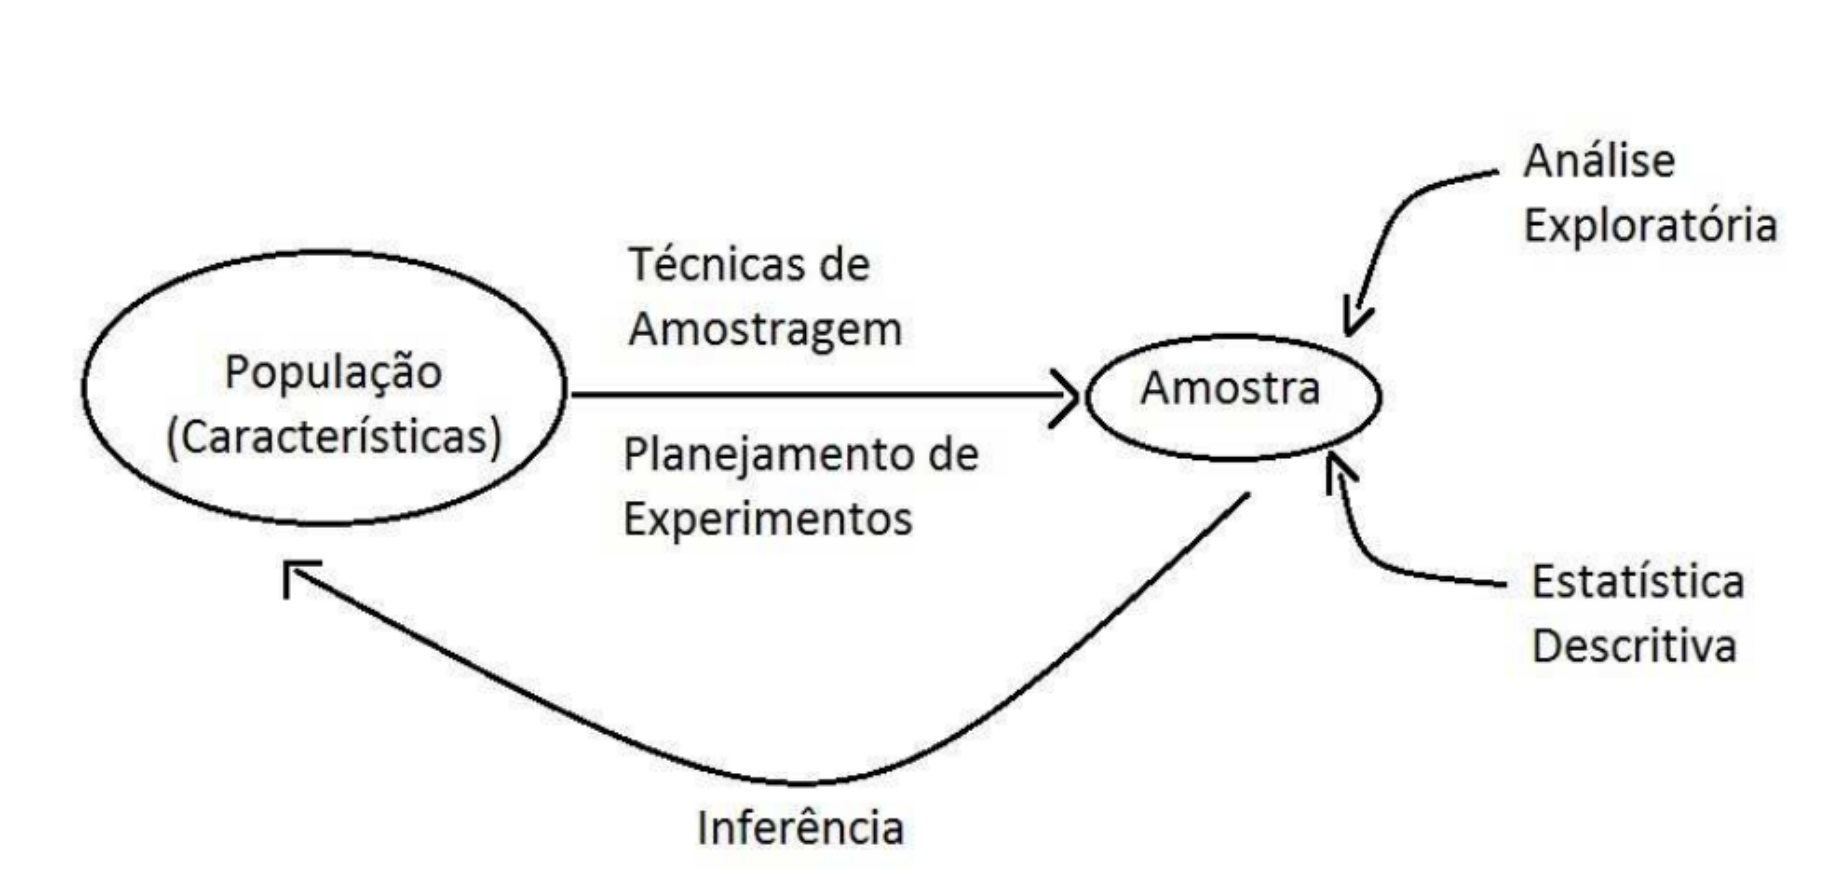
Análise
Exploratória
Técnicas de
Amostragem
População
(Características)
Amostra
Planejamento de
Experimentos
Estatística
Descritiva
Inferência

Algumas Definições

Estatística: é uma ciência baseada na **Teoria da Probabilidade**, cujo o objetivo principal é nos auxiliar a tomar decisões ou tirar conclusões em situações de incerteza, a partir dos dados.

"Estatística é um conjunto de técnicas que permite, de forma sistemática, organizar, descrever, analisar e interpretar dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento."

Marcos Magalhães

Resumo: $\boxed{\text{Estatística}} \Longleftrightarrow \boxed{\text{Incerteza}}$

Algumas Definições

População: É uma coleção completa de todos os elementos a serem estudados e que possuem certa característica comum.

Observação: A população deve ser bem definida.

Amostra: É um subconjunto de membros selecionados de uma população.

Técnicas de Amostragem

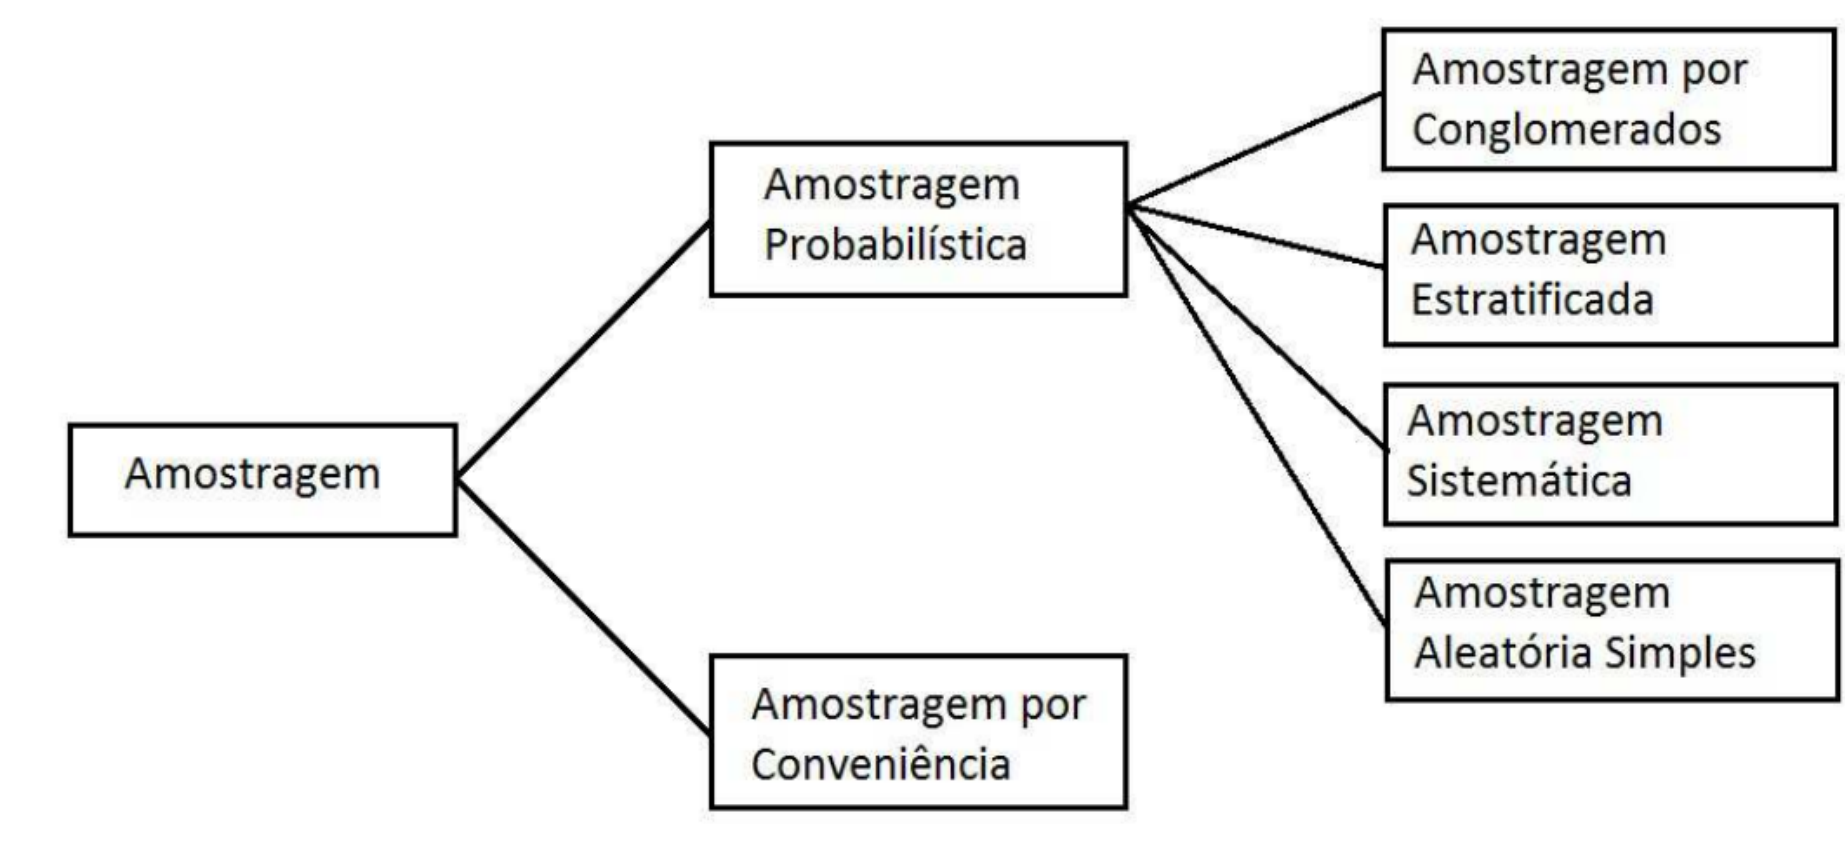

Algumas Definições

Censo: É um conjunto de dados obtidos de todos os membros da população.

Variável: Qualquer característica de interesse associada aos elementos de uma população.

Classificação de variáveis

Qualitativa
- **Nominal** (Ex: cor, sexo, estado civil)
- **Ordinal** (Ex: grau de escolaridade, classe social, porte de empresa)

Quantitativa
- **Discreta** (Ex: n° de pessoas, n° de defeitos)
- **Contínua** (Ex: peso, temperatura, preço)

Fases do método Estatístico

- Definição do Problema: fase onde o pesquisador define ou formula o problema a ser estudado;
- Planejamento: após a definição do problema esta fase consiste em se levantar informações relevantes ao estudo e como determinar o procedimento necessário para resolvê-lo;
- Coleta de dados: passo essencialmente operacional, compreendendo a coleta das informações definidas anteriormente;
- Apuração dos dados: aqui os dados são tratados para sua melhor apresentação;
- Análise e interpretação: fase onde os dados são analisados para a retirada de conclusões;

O que fazer com os dados coletados ?

Etapa inicial: Estatística descritiva/Análise exploratória

Consiste em medidas resumo (média, mediana, moda, variância, coeficiente de variação, etc.), tabelas e gráficos.

Algumas Definições

Suponha que X representa uma variável. Denota-se por $\mathbf{x} = (x_1, x_2, \ldots, x_n)$, n observações da variável X.

Desejamos conhecer o "comportamento" da varíavel X. Para isso, considere as seguintes definições:

Definições Importantes

Parâmetro: É uma medida numérica que descreve alguma característica de uma população;

Estatística ou estimador: É uma função da amostra utilizada para estimar o parâmetro;

Estimativa: É o valor numérico que a estatística assume quando avaliada nos dados observados.

Definições Importantes

Parâmetro	Estimador	Estimativa
Média populacional (μ)	média amostral ($\hat{\mu}$ ou $\bar{X}$)	$\hat{\mu}(\mathbf{x})$ ou $\bar{x}$
Variância populacional (σ^2)	Variância Amostral ($\hat{\sigma^2}$ ou S^2)	$\hat{\sigma}^2(\mathbf{x})$ ou s^2
Proporção populacional (p)	Proporção amostral ($\hat{p}$)	$\hat{p}(\mathbf{x})$

Definições Importantes

Dados Brutos: É o conjunto de observações de uma variável, apresentados da forma em que foram coletados;

Ex.: 3,7,2,1,5,7.

Rol: É o conjunto de observações de uma variável, apresentados de forma ordenada (crescente ou decrescente).

Ex.: 1,2,3,5,7,7.

Definições Importantes

Em uma notação geral, podemos denotar os **dados brutos** e o **rol** das seguintes formas:

Dados Brutos: $x_1, x_2, \ldots, x_n$

Rol: $x_{(1)}, x_{(2)}, \ldots, x_{(n)}$ tal que

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)} \quad \text{(crescente)}$$

ou

$$x_{(1)} \geq x_{(2)} \geq \cdots \geq x_{(n)} \quad \text{(decrescente)}$$

em que n representa o tamanho da amostra ou o número total de indivíduos na amostra.

Medidas Resumo

Medidas de posição: moda, média, mediana (medidas de tendência central), quantis (quartis, decis, percentis).

Medidas de dispersão: amplitude, intervalo interquartil, variância, desvio-padrão, coeficiente de variação.

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

$M_o = 3$ (Unimodal)

Ex 2- Dados: 4,1,7,4,7

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

$M_o = 3$ (Unimodal)

Ex 2- Dados: 4,1,7,4,7

$M_o = 4$ e 7 (Bimodal)

Ex 3 - Dados: 8,1,7,4,0

Medidas Resumo: Medidas de Posição

Moda: É a realização mais frequente do conjunto de valores observados.

Notação: M_o

Ex 1- Dados: 2,3,5,3,1

$M_o = 3$ (Unimodal)

Ex 2- Dados: 4,1,7,4,7

$M_o = 4$ e 7 (Bimodal)

Ex 3 - Dados: 8,1,7,4,0

$\nexists\ M_o$ (Amodal)

Medidas Resumo: Medidas de Posição

Média aritmética (média amostral): É a soma das observações dividido pelo número total delas.

Notação: $\bar{X}$

Descrição matemática:

$$\bar{X} = \frac{X_1 + X_2 + \cdots + X_n}{n} = \frac{\sum_{i=1}^{n} X_i}{n}$$

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

$$\bar{x} = \frac{2+3+5+3+1}{5} = 2,8$$

Desvantagem da Média amostral: Sofre influência de valores extremos (*outliers*).

Ex 2 - Dados: 0, 10, 12, 12, 16.

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

$$\bar{x} = \frac{2+3+5+3+1}{5} = 2,8$$

Desvantagem da Média amostral: Sofre influência de valores extremos (*outliers*).

Ex 2 - Dados: 0, 10, 12, 12, 16.

$$\bar{x} = \frac{0+10+12+12+16}{5} = 10$$

Ex 3 - Dados: 1, 3, 5, 6, 35

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

$$\bar{x} = \frac{2+3+5+3+1}{5} = 2,8$$

Desvantagem da Média amostral: Sofre influência de valores extremos (*outliers*).

Ex 2 - Dados: 0, 10, 12, 12, 16.

$$\bar{x} = \frac{0+10+12+12+16}{5} = 10$$

Ex 3 - Dados: 1, 3, 5, 6, 35

$$\bar{x} = \frac{1+3+5+6+35}{5} = 10$$

Medidas Resumo: Medidas de Posição

Mediana: É a observação que ocupa a posição central do conjunto de observações (amostra), quando estão ordenados de forma crescente (ou decrescente).

Notação: M_d

Como encontrar a mediana ?

Medidas Resumo: Medidas de Posição

Passo 1: Ordenar os dados, ou seja, construir o rol.

Passo 2: Encontrar a posição da mediana,

$$P = \frac{n}{2}$$

A mediana será o elemento, de tal forma que

$$M_d = \begin{cases} \frac{x_{(P)} + x_{(P+1)}}{2}, & \text{se P é inteiro} \\ x_{([P]+1)}, & \text{se P não é inteiro} \end{cases}$$

em que [P] indica a parte inteira do número P.

Ex. $[3,5] = 3$

Medidas Resumo: Medidas de Posição

Ex 1 - Dados: 2, 3, 5, 3, 1

Rol: 1, 2, 3, 3, 5

$P = \frac{5}{2} = 2,5 \Rightarrow M_d = x_{([2,5]+1)} = x_{(3)} = 3$

Ex 2 - Dados: 1, 3, 5, 6, 35

$P = \frac{5}{2} = 2,5 \Rightarrow M_d = x_{([2,5]+1)} = x_{(3)} = 5$

Medidas Resumo: Medidas de Posição

Quantis (quartil, decil, percentil): O quantil de ordem p ou o p-quantil, indicado por $q(p)$, sendo p uma proporção $(0 < p < 1)$, é uma medida em que $100p\%$ das observações sejam menores do que $q(p)$.

Notação: $q(p)$.

Como encontrar o quantil de ordem p ?

Medidas Resumo: Medidas de Posição

Passo 1: Ordenar os dados, ou seja, construir o rol.

Passo 2: Encontrar a posição do p-quantil,

$$P = p \cdot n$$

O quantil de ordem p ou o p-quantil será o elemento , de tal forma que

$$q(p) = \begin{cases} \frac{x_{(P)}+x_{(P+1)}}{2}, & \text{se P é inteiro} \\ x_{([P]+1)}, & \text{se P não é inteiro} \end{cases}$$

em que [P] indica a parte inteira do número P.

Medidas Resumo: Medidas de Posição

Alguns quantis e seus nomes particulares:

a) Quartis: divide o rol em 4 partes iguais.

Notação: $Q_1 = q(25\%); Q_2 = q(50\%); Q_3 = q(75\%)$

b) Decis: divide o rol em 10 partes iguais.

Notação: $D_1 = q(10\%); D_2 = q(20\%); \cdots ; D_9 = q(90\%)$

b) Percentis: divide o rol em 100 partes iguais.

Notação: $P_1 = q(1\%); P_2 = q(2\%); \cdots ; P_{99} = q(99\%)$

Medidas Resumo: Medidas de Posição

Alguns casos particulares:

$$Q_1 : 1^{\text{o}} \text{ Quartil} = P_{25} : 25^{\text{o}} \text{ Percentil}$$

$$Q_2 : 2^{\text{o}} \text{ Quartil} = M_d : \text{Mediana} = D_5 : 5^{\text{o}} \text{ Decil} = P_{50} : 50^{\text{o}} \text{ Percentil}$$

$$Q_3 : 3^{\text{o}} \text{ Quartil} = P_{75} : 75^{\text{o}} \text{ Percentil}$$

$$D_1 : 1^{\text{o}} \text{ Decil} = P_{10} : 10^{\text{o}} \text{ Percentil}$$

Medidas Resumo: Medidas de Posição

Ex 1 (Primeiro Quartil, Q_1) - Dados: 3, 2, 8, 5, 3, 7, 3, 9, 2

Medidas Resumo: Medidas de Posição

Ex 1 (Primeiro Quartil, Q_1) - Dados: 3, 2, 8, 5, 3, 7, 3, 9, 2

Rol: 2, 2, 3, 3, 3, 5, 7, 8, 9

$n = 9$ e $p = 0,25$ ou 25%

$P = n \cdot p = 9 \times 0,25 = 2,25$

$Q_1 = q(25\%) = x_{([P]+1)} = x_{([2,25]+1)} = x_{(3)} = 3$

Ex 2 (Terceiro Quartil, Q_3) - Dados: 18, 13, 12, 10, 17, 10

Medidas Resumo: Medidas de Posição

Ex 1 (Primeiro Quartil, Q_1) - Dados: 3, 2, 8, 5, 3, 7, 3, 9, 2

Rol: 2, 2, 3, 3, 3, 5, 7, 8, 9

$n = 9$ e $p = 0,25$ ou 25%

$P = n \cdot p = 9 \times 0,25 = 2,25$

$Q_1 = q(25\%) = x_{([P]+1)} = x_{([2,25]+1)} = x_{(3)} = 3$

Ex 2 (Terceiro Quartil, Q_3) - Dados: 18, 13, 12, 10, 17, 10

Rol: 10, 10, 12, 13, 17, 18

$n = 6$ e $p = 0,75$ ou 75%

$P = n \cdot p = 6 \times 0,75 = 4,5$

$Q_3 = q(75\%) = x_{([P]+1)} = x_{([4,5]+1)} = x_{(5)} = 17$

Medidas Resumo: Medidas de Dispersão

Finalidade: Encontrar um valor que resuma a variabilidade de um conjunto de dados.

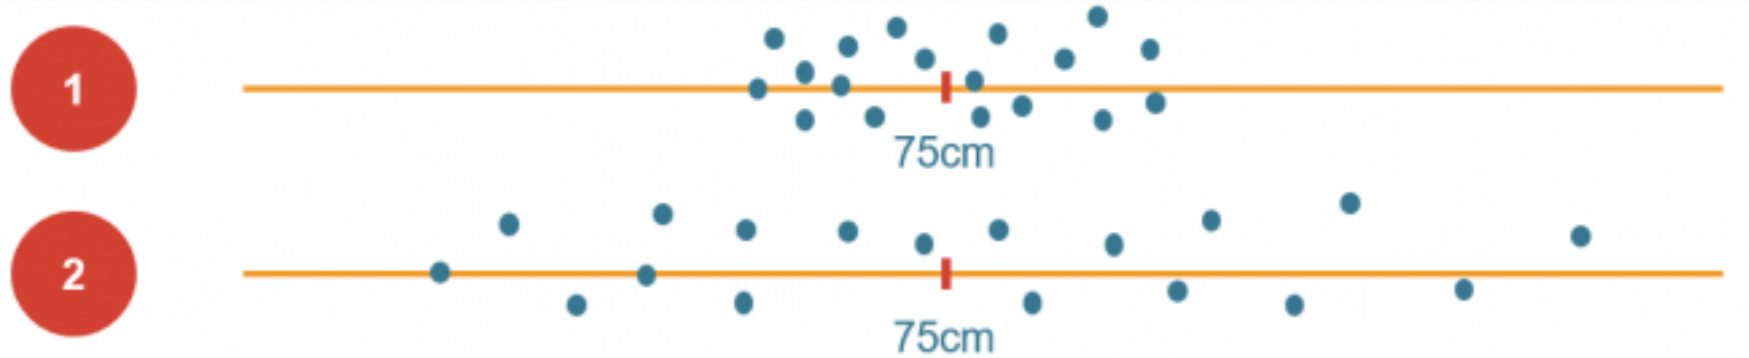

Medidas Resumo: Medidas de Dispersão

Amplitude: É a diferença entre o maior e o menor valor presentes em um conjunto de dados.

Notação: A_{mp}

$$A_{mp} = \max \ - \ \min$$

Ex. - Rol: 8, 9, 10, 13, 14

$$A_{mp} = 14 - 8 = 6$$

Medidas Resumo: Medidas de Dispersão

Amplitude ou Intervalo Interquartil: É a diferença entre o terceiro e o primeiro quartil.

Notação: d_Q

$$d_Q = Q_3 - Q_1$$

Medidas Resumo: Medidas de Dispersão

Ex. - Dados: 7, 5, 2, 9, 0, 8, 8, 2, 19, 13

Medidas Resumo: Medidas de Dispersão

Ex. - Dados: 7, 5, 2, 9, 0, 8, 8, 2, 19, 13

Rol: 0, 2, 2, 5, 7, 8, 8, 9, 13, 19

n=10, p=0.25 e p=0.75

$P = 10 \times 0.25 = 2.5$

$Q_1 = q(25\%) = x_{([P]+1)} = x_{([2.5]+1)} = x_{(3)} = 2$

$P = 10 \times 0.75 = 7.5$

$Q_3 = q(75\%) = x_{([P]+1)} = x_{([7.5]+1)} = x_{(8)} = 9$

$$d_Q = Q_3 - Q_1 = 9 - 2 = 7$$

Medidas Resumo: Medidas de Dispersão

Variância: É a soma dos quadrados dos desvios $(X_i - \mu)$ ou $(X_i - \hat{\mu})$ dividido pelo número total de elementos da amostra.

1 - Variância Populacional: A variância de uma população $X_1, ..., X_N$ de N elementos é a medida de dispersão definida como a média do quadrado dos desvios dos elementos em relação à sua média populacional μ.

Notação: σ^2

$$\sigma^2 = \sum_{i=1}^{N} \frac{(X_i - \mu)^2}{N}$$

Medidas Resumo: Medidas de Dispersão

2 - Variância Amostral: A variância de uma amostra $X_1, ..., X_n$ de n elementos é definida como a soma ao quadrado dos desvios dos elementos em relação à sua média $\overline{x}$ dividido por $(n-1)$.

Notação: $\hat{\sigma}^2$ ou S^2

$$S^2 = \sum_{i=1}^{n} \frac{(X_i - \overline{X})^2}{n-1}$$

Aqui iremos utilizar S^2 para encontrar o valor da variância.

Medidas Resumo: Medidas de Dispersão

Podemos reescrever S^2 por

$$S^2 = \frac{n\sum_{i=1}^{n} X_i^2 - \left(\sum_{i=1}^{n} X_i\right)^2}{n(n-1)}$$

OBS.: $\sum_{i=1}^{n} X_i^2 \neq \left(\sum_{i=1}^{n} X_i\right)^2$.

Medidas Resumo: Medidas de Dispersão

Ex.- Dados: 2, 3, 4, 7, 9.

Medidas Resumo: Medidas de Dispersão

Ex.- Dados: 2, 3, 4, 7, 9.

n=5

$$\overline{x} = \frac{\sum_{i=1}^{5} x_i}{5} = \frac{2+3+4+7+9}{5} = \frac{25}{5} = 5$$

$$s^2 = \sum_{i=1}^{5} \frac{(x_i - \overline{x})^2}{5-1} = \frac{(2-5)^2+(3-5)^2+(4-5)^2+(7-5)^2+(9-5)^2}{5-1} = \frac{34}{4} = 8.5$$

Medidas Resumo: Medidas de Dispersão

Desvio Padrão: é a raiz quadrada da variância.

1 - Desvio Padrão Populacional: é a raiz quadrada da variância populacional.

Notação: σ

$$\sigma = \sqrt{\sum_{i=1}^{N} \frac{(X_i - \mu)^2}{N}}$$

Medidas Resumo: Medidas de Dispersão

2 - Desvio Padrão Amostral: é a raiz quadrada da variância amostral.

Notação: $\hat{\sigma}$ ou S

$$S = \sqrt{\sum_{i=1}^{n} \frac{(X_i - \overline{X})^2}{n-1}}$$

Obs.: O desvio padrão tem a mesma unidade de medida dos dados.

Medidas Resumo: Medidas de Dispersão

Ex. - Considerando o exemplo anterior, Dados: 2, 3, 4, 7, 9.

n=5

$\overline{x} = 5$

$s^2 = 8.5$

Então, o desvio padrão amostral é

$$s = \sqrt{s^2} = \sqrt{8.5} = 2.9155$$

Medidas Resumo: Medidas de Dispersão

Coeficiente de variação: é uma medida de dispersão relativa, que descreve o desvio-padrão relativo à média.

Notação: CV ou $CV(\%)$

$$CV = \frac{\sigma}{\mu} \text{ ou } CV = \frac{S}{\overline{X}}$$

Obs.: Para expressar o coeficiente de variação em porcentagem, basta multiplicar por 100 ($CV(\%)$).

Medidas Resumo: Medidas de Dispersão

Interpretação: quanto menor o coeficiente de variação, menor é a variação dos dados

Obs.: O CV é uma medida adimensional (sem unidade de medida).

Medidas Resumo: Medidas de Dispersão

Ex.: Considere duas variáveis de interesse X e Y, com as seguintes informações:

$$X : \text{Altura} \qquad Y : \text{Peso}$$

$$\overline{x} = 1.72m \qquad \overline{y} = 68.7kg$$

$$s_x = 0.23m \qquad s_y = 12.3kg$$

Qual conjunto de dados tem maior variabilidade ?

Medidas Resumo: Medidas de Dispersão

Continuação exemplo anterior

X : Altura

$CV = \frac{0.23}{1.72} \times 100 = 13.372\%$

Y : Peso

$CV = \frac{12.3}{68.7} \times 100 = 17.904\%$

Resp.: Conjunto de dados pesos.

Tipo de Variáveis X Medidas Resumo

Variável

- **Qualitativa:** Moda
- **Quantitativa:** Moda; Média; Mediana; Quantis; Amplitude Interquartil; Variância; Desvio-Padrão; Coeficiente de Variação.