Inferência Estatística

Cleber Martins Xavier
Universidade Federal de Sergipe

Universidade Federal de Sergipe

Introdução à Inferência

Objetivo:

Produzir informações sobre dada característica da população na qual estamos interessados, a partir de informações colhidas de uma parte dessa população (amostra).

$$\boxed{\boxed{\text{Característica: Variável aleatória}}}$$

$$\begin{aligned} X &: \Omega \to \mathbb{R} \\ X &: f_X(x;\theta) \to \text{ modelo estatístico} \end{aligned}$$

Se tivéssemos a informação completa sobre a f.m.p ou a f.d.p da variável em questão, não teríamos necessidade de coletar uma amostra, uma vez que toda a informação desejada seria obtida por meio da distribuição variável.

Situação prática: θ é desconhecido

Interesse: Estimar θ (Métodos de estimação pontual)

Introdução à Inferência Estatística

Para isso, considere uma a.a. de X:

$$\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$$

Cada X_i é independente e tem a mesma distribuição de X. Associada a uma a.a. de $\boldsymbol{X}$, temos o vetor de observações:

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_n).$$

Com base na a.a. podemos obter uma estatística ou estimador que é função da a.a.

$$T = T(X_1, X_2, \ldots, X_n)$$

As estatísticas mais comuns são:

- Média Amostral: $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$;
- Variância amostral: $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$;
- Menor valor da amostra: $X_{(1)} = \min(X_1, \ldots, X_n)$;
- Maior valor da amostra: $X_{(n)} = \max(X_1, \ldots, X_n)$;

Problema da inferência estatística: Fazer uma afirmação sobre os parâmetros da população através da amostra.

Nossa decisão será baseada na estatística T. Colhida uma amostra observada, $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$, teremos observado um particular valor de T, dito t. Baseado nesse valor t é que faremos afirmação sobre θ, o parâmetro populacional.

A validade da nossa resposta seria melhor compreendida se soubéssemos o que acontece com a estatística T, quando retiramos todas as amostras de uma população conhecida.

Isto é, qual a distribuição de T quando $(X_1, \ldots, X_n)$ assume todos os possíveis valores.

Essa distribuição é chamada de distribuição amostral da estatística T. Vale ressaltar que a distribuição de T irá depender da distribuição de X.

Seguindo essa ideia, iremos estudar distribuições amostrais de algumas estatísticas importantes.

Distribuição Amostral da Média

Considere uma v.a. X, cujos parâmetros média e variância populacional são, respectivamente, $\mu = E(X)$ e $\sigma^2 = Var(X)$.

Vamos retirar todas a possíveis amostras de tamanho n dessa população e, para cada uma, calcular a média $\bar{X}$.

Em seguida, consideremos a distribuição amostral de $\bar{X}$ e estudaremos suas propriedades.

Distribuição Amostral da Média

Teorema: Seja X uma v.a. com média μ e variância σ^2 e seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de X. Então,

$$E(\bar{X}) = \mu \quad \text{e} \quad Var(\bar{X}) = \frac{\sigma^2}{n}.$$

Distribuição Amostral da Média

Teorema: Seja X uma v.a. com média μ e variância σ^2 e seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de X. Então,

$$E(\bar{X}) = \mu \quad \text{e} \quad Var(\bar{X}) = \frac{\sigma^2}{n}.$$

Prova: $E(\bar{X}) = E\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \frac{1}{n}\sum_{i=1}^{n} \mu = \frac{1}{n} n\mu = \mu$

$Var(\bar{X}) = Var\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) = \frac{1}{n^2}\sum_{i=1}^{n} Var(X_i) = \frac{1}{n^2}\sum_{i=1}^{n} \sigma^2 = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$

Distribuição Amostral da Média

O que acontece com a distribuição de $\bar{X}$ quando aumentamos o tamanho da amostra (n)?

$$\begin{aligned} E(\bar{X}) = E(X) &= \mu \\ Var(\bar{X}) = \frac{\sigma^2}{n} &\rightarrow 0 \text{ (diminui)} \end{aligned}$$

Este Resultado é conhecido como **Teorema Central do Limite (TCL)**.

Distribuição Amostral da Média

Teorema: Para amostras aleatórias (a.a.), retiradas de uma população com média μ e variância σ^2 finita, a distribuição amostral da média aproxima-se, para n grande, de uma distribuição normal com média μ e variância σ^2/n

$$\bar{X} \sim Normal\left(\mu, \frac{\sigma^2}{n}\right)$$

Padronizando, obtemos:

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim Normal(0, 1).$$

Distribuição Amostral da Média

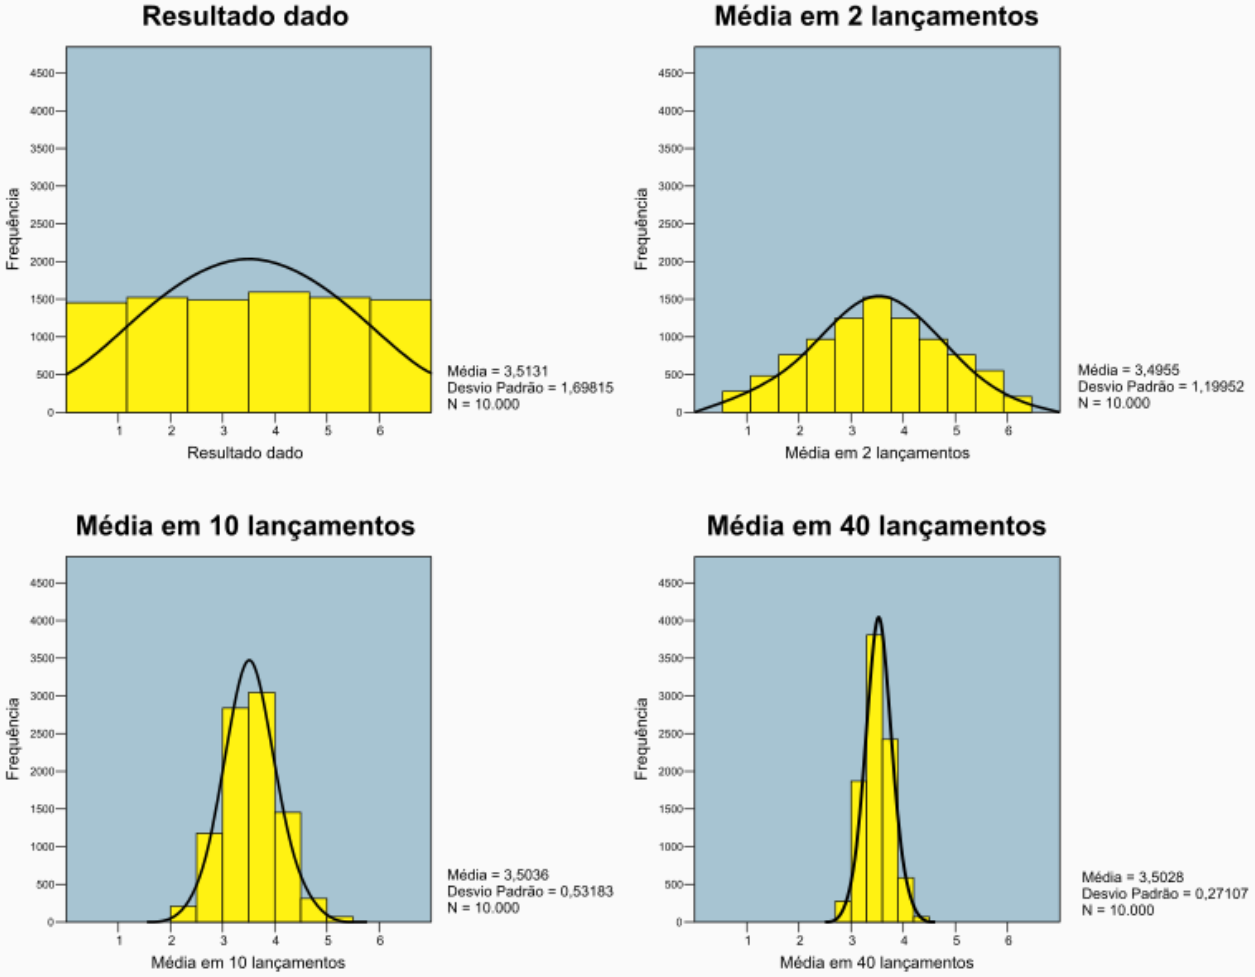

Distribuição Amostral da Média

Ex.: Uma v.a. X tem distribuição normal com média 10 e desvio padrão 3.

a) Se $\bar{X}$ for a média de uma amostra de 25 elementos retirados dessa população, calcule $P(9 < \bar{X} < 11)$.

Distribuição Amostral da Média

Ex.: Uma v.a. X tem distribuição normal com média 10 e desvio padrão 3.

a) Se $\bar{X}$ for a média de uma amostra de 25 elementos retirados dessa população, calcule $P(9 < \bar{X} < 11)$.

R.:

$$X \sim \mathcal{N}(10, 3^2) \Longleftrightarrow \bar{X} \sim \mathcal{N}\left(10, \frac{3^2}{n}\right)$$

$P(9 < \bar{X} < 11) = P\left(\frac{9-10}{3/5} < Z < \frac{11-10}{3/5}\right) = P(-1,67 < Z < 1,67) = 0,905$

b) Que tamanho deveria ter a amostra para que $P(9 < \bar{X} < 11) = 0.95$?

Distribuição Amostral da Média

Ex.: Uma v.a. X tem distribuição normal com média 10 e desvio padrão 3.

a) Se $\bar{X}$ for a média de uma amostra de 25 elementos retirados dessa população, calcule $P(9 < \bar{X} < 11)$.

R.:

$$X \sim \mathcal{N}(10, 3^2) \Longleftrightarrow \bar{X} \sim \mathcal{N}\left(10, \frac{3^2}{n}\right)$$

$P(9 < \bar{X} < 11) = P\left(\frac{9-10}{3/5} < Z < \frac{11-10}{3/5}\right) = P(-1,67 < Z < 1,67) = 0,905$

b) Que tamanho deveria ter a amostra para que $P(9 < \bar{X} < 11) = 0.95$?

R.: $P(9 < \bar{X} < 11) = P\left(\frac{9-10}{3/\sqrt{n}} < Z < \frac{11-10}{3/\sqrt{n}}\right) = P\left(\frac{-\sqrt{n}}{3} < Z < \frac{\sqrt{n}}{3}\right) = 0,95 \Leftrightarrow 2P(0 < Z < \sqrt{n}/3) = 0,95 \Rightarrow P(Z < \sqrt{n}/3) - P(Z < 0) = 0,475 \Leftrightarrow P(Z < \sqrt{n}/3) = 0,975$

Distribuição Amostral da Média

Table of Standard Normal Probabilities for Positive Z-scores

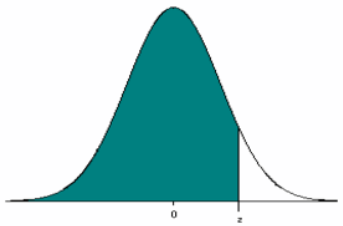

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	$\boxed{0.9750}$	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890

$$P\left(Z < \frac{\sqrt{n}}{3}\right) = 0.975 \Rightarrow \frac{\sqrt{n}}{3} = 1,96 \Rightarrow \sqrt{n} = 1,96 \times 3 \Rightarrow n \approx 35$$

Distribuição Amostral da Proporção

Seja X uma v.a. definida da seguinte maneira:

$$X = \begin{cases} 1, & \text{se ocorrer o sucesso (interesse)} \\ 0, & \text{se ocorrer o fracasso} \end{cases}$$

Logo, $\mu = E(X) = p$ e $\sigma^2 = Var(X) = p(1-p)$.

Considere uma a.a. $\boldsymbol{X} = (X_1, \ldots, X_n)$ da v.a. X e o interesse é a proporção $\hat{p}$ de indivíduos/elementos que possui a característica na amostra (sucesso). Isto é,

$$\hat{p} = \frac{\sum_{i=1}^{n} X_i}{n} = \bar{X}$$

Distribuição Amostral da Proporção

Observe que cada $X_i, \quad i = 1, \ldots, n$ tem distribuição Bernoulli com $\mu = E(X_i) = p$ e $\sigma^2 = Var(X_i) = p(1-p)$ e são independentes.

Pelo TCL, $\hat{p}$ (ou $\bar{X}$) terá distribuição aproximadamente Normal com média p e variância $\frac{p(1-p)}{n}$, ou seja,

$$\hat{p} \sim \mathcal{N}\left(p, \frac{p(1-p)}{n}\right) \Longleftrightarrow Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1)$$

Distribuição Amostral da Proporção

Ex.: Um procedimento de controle de qualidade foi planejado para garantir um máximo de 10% de itens defeituosos na produção. Supondo que a produção esteja sob controle ($p = 10\%$) e que os itens sejam vendidos em caixas com 100 unidades, qual a probabilidade de que uma caixa tenha mais do que 10% de defeituosos ?

Distribuição Amostral da Proporção

Ex.: Um procedimento de controle de qualidade foi planejado para garantir um máximo de 10% de itens defeituosos na produção. Supondo que a produção esteja sob controle ($p = 10\%$) e que os itens sejam vendidos em caixas com 100 unidades, qual a probabilidade de que uma caixa tenha mais do que 10% de defeituosos ?

$$X \sim Bernoulli(p) \Rightarrow E(X) = p \text{ e } Var(X) = p(1-p)$$

Sabemos que $\hat{p} = \bar{X} \sim \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$. Logo

$$\begin{aligned} P\left(\sum_{i=1}^{n} X_i > 10\right) &= P(\bar{X} > 0,10) = P(\hat{p} > 0,10) \\ &= P\left(Z > \frac{0,10 - 0,10}{\sqrt{\frac{0,1(0,9)}{100}}}\right) = P(Z > 0) = 0,5 \end{aligned}$$

Estimação Pontual

Estimação pontual

Um dos problemas em inferência estatística é como obter um estimador de determinado parâmetro populacional. A seguir discutiremos alguns métodos de obtenção de estimadores.

Estimadores de Mínimos Quadrados

Seja Y uma v.a. e $Y_1, Y_2, \ldots, Y_n$ n realizações independentes de Y. Suponha que podemos escrever as observações da forma

$$Y_i = g_i(\theta_1, \ldots, \theta_k) + \mathcal{E}_i, \quad i = 1, 2, \ldots, n$$

em que g_i são funções conhecidas, $\theta_1, \ldots, \theta_k$ são k parâmetros desconhecidos e de interesse e $\mathcal{E}_i$ é o erro aleatório que satisfaz as seguintes condições

- $E(\mathcal{E}_i) = 0$
- $Var(\mathcal{E}_i) = \sigma^2$
- $Cov(\mathcal{E}_i, \mathcal{E}_j) = E(\mathcal{E}_i\mathcal{E}_j) - E(\mathcal{E}_i)E(\mathcal{E}_j) = 0, \quad \forall i \neq j \quad \text{e} \quad j = 1, 2, \ldots, n$

Estimadores de Mínimos Quadrados

Para cada Y_i temos que o valor esperado é $g_i(\theta_1, \ldots, \theta_k)$, isto é,

$$\begin{aligned} E(Y_i) &= E(g_i(\theta_1, \ldots, \theta_k) + \mathcal{E}_i) \\ &= g_i(\theta_1, \ldots, \theta_k) + E(\mathcal{E}_i) \\ &= g_i(\theta_1, \ldots, \theta_k) \end{aligned}$$

Estimadores de Mínimos Quadrados

O método de mínimos quadrados afirma que devemos estimar $\theta_1, \ldots, \theta_k$ por $\hat{\theta}_1, \ldots, \hat{\theta}_k$, o qual faz o valor esperado $\hat{Y}_i = E(Y_i)$ tão perto quanto possível do ponto observado de Y_i. Isto é, se observarmos $Y_1 = y_1, Y_2 = y_2, \ldots, Y_n = y_n$, as estimativas de $\hat{\theta}_1, \ldots, \hat{\theta}_k$ (que são estimadores) devem minimizar a soma dos quadrados dos erros

$$\begin{aligned} S(\theta_1, \ldots, \theta_k) &= \sum_{i=1}^{n} \mathcal{E}_i^2 \\ &= \sum_{i=1}^{n} (Y_i - g_i(\theta_1, \ldots, \theta_k))^2 \end{aligned}$$

Estimadores de Mínimos Quadrados

Os estimadores de mínimos quadrados de $\theta_1, \ldots, \theta_k$ satisfaz as seguintes equações

$$\frac{\partial S(\theta_1, \ldots, \theta_k)}{\partial \theta_j} = 0, \quad \forall j = 1, 2, \ldots, k$$

Essas equações são conhecidas como equações normais.

OBS.: $\hat{\theta}(\boldsymbol{Y})$ estimador; $\hat{\theta}(\boldsymbol{y})$ estimativa.

Estimadores de Mínimos Quadrados

Ex.: (Modelos de Regressão)

- Em diversos problemas das áreas médicas, biológica, computacional, industrial entre outras, é de grande interesse verificar se duas ou mais variáveis estão relacionadas de alguma forma;
- Para expressar esta relação é muito importante estabelecer um modelo matemático;
- Este tipo de modelagem ajuda a entender como determinadas variáveis influenciam outra variável;

Estimadores de Mínimos Quadrados

Diagramas de dispersão que sugerem uma regressão linear entre as variáveis

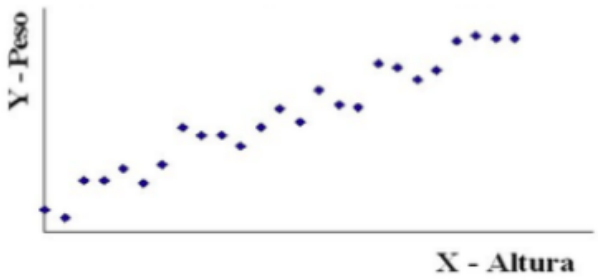

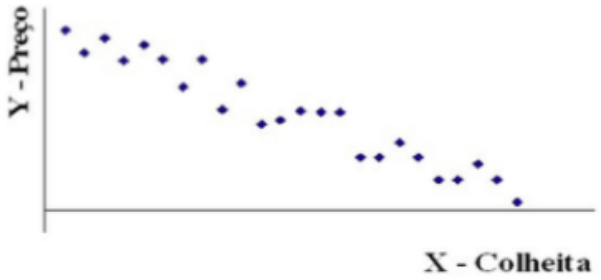

Existência de correlação positiva (em média, quanto maior for a altura maior será o peso)

Existência de correlação negativa (em média, quanto maior for for a colheita menor será o preço

Estimadores de Mínimos Quadrados

O Coeficiente de correlação linear é dada por

$$r(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}}$$

Este coeficiente é uma do grau de dependência linear entre as duas variáveis, X e Y.

- $-1 \leq r \leq 1$;
- $r = 1$: relação linear perfeita (e positiva) entre X e Y;
- $r = 0$: inexistência de relação linear entre X e Y;
- $r = -1$: relação linear perfeita (e negativa) entre X e Y;
- $r > 0$: relação linear positiva entre X e Y;
- $r < 0$: relação linear nehativa entre X e Y;

Estimadores de Mínimos Quadrados

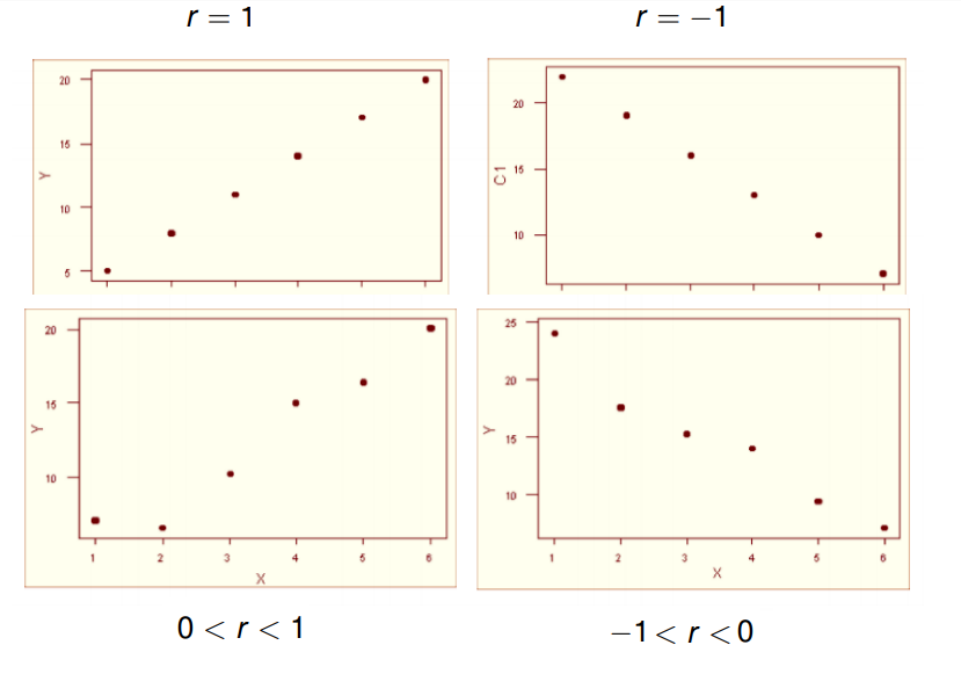

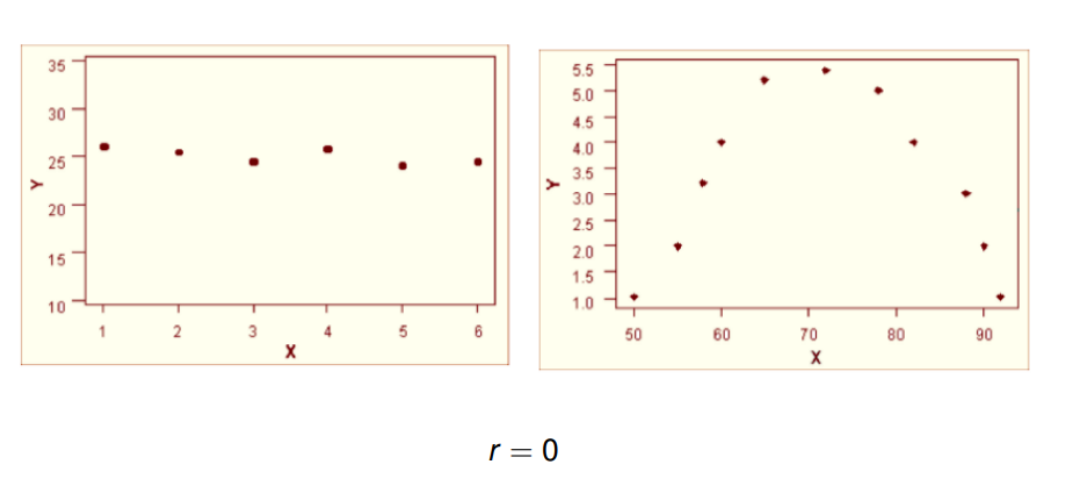

Estimadores de Mínimos Quadrados

Considere o seguinte modelo

$$Y = E(Y|X = x) + \mathcal{E} = \alpha + \beta x + \mathcal{E}$$

- Y variável dependente ou explicada;
- X variável independente ou explicativa;
- α coeficiente de regressão que representa o intercepto (parâmetro desconhecido);
- β coeficiente de regressão que representa o declive (inclinação) (parâmetro desconhecido);
- $\mathcal{E}$ erro aleatório ou estocástico;

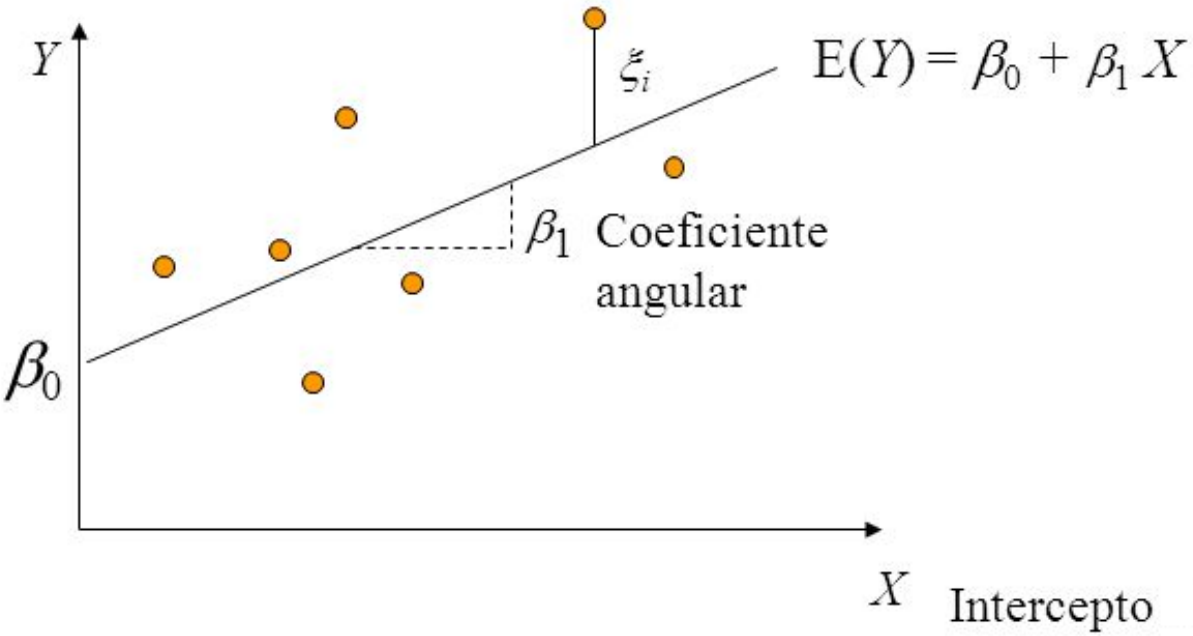

Inclinação

Intercepto

Erro Aleatório

$$Y_i = \beta_0 + \beta_1 X_i + \xi_i$$

Variável Dependente

Variável Independente

Estimadores de Mínimos Quadrados

Dadas n observações da variável $X : x_1, \ldots, x_n$, obtemos n v.a.'s $Y_1, Y_2, \ldots, Y_n$ satisfazendo a equação

$$Y_i = E(Y|X = x_i) + \mathcal{E} = \alpha + \beta x_i + \mathcal{E}_i \quad i = 1, 2 \ldots, n$$

Assumindo que as v.a.'s $\mathcal{E}_i$ são v.a's com média zero e variância σ^2.

Devemos encontrar os valores de α e β que minimizam a soma dos quadrados do erros (ou desvios ou resíduos), dados por

$$\mathcal{E}_i = y_i - (\alpha + \beta x_i)$$

Estimadores de Mínimos Quadrados

Obtemos, então, a quantidade de informação perdida pelo modelo ou soma dos quadrados dos resíduos

$$SQ(\alpha, \beta) = \sum_{i=1}^{n} \mathcal{E}_i^2 = \sum_{i=1}^{n} (y_i - \alpha - \beta x_i)^2$$

O estimador de mínimos quadrados para α e β é obtido fazendo

$$\frac{\partial SQ(\alpha, \beta)}{\partial \alpha} = 0 \quad \text{e} \quad \frac{\partial SQ(\alpha, \beta)}{\partial \beta} = 0$$

Estimadores de Mínimos Quadrados

$$
\begin{aligned}
\left.\frac{\partial SQ(\alpha,\beta)}{\partial \alpha}\right|_{\alpha=\hat{\alpha}} &= 0 \\
2\sum_{i=1}^{n}(y_i - \hat{\alpha} - \hat{\beta}x_i)(-1) &= 0 \\
\sum_{i=1}^{n} y_i - n\hat{\alpha} - \hat{\beta}\sum_{i=1}^{n} x_i &= 0 \\
-n\hat{\alpha} - \hat{\beta}\sum_{i=1}^{n} x_i &= -\sum_{i=1}^{n} y_i \\
\hat{\alpha} = \frac{\sum_{i=1}^{n} y_i - \hat{\beta}\sum_{i=1}^{n} x_i}{n} &\Rightarrow \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}
\end{aligned}
$$

Estimadores de Mínimos Quadrados

$$
\begin{aligned}
\left.\frac{\partial SQ(\alpha,\beta)}{\partial \beta}\right|_{\beta=\hat{\beta}} &= 0 \\
2\sum_{i=1}^{n}(y_i - \hat{\alpha} - \hat{\beta}x_i)(-x_i) &= 0 \\
\sum_{i=1}^{n} x_i y_i - \hat{\alpha}\sum_{i=1}^{n} x_i - \hat{\beta}\sum_{i=1}^{n} x_i^2 &= 0 \\
-\hat{\alpha}\sum_{i=1}^{n} x_i - \hat{\beta}\sum_{i=1}^{n} x_i^2 &= -\sum_{i=1}^{n} x_i y_i \\
\hat{\beta} &= \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^{n} x_i^2 - n\bar{x}^2}
\end{aligned}
$$

Estimadores de Mínimos Quadrados

Reta de regressão estimada

$$\hat{y} = \hat{\alpha} + \hat{\beta}x$$

Definindo

$$S_{xy} = \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}, \quad S_{xx} = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2, \quad S_{yy} = \sum_{i=1}^{n} y_i^2 - n\bar{y}^2$$

Obtemos

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \quad \text{e} \quad \hat{\beta} = \frac{S_{xy}}{S_{xx}}$$

Utilizando esta notação temos que

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$$

Estimadores de Mínimos Quadrados

Ex.:(Aplicação) Um psicólogo esta investigando a existência de um relação linear entre o tempo que um indivíduo leva a reagir a um estímulo visual (Y) e a respetiva idade (X), para indivíduos com idades compreendidas no intervalo $[20, 40]$. Os resultados observados permitiram obter:

$$n = 20, \sum_{i=1}^{n} y_i = 2150, \sum_{i=1}^{n} x_i = 600, \sum_{i=1}^{n} x_i y_i = 65400,$$

$$\bar{y} = 107.50, \bar{x} = 30, \sum_{i=1}^{n} x_i^2 = 19000$$

Obtenha a equação do modelo ajustado, interprete as estimativas obtidas e estime o tempo médio de reação para um indivíduo de 25 anos.

Estimadores de Mínimos Quadrados

R.: $Sxy = 65400 - 20 \times 30 \times 107,50 = 900$

$Sxx = 19000 - 20 \times 302 = 1000$

logo

$\hat{\beta} = \frac{900}{1000} = 0.9$

$\hat{\alpha} = 107.50 - 0.9 \times 30 = 80.50$

Equação do Modelo Ajustado: $\hat{y}_i = 80.50 + 0.9x_i$

Interpretação $\hat{\alpha} = 80.50$, tempo de reação para um recém-nascido;

$\hat{\beta} = 0.9$, por cada ano de envelhecimento das pessoas, o tempo médio de reação aumenta 0,9 unidades.

Previsão: $\hat{y}(25) = 80.50 + 0.9 \times 25 = 103$

Estimadores de Mínimos Quadrados

Ex2: Considere o modelo de regressão escrito na forma matricial em Y representa a persistência de uma fibra e X o diâmetro dessa fibra. Obtenha a estimativa de θ pelo método de mínimos quadrados.

$$\begin{pmatrix} 3,9 \\ 4,7 \\ 5,6 \\ 5,8 \\ 7,0 \end{pmatrix} = \begin{pmatrix} 1,2 \\ 1,5 \\ 1,7 \\ 2,0 \\ 2,6 \end{pmatrix} \theta + \begin{pmatrix} \mathcal{E}_1 \\ \mathcal{E}_2 \\ \mathcal{E}_3 \\ \mathcal{E}_4 \\ \mathcal{E}_5 \end{pmatrix}$$

Estimadores de Mínimos Quadrados

Modelo: $y_i = x_i\theta + \mathcal{E}_i \quad i = 1, 2, \ldots, 5$

$$\begin{aligned} \mathcal{E}_i &= y_i - x_i\theta \\ SQ(\theta) &= \sum_{i=1}^{5} \mathcal{E}_i^2 \\ &= \sum_{i=1}^{5} (y_i - x_i\theta)^2 \end{aligned}$$

Estimadores de Mínimos Quadrados

Primeiramente, vamos obter o estimador de mínimos quadrados para θ

$$
\begin{aligned}
\frac{dSQ(\theta)}{d\theta} &= 0 \\
2\sum_{i=1}^{5}(y_i - x_i\hat{\theta})(-x_i) &= 0 \\
\sum_{i=1}^{5} x_i y_i - \hat{\theta}\sum_{i=1}^{5} x_i^2 &= 0 \\
\hat{\theta} &= \frac{\sum_{i=1}^{5} x_i y_i}{\sum_{i=1}^{5} x_i^2}
\end{aligned}
$$

Estimadores de Mínimos Quadrados

A estimativa para θ é

$$\hat{\theta} = \frac{3,9(1,2) + 4,7(1,5) + 5,6(1,7) + 5,8(2) + 7(2,6)}{1,2^2 + 1,5^2 + 1,7^2 + 2^2 + 2,6^2} = \frac{51,05}{17,34} = 2,94$$

logo,

Equação do Modelo Ajustado: $\hat{y}_i = 2.94x_i$

Estimadores de Máxima Verossimilhança

Seja X uma v.a. com f.m.p (ou f.d.p) $p_X(x;\theta)$ (ou $f_X(x;\theta)$), em que θ é o parâmetro, tal que $\theta \in \Theta \subseteq I\!R$. Considere $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma a.a. da v.a. X e $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$ a amostra observada ou vetor de observações de $\boldsymbol{X}$.

A f.d.p (ou f.m.p) conjunta é dada por

$$f_{\boldsymbol{X}}(x_1, \ldots, x_n) = \prod_{i=1}^{n} f_{X_i}(x_i;\theta) = \prod_{i=1}^{n} f_X(x_i;\theta)$$

ou

$$p_{\boldsymbol{X}}(x_1, \ldots, x_n) = \prod_{i=1}^{n} p_{X_i}(x_i;\theta) = \prod_{i=1}^{n} p_X(x_i;\theta)$$

Estimadores de Máxima Verossimilhança

Definição: Seja $X_1, \ldots, X_n$ uma a.a. da v.a. X. A função de verossimilhança $L(\theta; \boldsymbol{x})$ é definida por

$$L(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} f_{\mathrm{X}}(x_i; \theta)$$

ou

$$L(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} p_{\mathrm{X}}(x_i; \theta)$$

que deve ser considerada como uma função de θ.

Estimadores de Máxima Verossimilhança

Interpretação: Podemos interpretar $L(\theta, \boldsymbol{x})$ como uma medida de plausibilidade de θ ter produzido o vetor de observações $\boldsymbol{x}$, com a suposta f.m.p ou f.d.p.

Estimadores de Máxima Verossimilhança

Definição: O estimador de máxima verossimilhança de θ, denotador por $\hat{\theta}$, é o valor que maximiza $L(\theta, \boldsymbol{x})$.

Em alguns casos podemos obter o máximo de $L(\theta; \boldsymbol{x})$ fazendo

$$\frac{dL(\theta; \boldsymbol{x})}{d\theta} = 0$$

e verificando se

$$\left.\frac{d^2L(\theta; \boldsymbol{x})}{d\theta^2}\right|_{\theta=\hat{\theta}(\boldsymbol{x})} < 0$$

Estimadores de Máxima Verossimilhança

Definição: A função log-verossimilhança $l(\theta, \boldsymbol{x})$ é definida pelo logaritmo natural de $L(\theta; \boldsymbol{x})$:

$$l(\theta, \boldsymbol{x}) = \log_e(L(\theta; \boldsymbol{x}))$$

Maximizar $L(\theta, \boldsymbol{x})$ é equivalente a maximizar $l(\theta, \boldsymbol{x})$, o que quase sempre é mais simples. Assim, se $\hat{\theta}$ existe ele também deve satisfazer a equação de verossimilhança

$$\frac{dl(\theta; \boldsymbol{x})}{d\theta} = 0$$

OBS.: Em estatística "log" é a notação usual para "ln".

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Exponencial com parâmetro λ, $\lambda > 0$. Encontrar o estimador de máxima verossimilhança para λ.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Exponencial com parâmetro λ, $\lambda > 0$. Encontrar o estimador de máxima verossimilhança para λ.

A f.d.p. de X é $f_X(x;\lambda) = \lambda e^{-\lambda x}, \quad x \geq 0$ e $\lambda > 0$

A função de verossimilhança associada ao vetor de observações $\boldsymbol{x}$ da a.a. $\boldsymbol{X}$é

$$L(\lambda, \boldsymbol{x}) = \prod_{i=1}^{n} \{f_X(x_i;\lambda)\} = \prod_{i=1}^{n} \left\{\lambda e^{-\lambda x_i}\right\} = \lambda^n e^{-\lambda \sum_{i=1}^{n} x_i}$$

A função log-verossimilhança é

$$l(\theta; \boldsymbol{x}) = ln(\lambda^n e^{-\lambda \sum_{i=1}^{n} x_i}) = nln(\lambda) - \lambda \sum_{i=1}^{n} x_i$$

Estimadores de Máxima Verossimilhança

O estimador de máxima verossimilhança de λ é obtido buscando a solução em

$$
\begin{aligned}
\frac{dl(\lambda, \boldsymbol{x})}{d\lambda} &= 0 \\
\frac{n}{\lambda} - \sum_{i=1}^{n} x_i &= 0 \\
\frac{n}{\lambda} &= \sum_{i=1}^{n} x_i \\
\hat{\lambda} &= \frac{n}{\sum_{i=1}^{n} x_i} = \bar{X}^{-1}
\end{aligned}
$$

Estimadores de Máxima Verossimilhança

Verificando se $\hat{\lambda}$ é um ponto de máximo

$$\begin{aligned} \left.\frac{d^2 l(\lambda, \boldsymbol{x})}{d\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} &< 0 \\ \left.\frac{-n}{\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} = \frac{-n}{(1/\bar{x})^2} &< 0 \end{aligned}$$

Portanto, $\hat{\lambda} = \bar{X}^{-1}$ é o estimador de máxima verossimilhança para λ.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Poisson com parâmetro $\lambda > 0$. Encontrar o estimador de máxima de verossimilhança para λ.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Poisson com parâmetro $\lambda > 0$. Encontrar o estimador de máxima de verossimilhança para λ.

A f.m.p de X é

$$p_X(x; \lambda) = \frac{e^{-\lambda}\lambda^x}{x!}, \quad x = 0, 1, 2 \ldots \text{ e } \lambda > 0$$

A função de verossimilhança associada ao vetor de observações $\boldsymbol{x}$ da a.a. $\boldsymbol{X}$ é

$$L(\lambda, \boldsymbol{X}) = \prod_{i=1}^{n} \{p_X(x_i; \lambda)\} = \prod_{i=1}^{n} \left\{ \frac{e^{-\lambda}\lambda^{x_i}}{x_i!} \right\}$$

Estimadores de Máxima Verossimilhança

A função log-verossimilhança é

$$l(\lambda, \boldsymbol{x}) = ln\left(\prod_{i=1}^{n}\left\{\frac{e^{-\lambda}\lambda^{x_i}}{x_i!}\right\}\right) = -n\lambda + \sum_{i=1}^{n} x_i \ln(\lambda) - \sum_{i=1}^{n} \log(x_i!)$$

O estimador de máxima verossimilhança de λ é obtido buscando a solução em

$$\begin{aligned}
\frac{dl(\lambda, \boldsymbol{x})}{d\lambda} &= 0 \\
-n + \frac{\sum_{i=1}^{n} x_i}{\hat{\lambda}} &= 0 \\
\hat{\lambda} &= \frac{\sum_{i=1}^{n} x_i}{n} = \bar{x}
\end{aligned}$$

Estimadores de Máxima Verossimilhança

Verificando se $\hat{\lambda}$ é um ponto de máximo

$$\begin{aligned} \left.\frac{d^2 l(\lambda, \boldsymbol{x})}{d\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} &< 0 \\ \left.-\frac{\sum_{i=1}^{n} x_i}{\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} = -\frac{\sum_{i=1}^{n} x_i}{\bar{x}^2} &< 0 \end{aligned}$$

Portanto, o estimador de máxima verossimilhança para λ é

$$\hat{\lambda} = \frac{\sum_{i=1}^{n} X_i}{n} = \bar{X}$$

Estimadores de Máxima Verossimilhança

Propriedade:(Invariância) Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a da v.a. X com f.m.p. $p_X(x;\theta)$ ou f.d.p. $f_X(x;\theta)$. Se $\hat{\theta}$ é o estimador de máxima verossimilhança de θ, então $g(\hat{\theta})$ é o estimador de máxima verossimilhança de $g(\theta)$.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de tamanho n da v.a. X com distribuição Poisson com parâmetro θ. Encontre o estimador de máxima verossimilhança para $P(X = 0)$.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de tamanho n da v.a. X com distribuição Poisson com parâmetro θ. Encontre o estimador de máxima verossimilhança para $P(X = 0)$.

Já sabemos que o EMV de θ é $\bar{X}$, $\hat{\theta} = \bar{X}$.

Queremos o EMV para

$$g(\theta) = P(X = 0) = e^{-\theta}$$

Então, $g(\hat{\theta}) = e^{-\hat{\theta}} = e^{-\bar{x}}$ propriedade da invariância.

Propriedades dos Estimadores

Consideremos uma a.a. $\boldsymbol{X} = (X_1, \ldots, X_n)$ da v.a. X que descreve uma característica de interesse de uma população. Seja θ o parâmetro de interesse que desejamos estimar e $T(\boldsymbol{X}) = T(X_1, \ldots, X_n)$ um estimador para este parâmetro.

Vício (viés)

Def.: O vício de um estimador $T(\boldsymbol{X})$ é a diferença entre $E(T(\boldsymbol{X}))$ e θ

$$\mathcal{B}_\theta(T(\boldsymbol{X})) = E(T(\boldsymbol{X})) - \theta$$

Um estimador $T(\boldsymbol{X})$ é definido ser um estimador não-viciado (ou não-viesado) de θ se $\mathcal{B}_\theta(T(\boldsymbol{X})) = 0$, ou seja:

$$E(T(\boldsymbol{X})) = \theta,$$

para todo θ.

Vicio (viés)

Def.: Um estimador viciado de $T(\boldsymbol{X})$ de θ é dito assintoticamente não-viciado se

$$\lim_{n\to\infty} \mathcal{B}_\theta(T(\boldsymbol{X})) = 0$$

Erro quadrático médio

Def.: O erro quadrático médio de um estimador $T(\boldsymbol{X})$ de θ é definido por

$$EQM_\theta(T(\boldsymbol{X})) = E\left((T(\boldsymbol{X}) - \theta)^2\right)$$

que é uma medida de desempenho razoável para um estimador.

O EQM pode ser determinado pela média e variância de $T(\boldsymbol{X})$:

$$EQM_\theta(T(\boldsymbol{X})) = Var(T(\boldsymbol{X})) + \{\mathcal{B}_\theta(T(\boldsymbol{X}))\}^2$$

Erro quadrático médio

Demonstração:

$$
\begin{aligned}
EQM_\theta(T(\boldsymbol{X})) &= E(T^2(\boldsymbol{X}) - 2\theta T(\boldsymbol{X}) + \theta^2) \\
&= E(T^2(\boldsymbol{X})) - \{E(T(\boldsymbol{X}))\}^2 + \{E(T(\boldsymbol{X}))\}^2 - 2\theta E(T(\boldsymbol{X})) \\
&+ \theta^2 \\
&= Var(T(\boldsymbol{X})) + \{E(T(\boldsymbol{X})) - \theta\}^2 \\
&= Var(T(\boldsymbol{X})) + \{\mathcal{B}_\theta(T(\boldsymbol{X}))\}^2
\end{aligned}
$$

Consistência

Def.: Seja $\{T_n(\boldsymbol{X})\}_{n\geq 1}$ uma sequência de estimadores de θ. A sequência $\{T_n(\boldsymbol{X})\}_{n\geq 1}$ é definida ser uma sequência consistente de estimadores de θ se, para todo $\epsilon > 0$, satisfaz:

$$\lim_{n\to\infty} P\left(|T_n(\boldsymbol{X}) - \theta| \geq \epsilon\right) = 0$$

Consistência

Proposição: uma sequência $\{T_n(\boldsymbol{X})\}_{n\geq 1}$ de estimadores de θ é consistente se

$$\lim_{n\to\infty} E(T(\boldsymbol{X})) = \theta$$

e

$$\lim_{n\to\infty} Var(T(\boldsymbol{X})) = 0$$

Exemplo

Exemplo: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição $\mathcal{N}(\mu, \sigma^2)$. Considere os estimadores de μ e σ^2, respectivamente, $\hat{\mu} = \bar{X}$ e $\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}$. Calcule os vícios para estes estimadores.

Exemplo

Exemplo: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição $\mathcal{N}(\mu, \sigma^2)$. Considere os estimadores de μ e σ^2, respectivamente, $\hat{\mu} = \bar{X}$ e $\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}$. Calcule os vícios para estes estimadores.

Para a média

$$\mathcal{B}_\theta(\hat{\mu}) = E(\bar{X}) - \mu = E\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) - \mu = \frac{1}{n} n\mu - \mu = 0$$

Exemplo

Para a variância

$$
\begin{aligned}
\mathcal{B}_\theta(\hat{\sigma}^2) &= E\left(\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}\right) - \sigma^2 \\
&= \frac{1}{n}E\left(\sum_{i=1}^{n} X_i^2 - 2\bar{X}\sum_{i=1}^{n} X_i + n\bar{X}^2\right) - \sigma^2 \\
&= \frac{1}{n}\left\{\sum_{i=1}^{n} E(X_i^2)\right\} - 2E(\bar{X}^2) + E(\bar{X}^2) - \sigma^2 \\
&= \frac{1}{n}\left\{\sum_{i=1}^{n} E(X_i^2)\right\} - E(\bar{X}^2) - \sigma^2
\end{aligned}
$$

Exemplo

Sabemos que $Var(X_i) = E({X_i}^2) - \{E(X_i)\}^2$e $Var(\bar{X}) = E(\bar{X}^2) - \{E(\bar{X})\}^2$. Logo, $E({X_i}^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Portanto,

$$\begin{aligned}
\mathcal{B}_\theta(\hat{\sigma}^2) &= \frac{1}{n}\left\{\sum_{i=1}^{n}(\sigma^2 + \mu^2)\right\} - \frac{\sigma^2}{n} - \mu^2 - \sigma^2 \\
&= \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2 - \sigma^2 \\
&= -\frac{\sigma^2}{n}
\end{aligned}$$

Verificando o vício assintoticamente:

$$\lim_{n\to\infty} \mathcal{B}_{\sigma^2}(\hat{\sigma}^2) = \lim_{n\to\infty} -\frac{\sigma^2}{n} = -\sigma^2 \lim_{n\to\infty} \frac{1}{n} = 0$$

Dessa forma, $\hat{\sigma}^2$ é um estimador assintoticamente não-viciado.

Exemplo

Observação: O cálculo do vício de um estimador pode ser usado para sugerir novos estimadores. Por exemplo, considere o estimador $\hat{\sigma}^2$ de σ^2, cujo vício é $-\frac{\sigma^2}{n}$. Um novo estimador não-viciado, pode ser obtido por

$$\begin{aligned}
\mathcal{B}_\theta(\hat{\sigma}^2) &= E(\hat{\sigma}^2) - \sigma^2 \\
E(\hat{\sigma}^2) &= -\frac{\sigma^2}{n} + \sigma^2 \\
&= \frac{\sigma^2(n-1)}{n}
\end{aligned}$$

Exemplo

Com isso temos um novo estimador, S^2, definido por

$$
\begin{aligned}
E\left(\frac{n}{n-1}\hat{\sigma}^2\right) &= \sigma^2 \\
S^2 &= \frac{n\hat{\sigma}^2}{n-1} = \frac{n}{n-1}\sum_{i=1}^{n}\frac{(X_i-\bar{X})^2}{n} \\
&= \frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{n-1}
\end{aligned}
$$

Isso implica que $E(S^2) = \sigma^2$ e, consequentemente, $\mathcal{B}_{\sigma^2}(S^2) = 0$.

Exemplo

Exemplo: Considere o estimador S^2 para σ^2. Calcule o seu EQM e verifique se este estimador é consistente. Utilize o seguinte resultado

$$\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1},$$

$E(Y) = n - 1$ e $Var(Y) = 2(n-1)$

Exemplo

Para $S^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}$ temos que

$$
\begin{aligned}
EQM_{\sigma^2}(S^2) &= Var(S^2) + \{\mathcal{B}_{\sigma^2}(S^2)\}^2 \\
&= Var\left(\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}\right) \\
&= Var\left(\frac{\sigma^2 \sum_{i=1}^{n}(X_i - \bar{X})^2}{\sigma^2(n-1)}\right) \\
&= \frac{\sigma^4}{(n-1)^2} 2(n-1) \\
&= \frac{2\sigma^4}{n-1}
\end{aligned}
$$

Exemplo

Para verificar se S^2 é consistente temos que verificar que

$$\lim_{n\to\infty} E(S^2) = \sigma^2 \quad \text{e} \quad \lim_{n\to\infty} Var(S^2) = 0$$

Logo,

$$\begin{aligned}
\lim_{n\to\infty} E(S^2) &= \lim_{n\to\infty} E\left(\frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{n-1}\right) = \lim_{n\to\infty} E\left(\frac{\sigma^2\sum_{i=1}^{n}(X_i-\bar{X})^2}{\sigma^2(n-1)}\right) \\
&= \lim_{n\to\infty} \frac{\sigma^2}{n-1} E\left(\frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{\sigma^2}\right) = \lim_{n\to\infty} \frac{\sigma^2}{n-1}(n-1) \\
&= \sigma^2
\end{aligned}$$

Exemplo

$$
\begin{aligned}
\lim_{n\to\infty} Var(S^2) &= \lim_{n\to\infty} \frac{2\sigma^4}{n-1} \\
&= 2\sigma^4 \lim_{n\to\infty} \frac{1}{n-1} \\
&= 0
\end{aligned}
$$

Logo, S^2 é consistente.