Inferência Estatística

Cleber Martins Xavier
Universidade Federal de Sergipe

Universidade Federal de Sergipe

Introdução à Inferência

Objetivo:

Produzir informações sobre dada característica da população na qual estamos interessados, a partir de informações colhidas de uma parte dessa população (amostra).

$$\boxed{\boxed{\text{Característica: Variável aleatória}}}$$

$$\begin{aligned} X &: \Omega \to \mathbb{R} \\ X &: f_X(x;\theta) \to \text{ modelo estatístico} \end{aligned}$$

Se tivéssemos a informação completa sobre a f.m.p ou a f.d.p da variável em questão, não teríamos necessidade de coletar uma amostra, uma vez que toda a informação desejada seria obtida por meio da distribuição variável.

Situação prática: θ é desconhecido

Interesse: Estimar θ (Métodos de estimação pontual)

Introdução à Inferência Estatística

Para isso, considere uma a.a. de X:

$$\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$$

Cada X_i é independente e tem a mesma distribuição de X. Associada a uma a.a. de $\boldsymbol{X}$, temos o vetor de observações:

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_n).$$

Com base na a.a. podemos obter uma estatística ou estimador que é função da a.a.

$$T = T(X_1, X_2, \ldots, X_n)$$

As estatísticas mais comuns são:

- Média Amostral: $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$;
- Variância amostral: $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$;
- Menor valor da amostra: $X_{(1)} = \min(X_1, \ldots, X_n)$;
- Maior valor da amostra: $X_{(n)} = \max(X_1, \ldots, X_n)$;

Problema da inferência estatística: Fazer uma afirmação sobre os parâmetros da população através da amostra.

Nossa decisão será baseada na estatística T. Colhida uma amostra observada, $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$, teremos observado um particular valor de T, dito t. Baseado nesse valor t é que faremos afirmação sobre θ, o parâmetro populacional.

A validade da nossa resposta seria melhor compreendida se soubéssemos o que acontece com a estatística T, quando retiramos todas as amostras de uma população conhecida.

Isto é, qual a distribuição de T quando $(X_1, \ldots, X_n)$ assume todos os possíveis valores.

Essa distribuição é chamada de distribuição amostral da estatística T. Vale ressaltar que a distribuição de T irá depender da distribuição de X.

Seguindo essa ideia, iremos estudar distribuições amostrais de algumas estatísticas importantes.

Distribuição Amostral da Média

Considere uma v.a. X, cujos parâmetros média e variância populacional são, respectivamente, $\mu = E(X)$ e $\sigma^2 = Var(X)$.

Vamos retirar todas a possíveis amostras de tamanho n dessa população e, para cada uma, calcular a média $\bar{X}$.

Em seguida, consideremos a distribuição amostral de $\bar{X}$ e estudaremos suas propriedades.

Distribuição Amostral da Média

Teorema: Seja X uma v.a. com média μ e variância σ^2 e seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de X. Então,

$$E(\bar{X}) = \mu \quad \text{e} \quad Var(\bar{X}) = \frac{\sigma^2}{n}.$$

Distribuição Amostral da Média

Teorema: Seja X uma v.a. com média μ e variância σ^2 e seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de X. Então,

$$E(\bar{X}) = \mu \quad \text{e} \quad Var(\bar{X}) = \frac{\sigma^2}{n}.$$

Prova: $E(\bar{X}) = E\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \frac{1}{n}\sum_{i=1}^{n} \mu = \frac{1}{n} n\mu = \mu$

$Var(\bar{X}) = Var\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) = \frac{1}{n^2}\sum_{i=1}^{n} Var(X_i) = \frac{1}{n^2}\sum_{i=1}^{n} \sigma^2 = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$

Distribuição Amostral da Média

O que acontece com a distribuição de $\bar{X}$ quando aumentamos o tamanho da amostra (n)?

$$\begin{aligned} E(\bar{X}) = E(X) &= \mu \\ Var(\bar{X}) = \frac{\sigma^2}{n} &\rightarrow 0 \text{ (diminui)} \end{aligned}$$

Este Resultado é conhecido como **Teorema Central do Limite (TCL)**.

Distribuição Amostral da Média

Teorema: Para amostras aleatórias (a.a.), retiradas de uma população com média μ e variância σ^2 finita, a distribuição amostral da média aproxima-se, para n grande, de uma distribuição normal com média μ e variância σ^2/n

$$\bar{X} \sim Normal\left(\mu, \frac{\sigma^2}{n}\right)$$

Padronizando, obtemos:

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim Normal(0, 1).$$

Distribuição Amostral da Média

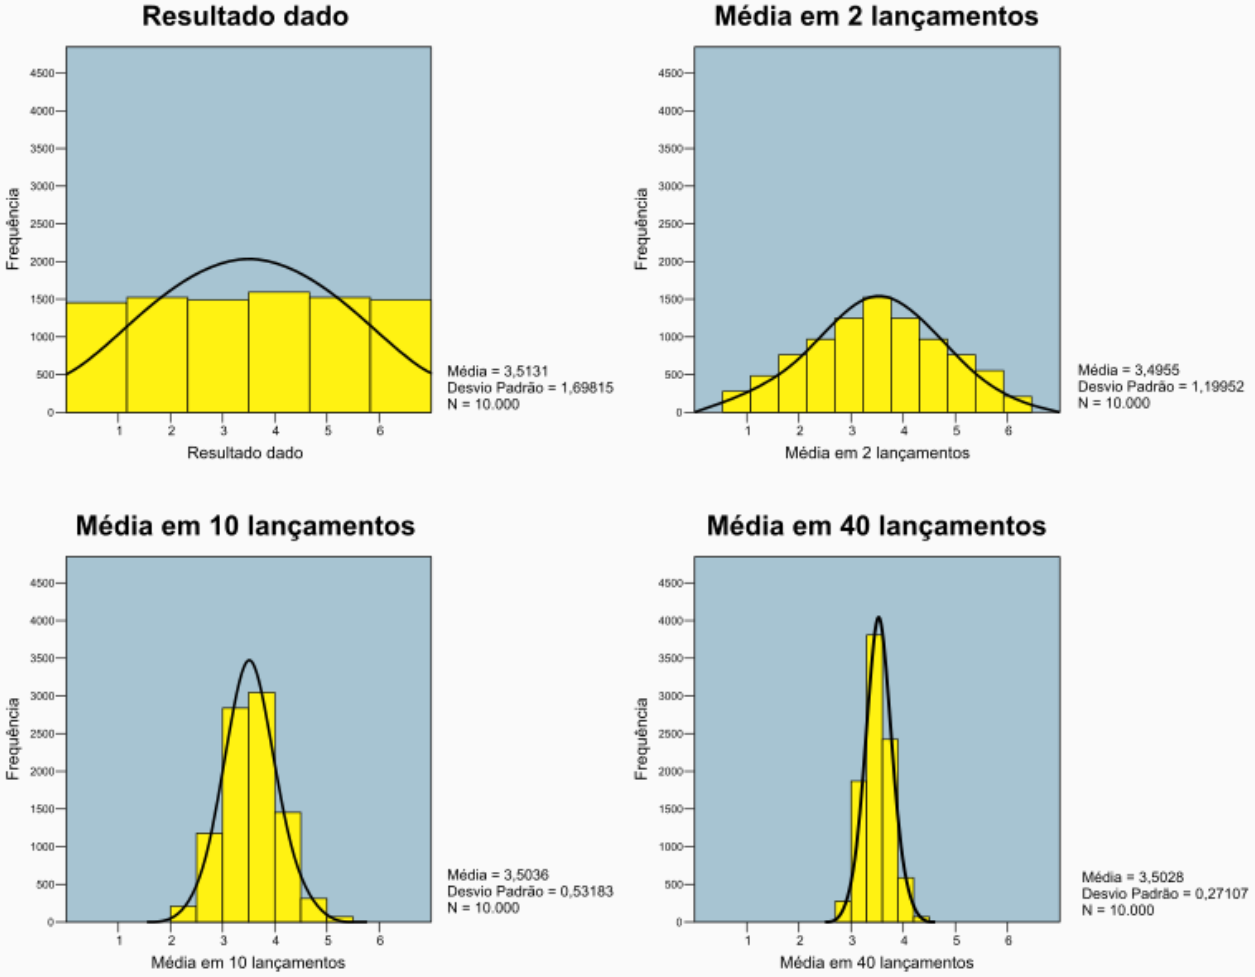

Distribuição Amostral da Média

Ex.: Uma v.a. X tem distribuição normal com média 10 e desvio padrão 3.

a) Se $\bar{X}$ for a média de uma amostra de 25 elementos retirados dessa população, calcule $P(9 < \bar{X} < 11)$.

Distribuição Amostral da Média

Ex.: Uma v.a. X tem distribuição normal com média 10 e desvio padrão 3.

a) Se $\bar{X}$ for a média de uma amostra de 25 elementos retirados dessa população, calcule $P(9 < \bar{X} < 11)$.

R.:

$$X \sim \mathcal{N}(10, 3^2) \Longleftrightarrow \bar{X} \sim \mathcal{N}\left(10, \frac{3^2}{n}\right)$$

$P(9 < \bar{X} < 11) = P\left(\frac{9-10}{3/5} < Z < \frac{11-10}{3/5}\right) = P(-1,67 < Z < 1,67) = 0,905$

b) Que tamanho deveria ter a amostra para que $P(9 < \bar{X} < 11) = 0.95$?

Distribuição Amostral da Média

Ex.: Uma v.a. X tem distribuição normal com média 10 e desvio padrão 3.

a) Se $\bar{X}$ for a média de uma amostra de 25 elementos retirados dessa população, calcule $P(9 < \bar{X} < 11)$.

R.:

$$X \sim \mathcal{N}(10, 3^2) \Longleftrightarrow \bar{X} \sim \mathcal{N}\left(10, \frac{3^2}{n}\right)$$

$P(9 < \bar{X} < 11) = P\left(\frac{9-10}{3/5} < Z < \frac{11-10}{3/5}\right) = P(-1,67 < Z < 1,67) = 0,905$

b) Que tamanho deveria ter a amostra para que $P(9 < \bar{X} < 11) = 0.95$?

R.: $P(9 < \bar{X} < 11) = P\left(\frac{9-10}{3/\sqrt{n}} < Z < \frac{11-10}{3/\sqrt{n}}\right) = P\left(\frac{-\sqrt{n}}{3} < Z < \frac{\sqrt{n}}{3}\right) = 0,95 \Leftrightarrow 2P(0 < Z < \sqrt{n}/3) = 0,95 \Rightarrow P(Z < \sqrt{n}/3) - P(Z < 0) = 0,475 \Leftrightarrow P(Z < \sqrt{n}/3) = 0,975$

Distribuição Amostral da Média

Table of Standard Normal Probabilities for Positive Z-scores

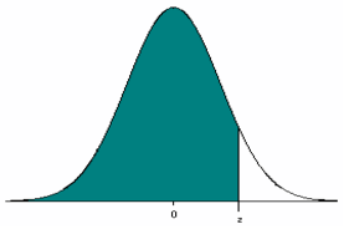

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	$\boxed{0.9750}$	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890

$$P\left(Z < \frac{\sqrt{n}}{3}\right) = 0.975 \Rightarrow \frac{\sqrt{n}}{3} = 1,96 \Rightarrow \sqrt{n} = 1,96 \times 3 \Rightarrow n \approx 35$$

Distribuição Amostral da Proporção

Seja X uma v.a. definida da seguinte maneira:

$$X = \begin{cases} 1, & \text{se ocorrer o sucesso (interesse)} \\ 0, & \text{se ocorrer o fracasso} \end{cases}$$

Logo, $\mu = E(X) = p$ e $\sigma^2 = Var(X) = p(1-p)$.

Considere uma a.a. $\boldsymbol{X} = (X_1, \ldots, X_n)$ da v.a. X e o interesse é a proporção $\hat{p}$ de indivíduos/elementos que possui a característica na amostra (sucesso). Isto é,

$$\hat{p} = \frac{\sum_{i=1}^{n} X_i}{n} = \bar{X}$$

Distribuição Amostral da Proporção

Observe que cada $X_i, \quad i = 1, \ldots, n$ tem distribuição Bernoulli com $\mu = E(X_i) = p$ e $\sigma^2 = Var(X_i) = p(1-p)$ e são independentes.

Pelo TCL, $\hat{p}$ (ou $\bar{X}$) terá distribuição aproximadamente Normal com média p e variância $\frac{p(1-p)}{n}$, ou seja,

$$\hat{p} \sim \mathcal{N}\left(p, \frac{p(1-p)}{n}\right) \Longleftrightarrow Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1)$$

Distribuição Amostral da Proporção

Ex.: Um procedimento de controle de qualidade foi planejado para garantir um máximo de 10% de itens defeituosos na produção. Supondo que a produção esteja sob controle ($p = 10\%$) e que os itens sejam vendidos em caixas com 100 unidades, qual a probabilidade de que uma caixa tenha mais do que 10% de defeituosos ?

Distribuição Amostral da Proporção

Ex.: Um procedimento de controle de qualidade foi planejado para garantir um máximo de 10% de itens defeituosos na produção. Supondo que a produção esteja sob controle ($p = 10\%$) e que os itens sejam vendidos em caixas com 100 unidades, qual a probabilidade de que uma caixa tenha mais do que 10% de defeituosos ?

$$X \sim Bernoulli(p) \Rightarrow E(X) = p \text{ e } Var(X) = p(1-p)$$

Sabemos que $\hat{p} = \bar{X} \sim \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$. Logo

$$\begin{aligned} P\left(\sum_{i=1}^{n} X_i > 10\right) &= P(\bar{X} > 0,10) = P(\hat{p} > 0,10) \\ &= P\left(Z > \frac{0,10 - 0,10}{\sqrt{\frac{0,1(0,9)}{100}}}\right) = P(Z > 0) = 0,5 \end{aligned}$$

Estimação Pontual

Estimação pontual

Um dos problemas em inferência estatística é como obter um estimador de determinado parâmetro populacional. A seguir discutiremos alguns métodos de obtenção de estimadores.

Estimadores de Mínimos Quadrados

Seja Y uma v.a. e $Y_1, Y_2, \ldots, Y_n$ n realizações independentes de Y. Suponha que podemos escrever as observações da forma

$$Y_i = g_i(\theta_1, \ldots, \theta_k) + \mathcal{E}_i, \quad i = 1, 2, \ldots, n$$

em que g_i são funções conhecidas, $\theta_1, \ldots, \theta_k$ são k parâmetros desconhecidos e de interesse e $\mathcal{E}_i$ é o erro aleatório que satisfaz as seguintes condições

- $E(\mathcal{E}_i) = 0$
- $Var(\mathcal{E}_i) = \sigma^2$
- $Cov(\mathcal{E}_i, \mathcal{E}_j) = E(\mathcal{E}_i\mathcal{E}_j) - E(\mathcal{E}_i)E(\mathcal{E}_j) = 0, \quad \forall i \neq j \quad \text{e} \quad j = 1, 2, \ldots, n$

Estimadores de Mínimos Quadrados

Para cada Y_i temos que o valor esperado é $g_i(\theta_1, \ldots, \theta_k)$, isto é,

$$\begin{aligned} E(Y_i) &= E(g_i(\theta_1, \ldots, \theta_k) + \mathcal{E}_i) \\ &= g_i(\theta_1, \ldots, \theta_k) + E(\mathcal{E}_i) \\ &= g_i(\theta_1, \ldots, \theta_k) \end{aligned}$$

Estimadores de Mínimos Quadrados

O método de mínimos quadrados afirma que devemos estimar $\theta_1, \ldots, \theta_k$ por $\hat{\theta}_1, \ldots, \hat{\theta}_k$, o qual faz o valor esperado $\hat{Y}_i = E(Y_i)$ tão perto quanto possível do ponto observado de Y_i. Isto é, se observarmos $Y_1 = y_1, Y_2 = y_2, \ldots, Y_n = y_n$, as estimativas de $\hat{\theta}_1, \ldots, \hat{\theta}_k$ (que são estimadores) devem minimizar a soma dos quadrados dos erros

$$\begin{aligned} S(\theta_1, \ldots, \theta_k) &= \sum_{i=1}^{n} \mathcal{E}_i^2 \\ &= \sum_{i=1}^{n} (Y_i - g_i(\theta_1, \ldots, \theta_k))^2 \end{aligned}$$

Estimadores de Mínimos Quadrados

Os estimadores de mínimos quadrados de $\theta_1, \ldots, \theta_k$ satisfaz as seguintes equações

$$\frac{\partial S(\theta_1, \ldots, \theta_k)}{\partial \theta_j} = 0, \quad \forall j = 1, 2, \ldots, k$$

Essas equações são conhecidas como equações normais.

OBS.: $\hat{\theta}(\boldsymbol{Y})$ estimador; $\hat{\theta}(\boldsymbol{y})$ estimativa.

Estimadores de Mínimos Quadrados

Ex.: (Modelos de Regressão)

- Em diversos problemas das áreas médicas, biológica, computacional, industrial entre outras, é de grande interesse verificar se duas ou mais variáveis estão relacionadas de alguma forma;
- Para expressar esta relação é muito importante estabelecer um modelo matemático;
- Este tipo de modelagem ajuda a entender como determinadas variáveis influenciam outra variável;

Estimadores de Mínimos Quadrados

Diagramas de dispersão que sugerem uma regressão linear entre as variáveis

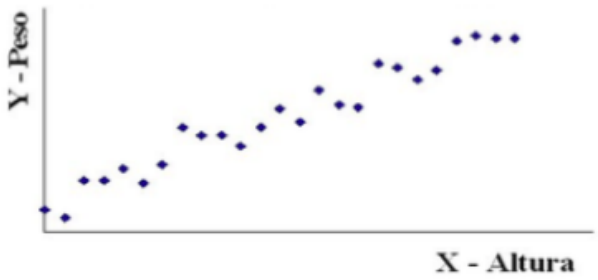

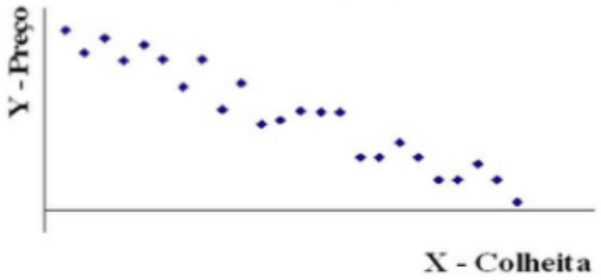

Existência de correlação positiva (em média, quanto maior for a altura maior será o peso)

Existência de correlação negativa (em média, quanto maior for for a colheita menor será o preço

Estimadores de Mínimos Quadrados

O Coeficiente de correlação linear é dada por

$$r(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}}$$

Este coeficiente é uma do grau de dependência linear entre as duas variáveis, X e Y.

- $-1 \leq r \leq 1$;
- $r = 1$: relação linear perfeita (e positiva) entre X e Y;
- $r = 0$: inexistência de relação linear entre X e Y;
- $r = -1$: relação linear perfeita (e negativa) entre X e Y;
- $r > 0$: relação linear positiva entre X e Y;
- $r < 0$: relação linear nehativa entre X e Y;

Estimadores de Mínimos Quadrados

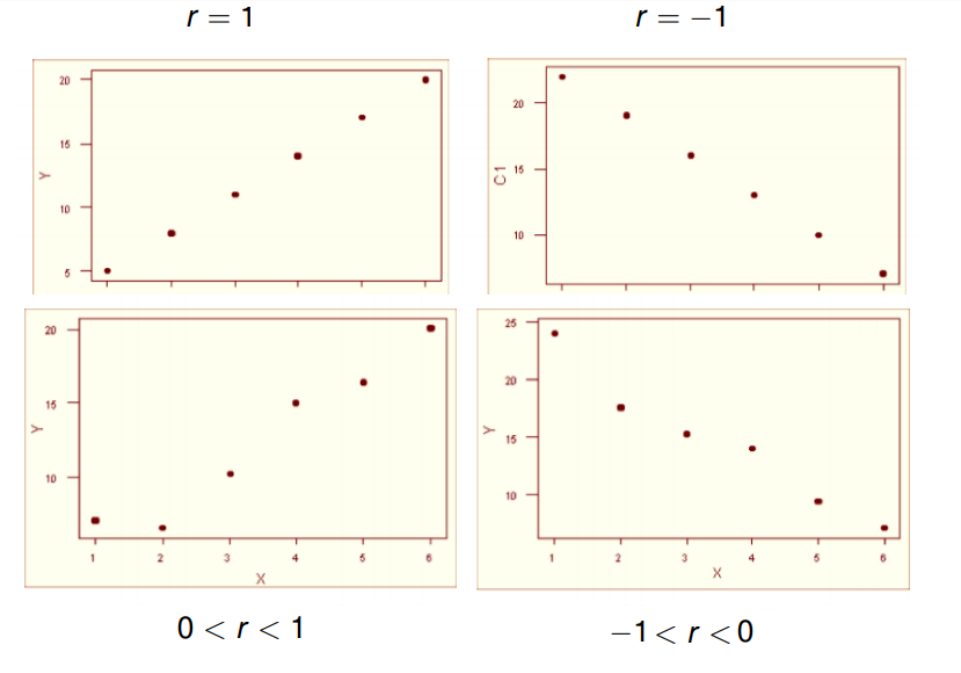

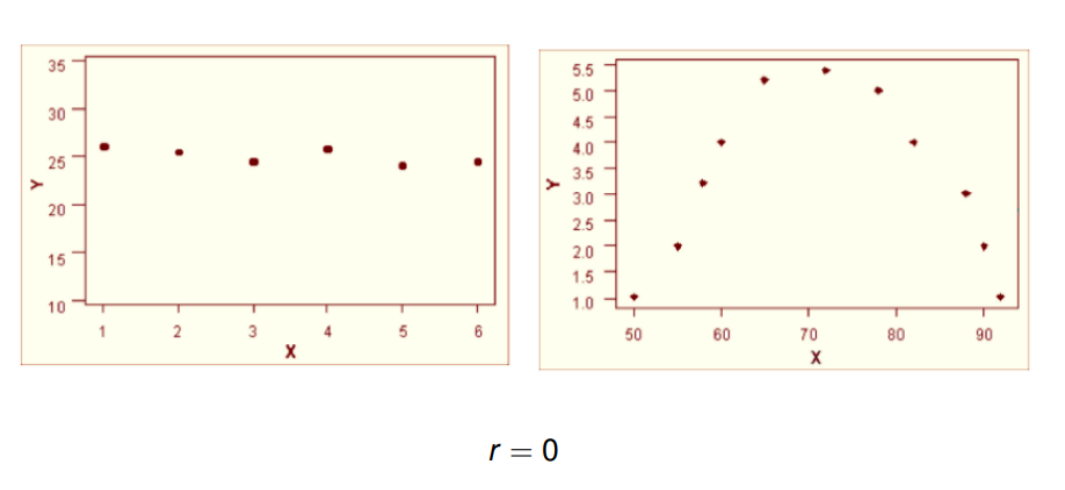

Estimadores de Mínimos Quadrados

Considere o seguinte modelo

$$Y = E(Y|X = x) + \mathcal{E} = \alpha + \beta x + \mathcal{E}$$

- Y variável dependente ou explicada;
- X variável independente ou explicativa;
- α coeficiente de regressão que representa o intercepto (parâmetro desconhecido);
- β coeficiente de regressão que representa o declive (inclinação) (parâmetro desconhecido);
- $\mathcal{E}$ erro aleatório ou estocástico;

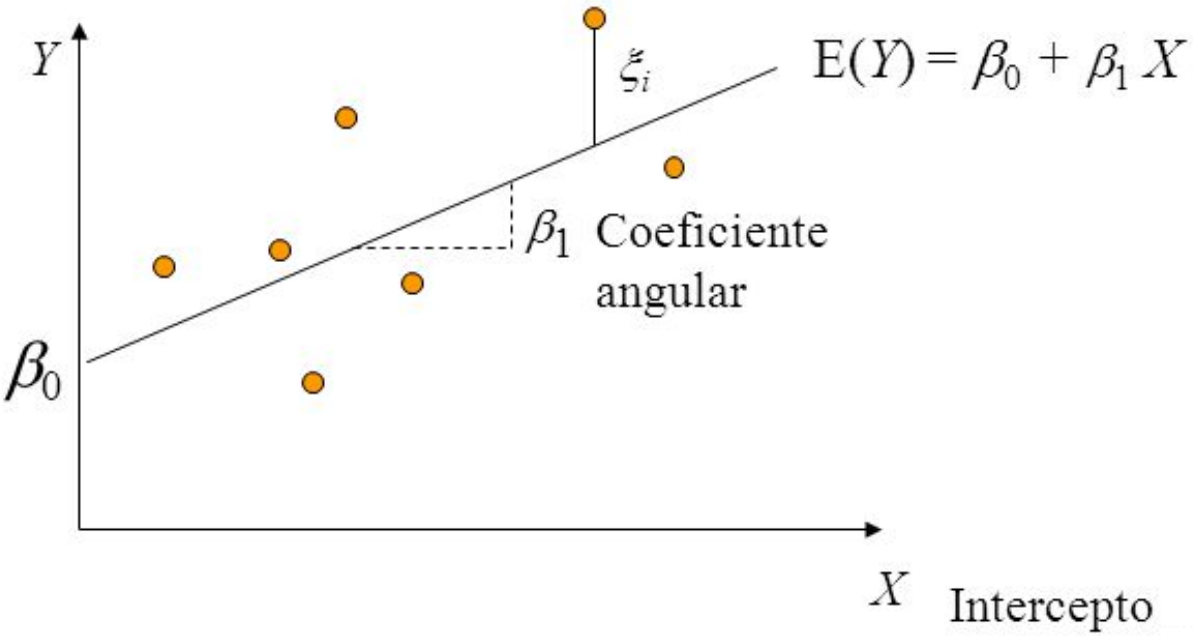

Inclinação

Intercepto

Erro Aleatório

$$Y_i = \beta_0 + \beta_1 X_i + \xi_i$$

Variável Dependente

Variável Independente

Estimadores de Mínimos Quadrados

Dadas n observações da variável $X : x_1, \ldots, x_n$, obtemos n v.a.'s $Y_1, Y_2, \ldots, Y_n$ satisfazendo a equação

$$Y_i = E(Y|X = x_i) + \mathcal{E} = \alpha + \beta x_i + \mathcal{E}_i \quad i = 1, 2 \ldots, n$$

Assumindo que as v.a.'s $\mathcal{E}_i$ são v.a's com média zero e variância σ^2.

Devemos encontrar os valores de α e β que minimizam a soma dos quadrados do erros (ou desvios ou resíduos), dados por

$$\mathcal{E}_i = y_i - (\alpha + \beta x_i)$$

Estimadores de Mínimos Quadrados

Obtemos, então, a quantidade de informação perdida pelo modelo ou soma dos quadrados dos resíduos

$$SQ(\alpha, \beta) = \sum_{i=1}^{n} \mathcal{E}_i^2 = \sum_{i=1}^{n} (y_i - \alpha - \beta x_i)^2$$

O estimador de mínimos quadrados para α e β é obtido fazendo

$$\frac{\partial SQ(\alpha, \beta)}{\partial \alpha} = 0 \quad \text{e} \quad \frac{\partial SQ(\alpha, \beta)}{\partial \beta} = 0$$

Estimadores de Mínimos Quadrados

$$
\begin{aligned}
\left.\frac{\partial SQ(\alpha,\beta)}{\partial \alpha}\right|_{\alpha=\hat{\alpha}} &= 0 \\
2\sum_{i=1}^{n}(y_i - \hat{\alpha} - \hat{\beta}x_i)(-1) &= 0 \\
\sum_{i=1}^{n} y_i - n\hat{\alpha} - \hat{\beta}\sum_{i=1}^{n} x_i &= 0 \\
-n\hat{\alpha} - \hat{\beta}\sum_{i=1}^{n} x_i &= -\sum_{i=1}^{n} y_i \\
\hat{\alpha} = \frac{\sum_{i=1}^{n} y_i - \hat{\beta}\sum_{i=1}^{n} x_i}{n} &\Rightarrow \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}
\end{aligned}
$$

Estimadores de Mínimos Quadrados

$$
\begin{aligned}
\left.\frac{\partial SQ(\alpha,\beta)}{\partial \beta}\right|_{\beta=\hat{\beta}} &= 0 \\
2\sum_{i=1}^{n}(y_i - \hat{\alpha} - \hat{\beta}x_i)(-x_i) &= 0 \\
\sum_{i=1}^{n} x_i y_i - \hat{\alpha}\sum_{i=1}^{n} x_i - \hat{\beta}\sum_{i=1}^{n} x_i^2 &= 0 \\
-\hat{\alpha}\sum_{i=1}^{n} x_i - \hat{\beta}\sum_{i=1}^{n} x_i^2 &= -\sum_{i=1}^{n} x_i y_i \\
\hat{\beta} &= \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^{n} x_i^2 - n\bar{x}^2}
\end{aligned}
$$

Estimadores de Mínimos Quadrados

Reta de regressão estimada

$$\hat{y} = \hat{\alpha} + \hat{\beta}x$$

Definindo

$$S_{xy} = \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}, \quad S_{xx} = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2, \quad S_{yy} = \sum_{i=1}^{n} y_i^2 - n\bar{y}^2$$

Obtemos

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} \quad \text{e} \quad \hat{\beta} = \frac{S_{xy}}{S_{xx}}$$

Utilizando esta notação temos que

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$$

Estimadores de Mínimos Quadrados

Ex.:(Aplicação) Um psicólogo esta investigando a existência de um relação linear entre o tempo que um indivíduo leva a reagir a um estímulo visual (Y) e a respetiva idade (X), para indivíduos com idades compreendidas no intervalo $[20, 40]$. Os resultados observados permitiram obter:

$$n = 20, \sum_{i=1}^{n} y_i = 2150, \sum_{i=1}^{n} x_i = 600, \sum_{i=1}^{n} x_i y_i = 65400,$$

$$\bar{y} = 107.50, \bar{x} = 30, \sum_{i=1}^{n} x_i^2 = 19000$$

Obtenha a equação do modelo ajustado, interprete as estimativas obtidas e estime o tempo médio de reação para um indivíduo de 25 anos.

Estimadores de Mínimos Quadrados

R.: $Sxy = 65400 - 20 \times 30 \times 107,50 = 900$

$Sxx = 19000 - 20 \times 302 = 1000$

logo

$\hat{\beta} = \frac{900}{1000} = 0.9$

$\hat{\alpha} = 107.50 - 0.9 \times 30 = 80.50$

Equação do Modelo Ajustado: $\hat{y}_i = 80.50 + 0.9x_i$

Interpretação $\hat{\alpha} = 80.50$, tempo de reação para um recém-nascido;

$\hat{\beta} = 0.9$, por cada ano de envelhecimento das pessoas, o tempo médio de reação aumenta 0,9 unidades.

Previsão: $\hat{y}(25) = 80.50 + 0.9 \times 25 = 103$

Estimadores de Mínimos Quadrados

Ex2: Considere o modelo de regressão escrito na forma matricial em Y representa a persistência de uma fibra e X o diâmetro dessa fibra. Obtenha a estimativa de θ pelo método de mínimos quadrados.

$$\begin{pmatrix} 3,9 \\ 4,7 \\ 5,6 \\ 5,8 \\ 7,0 \end{pmatrix} = \begin{pmatrix} 1,2 \\ 1,5 \\ 1,7 \\ 2,0 \\ 2,6 \end{pmatrix} \theta + \begin{pmatrix} \mathcal{E}_1 \\ \mathcal{E}_2 \\ \mathcal{E}_3 \\ \mathcal{E}_4 \\ \mathcal{E}_5 \end{pmatrix}$$

Estimadores de Mínimos Quadrados

Modelo: $y_i = x_i\theta + \mathcal{E}_i \quad i = 1, 2, \ldots, 5$

$$\begin{aligned} \mathcal{E}_i &= y_i - x_i\theta \\ SQ(\theta) &= \sum_{i=1}^{5} \mathcal{E}_i^2 \\ &= \sum_{i=1}^{5} (y_i - x_i\theta)^2 \end{aligned}$$

Estimadores de Mínimos Quadrados

Primeiramente, vamos obter o estimador de mínimos quadrados para θ

$$
\begin{aligned}
\frac{dSQ(\theta)}{d\theta} &= 0 \\
2\sum_{i=1}^{5}(y_i - x_i\hat{\theta})(-x_i) &= 0 \\
\sum_{i=1}^{5} x_i y_i - \hat{\theta}\sum_{i=1}^{5} x_i^2 &= 0 \\
\hat{\theta} &= \frac{\sum_{i=1}^{5} x_i y_i}{\sum_{i=1}^{5} x_i^2}
\end{aligned}
$$

Estimadores de Mínimos Quadrados

A estimativa para θ é

$$\hat{\theta} = \frac{3,9(1,2) + 4,7(1,5) + 5,6(1,7) + 5,8(2) + 7(2,6)}{1,2^2 + 1,5^2 + 1,7^2 + 2^2 + 2,6^2} = \frac{51,05}{17,34} = 2,94$$

logo,

Equação do Modelo Ajustado: $\hat{y}_i = 2.94x_i$

Estimadores de Máxima Verossimilhança

Seja X uma v.a. com f.m.p (ou f.d.p) $p_X(x;\theta)$ (ou $f_X(x;\theta)$), em que θ é o parâmetro, tal que $\theta \in \Theta \subseteq I\!R$. Considere $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma a.a. da v.a. X e $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$ a amostra observada ou vetor de observações de $\boldsymbol{X}$.

A f.d.p (ou f.m.p) conjunta é dada por

$$f_{\boldsymbol{X}}(x_1, \ldots, x_n) = \prod_{i=1}^{n} f_{X_i}(x_i;\theta) = \prod_{i=1}^{n} f_X(x_i;\theta)$$

ou

$$p_{\boldsymbol{X}}(x_1, \ldots, x_n) = \prod_{i=1}^{n} p_{X_i}(x_i;\theta) = \prod_{i=1}^{n} p_X(x_i;\theta)$$

Estimadores de Máxima Verossimilhança

Definição: Seja $X_1, \ldots, X_n$ uma a.a. da v.a. X. A função de verossimilhança $L(\theta; \boldsymbol{x})$ é definida por

$$L(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} f_{\mathrm{X}}(x_i; \theta)$$

ou

$$L(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} p_{\mathrm{X}}(x_i; \theta)$$

que deve ser considerada como uma função de θ.

Estimadores de Máxima Verossimilhança

Interpretação: Podemos interpretar $L(\theta, \boldsymbol{x})$ como uma medida de plausibilidade de θ ter produzido o vetor de observações $\boldsymbol{x}$, com a suposta f.m.p ou f.d.p.

Estimadores de Máxima Verossimilhança

Definição: O estimador de máxima verossimilhança de θ, denotador por $\hat{\theta}$, é o valor que maximiza $L(\theta, \boldsymbol{x})$.

Em alguns casos podemos obter o máximo de $L(\theta; \boldsymbol{x})$ fazendo

$$\frac{dL(\theta; \boldsymbol{x})}{d\theta} = 0$$

e verificando se

$$\left.\frac{d^2L(\theta; \boldsymbol{x})}{d\theta^2}\right|_{\theta=\hat{\theta}(\boldsymbol{x})} < 0$$

Estimadores de Máxima Verossimilhança

Definição: A função log-verossimilhança $l(\theta, \boldsymbol{x})$ é definida pelo logaritmo natural de $L(\theta; \boldsymbol{x})$:

$$l(\theta, \boldsymbol{x}) = \log_e(L(\theta; \boldsymbol{x}))$$

Maximizar $L(\theta, \boldsymbol{x})$ é equivalente a maximizar $l(\theta, \boldsymbol{x})$, o que quase sempre é mais simples. Assim, se $\hat{\theta}$ existe ele também deve satisfazer a equação de verossimilhança

$$\frac{dl(\theta; \boldsymbol{x})}{d\theta} = 0$$

OBS.: Em estatística "log" é a notação usual para "ln".

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Exponencial com parâmetro λ, $\lambda > 0$. Encontrar o estimador de máxima verossimilhança para λ.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Exponencial com parâmetro λ, $\lambda > 0$. Encontrar o estimador de máxima verossimilhança para λ.

A f.d.p. de X é $f_X(x;\lambda) = \lambda e^{-\lambda x}, \quad x \geq 0$ e $\lambda > 0$

A função de verossimilhança associada ao vetor de observações $\boldsymbol{x}$ da a.a. $\boldsymbol{X}$é

$$L(\lambda, \boldsymbol{x}) = \prod_{i=1}^{n} \{f_X(x_i;\lambda)\} = \prod_{i=1}^{n} \left\{\lambda e^{-\lambda x_i}\right\} = \lambda^n e^{-\lambda \sum_{i=1}^{n} x_i}$$

A função log-verossimilhança é

$$l(\theta; \boldsymbol{x}) = ln(\lambda^n e^{-\lambda \sum_{i=1}^{n} x_i}) = nln(\lambda) - \lambda \sum_{i=1}^{n} x_i$$

Estimadores de Máxima Verossimilhança

O estimador de máxima verossimilhança de λ é obtido buscando a solução em

$$
\begin{aligned}
\frac{dl(\lambda, \boldsymbol{x})}{d\lambda} &= 0 \\
\frac{n}{\lambda} - \sum_{i=1}^{n} x_i &= 0 \\
\frac{n}{\lambda} &= \sum_{i=1}^{n} x_i \\
\hat{\lambda} &= \frac{n}{\sum_{i=1}^{n} x_i} = \bar{X}^{-1}
\end{aligned}
$$

Estimadores de Máxima Verossimilhança

Verificando se $\hat{\lambda}$ é um ponto de máximo

$$\begin{aligned} \left.\frac{d^2 l(\lambda, \boldsymbol{x})}{d\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} &< 0 \\ \left.\frac{-n}{\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} = \frac{-n}{(1/\bar{x})^2} &< 0 \end{aligned}$$

Portanto, $\hat{\lambda} = \bar{X}^{-1}$ é o estimador de máxima verossimilhança para λ.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Poisson com parâmetro $\lambda > 0$. Encontrar o estimador de máxima de verossimilhança para λ.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição Poisson com parâmetro $\lambda > 0$. Encontrar o estimador de máxima de verossimilhança para λ.

A f.m.p de X é

$$p_X(x; \lambda) = \frac{e^{-\lambda}\lambda^x}{x!}, \quad x = 0, 1, 2 \ldots \text{ e } \lambda > 0$$

A função de verossimilhança associada ao vetor de observações $\boldsymbol{x}$ da a.a. $\boldsymbol{X}$ é

$$L(\lambda, \boldsymbol{X}) = \prod_{i=1}^{n} \{p_X(x_i; \lambda)\} = \prod_{i=1}^{n} \left\{ \frac{e^{-\lambda}\lambda^{x_i}}{x_i!} \right\}$$

Estimadores de Máxima Verossimilhança

A função log-verossimilhança é

$$l(\lambda, \boldsymbol{x}) = ln\left(\prod_{i=1}^{n}\left\{\frac{e^{-\lambda}\lambda^{x_i}}{x_i!}\right\}\right) = -n\lambda + \sum_{i=1}^{n} x_i \ln(\lambda) - \sum_{i=1}^{n} \log(x_i!)$$

O estimador de máxima verossimilhança de λ é obtido buscando a solução em

$$\begin{aligned}
\frac{dl(\lambda, \boldsymbol{x})}{d\lambda} &= 0 \\
-n + \frac{\sum_{i=1}^{n} x_i}{\hat{\lambda}} &= 0 \\
\hat{\lambda} &= \frac{\sum_{i=1}^{n} x_i}{n} = \bar{x}
\end{aligned}$$

Estimadores de Máxima Verossimilhança

Verificando se $\hat{\lambda}$ é um ponto de máximo

$$\begin{aligned} \left.\frac{d^2 l(\lambda, \boldsymbol{x})}{d\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} &< 0 \\ \left.-\frac{\sum_{i=1}^{n} x_i}{\lambda^2}\right|_{\lambda=\hat{\lambda}(\boldsymbol{x})} = -\frac{\sum_{i=1}^{n} x_i}{\bar{x}^2} &< 0 \end{aligned}$$

Portanto, o estimador de máxima verossimilhança para λ é

$$\hat{\lambda} = \frac{\sum_{i=1}^{n} X_i}{n} = \bar{X}$$

Estimadores de Máxima Verossimilhança

Propriedade:(Invariância) Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a da v.a. X com f.m.p. $p_X(x;\theta)$ ou f.d.p. $f_X(x;\theta)$. Se $\hat{\theta}$ é o estimador de máxima verossimilhança de θ, então $g(\hat{\theta})$ é o estimador de máxima verossimilhança de $g(\theta)$.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de tamanho n da v.a. X com distribuição Poisson com parâmetro θ. Encontre o estimador de máxima verossimilhança para $P(X = 0)$.

Estimadores de Máxima Verossimilhança

Ex.: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. de tamanho n da v.a. X com distribuição Poisson com parâmetro θ. Encontre o estimador de máxima verossimilhança para $P(X = 0)$.

Já sabemos que o EMV de θ é $\bar{X}$, $\hat{\theta} = \bar{X}$.

Queremos o EMV para

$$g(\theta) = P(X = 0) = e^{-\theta}$$

Então, $g(\hat{\theta}) = e^{-\hat{\theta}} = e^{-\bar{x}}$ propriedade da invariância.

Propriedades dos Estimadores

Consideremos uma a.a. $\boldsymbol{X} = (X_1, \ldots, X_n)$ da v.a. X que descreve uma característica de interesse de uma população. Seja θ o parâmetro de interesse que desejamos estimar e $T(\boldsymbol{X}) = T(X_1, \ldots, X_n)$ um estimador para este parâmetro.

Vício (viés)

Def.: O vício de um estimador $T(\boldsymbol{X})$ é a diferença entre $E(T(\boldsymbol{X}))$ e θ

$$\mathcal{B}_\theta(T(\boldsymbol{X})) = E(T(\boldsymbol{X})) - \theta$$

Um estimador $T(\boldsymbol{X})$ é definido ser um estimador não-viciado (ou não-viesado) de θ se $\mathcal{B}_\theta(T(\boldsymbol{X})) = 0$, ou seja:

$$E(T(\boldsymbol{X})) = \theta,$$

para todo θ.

Vicio (viés)

Def.: Um estimador viciado de $T(\boldsymbol{X})$ de θ é dito assintoticamente não-viciado se

$$\lim_{n\to\infty} \mathcal{B}_\theta(T(\boldsymbol{X})) = 0$$

Erro quadrático médio

Def.: O erro quadrático médio de um estimador $T(\boldsymbol{X})$ de θ é definido por

$$EQM_\theta(T(\boldsymbol{X})) = E\left((T(\boldsymbol{X}) - \theta)^2\right)$$

que é uma medida de desempenho razoável para um estimador.

O EQM pode ser determinado pela média e variância de $T(\boldsymbol{X})$:

$$EQM_\theta(T(\boldsymbol{X})) = Var(T(\boldsymbol{X})) + \{\mathcal{B}_\theta(T(\boldsymbol{X}))\}^2$$

Erro quadrático médio

Demonstração:

$$
\begin{aligned}
EQM_\theta(T(\boldsymbol{X})) &= E(T^2(\boldsymbol{X}) - 2\theta T(\boldsymbol{X}) + \theta^2) \\
&= E(T^2(\boldsymbol{X})) - \{E(T(\boldsymbol{X}))\}^2 + \{E(T(\boldsymbol{X}))\}^2 - 2\theta E(T(\boldsymbol{X})) \\
&+ \theta^2 \\
&= Var(T(\boldsymbol{X})) + \{E(T(\boldsymbol{X})) - \theta\}^2 \\
&= Var(T(\boldsymbol{X})) + \{\mathcal{B}_\theta(T(\boldsymbol{X}))\}^2
\end{aligned}
$$

Consistência

Def.: Seja $\{T_n(\boldsymbol{X})\}_{n\geq 1}$ uma sequência de estimadores de θ. A sequência $\{T_n(\boldsymbol{X})\}_{n\geq 1}$ é definida ser uma sequência consistente de estimadores de θ se, para todo $\epsilon > 0$, satisfaz:

$$\lim_{n\to\infty} P\left(|T_n(\boldsymbol{X}) - \theta| \geq \epsilon\right) = 0$$

Consistência

Proposição: uma sequência $\{T_n(\boldsymbol{X})\}_{n\geq 1}$ de estimadores de θ é consistente se

$$\lim_{n\to\infty} E(T(\boldsymbol{X})) = \theta$$

e

$$\lim_{n\to\infty} Var(T(\boldsymbol{X})) = 0$$

Exemplo

Exemplo: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição $\mathcal{N}(\mu, \sigma^2)$. Considere os estimadores de μ e σ^2, respectivamente, $\hat{\mu} = \bar{X}$ e $\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}$. Calcule os vícios para estes estimadores.

Exemplo

Exemplo: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com distribuição $\mathcal{N}(\mu, \sigma^2)$. Considere os estimadores de μ e σ^2, respectivamente, $\hat{\mu} = \bar{X}$ e $\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}$. Calcule os vícios para estes estimadores.

Para a média

$$\mathcal{B}_\theta(\hat{\mu}) = E(\bar{X}) - \mu = E\left(\frac{\sum_{i=1}^{n} X_i}{n}\right) - \mu = \frac{1}{n} n\mu - \mu = 0$$

Exemplo

Para a variância

$$
\begin{aligned}
\mathcal{B}_\theta(\hat{\sigma}^2) &= E\left(\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}\right) - \sigma^2 \\
&= \frac{1}{n}E\left(\sum_{i=1}^{n} X_i^2 - 2\bar{X}\sum_{i=1}^{n} X_i + n\bar{X}^2\right) - \sigma^2 \\
&= \frac{1}{n}\left\{\sum_{i=1}^{n} E(X_i^2)\right\} - 2E(\bar{X}^2) + E(\bar{X}^2) - \sigma^2 \\
&= \frac{1}{n}\left\{\sum_{i=1}^{n} E(X_i^2)\right\} - E(\bar{X}^2) - \sigma^2
\end{aligned}
$$

Exemplo

Sabemos que $Var(X_i) = E({X_i}^2) - \{E(X_i)\}^2$e $Var(\bar{X}) = E(\bar{X}^2) - \{E(\bar{X})\}^2$. Logo, $E({X_i}^2) = \sigma^2 + \mu^2$ e $E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$. Portanto,

$$\begin{aligned}
\mathcal{B}_\theta(\hat{\sigma}^2) &= \frac{1}{n}\left\{\sum_{i=1}^{n}(\sigma^2 + \mu^2)\right\} - \frac{\sigma^2}{n} - \mu^2 - \sigma^2 \\
&= \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2 - \sigma^2 \\
&= -\frac{\sigma^2}{n}
\end{aligned}$$

Verificando o vício assintoticamente:

$$\lim_{n\to\infty} \mathcal{B}_{\sigma^2}(\hat{\sigma}^2) = \lim_{n\to\infty} -\frac{\sigma^2}{n} = -\sigma^2 \lim_{n\to\infty} \frac{1}{n} = 0$$

Dessa forma, $\hat{\sigma}^2$ é um estimador assintoticamente não-viciado.

Exemplo

Observação: O cálculo do vício de um estimador pode ser usado para sugerir novos estimadores. Por exemplo, considere o estimador $\hat{\sigma}^2$ de σ^2, cujo vício é $-\frac{\sigma^2}{n}$. Um novo estimador não-viciado, pode ser obtido por

Exemplo

Observação: O cálculo do vício de um estimador pode ser usado para sugerir novos estimadores. Por exemplo, considere o estimador $\hat{\sigma}^2$ de σ^2, cujo vício é $-\frac{\sigma^2}{n}$. Um novo estimador não-viciado, pode ser obtido por

$$\begin{aligned}
\mathcal{B}_\theta(\hat{\sigma}^2) &= E(\hat{\sigma}^2) - \sigma^2 \\
E(\hat{\sigma}^2) &= -\frac{\sigma^2}{n} + \sigma^2 \\
&= \frac{\sigma^2(n-1)}{n}
\end{aligned}$$

Exemplo

Com isso temos um novo estimador, S^2, definido por

$$
\begin{aligned}
E\left(\frac{n}{n-1}\hat{\sigma}^2\right) &= \sigma^2 \\
S^2 &= \frac{n\hat{\sigma}^2}{n-1} = \frac{n}{n-1}\sum_{i=1}^{n}\frac{(X_i-\bar{X})^2}{n} \\
&= \frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{n-1}
\end{aligned}
$$

Isso implica que $E(S^2) = \sigma^2$ e, consequentemente, $\mathcal{B}_{\sigma^2}(S^2) = 0$.

Exemplo

Exemplo: Considere o estimador S^2 para σ^2. Calcule o seu EQM e verifique se este estimador é consistente. Utilize o seguinte resultado

$$\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1},$$

$E(Y) = n - 1$ e $Var(Y) = 2(n-1)$

Exemplo

Para $S^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}$ temos que

$$
\begin{aligned}
EQM_{\sigma^2}(S^2) &= Var(S^2) + \{\mathcal{B}_{\sigma^2}(S^2)\}^2 \\
&= Var\left(\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}\right) \\
&= Var\left(\frac{\sigma^2 \sum_{i=1}^{n}(X_i - \bar{X})^2}{\sigma^2(n-1)}\right) \\
&= \frac{\sigma^4}{(n-1)^2} 2(n-1) \\
&= \frac{2\sigma^4}{n-1}
\end{aligned}
$$

Exemplo

Para verificar se S^2 é consistente temos que verificar que

$$\lim_{n\to\infty} E(S^2) = \sigma^2 \quad \text{e} \quad \lim_{n\to\infty} Var(S^2) = 0$$

Logo,

$$\begin{aligned}
\lim_{n\to\infty} E(S^2) &= \lim_{n\to\infty} E\left(\frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{n-1}\right) = \lim_{n\to\infty} E\left(\frac{\sigma^2\sum_{i=1}^{n}(X_i-\bar{X})^2}{\sigma^2(n-1)}\right) \\
&= \lim_{n\to\infty} \frac{\sigma^2}{n-1} E\left(\frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{\sigma^2}\right) = \lim_{n\to\infty} \frac{\sigma^2}{n-1}(n-1) \\
&= \sigma^2
\end{aligned}$$

Exemplo

$$
\begin{aligned}
\lim_{n\to\infty} Var(S^2) &= \lim_{n\to\infty} \frac{2\sigma^4}{n-1} \\
&= 2\sigma^4 \lim_{n\to\infty} \frac{1}{n-1} \\
&= 0
\end{aligned}
$$

Logo, S^2 é consistente.

Estimação por intervalos

Estimação por intervalos

Intervalos de confiança

Objetivo: Construir intervalos que indiquem além da estimativa pontual, uma medida de precisão dessa estimativa. Esses Intervalos são chamados **Intervalos de confiança**.

Estimação intervalar para a média populacional

Considere $\mathbf{X} = (X_1, \ldots, X_n)$ uma a.a. da v.a. X com $E(X) = \mu$ e $Var(X) = \sigma^2$.

Já sabemos que a média amostral ($\bar{X}$) é um estimador pontual para a média populacional μ e que a distribuição amostral de $\bar{X}$ é

$$\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$$

Com isso temos

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Para obtermos uma estimação intervelar para o parâmetro μ, iremos considerar as seguintes situações:

Variância conhecida

Seja α um valor pequeno $(0 < \alpha < 1)$, tal que:

$$\begin{aligned} \alpha &: \text{ nível de significância} \\ (1-\alpha) &: \text{ nível de confiança} \end{aligned}$$

Uma estimativa de **intervalo de confiança** para μ é

$$P(l \leq \mu \leq m) = \underbrace{1 - \alpha}$$

Limite inferior

Limite superior

Coeficiente de confiança

Desenvolvimento do intervalo de confiança

Podemos escrever

$$P\left(-z_{\alpha/2} \leq \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1-\alpha.$$

Agora manipulando as grandezas dentro dos parênteses, (1) multiplicando por $\sigma/\sqrt{n}$, (2) subtraindo $\bar{X}$ de cada termo e (3) multiplicando por (-1). Temos que

$$P\left(\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right) = 1-\alpha.$$

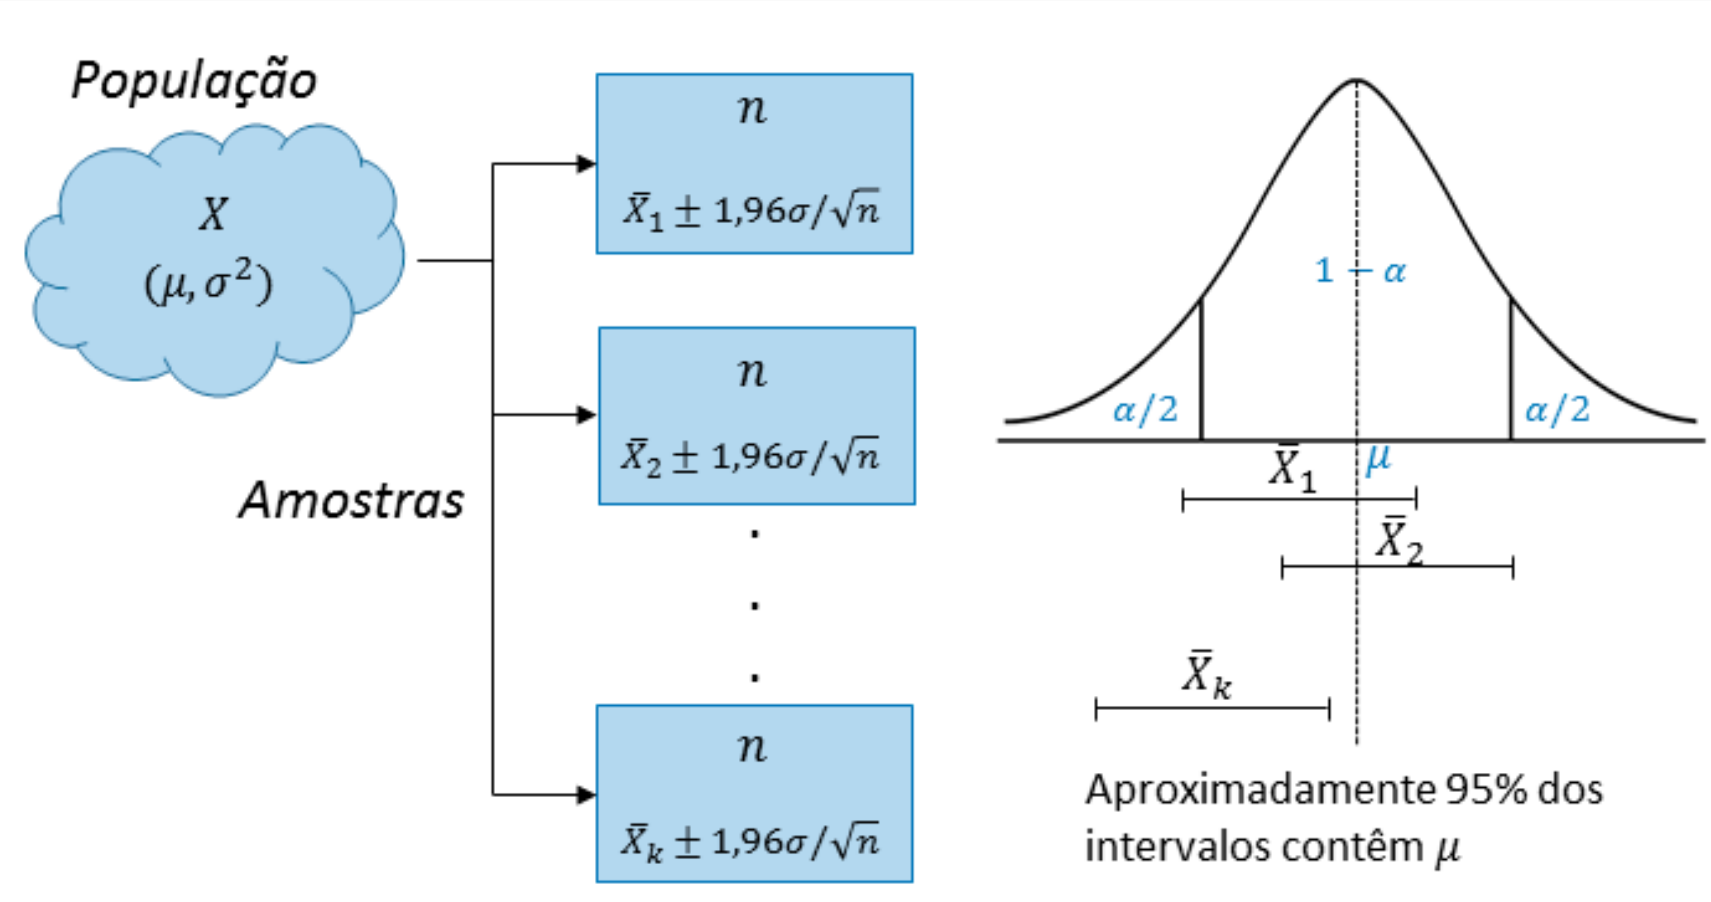
População
X
(μ, σ^2)
Amostras
n
$\bar{X}_1 \pm 1{,}96\sigma/\sqrt{n}$
n
$\bar{X}_2 \pm 1{,}96\sigma/\sqrt{n}$
n
$\bar{X}_k \pm 1{,}96\sigma/\sqrt{n}$
$1-\alpha$
$\alpha/2$
$\alpha/2$
$\bar{X}_1$
μ
$\bar{X}_2$
$\bar{X}_k$
Aproximadamente 95% dos intervalos contêm μ

Intervalo de confiança para a média

IC para μ com variância conhecida

Def.: Se $\bar{x}$ for a média amostral de uma amostra alteatória, de tamanho n, proveniente de uma população normal com variância conhecida σ^2, um intervalo com $(1-\alpha)100\%$ de confiança para μ é dado por

$$IC_{(1-\alpha)100\%} = \left[\bar{x} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right]$$

sendo $z_{\alpha/2}$ o ponto superior com $100\frac{\alpha}{2}\%$ da distribuição normal padrão.

Intervalo de confiança para a média

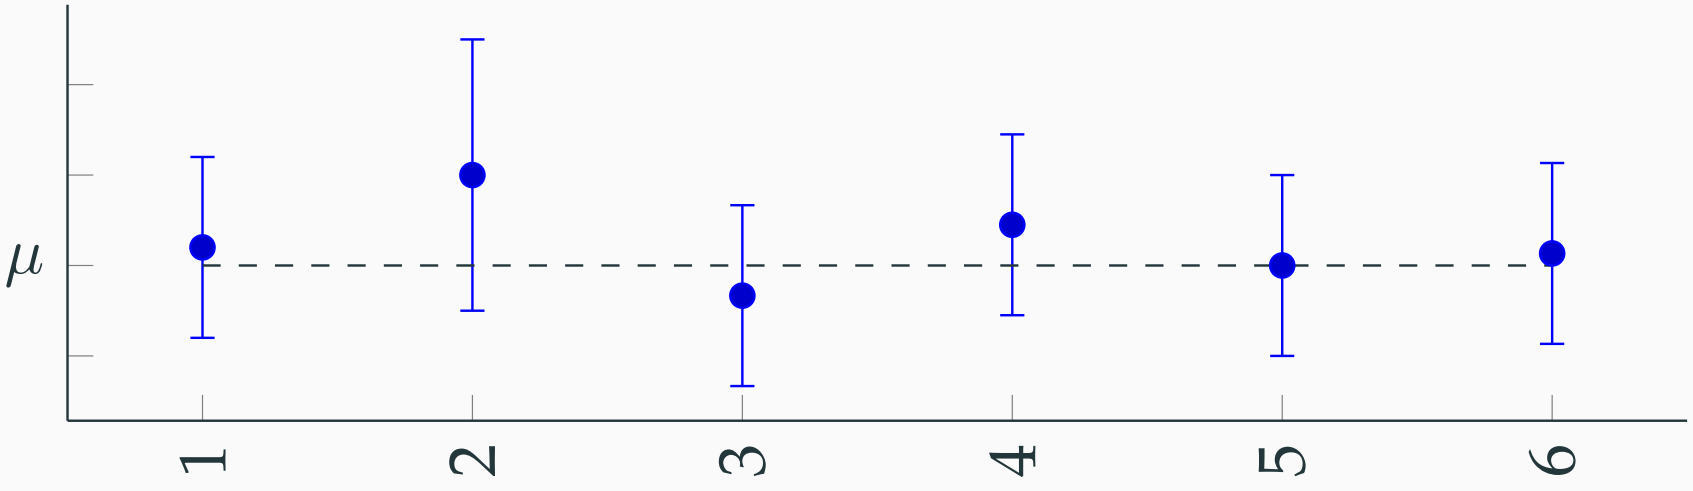

Figura 1: Estimativas intervalares para μ em diferentes amostras.

Interpretação

Se pudessemos construir uma grande quantidade de intervalos, todos baseados em amostras de mesmo tamanho n, esperamos que $(1-\alpha)100\%$ deles contenham o verdadeiro valor do parâmetro μ.

Intervalo de confiança para a média

O IC para μ, com σ^2 conhecido, pode ser visto como

$P(|\text{média amostral} - \text{média populacional}| \leq \text{erro amostral}) = 1 - \alpha$

Sabemos que

$$P\left(\left|\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right| \leq z_{\alpha/2}\right) = 1 - \alpha$$

e podemos escrever

$$P\left(|\bar{X} - \mu| \leq z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

Intervalo de confiança para a média

Erro amostral e tamanho da amostra

Def.: Define-se por erro amostral ou erro máximo ($\mathcal{E}$) de μ a quantidade

$$\mathcal{E} = z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$$

e o IC corresponde a $IC = [\bar{X} - \mathcal{E}, \bar{X} + \mathcal{E}]$.

Fixando o erro máximo admissível, podemos calcular o tamanho da amostra por

$$\mathcal{E} = z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \Rightarrow n = \left(z_{\alpha/2}\frac{\sigma}{\mathcal{E}}\right)^2$$

Exemplo

Ex.: Suponha que comprimentos de jacarés adultos de uma certa raça siga uma distribuição normal com média μ, desconhecida, e variância igual a 0.01 m^2. Uma amostra de 10 animais foi sorteada e forneceu média 1.69 m. Obtenha um intervalo de confiança de 95% para μ.

Exemplo

Ex.: Suponha que comprimentos de jacarés adultos de uma certa raça siga uma distribuição normal com média μ, desconhecida, e variância igual a 0.01 m^2. Uma amostra de 10 animais foi sorteada e forneceu média 1.69 m. Obtenha um intervalo de confiança de 95% para μ.

$$
\begin{aligned}
IC_{(1-\alpha)100\%} &= \left(\bar{x} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right) \\
IC_{95\%} &= \left(1,69 \pm 1,96\sqrt{\frac{0,01}{10}}\right) \\
IC_{95\%} &= \left(1,69 - 1,96\sqrt{\frac{0,01}{10}}; 1,69 + 1,96\sqrt{\frac{0,01}{10}}\right) \\
IC_{95\%} &= \left(1,63; 1,75\right)
\end{aligned}
$$

Variância desconhecida

IC para μ com variância desconhecida

Def.: Se $\bar{x}$ e s forem a média e o desvio padrão de uma amostra aleatória proveniente de uma população normal, com variância desconhecida σ^2, então um intervalo de confiança de $100(1-\alpha)\%$ para a média μ é dada por

$$IC_{(1-\alpha)100\%} = \left(\bar{x} \pm t_{\alpha/2,n-1}\frac{s}{\sqrt{n}}\right)$$

sendo $t_{\alpha/2}$ o ponto superior $100_{\alpha/2}\%$ da distribuição t, com $n-1$ graus de liberdade.

Intervalo de confiança para a proporção

Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma amostra aleatória da variável aleatória X com distribuição Bernoulli(p). Assim, $E(X) = p$ e $\text{Var}(X) = p(1-p)$. Considere $\hat{p} = \bar{X}$ o estimador de p.

Para n suficientemente grande, temos que

$$\hat{p} \sim \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$$

e com isso

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0, 1).$$

Intervalo de confiança para a proporção

Assim, para um nível de confiança pré-fixado em $(1-\alpha)$ temos

$$\begin{aligned} P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) &= (1-\alpha) \\ P\left(\hat{p} - z_{\alpha/2}\sqrt{\frac{p(1-p)}{n}} \leq p \leq \hat{p} + z_{\alpha/2}\sqrt{\frac{p(1-p)}{n}}\right) &= (1-\alpha) \end{aligned}$$

Logo, o IC para p seria

$$\hat{p} \pm z_{\alpha/2}\sqrt{\frac{p(1-p)}{n}}$$

Podemos observar que os limites do intervalo dependem do parâmetro p que é desconhecido. Dessa forma, iremos considerar as seguintes abordagens:

Intervalo de confiança para a proporção

Abordagem otimista

Substituir p pela proporção amostral de sucesso, $\hat{p}$. Assim o intervalo com $(1-\alpha)100\%$ de confiança para p é dado por

$$IC_{(1-\alpha)100\%} = \left(\hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right)$$

Abordagem conservativa

Utilizar o fato de que o valor máximo da variância de X, $p(1-p)$, é atingido quando $p = \frac{1}{2}$. Logo, $p(1-p) \leq \frac{1}{4}$, ou equivalentemente, $\sqrt{\frac{p(1-p)}{n}} \leq \sqrt{\frac{1}{4n}}$. Logo, o IC para p é dado por

$$IC_{(1-\alpha)100\%} = \left(\hat{p} \pm z_{\alpha/2}\sqrt{\frac{1}{4n}}\right)$$

Intervalo de confiança para a proporção

Erro amostral e tamanho da amostra

De forma similar, o erro amostral da verdadeira população p é definida por

$$\mathcal{E} = z_{\alpha/2}\sqrt{\frac{p(1-p)}{n}}$$

Quando o erro amostral é fixado, o tamanho amostral n adequado é

$$n = z^2_{\alpha/2}\frac{p(1-p)}{\mathcal{E}^2}$$

que depende do parâmetro desconhecido p. Logo,

- Se tivermos informações anteriores sobre p, temos $n = z^2_{\alpha/2}\frac{\hat{p}(1-\hat{p})}{\mathcal{E}^2}$
- Na falta de informações sobre p, utilizamos a abordagem conservativa ($p = 1/2$), $n = \left(\frac{z_{\alpha/2}}{2\mathcal{E}}\right)^2$.

Exemplo

Ex.: Entre 500 pessoas indagadas a respeito de suas preferências eleitorais, 260 mostraram-se favoráveis ao candidato D. Calcular um intervalo de confiança com 90% de confiança para a porcentagem dos eleitores favoráveis a este candidato.

Exemplo

Ex.: Entre 500 pessoas indagadas a respeito de suas preferências eleitorais, 260 mostraram-se favoráveis ao candidato D. Calcular um intervalo de confiança com 90% de confiança para a porcentagem dos eleitores favoráveis a este candidato.

Otimista:

$$\begin{aligned} IC_{(1-\alpha)100\%} &= \left(\hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right) \\ IC_{90\%} &= \left(0,52 \pm 1,64\sqrt{\frac{0,52(0,48)}{500}}\right) \\ IC_{90\%} &= (0,4834; 0,5566) \end{aligned}$$

Exemplo

Conservativa:

$$
\begin{aligned}
IC_{(1-\alpha)100\%} &= \left(\hat{p} \pm z_{\alpha/2}\sqrt{\frac{1}{4n}}\right) \\
IC_{90\%} &= \left(0,52 \pm 1,64\sqrt{\frac{1}{4(500)}}\right) \\
IC_{90\%} &= (0,4833; 0,5567)
\end{aligned}
$$

Exemplo

Ex.: Deseja-se investigar as preferências eleitorais. Qual deve ser o tamanho da amostra mínima que garanta um erro máximo de 2% a um nível de 95% de confiança ?

Exemplo

Ex.: Deseja-se investigar as preferências eleitorais. Qual deve ser o tamanho da amostra mínima que garanta um erro máximo de 2% a um nível de 95% de confiança ?

$$
\begin{aligned}
n &= \left(\frac{z_{\alpha/2}}{2\mathcal{E}}\right)^2 \\
n &= \left(\frac{1,96}{2(0.002)}\right)^2 \\
n &= 49^2 = 2401
\end{aligned}
$$

Exercícios

Ex: Seja $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma amostra aleatória de uma população com distribuição Binomial(M,p), com M conhecido. Encontre o estimador de máxima verossimilhança para p.

Exercícios

Ex. Em um estudo sobre o tempo que os estudantes gastam para obterem o grau de bacharel, 80 estudantes foram selecionados aleatoriamente e verificou-se que tinha uma média de 4,8 anos. Supondo $\sigma = 2,2$ anos, construa o intervalo com 90% de confiança para a média populacional.

Exercícios

Ex. Suponha que estejamos interessados em estimar a porcentagem de consumidores de um certo produto. Se a amostra de tamanho 300 forneceu 100 indivíduos que consomem o produto determine o intervalo com 95% de confiança para p.

Teste de Hipóteses

Teste de Hipóteses

- Teste de hipótese é um procedimento que utiliza os dados para decidir sobre uma determinada afirmação à respeito de um parâmetro desconhecido da população;
- Decidir se alguma hipótese que tenha sido formulada está correta ou não, consiste apenas na escolha entre duas decisões:

REJEITAR OU NÃO REJEITAR TAL HIPÓTESE

Teste de Hipóteses

Objetivo:

Verificar se os dados amostrais trazem evidências que apóiem ou não uma hipótese (estatística) formulada.

Ex. 1: Considere que uma industria compra de um certo fabricante pinos, cuja resistência média à ruptura é especificada em 60 kgf. Em um determinado dia, a indústria recebeu um lote de pinos e a equipe técnica da indústria deseja verificar se o lote atende as especificações.

Teste de Hipóteses

- Seja X uma variável aleatória com função densidade de probabilidade $f_X(x;\theta)$ ou função massa de probabilidade $p_X(x;\theta)$, $x \in R_X$ e $\theta \in \Theta \subseteq \mathbb{R}$;
- Considere $\boldsymbol{X} = (X_1, \ldots, X_n)$ uma amostra aleatória da variável aleatória X;
- Considere também $\boldsymbol{x} = (x_1, \ldots, x_n)$ o vetor de observações de $\boldsymbol{X}$;

Teste de Hipóteses

Hipótese Estatística

É uma afirmação sobre o(s) parâmetro(s) de uma característica (variável aleatória) da população.

Hipótese Nula e Alternativa

Hipótese Nula (H_0)**:** É a hipótese estatística principal, a qual tentaremos validar no teste.

Hipótese Alternativa $(H_1 \textbf{ou} H_a)$**:** É a hipótese que contraria a hipótese nula.

Escrevemos $H_0 : \theta \in \Theta_0$ versus $H_1 : \theta \in \Theta_1$ tal que $\Theta_0 \cap \Theta_1 = \emptyset$

Continuação Ex.1:

H_0 : O lote atende as especificações (Hipótese Nula)

H_1 : O lote não atende as especificações (Hipótese Alternativa)

ou seja,

$$H_0 : \mu = 60 \quad \text{(Hipótese simples)}$$
$$H_1 : \mu \neq 60 \quad \text{(Hipótese composta bilateral)}$$

Estatística de Teste:

É uma regra de decisão que nos possibilita decidir por rejeitar ou não H_0 com base na amostra;

Região de Rejeição ou Região Crítica (R_c)

É o conjunto de valores assumidos pela estatística de teste para os quais a hipótese nula é rejeitada. Seu complementar é a Região de Aceitação (R_a).

Continuação Ex.1: Queremos testar

$$H_0 : \mu = 60 \text{vs} H_1 : \mu \neq 60$$

Suponha que a equipe técnica da indústria tenha retirado uma amostra de tamanho $n = 16$, do lote recebido, medir a resistência de cada pino e calcular a resistência média $\bar{X}$. Mas,

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{25}{16}\right)$$

Para quais valores de $\bar{X}$ a equipe técnica deve rejeitar H_0 e portanto não aceitar o lote ?

Se o lote está fora de especificação, isto é, $H_1 : \mu \neq 60$ espera-se que a média amostral seja inferior ou superior a 60 kgf.

Suponha que a equipe técnica decidiu adotar a seguinte regra: rejeitar H_0 se $\bar{X}$ for maior que 62,5 kgf ou menor que 57,5 kgf.

$$
\begin{aligned}
R_c &= \left\{\bar{X} > 62,5 \text{ ou } \bar{X} < 57,5\right\} \Rightarrow \text{ Região de rejeição de } H_0 \\
R_a &= \left\{57,5 \leq \bar{X} \leq 62,4\right\} \Rightarrow \text{ Região de não rejeição de } H_0
\end{aligned}
$$

Teste de Hipóteses

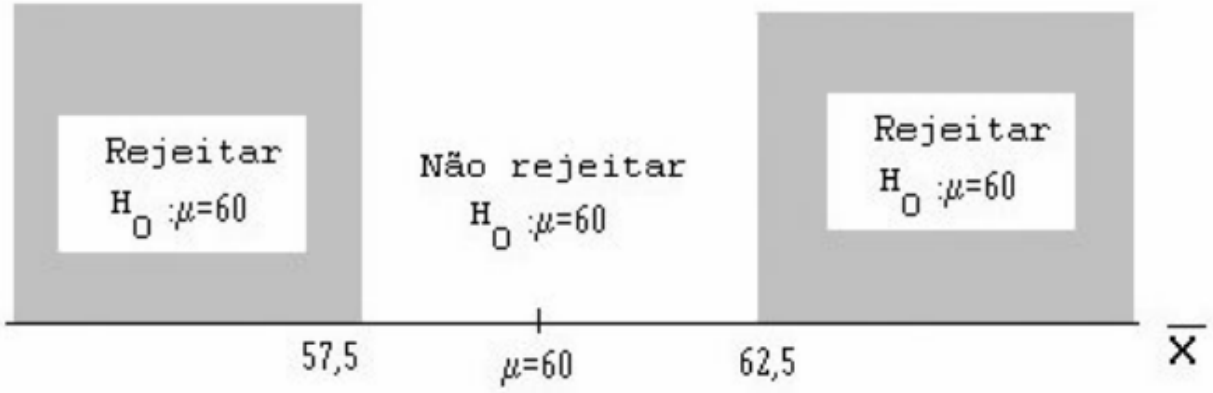

<u>Procedimento (teste)</u>

$$Se \;\; \bar{x} \in R_c \Rightarrow \text{Rejeita-se } \mathrm{H}_0$$

$$Se \;\; \bar{x} \notin R_c \Rightarrow Aceita\text{-se } \mathrm{H}_0$$

Teste de Hipóteses

Na tomada de decisão podemos cometer **dois tipos de erros**:

Erro Tipo I

Rejeitar H_0 quando H_0 é verdadeira.

Erro Tipo II

Não rejeitar H_0 quando H_0 é falsa.

Quadro Resumo:

H_0	DECISÃO	
	REJEITAR	NÃO-REJEITAR
VERDADEIRA	Erro Tipo I α	Decisão correta
FALSA	Decisão correta (Poder do teste, $1 - \beta$)	Erro Tipo II β

Teste de Hipóteses

A probabilidade de se cometer cada um dos erros pode ser escrita como:

$$P(\text{Erro Tipo I}) = P(\text{Rejeitar } H_0 | H_0 \text{ é verdadeira}) = \alpha$$

e

$$\begin{aligned} P(\text{Erro Tipo II}) &= P(\text{Não Rejeitar } H_0 | H_0 \text{ é falsa}) \\ &= P(\text{Não Rejeitar } H_0 | H_1 \text{ é verdadeira}) = \beta, \end{aligned}$$

em que α é o nível de significância e $1 - \beta$ é o poder do teste $(1 - \beta)$=P(Rejeitar $H_0 | H_1$ é verdadeiro).

Obs: Quanto maior o poder, melhor o teste.

Continuação Ex.1: Temos

$$H_0: \text{ Aceitar o lote} \quad vs \quad H_1: \text{ Não aceitar o lote}$$

Erro Tipo I: Não aceitar o lote sendo que ela está dentro das especificações;

Erro Tipo II: Aceitar o lote sendo que ele está fora das especificações;

Teste de Hipóteses

Considerando as hipóteses do exemplo anterior $H_0 : \mu = 60$ contra $H_1 \neq 60$, temos

$$\begin{aligned}
\alpha &= P(\bar{X} > 62,5 \text{ ou } \bar{X} < 57,5 | H_0 : \mu = 60) \\
&= P(\bar{X} > 62,5 | H_0 : \mu = 60) + P(\bar{X} < 57,5 | H_0 : \mu = 60)
\end{aligned}$$

Sob H_0 sabemos que $\bar{X} \sim \mathcal{N}(60, 25/16)$. Logo,

$$\begin{aligned}
\alpha &= P\left(\frac{\bar{X} - 60}{\sqrt{25/16}} > \frac{62,5 - 60}{\sqrt{25/16}}\right) + P\left(\frac{\bar{X} - 60}{\sqrt{25/16}} < \frac{57,5 - 60}{\sqrt{25/16}}\right) \\
&= P(Z > 2) + P(Z < -2) \\
&= 0,02275 + 0,02275 = 0,0445
\end{aligned}$$

Teste de Hipóteses

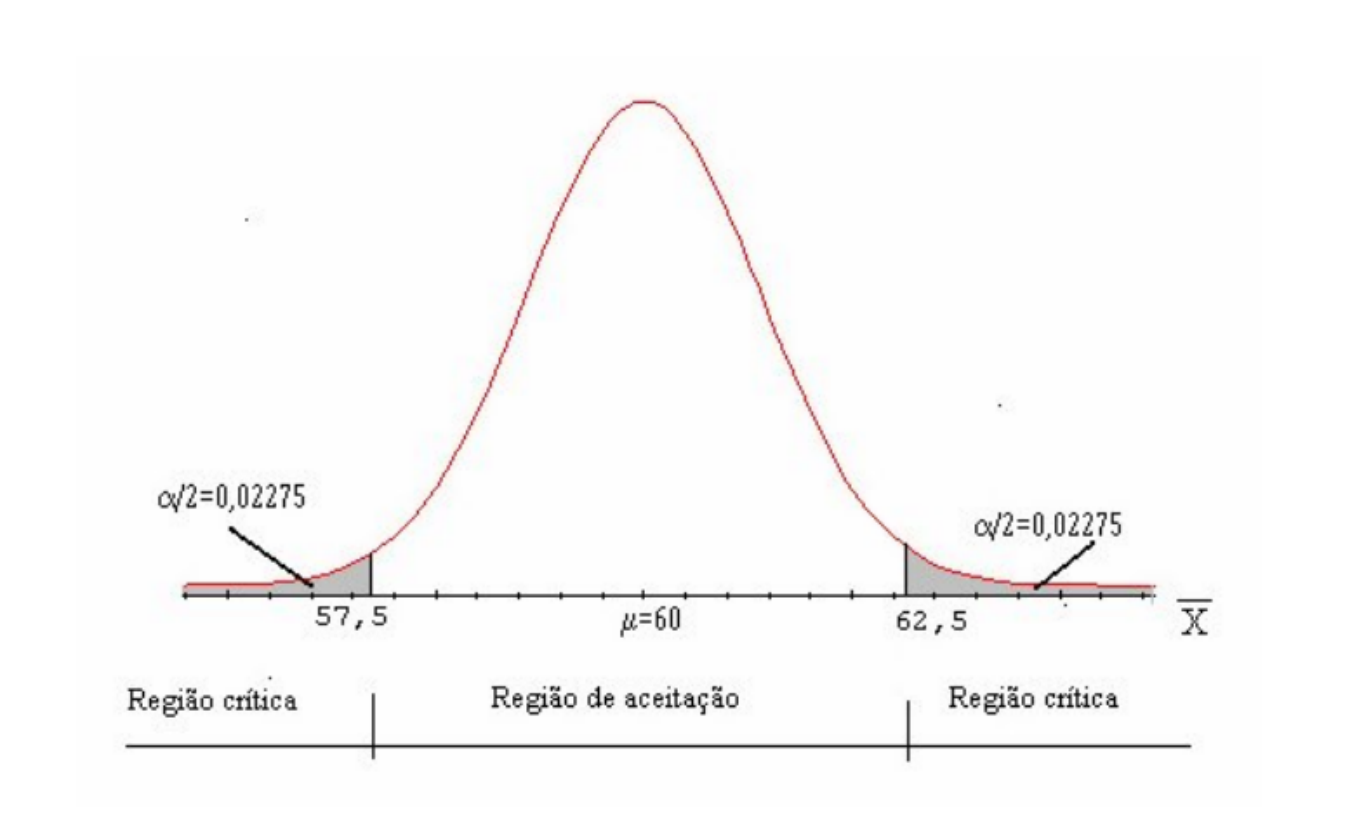

Teste de Hipóteses

Para β temos

$$\beta = P(\text{Aceitar } H_0 | H_1 \text{ Verdadeira}) = P(57,5 \leq \bar{x} \leq 62,5 | H_1 : \mu \neq 60)$$

Para o cáculo de β vamos considerar $H_1 : \mu = 63,5$. Sob H_1, $\bar{X} \sim \mathcal{N}(63,5; 25/16)$.

$$\begin{aligned}
\beta &= P(57,5 \leq \bar{X} \leq 62,5 | H_1 : \mu = 63,5) \\
&= P(\bar{X} \leq 62,5) - P(\bar{X} \leq 57,5) \\
&= P(Z \leq -0,8) - P(Z \leq -4,8) \\
&= 0,21186 + 0,00 \\
&= 0,21186
\end{aligned}$$

Teste de Hipóteses

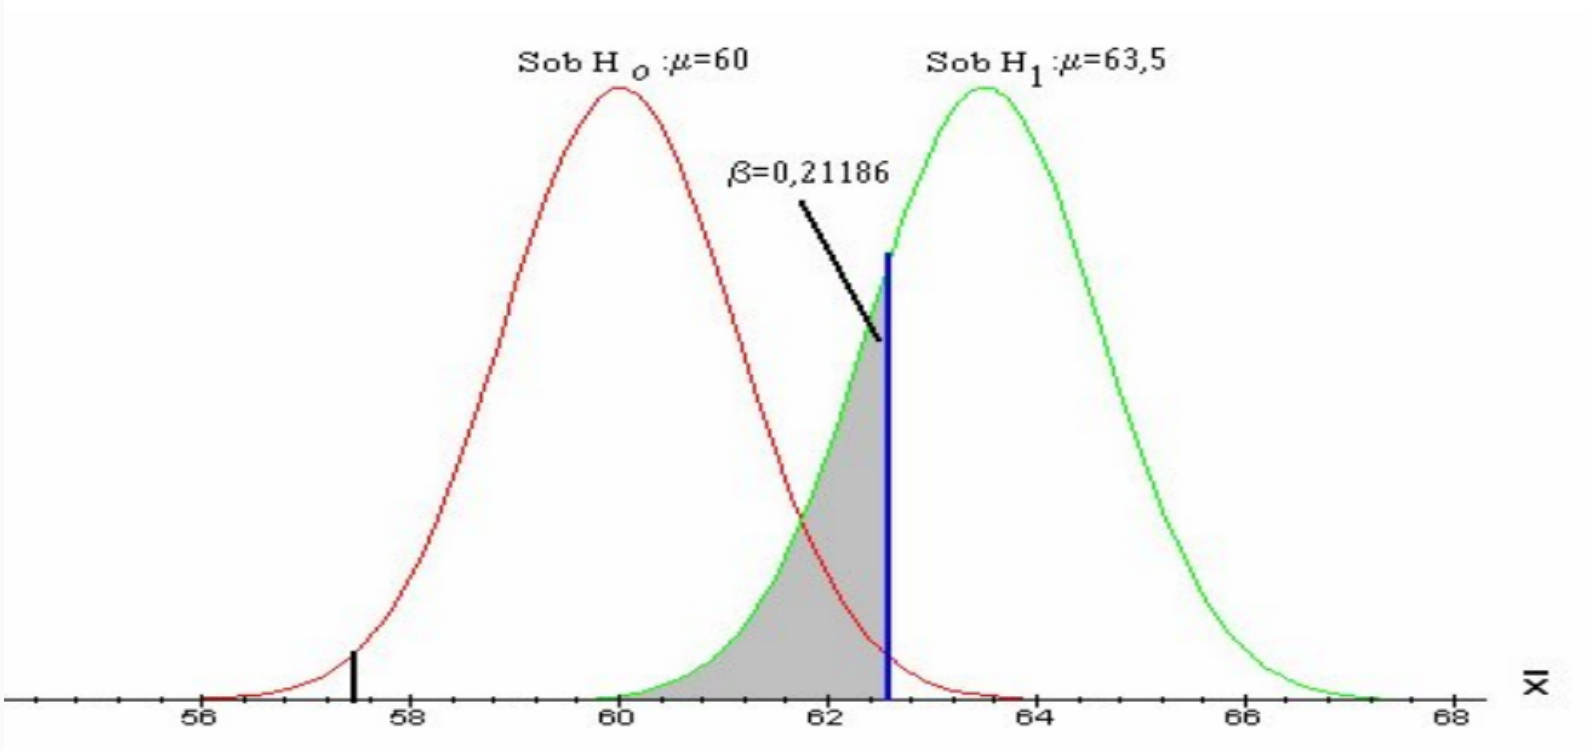

Teste de Hipóteses

O procedimento para a realização de um teste de hipótese pode ser resumido nos seguintes passos:

- Enumerar as hipóteses:

  $H_0 : \theta = \theta_0 \times H_1 : \theta \neq \theta_0$ (Bilateral);
  $H_0 : \theta = \theta_0 \times H_1 : \theta < \theta_0$ (Unilateral à esquerda);
  $H_0 : \theta = \theta_0 \times H_1 : \theta > \theta_0$ (Unilateral à Direita)

- Determinar a Estatística de Teste;
- Fixar o nível de significância α;
- Determinar a R_c e/ou R_a que serão definidos de acordo com o α fixado;
- Encontrar o valor da estatística e verificar se pertence à R_c ou à R_a.

Teste de Hipóteses para a média

Hipóteses da forma:

- $H_0 : \mu = \mu_0 \times H_1 : \mu \neq \mu_0$ (Bilateral);
- $H_0 : \mu = \mu_0 \times H_1 : \mu < \mu_0$ (Unilateral à esquerda);
- $H_0 : \mu = \mu_0 \times H_1 : \mu > \mu_0$ (Unilateral à Direita)

Teste de Hipóteses para a média

A **Estatística de Teste** vai depender se a variância populacional σ^2 é conhecida ou desconhecida. Sob H_0, temos

Estatística de Teste se σ^2 é conhecida

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$$

Estatística de Teste se σ^2 é desconhecida

$$T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \sim t - \text{ Student } (n-1)$$

Teste de Hipóteses para a média

A **Região Crítica ou de Rejeição** R_c depende das hipóteses a serem testadas. Se

(a) $H_0 : \mu = \mu_0 \ \times \ H_1 : \mu \neq \mu_0$

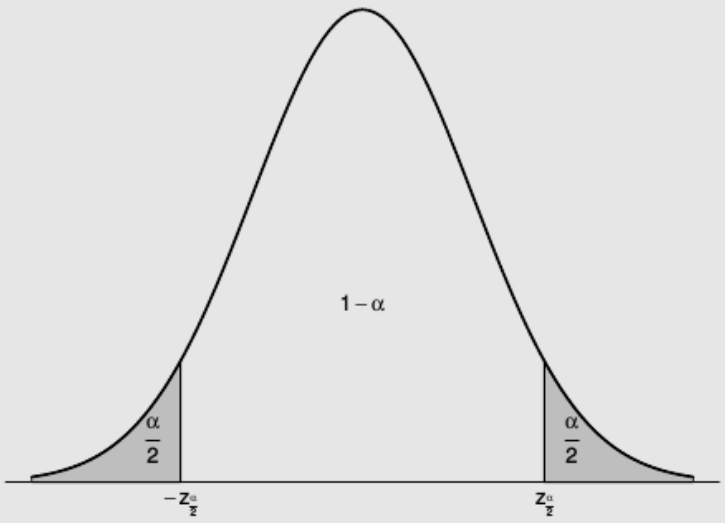

$$R_c = \{z : |z| > z_{\alpha/2}\}$$

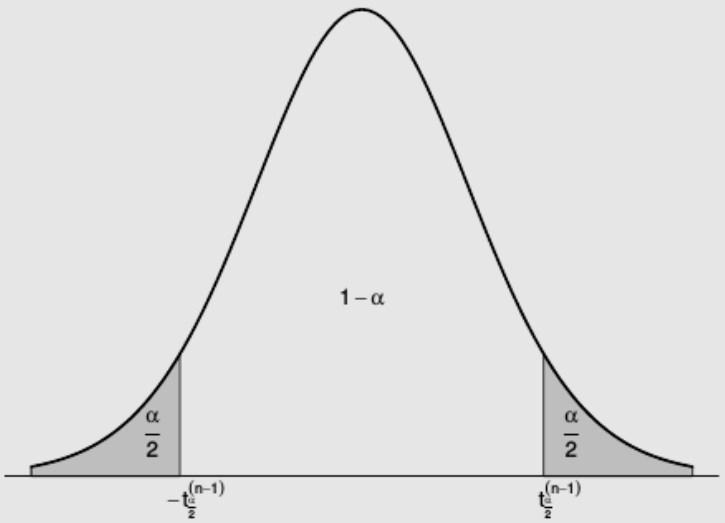

$$R_c = \{t : |t| > t_{\alpha/2}^{(n-1)}\}$$

Teste de Hipóteses para a média

(b) $H_0 : \mu \geq \mu_0 \ (\mu = \mu_0) \ \times \ H_1 : \mu < \mu_0$

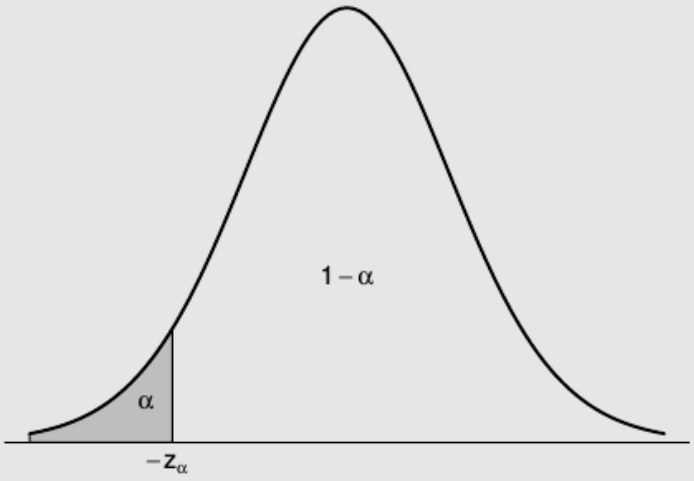

$$R_c = \{z : z < -z_\alpha\}$$

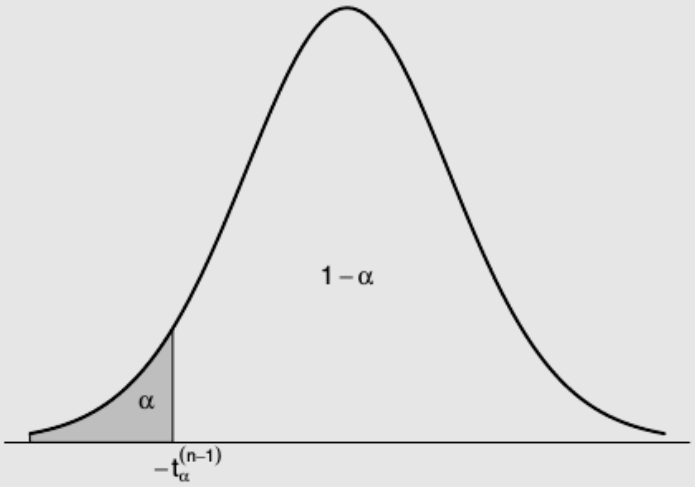

$$R_c = \{t : t < -t_\alpha^{(n-1)}\}$$

Teste de Hipóteses para a média

(c) $H_0 : \mu \leq \mu_0 \ (\mu = \mu_0) \ \times \ H_1 : \mu > \mu_0$

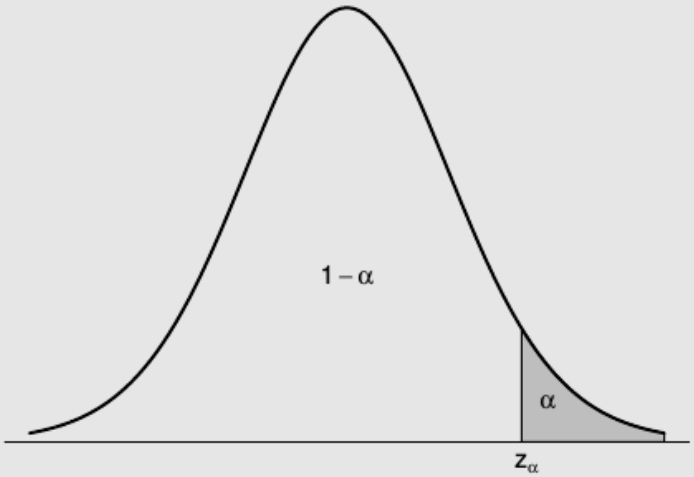

$$R_c = \{z : z > z_\alpha\}$$

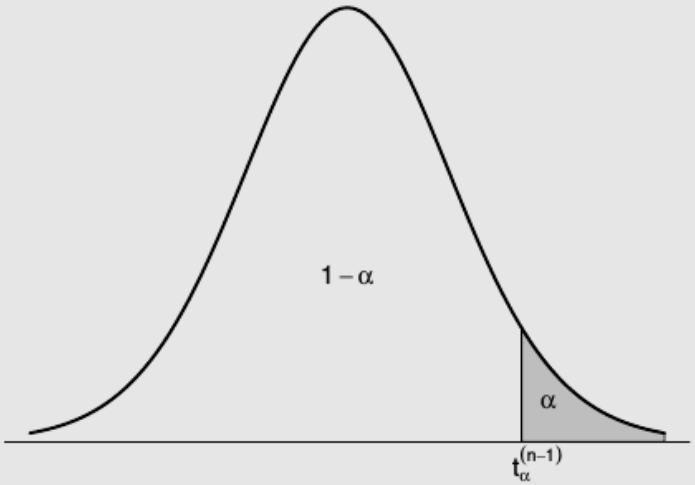

$$R_c = \{t : t > t_\alpha^{(n-1)}\}$$

Regra de Decisão

Se o valor da estatística Z ou T, dito z ou t, pertencer a Região Crítica ($z \in R_c$ ou $t \in R_c$) rejeitamos H_0 ao nível de significância α.

Teste de Hipóteses para a média

Ex.: A taxa de fósforo no sangue em indivíduos sádios tem distribuição aproximadamente $\mathcal{N}(3; (0,6)^2)$. Com o objetivo de saber se no artritismo essa taxa média era alterada, um pesquisador coletou uma amostra de 36 indivíduos doentes e observou a média de $3,12mg/100cc$. Considere $\alpha = 5\%$.

Teste de Hipóteses para a média

- Podemos decidir por rejeitar ou não a hipótese nula construindo a região de rejeição a partir dos valores assumidos pela estatística $\bar{X}$;
- Como ilustração, considere o teste bilateral com σ^2 conhecido.

$$H_0 : \mu = \mu_0 \ \times \ H_1 : \mu \neq \mu_0$$

Sabemos que, sob H_0,

$$P(|Z| > z_{\alpha/2}) = \alpha$$

$$P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < -z_{\alpha/2}\right) + P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{\alpha/2}\right) = \alpha$$

Teste de Hipóteses para a média

$$P\left(\bar{X} < \mu_0 - z_{\alpha/2}\sigma/\sqrt{n}\right) + P\left(\bar{X} > \mu_0 + z_{\alpha/2}\sigma/\sqrt{n}\right) = \alpha$$

Assim,

$$R_c = \left\{\bar{x} : \bar{x} < \mu_0 - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \text{ ou } \bar{x} > \mu_0 + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right\}$$

De forma análoga é possível encontrar a Região Crítica para outras hipóteses formuladas.

Teste de Hipóteses para a proporção

Hipóteses da forma:

- $H_0 : p = p_0 \times H_1 : p \neq p_0$ (Bilateral);
- $H_0 : p = p_0 \times H_1 : p < p_0$ (Unilateral à esquerda);
- $H_0 : p = p_0 \times H_1 : p > p_0$ (Unilateral à Direita)

Teste de Hipóteses para a proporção

A **Estatística de Teste**, sob H_0, é dada por

Estatística de Teste:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim \mathcal{N}(0,1)$$

Teste de Hipóteses para a proporção

A **Região Crítica ou de Rejeição** R_c dependerá das hipóteses a serem testadas:

(a) $H_0 : p = p_0 \ \times \ H_1 : p \neq p_0$

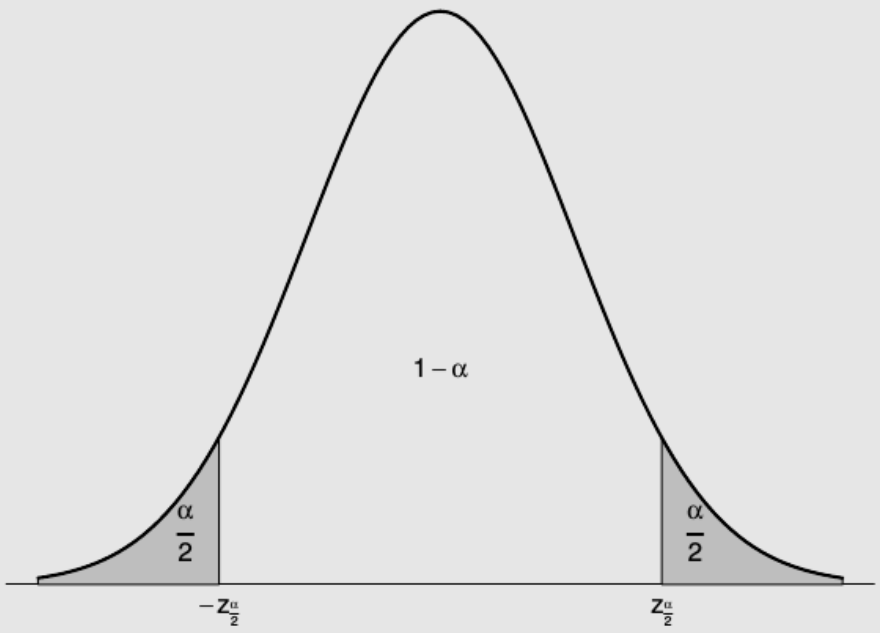

$$R_c = \{z : |z| > z_{\alpha/2}\}$$

Teste de Hipóteses para a proporção

(b) $H_0 : p \geq p_0 \ (p = p_0) \ \times \ H_1 : p < p_0$

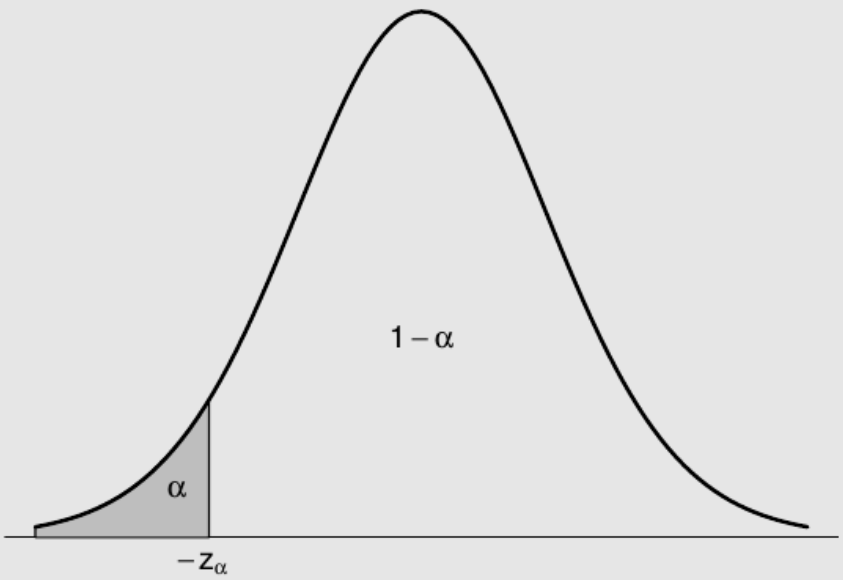

$$R_c = \{z : z < -z_\alpha\}$$

Teste de Hipóteses para a proporção

(c) $H_0 : p \leq p_0 \ (p = p_0) \ \times \ H_1 : p > p_0$

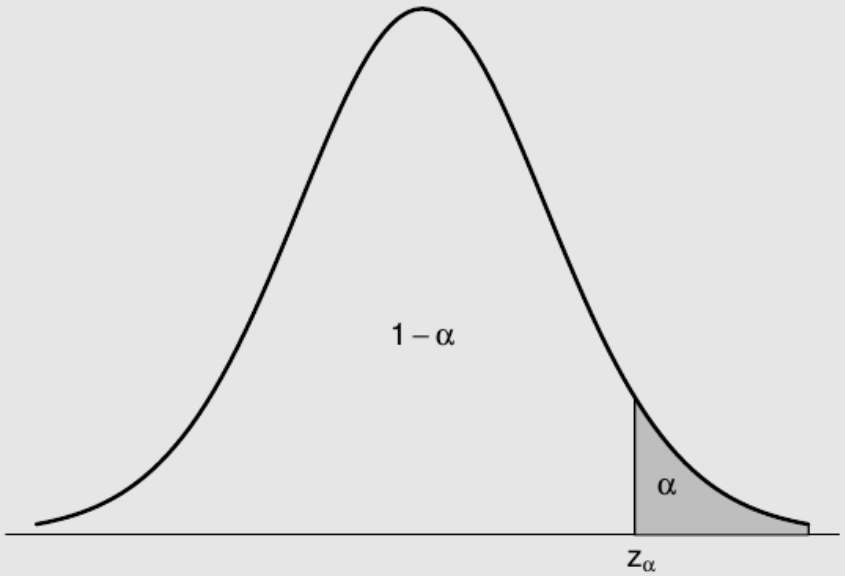

$$R_c = \{z : z > z_\alpha\}$$

Teste de Hipóteses para a proporção

Regra de Decisão

Se o valor da estatística Z, dito z, pertencer a Região Crítica ($z \in R_c$) rejeitamos H_0 ao nível de significância α.

Teste de Hipóteses para a proporção

Ex.: Um estudo é realizado para determinar a presença de pequenas anomalias em chapa metálicas de uma certa dimensão. Segundo o fabricante, a proporção de chapas em anomalias é inferior a 25%. Foram inspecionados 50 chapas escolhidas ao acaso e 7 delas apresentaram algum tipo de anomalia. Estes resultados justificam a afirmação do fabricante ? Considere $\alpha = 0,05$.