Probabilidade

Cleber Martins Xavier
Universidade Federal de Sergipe

Universidade Federal de Sergipe

Motivação

Motivação

Objetivo: Definir um modelo estatístico que seja adequado à descrição e interpretação de fenômenos aleatórios.

A princípio, vamos definir alguns conceitos básicos:

- **Experimentos ou fenômenos aleatórios ($\mathcal{E}$):** são situações ou acontecimentos cujos resultados não podem ser previstos com certeza, sob condições idênticas.
  Ex.: $\mathcal{E}_1$: Lançamento de um dado ou moeda;
  $\mathcal{E}_2$: Tempo de vida útil de um componente;

Motivação

Na realização de um experimento aleatório não podemos afirmar que um resultado particular ocorrerá, porém, podemos descrever o conjunto de todos os possíveis resultados do experimento.

- **Espaço amostral (Ω)**: refere-se ao conjunto de todos os possíveis resultados de um experimento ou fenômeno aleatório

$$\Omega = \{\omega_1, \omega_2, \ldots, \omega_n, \ldots\}$$

Ex.: Nos experimentos listados anteriormente, os espaços amostrais são:
$\Omega_1 = \{1, 2, 3, 4, 5, 6\}$ ou $\Omega_1\{C, K\}$ em que C=cara e K=coroa
$\Omega_2 = [0, +\infty)$

Motivação

- **Evento:** qualquer subconjunto do espaço amostral Ω de um experimento aleatório.
  Notação: $A, B, C, D, \ldots$ ou $A_1, A_2, A_3, \ldots$
  Note que se A é um evento, então $A \subseteq \Omega$

Tipos de eventos

- **Evento simples ou elementar:** é o evento formado por um único ponto amostral (conjunto unitário). **Ex.:** $A = \{\omega\}$
- **Evento composto:** é o evento formado por dois ou mais pontos do espaço amostral. **Ex.:** $A = \{\omega_1, \omega_2\}$
- **Evento certo:** é o evento formado por todos os pontos amostrais. **Ex.:** $A = \Omega$

Motivação

- **Evento impossível:** é o evento que não possi elementos de Ω, isto é, evento vazio. **Ex.:** $A = \varnothing$ ou $A = \{\}$

Alguns exemplos:

- A_1 : Resultado é "cara" $\Rightarrow A_1 = \{C\}$
- B_1 : Resultado maior do que 6 $\Rightarrow B_1 = \{\}$ ou $B_1 = \varnothing$
- C_1 : Resultado maior ou igual a 1 $\Rightarrow C_1 = \{1, 2, 3, 4, 5, 6\}$
- D_1 : Tempo de vida útil superior a 1000 hs $\Rightarrow D_1 = (1000, +\infty)$

Operações com eventos

Operações com eventos

Para ilustrar graficamente eventos é costume utilizar-se os mesmos diagramas usados na teoria dos conjuntos (Diagrama de Venn).

Considere eventos definidos em um espaço amostral Ω de um experimento aleatório.

- **União de eventos ($A \cup B$):** é o evento definido por todos os elementos que pertencem a A, ou a B, ou a ambos.

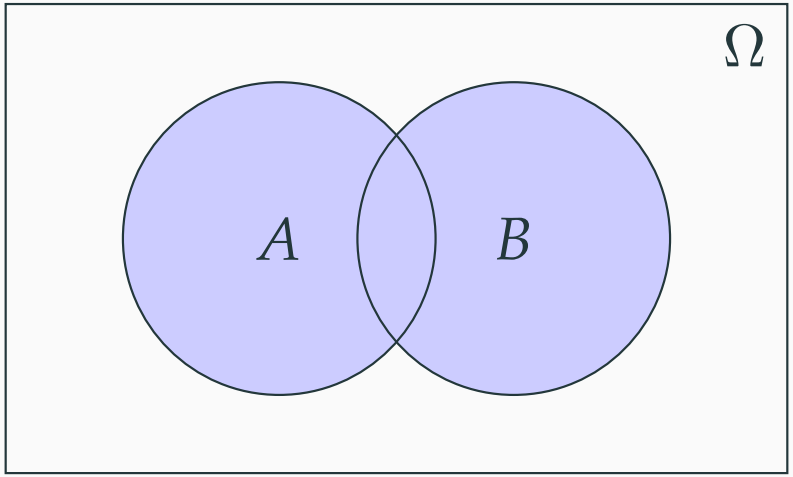

Operações com eventos

- **Intersecção de eventos ($A \cap B$):** é o evento definido por todos os elementos que pertencem a A e a B.

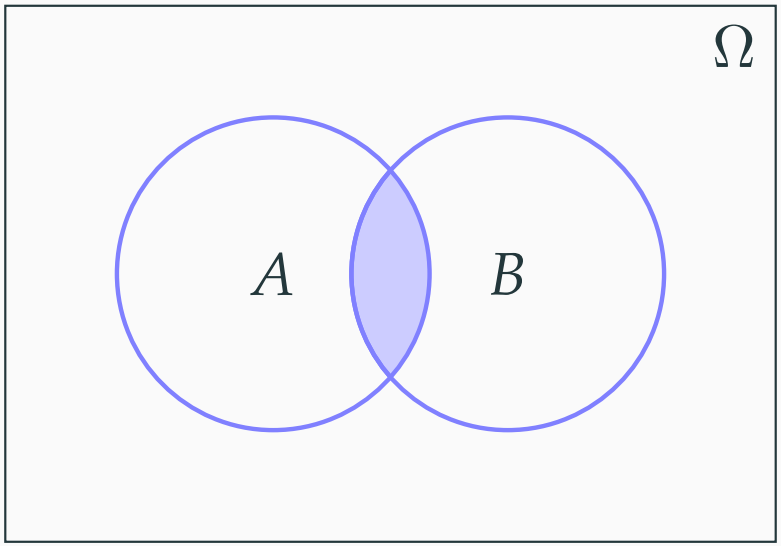

Operações com eventos

Casos particulares:

- Se $B \subseteq A$, então $A \cap B = B$

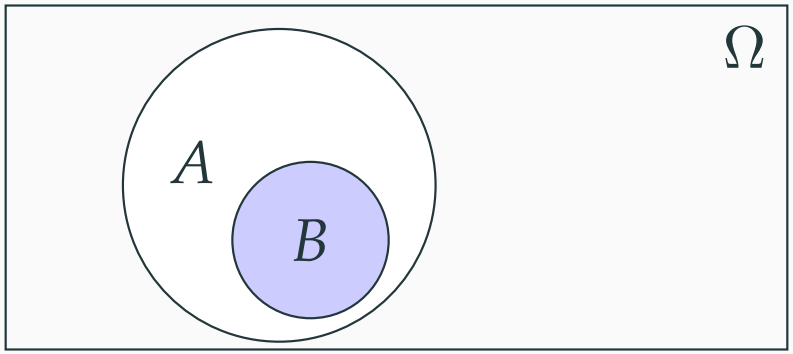

- Se A e B são disjuntos ou eventos mutuamente exclusivos (não tem elementos comuns), $A \cap B = \varnothing$

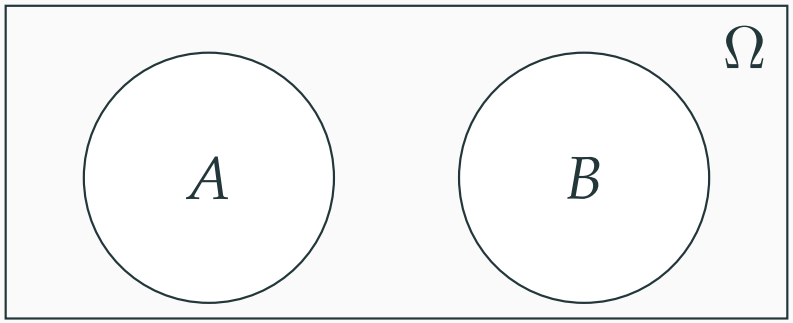

Operações com eventos

- **Diferença de eventos ($B - A$)**: é o evento definido pelos elementos de B que não pertecem a A.

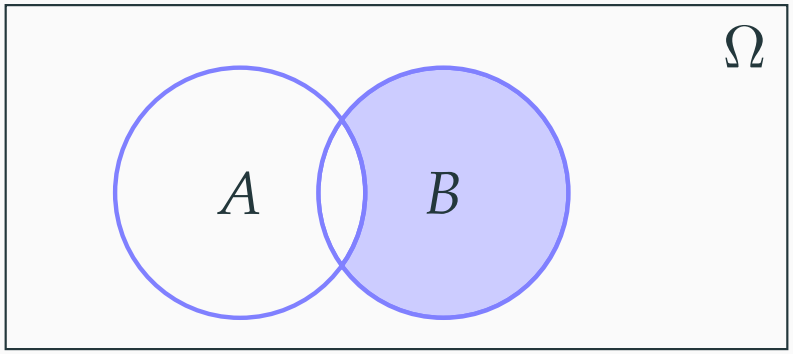

- **Evento complementar ($\overline{A}$ ou A^c)**: é o evento formado por todos os elementos de Ω que não estão em A.

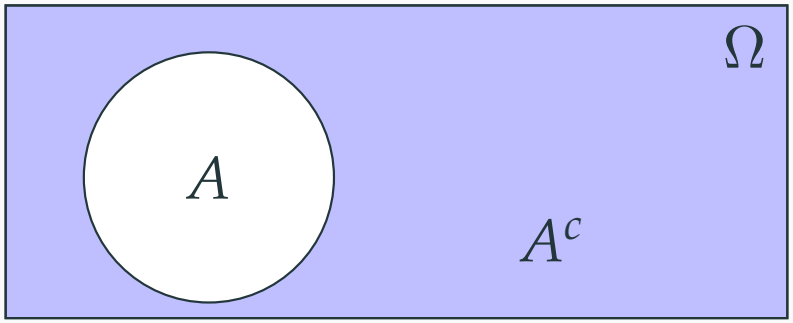

Operações com eventos

Alguns exemplos de eventos complementares:

- $(A \cup B)^c = A^c \cap B^c$ (Lei de De Morgan)

Operações com eventos

Alguns exemplos de eventos complementares:

- $(A \cup B)^c = A^c \cap B^c$ (Lei de De Morgan)

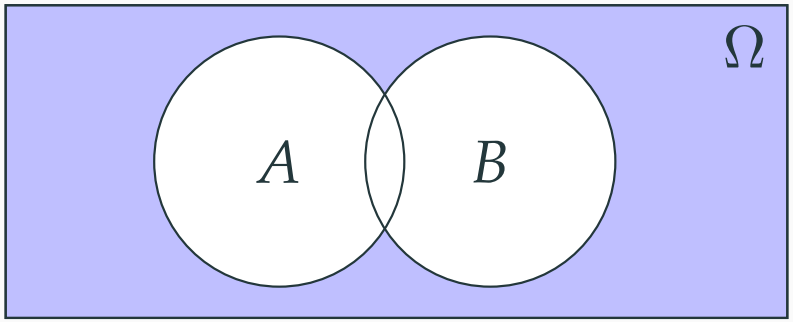

- $(A \cap B)^c = A^c \cup B^c$ (Lei de De Morgan)

Operações com eventos

Alguns exemplos de eventos complementares:

- $(A \cup B)^c = A^c \cap B^c$ (Lei de De Morgan)

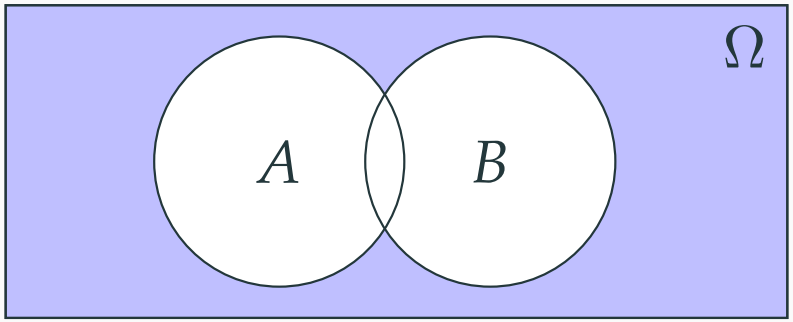

- $(A \cap B)^c = A^c \cup B^c$ (Lei de De Morgan)

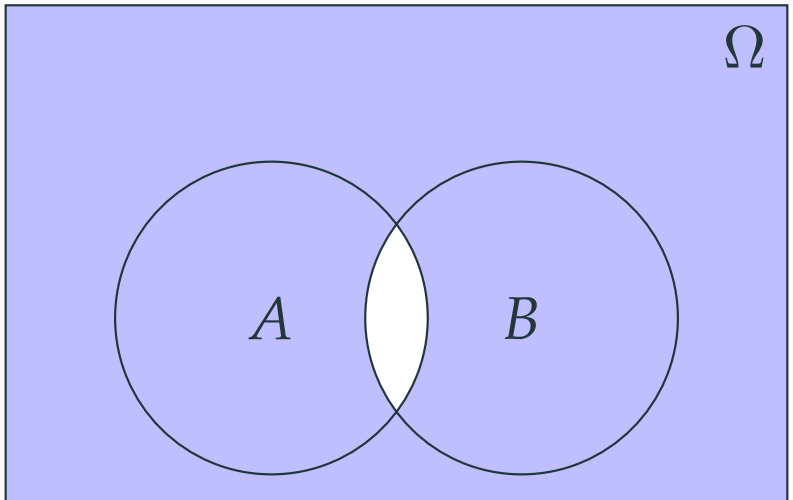

Operações com eventos

- $A \cup B^c = (A \cap B^c) \cup (A \cap B) \cup (A^c \cap B^c)$ ou $\Omega - (A^c \cap B)$

Operações com eventos

- $A \cup B^c = (A \cap B^c) \cup (A \cap B) \cup (A^c \cap B^c)$ ou $\Omega - (A^c \cap B)$

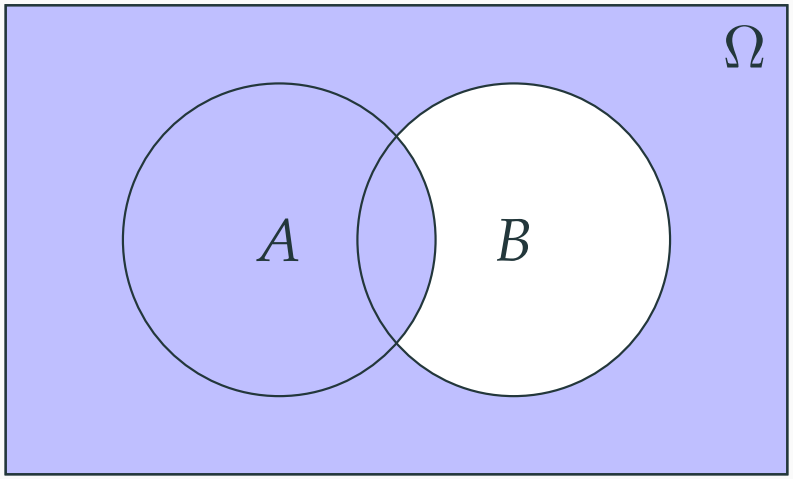

- $A \cap B^c = (A \cup B) \cap B^c$ ou $A - (A \cap B)$

Operações com eventos

- $A \cup B^c = (A \cap B^c) \cup (A \cap B) \cup (A^c \cap B^c)$ ou $\Omega - (A^c \cap B)$

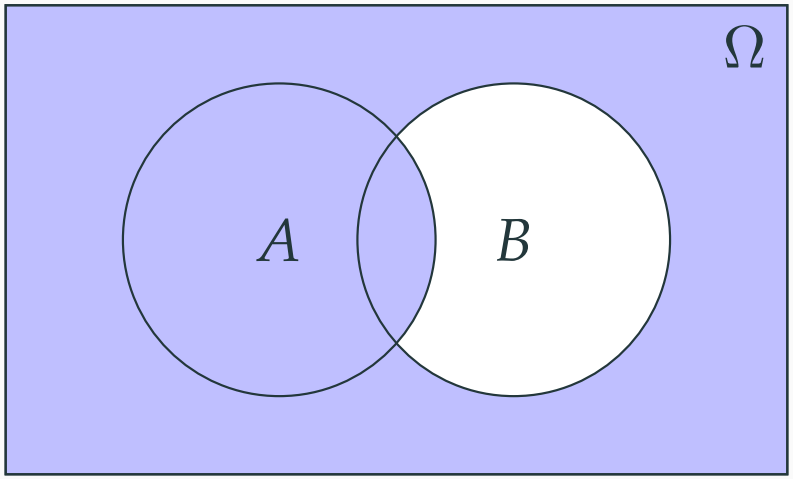

- $A \cap B^c = (A \cup B) \cap B^c$ ou $A - (A \cap B)$

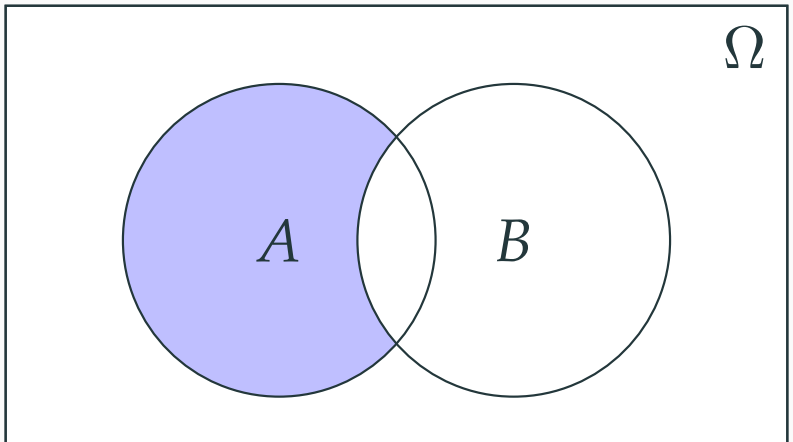

Operações com eventos

Outras operações:

- $A \cap \varnothing = \varnothing, \forall A;$
- $A \cup \varnothing = A;$
- $\varnothing^c$ ou $\overline{\varnothing} = \Omega;$
- Ω^c ou $\overline{\Omega} = \varnothing;$
- $(A^c)^c = A;$
- $B = (A \cap B) \cup (A^c \cap B);$
- $A = (A \cap B) \cup (A \cap B^c);$

Operações com eventos

Exemplo: Escrever $A \cup B$ como sendo a união de eventos disjuntos.

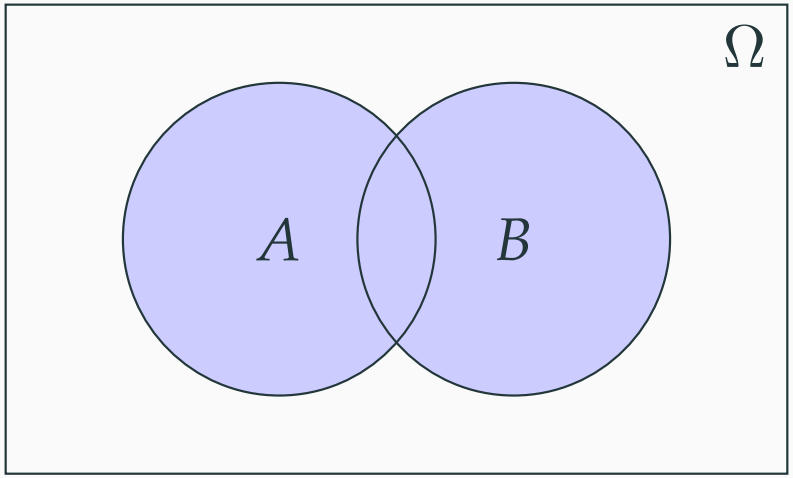

$$A \cup B = A \cup (A^c \cap B)$$

Verificando se A e $(A^c \cap B)$ são disjuntos:

$$\begin{aligned} A \cap (A^c \cap B) &= (A \cap A^c) \cap B \\ &= \varnothing \cap B \\ &= \varnothing \end{aligned}$$

Probabilidade

Probabilidade: Definição

- **Definição de probabilidade em espaços equiprováveis:** Se um experimento aleatório tiver n resultados possíveis, $\Omega = \{\omega_1, \ldots, \omega_n\}$, mutuamente exclusivos e igualmente possíveis e, se um evento A tiver n_A desses resultados, então a probabilidade do evento A, representada por $P(A)$, é dada por

$$P(A) = \frac{n_A}{n}$$

Probabilidade

Ex.: Lançamento de duas moedas honestas. Calcular a probabilidade de:

a) Obter duas faces iguais.

b) Obter pelo menos uma face diferente de cara.

1ª moeda	2ª Moeda	
	C	K
C	(C,C)	(C,K)
K	(K,C)	(K,K)

Ex.: Lançamento de duas moedas honestas. Calcular a probabilidade de:

a) Obter duas faces iguais.

b) Obter pelo menos uma face diferente de cara.

1ª moeda	2ª Moeda	
	C	K
C	(C,C)	(C,K)
K	(K,C)	(K,K)

R.a) $P(A) = \frac{n_A}{n} = \frac{2}{4} = \frac{1}{2}$

b) $P(B) = \frac{n_B}{n} = \frac{3}{4}$

Probabilidade: Definição

- **Definição de probabilidade axiomática:** A probabilidade de um evento A é definida como sendo um número $P(A)$ satisfazendo aos seguintes axiomas:

  1- $P(A) \geq 0, \forall A \subseteq \Omega$

  2- $P(\Omega) = 1$

  3- Se $A_1, A_2, \ldots$ são eventos mutuamente exclusivos, então

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Probabilidade: Definição

Propriedades:

- $0 \leq P(A) \leq 1$
- $P(\varnothing) = 0$
- Se $A \subseteq \Omega$, então $P(A) = 1 - P(A^c)$
- Se $A \subseteq B \subseteq \Omega$, então $P(A) \leq P(B)$
- Se $A, B \subseteq \Omega$, então $P(B) = P(B \cap A) + P(B \cap A^c)$
- Se $A, B \subseteq \Omega$, então $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- Se $A, B, C \subseteq \Omega$, então

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) \\ &- P(B \cap C) + P(A \cap B \cap C) \end{aligned}$$

Probabilidade: Definição

Exercício: Considere um experimento aleatório e os eventos A e B associados, tais que $P(A) = 1/2$, $P(B) = 1/2$ e $P(A \cap B) = 1/4$. Calcule as probabilidades:

a) $P(A^c \cap B^c)$

b) $P(A^c \cup B^c)$

Probabilidade: Definição

Exercício: Considere um experimento aleatório e os eventos A e B associados, tais que $P(A) = 1/2$, $P(B) = 1/2$ e $P(A \cap B) = 1/4$. Calcule as probabilidades:

a) $P(A^c \cap B^c)$

b) $P(A^c \cup B^c)$

R.: a) $(A^c \cap B^c) = (A \cup B)^c$, logo

$P(A^c \cap B^c) = P((A \cup B)^c) = 1 - P(A \cup B) =$

$1 - \{P(A) + P(B) - P(A \cap B)\} = 1 - \{\frac{1}{2} + \frac{1}{2} - \frac{1}{4}\} = \frac{1}{4}$

b)$(A^c \cup B^c) = (A \cap B)^c$, logo

$P(A^c \cup B^c) = P((A \cap B)^c) = 1 - P(A \cap B) = 1 - \frac{1}{4} = \frac{3}{4}$

Probabilidade Condicional

Def.: Sejam A e B dois eventos definidos em um mesmo espaço amostral Ω. A probabilidade condicional de A dado que o ocorreu o evento B, denotado por $P(A|B)$, é definido como

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \text{ se } P(B) > 0$$

Consequentemente, podemos escrever

$$P(A \cap B) = P(A|B).P(B)$$

conhecida como a regra do produto de probabilidades.

Probabilidade Condicional

Ex.: Suponha que um escritório possua 100 computadores dos tipos desktop (D) e laptop (L) sendo alguns novos (N) e outros com um certo tempo de uso (U), distribuídos da seguinte forma

	D	L	Total
N	40	30	70
U	20	10	30
Total	60	40	100

Um funcionário escolhe um laptop ao acaso. Qual a probabilidade de que seja novo?

Probabilidade Condicional

Ex.: Suponha que um escritório possua 100 computadores dos tipos desktop (D) e laptop (L) sendo alguns novos (N) e outros com um certo tempo de uso (U), distribuídos da seguinte forma

	D	L	Total
N	40	30	70
U	20	10	30
Total	60	40	100

Um funcionário escolhe um laptop ao acaso. Qual a probabilidade de que seja novo?

R.: $P(N|L) = \frac{P(N \cap L)}{P(L)} = \frac{30/100}{40/100} = \frac{30}{40} = 0.75$

Árvore de Probabilidades

Seja $A, B \subseteq \Omega$. Uma representação bastante útil é a árvore de probabilidades.

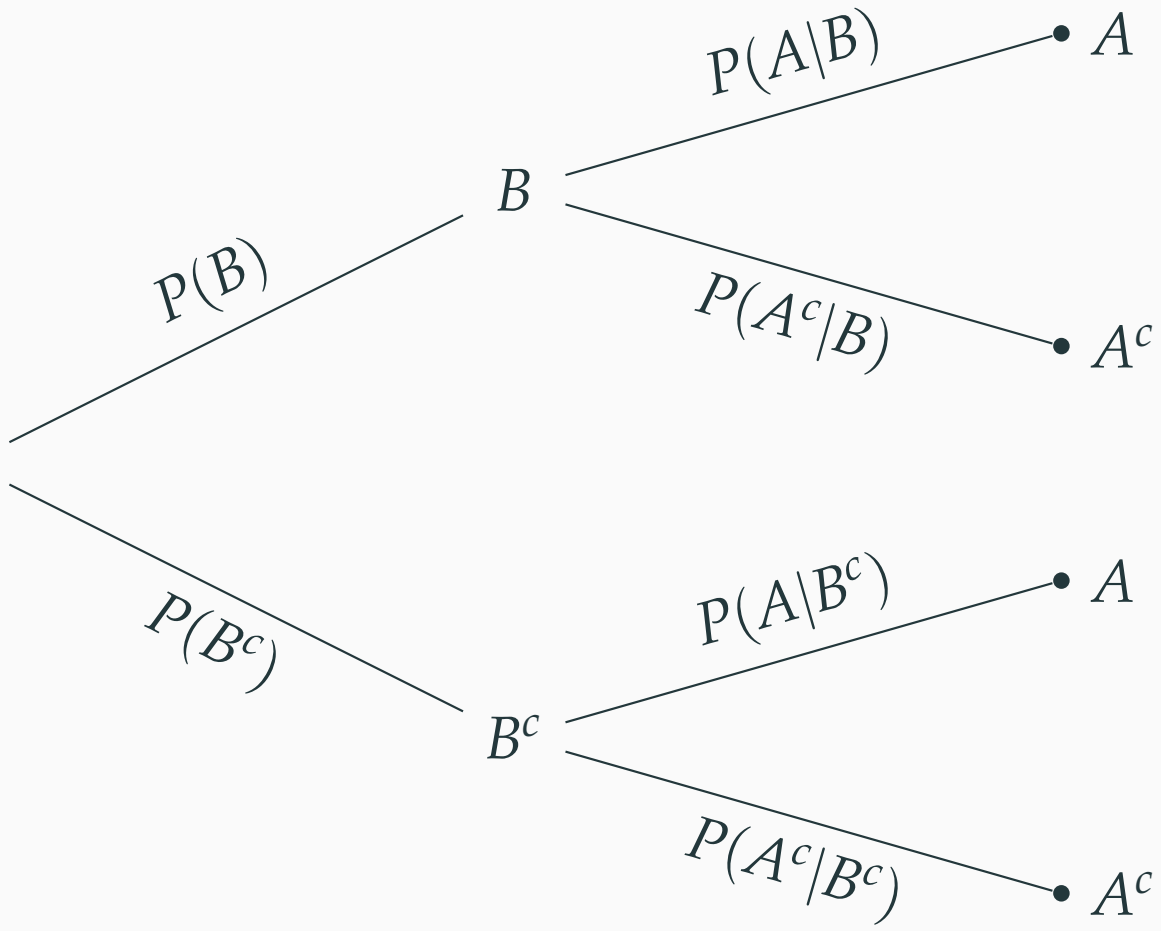

Árvore de Probabilidades

Ex.: No problema dos computadores, qual a probabilidade de um funcionário selecionar um desktop usado?

Árvore de Probabilidades

Ex.: No problema dos computadores, qual a probabilidade de um funcionário selecionar um desktop usado?

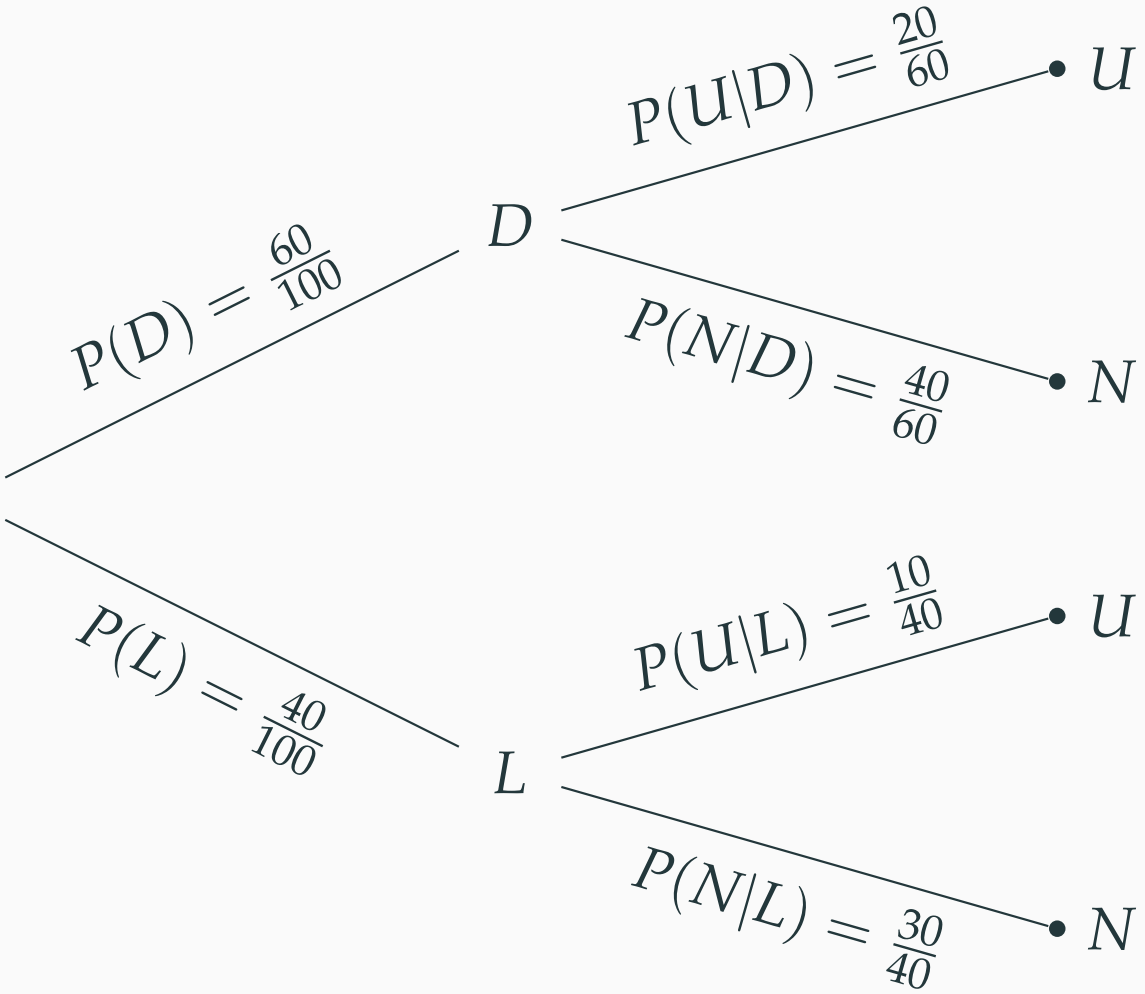

Probabilidade Condicional

Algumas propriedades:

- **a)** $P(\varnothing|B) = 0$
- **b)** Se $A \subseteq \Omega$ então $P(A^c|B) = 1 - P(A|B)$
- **c)** Se $A, C \subseteq \Omega$ então

$$P(A \cup C|B) = P(A|B) + P(C|B) - P(A \cap C|B)$$

Independência de Eventos

Def.: Dois eventos A e B definidos em Ω são independentes se a informação da ocorrência ou não de B não altera a probabilidade de ocorrência de A. Isto é,

$$P(A|B) = P(A), \text{ se } P(B) > 0$$

Logo, dois eventos A e B são independentes se, e somente se,

$$P(A \cap B) = P(A)P(B).$$

Independência de Eventos

Ex.: Um estudante se inscreve em dois processos seletivos com probabilidade 30% de ser aprovado na empresa I e 50% de ser aprovado na empresa II. Se as aprovações forem independentes, qual a probabilidade de que ele seja aprovado em pelo menos uma ?

Independência de Eventos

Ex.: Um estudante se inscreve em dois processos seletivos com probabilidade 30% de ser aprovado na empresa I e 50% de ser aprovado na empresa II. Se as aprovações forem independentes, qual a probabilidade de que ele seja aprovado em pelo menos uma ?

R.: Definindo os eventos:

$$A = \{\text{O estudante é aprovado na empresa I}\}$$
$$B = \{\text{O estudanto é aprovado na empresa II}\}$$

$$\begin{aligned} P(A \cup B) &= P(A) + P(B) - P(A \cap B) \\ &= P(A) + P(B) - P(A)P(B) \\ &= 0.3 + 0.5 - (0.3)(0.5) \end{aligned}$$

Independência de 3 eventos

Os eventos A, B e C em Ω são independentes se, e somente se,

- **a)** $P(A \cap B) = P(A)P(B)$
- **b)** $P(A \cap C) = P(A)P(C)$
- **c)** $P(B \cap C) = P(A)P(C)$
- **d)** $P(A \cap B \cap C) = P(A)P(B)P(C)$

Independência de Eventos

Resultado: Se A e B são eventos independentes em Ω, então:

- **i)** A e B^c são independentes;
- **ii)**A^c e B são independentes;
- **iii)** A^c e B^c são independentes;

Dem. (i)

$$\begin{aligned} P(A \cap B^c) &= P(A) - P(A \cap B) \\ &= P(A) - P(A)P(B) \\ &= P(A)(1 - P(B)) \\ &= P(A)P(B^c) \end{aligned}$$

OBS.: **NÃO** confundir eventos mutuamente exclusivos com eventos independentes.

Independência de Eventos

Exercício: Um atirador acerta 80% de seus disparos e outro (nas mesmas condições de tiro) acerta 70%. Qual a probabilidade de o alvo ser acertado se ambos os atiradores dispararem simultaneamente?

Independência de Eventos

Exercício: Um atirador acerta 80% de seus disparos e outro (nas mesmas condições de tiro) acerta 70%. Qual a probabilidade de o alvo ser acertado se ambos os atiradores dispararem simultaneamente?

Eventos:
A={O atirador 1 acerta o alvo} e B={O atirador 2 acerta o alvo}

$$\begin{aligned} P(A \cup B) &= P(A) + P(B) - P(A \cap B) \\ &= P(A) + P(B) - P(A)P(B) \\ &= 0.8 + 0.7 - (0.8)(0.7) \\ &= 1.5 - 0.56 \\ &= 0.94 \end{aligned}$$

O Teorema de Bayes

a) Partição do espaço amostral: Definição

Uma coleção de eventos $A_1, A_2, \ldots, A_k$ forma uma partição do espaço amostral se:

i) $A_i \cap A_j = \varnothing, \forall i \neq j, \quad i, j = 1, 2, \ldots, k$

ii) $\bigcup_{i=1}^{k} A_i = \Omega.$

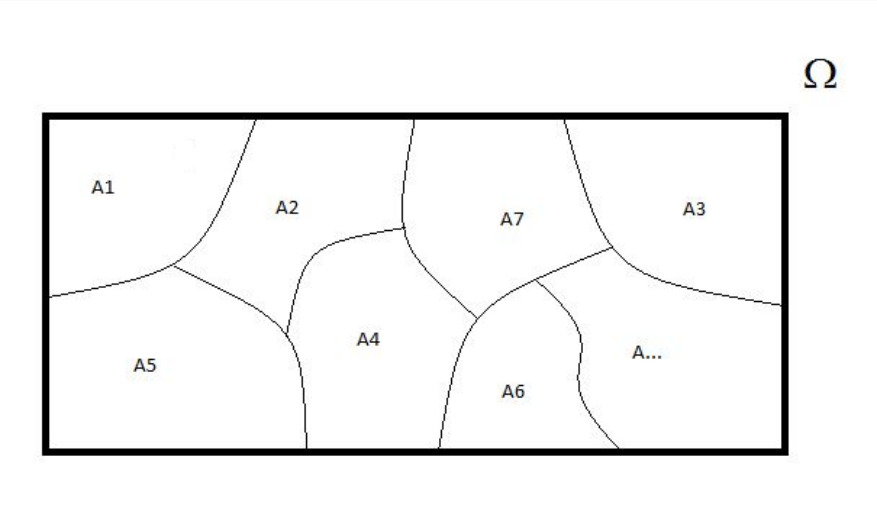

O Teorema de Bayes

b) Lema da probabilidade total:

Se $A_1, A_2, \ldots, A_k$ é uma partição de Ω, então para qualquer evento B de Ω, vale:

$$P(B) = \sum_{i=1}^{k} P(B \cap A_i) = \sum_{i=1}^{k} P(B|A_i)P(A_i)$$

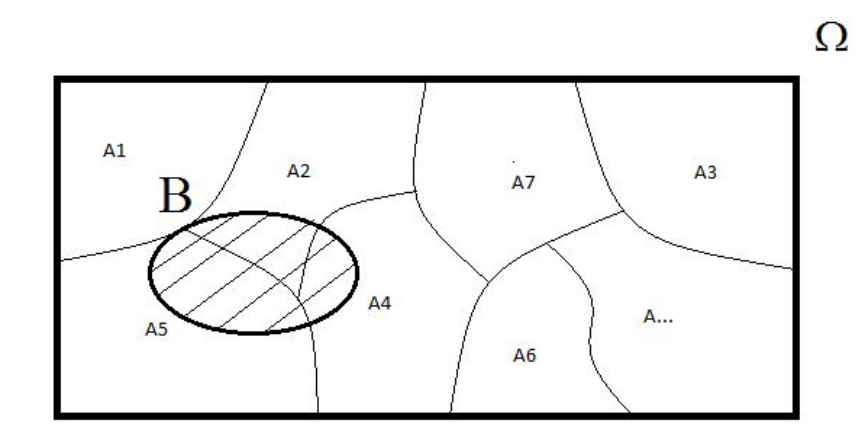

O Teorema de Bayes

Fórmula de Bayes: Se $A_1, A_2, \ldots, A_k$ formam uma partição de Ω e $B \subseteq \Omega$, com $P(B) > 0$, então

$$P(A_i|B) = \frac{P(A_i \cap B)}{P(B)} = \frac{P(B|A_i)P(A_i)}{\sum_{i=1}^{k} P(B|A_i)P(A_i)}$$

O Teorema de Bayes

Fórmula de Bayes: Se $A_1, A_2, \ldots, A_k$ formam uma partição de Ω e $B \subseteq \Omega$, com $P(B) > 0$, então

$$P(A_i|B) = \frac{P(A_i \cap B)}{P(B)} = \frac{P(B|A_i)P(A_i)}{\sum_{i=1}^{k} P(B|A_i)P(A_i)}$$

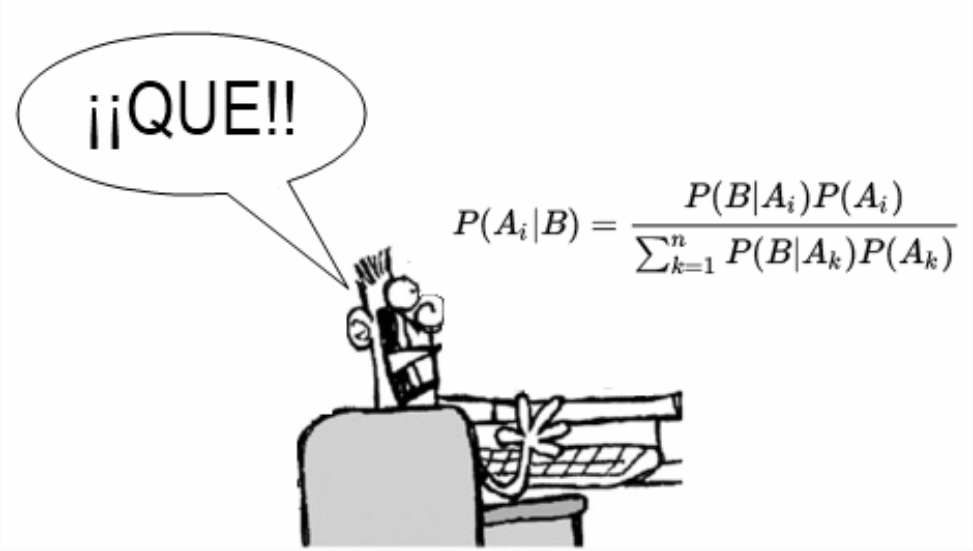

O Teorema de Bayes

Ex.: Uma montadora trabalha com dois fornecedores (A e B) de uma determinada peça. Sabe-se que 10% e 5% das peças provenientes dos fornecedores A e B, respectivamente, estão fora das especificações. A montadora recebe 30% das peças do fornecedor A e 70% do fornecedor B. Se uma peça do estoque inteiro é escolhida ao acaso, calcule:

a) A probabilidade de que ela esteja fora das especificações.

O Teorema de Bayes

Ex.: Uma montadora trabalha com dois fornecedores (A e B) de uma determinada peça. Sabe-se que 10% e 5% das peças provenientes dos fornecedores A e B, respectivamente, estão fora das especificações. A montadora recebe 30% das peças do fornecedor A e 70% do fornecedor B. Se uma peça do estoque inteiro é escolhida ao acaso, calcule:
a) A probabilidade de que ela esteja fora das especificações.

Eventos:
A={A peça é do fornecedor A}, B={A peça é do fornecedor B} e C={A peça está fora das especificações}
$P(A) = 0.3; P(B) = 0.7; P(C|A) = 0.1; P(C|B) = 0.05$

$$\begin{aligned} P(C) &= P(A \cap C) + P(B \cap C) = P(C|A)P(A) + P(C|B)P(B) \\ &= (0.1)(0.3) + (0.05)(0.7) = 0.065 \end{aligned}$$

O Teorema de Bayes

b) Se uma peça escolhida ao acaso está fora das especificações, qual é a probabilidade de que tenha sido fornecida por A ?

O Teorema de Bayes

b) Se uma peça escolhida ao acaso está fora das especificações, qual é a probabilidade de que tenha sido fornecida por A ?

$$
\begin{aligned}
P(A|C) &= \frac{P(A \cap C)}{P(C)} \\
&= \frac{P(C|A)P(A)}{P(C|A)P(A) + P(C|B)P(B)} \\
&= \frac{(0.1)(0.3)}{0.065} \\
&= 0.4615
\end{aligned}
$$

O Teorema de Bayes

Ex.: Estudos reveleram que 40% dos estudantes universitários já experimentaram algum tipo de droga ilícita. Uma universidade resolveu aplicar um teste com um detector de mentira para descobrir se seus estudantes já usaram algum tipo de droga ilícita. Sabemos que se o estudante já usou algum tipo de droga o detector vai dar positivo com certeza. Porém sabemos que o detector erra, ou seja, apresenta testes com um falso positivo, em 5% quando aplicado em estudantes que nunca usaram drogas. Se um estudante é selecionado aleatoriamente e o teste aplicado nele deu positivo, qual a probabilidade dele já ter usado algum tipo de droga ?

O Teorema de Bayes

Ex.: Estudos reveleram que 40% dos estudantes universitários já experimentaram algum tipo de droga ilícita. Uma universidade resolveu aplicar um teste com um detector de mentira para descobrir se seus estudantes já usaram algum tipo de droga ilícita. Sabemos que se o estudante já usou algum tipo de droga o detector vai dar positivo com certeza. Porém sabemos que o detector erra, ou seja, apresenta testes com um falso positivo, em 5% quando aplicado em estudantes que nunca usaram drogas. Se um estudante é selecionado aleatoriamente e o teste aplicado nele deu positivo, qual a probabilidade dele já ter usado algum tipo de droga ? **Eventos:** A={O estudante usou droga} e B={O teste deu positivo} $P(A) = 0.4; P(A^c) = 0.6; P(B|A) = 1; P(B|A^c) = 0.05$

$P(A|B) = \frac{P(B|A)P(A)}{P(B|A)P(A)+P(B|A^c)P(A^c)} = \frac{1(0.4)}{1(0.4)+0.05(0.6)} = 0.9302$

O Teorema de Bayes

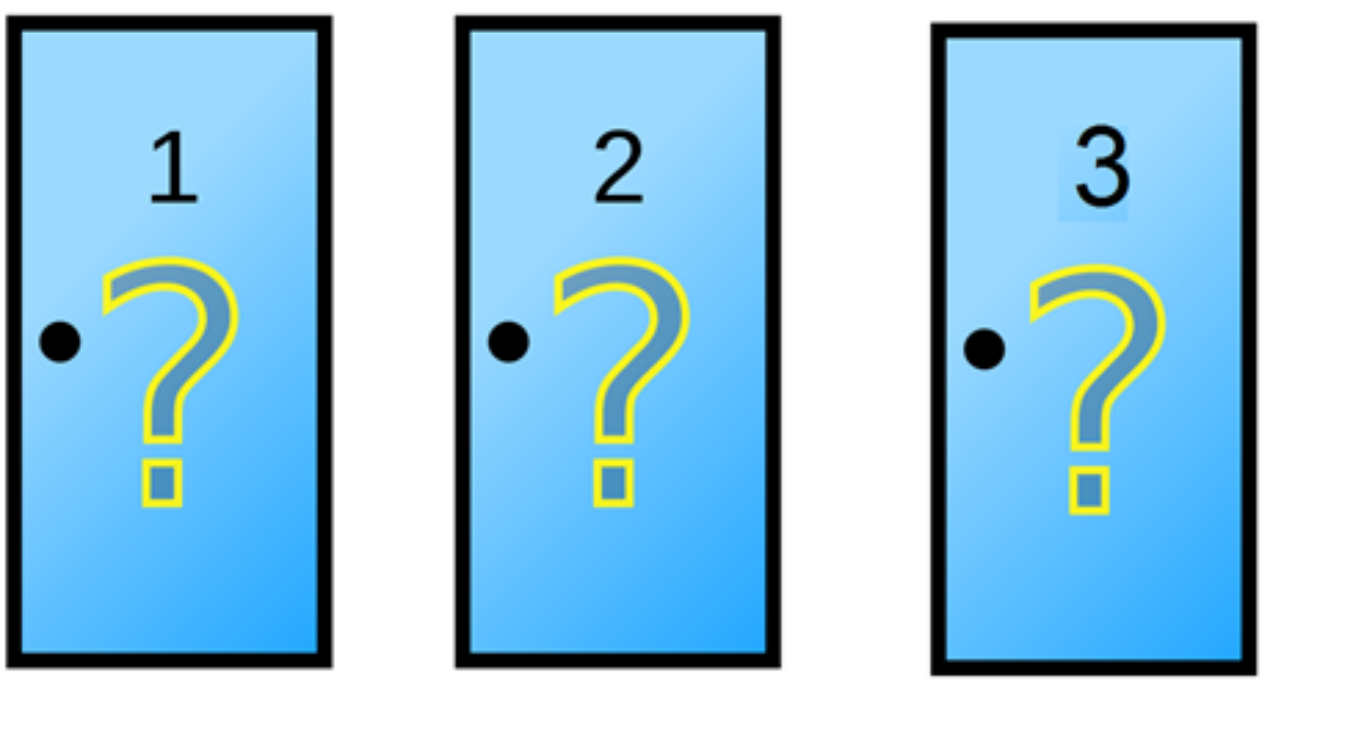

O Teorema de Bayes

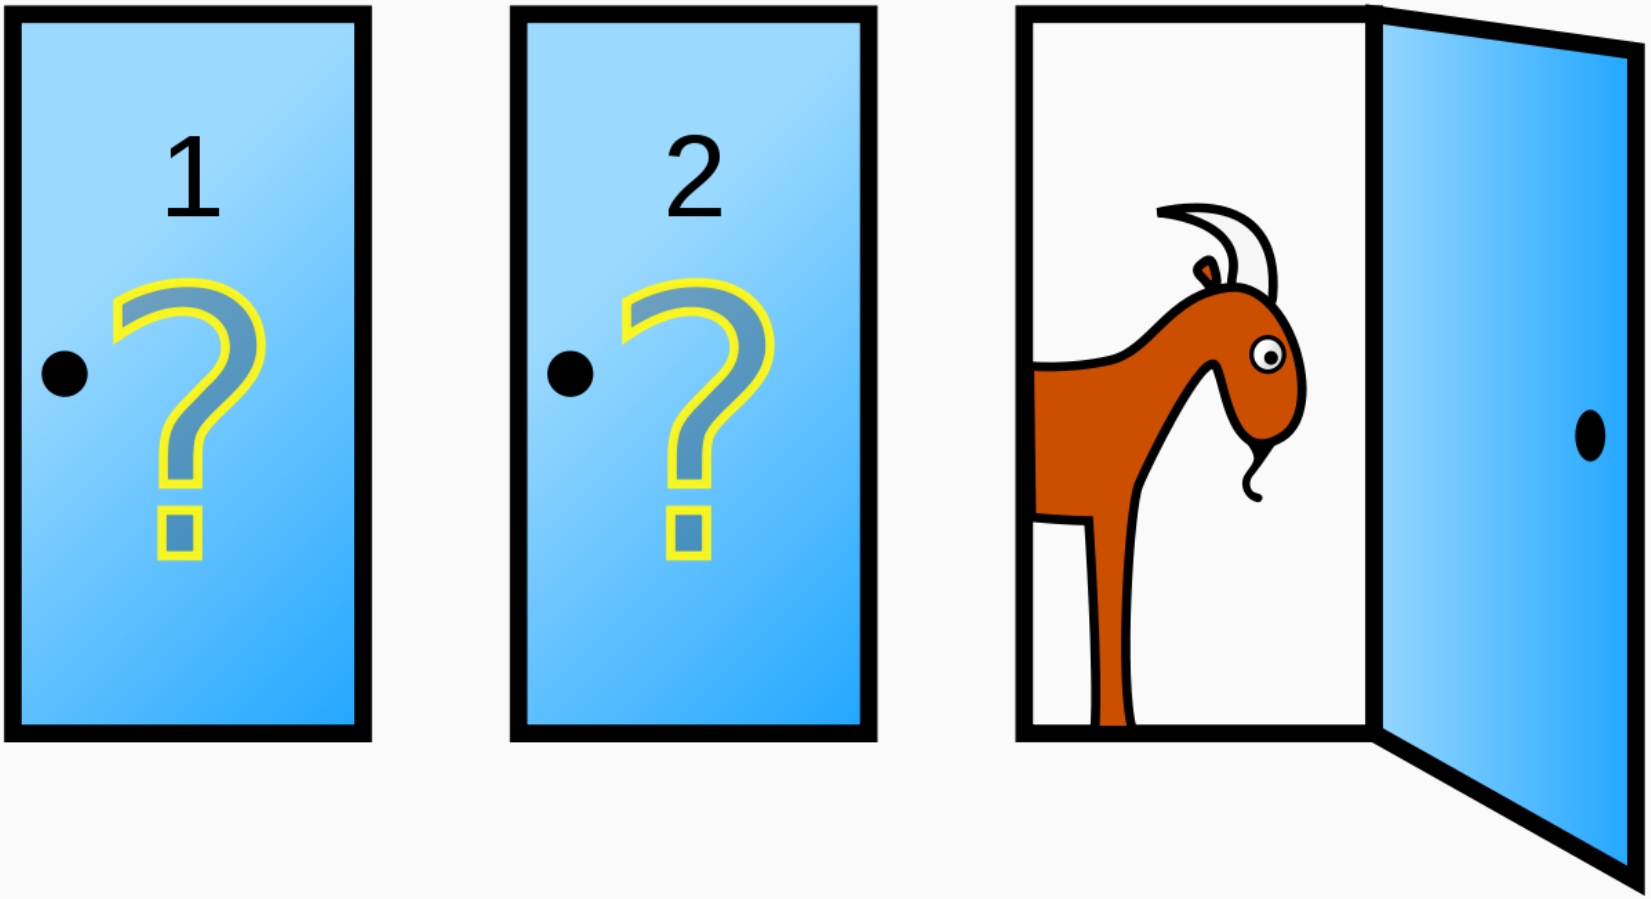

O Teorema de Bayes

George escolheu a porta número 2. A partição do espaço amostral (no momento da escolha da porta 2) é :

- A_1: George escolheu 2 e o prêmio está na porta 1;
- A_2: George escolheu 2 e o prêmio está na porta 2;
- A_3: George escolheu 2 e o prêmio está na porta 3;

$$P(A_i) = \frac{1}{3} \text{ para } i = 1, 2, 3$$

O evento B é Silvio Santos abrir a porta 3. Os condicionais são:

- $P(B|A_1) = 1$ (Silvio só pode abrir a porta 3)
- $P(B|A_2) = 1/2$ (Silvio pode abrir uma das portas)
- $P(B|A_3) = 0$ (Silvio não pode abrir a porta 3)

O Teorema de Bayes

Por Bayes

$$
\begin{aligned}
P(A_1|B) &= \frac{P(A_1 \cap B)}{P(B)} \\
&= \frac{P(B|A_1)P(A_1)}{P(A_1 \cap B) + P(A_2 \cap B) + P(A_3 \cap B)} \\
&= \frac{P(B|A_2)P(A_2)}{P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + P(B|A_3)P(A_3)} \\
&= \frac{1(1/3)}{1(1/3) + 1/2(1/3) + 0(1/3)} = 2/3 = 0,6667
\end{aligned}
$$

George e seu milhão

Variáveis aleatórias

Variáveis aleatórias

Def.: Seja $\mathcal{E}$ um experimento aleatório e Ω o espaço amostral associado a esse experimento. Uma função $X(\omega)$ que associa a cada elemento $\omega \in \Omega$ a um número real $x = x(\omega)$ é denominado **variável aleatória** (v.a) com R_x : valores possíveis de x.

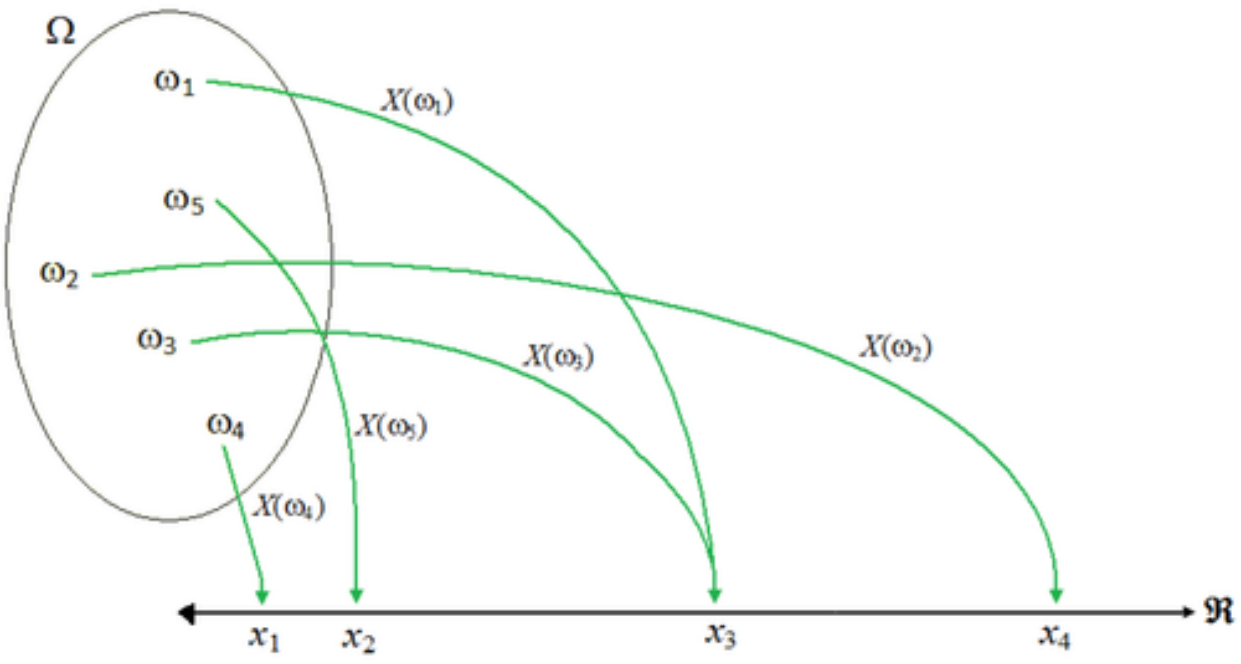

Obs.: $X : \Omega \longrightarrow I\!R$

Variáveis aleatórias

Ex.: Lançamento de uma moeda duas vezes. A variável aleatória X é o número de caras.

$$\Omega = \{(C, C); (C, K); (K, C); (K, K)\}$$

$X : n^{\circ}$ de caras
$R_x = \{0, 1, 2\}$

$$X = \begin{cases} 0, & \text{se ocorrer o evento } A_1 = \{(K, K)\} \\ 1, & \text{se ocorrer o evento } A_2 = \{(K, C); (C, K)\} \\ 2, & \text{se ocorrer o evento } A_3 = \{(C, C)\} \end{cases}$$

Classificação de Variáveis aleatórias

- Se a v.a. X assume valores em um conjunto finito ou infinito enumerável é chamada **variável aleatória discreta**;
- Se X assume valores em um conjunto infinito não-enumerável, é chamada **variável aleatória contínua**;

Exemplos:

- X indica o número de residentes em um domicílio. X pode assumir valores em $\mathbb{N}$ e assim é chamada de v.a. discreta;
- Y indica o tempo de vida do componente eletrônico, em horas. Y pode assumir valores em $\mathbb{R}^+$ e assim é chamada de v.a. contínua;

Variável aleatória discreta

Def.: Seja X uma v.a. discreta que assume valores em R_x, $R_x = \{x_1, x_2, \ldots, x_n, \ldots\}$. A cada possível resultado x_i associamos a um número

$$p(x_i) = P(X(\omega_i) = x_i), \;\; \omega_i \in \Omega \text{ e } x_i \in R_x$$

dita probabilidade de x_i. A função $p(x)$ é definida como função massa de probabilidade de X (f.m.p ou f.p de X).

As probabilidades $p(x_i)$ devem satisfazer as seguintes condições:

i) $p(x_i) \geq 0, \forall x_i \in R_x$

ii) $\sum_{i=1}^{\infty} p(x_i) = 1$

Interpretação da f.p

Seja X uma v.a. discreta com $R_x = \{x_1, x_2, \ldots, x_n\}$ e $p(x_i) = p_i$

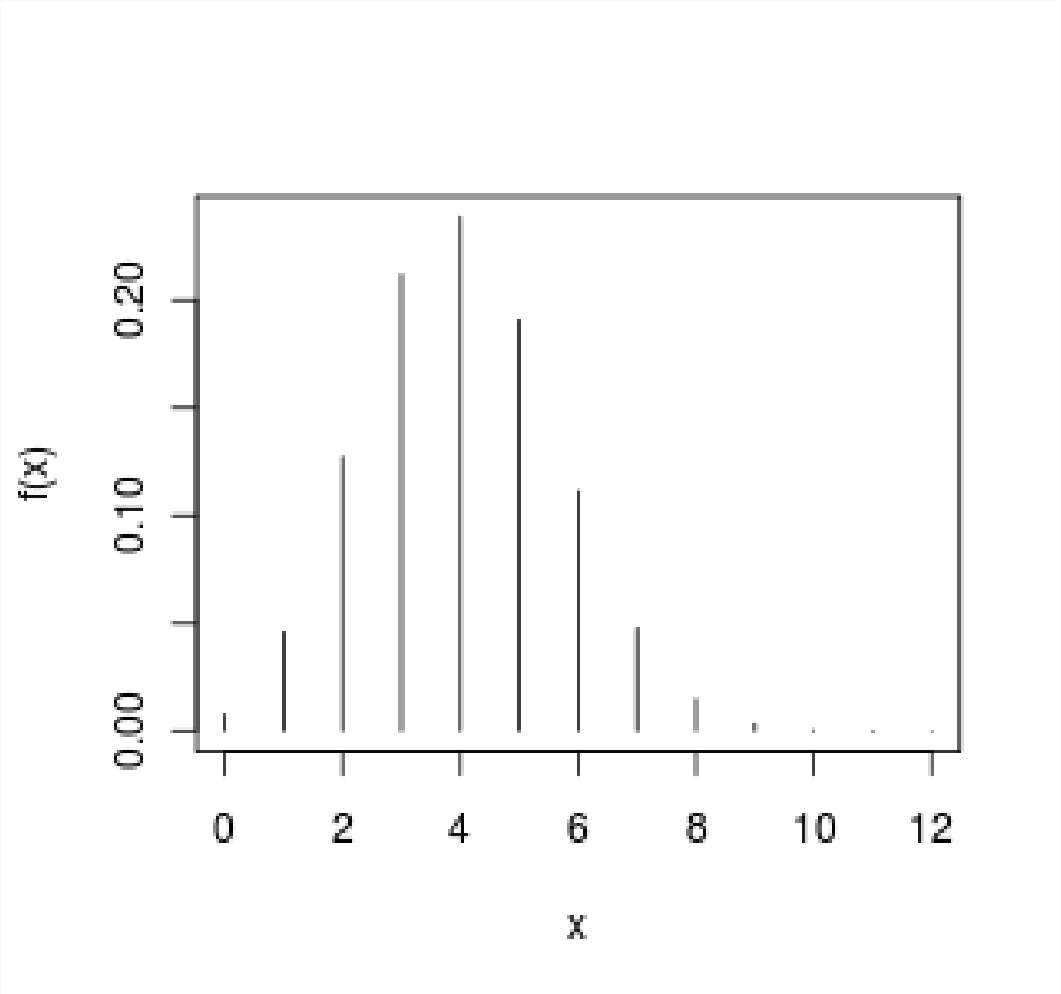

Variável aleatória discreta

Ex.: Lançamento de uma moeda duas vezes. A variável aleatória X é o número de caras.

$$\Omega = \{(C, C); (C, K); (K, C); (K, K)\}$$

$X : n^{\circ}$ de caras

$R_x = \{0, 1, 2\}$

x	0	1	2
P(X=x)	1/4	1/2	1/4

$P(X = 0) = 1/4, P(X = 1) = 1/2, P(X = 2) = 1/4$

Obs.: Devemos observar que:

- $0 \leq P(X = x_i) \leq 1$
- $P(X = 0) + P(X = 1) + P(X = 2) = 1/4 + 1/2 + 1/4 = 1$

Variável aleatória contínua

Def.: Seja X uma v.a. contínua que assume valores em R_x, $R_x \subseteq \mathbb{R}$. A função $f_X(x)$ é a função densidade de probabilidade (f.d.p.) para X, se satisfaz as seguintes propriedades:

i) $f_X(x) \geq 0$, para todo $x \in R_x$;

ii) $\int\limits_{R_x} f_X(x)dx = 1$ ou $(\int\limits_{-\infty}^{\infty} f_X(x)dx = 1)$

iii) $P(a < X < b) = \int\limits_{a}^{b} f_X(x)dx, \forall a, b \in R_x$

Interpretação da f.d.p

Seja X uma v.a. contínua com $R_x \subseteq I\!R$ temos

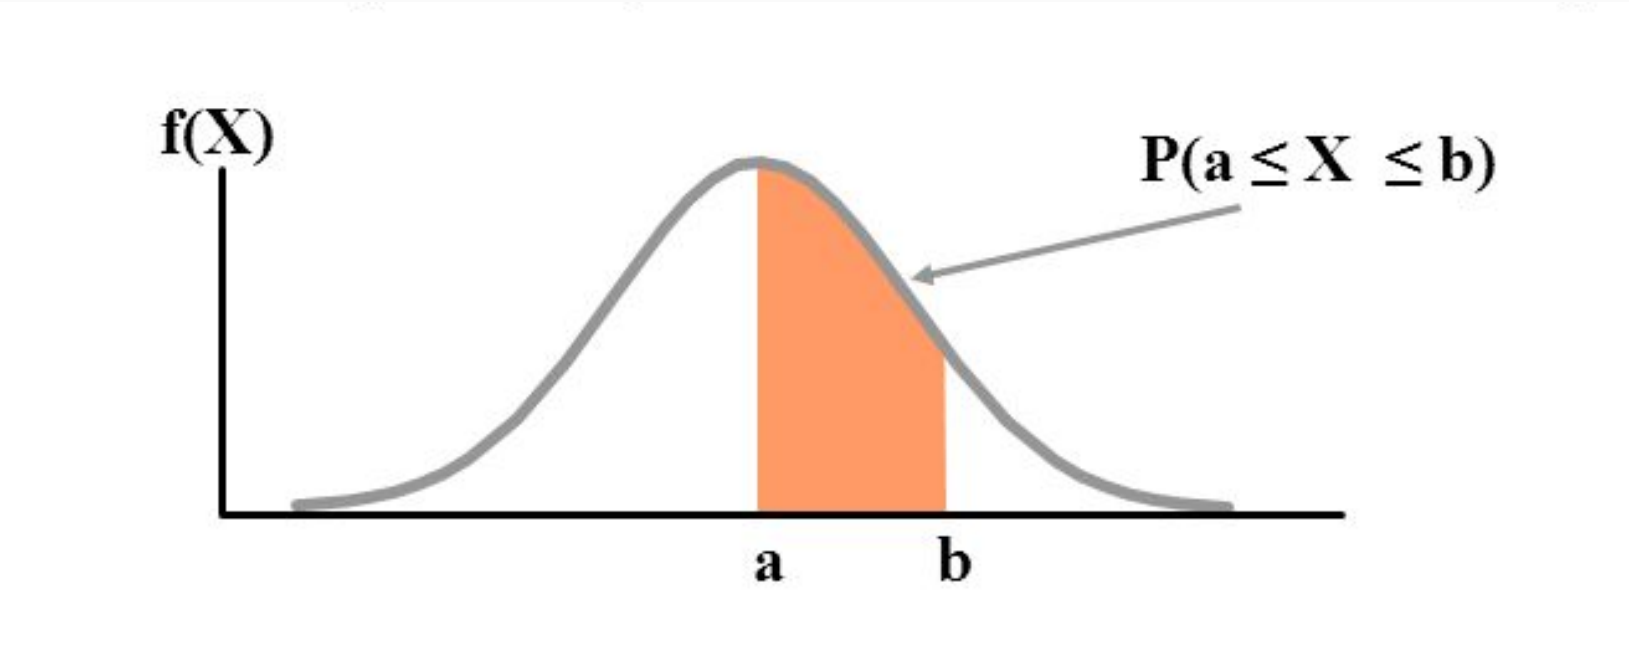

Propriedades

obs.: Se X é uma v.a. contínua assumindo valores em R_x então para todo $a \in R_x$, temos:

a) $P(X = a) = 0$

b) $P(X > a) = P(X \geq a)$

c) $P(X < a) = P(X \leq a)$

d) $P(X > a) = 1 - P(X \leq a) = 1 - P(X < a)$

e) $P(X < a) = 1 - P(X \geq a) = 1 - P(X > a)$

Variável aleatória contínua

Ex.: O tempo de duração de um componente (em minutos) é uma v.a. X com f.d.p dada por

$$f_X(x) = \begin{cases} \frac{5-x}{4}, \text{ se } 2 < x < 4 \\ 0, \text{ c.c. (caso contrário)} \end{cases}$$

a) Mostre que $f_X(x)$ é uma f.d.p.

Variável aleatória contínua

Ex.: O tempo de duração de um componente (em minutos) é uma v.a. X com f.d.p dada por

$$f_X(x) = \begin{cases} \frac{5-x}{4}, \text{ se } 2 < x < 4 \\ 0, \text{ c.c. (caso contrário)} \end{cases}$$

a) Mostre que $f_X(x)$ é uma f.d.p.

i) $f_X(x) \geq 0 \quad \forall \quad 2 < x < 4$

ii)

$$\begin{aligned} \int_2^4 \frac{5-x}{4} dx &= \frac{1}{4}\left(\int_2^4 5dx - \int_2^4 xdx\right) \\ &= \frac{1}{4}\left(5x|_2^4 - \frac{x^2}{2}|_2^4\right) \\ &= \frac{1}{4}(10-6) = \frac{4}{4} = 1 \end{aligned}$$

Variável aleatória contínua

b) Calcule a probabilidade de que o tempo de produção de um componente escolhido ao acaso seja menor do que 3 minutos.

Variável aleatória contínua

b) Calcule a probabilidade de que o tempo de produção de um componente escolhido ao acaso seja menor do que 3 minutos.

$$
\begin{aligned}
P(X < 3) &= \int_2^3 \frac{5-x}{4} dx \\
&= \frac{1}{4}\left(\int_2^3 5dx - \int_2^3 xdx\right) \\
&= \frac{1}{4}\left(5 - \frac{5}{2}\right) = \frac{5}{8}
\end{aligned}
$$

Função de distribuição acumulada

Def.: Seja X uma v.a. discreta que assume valores em R_x e com f.m.p $p(x) = P(X = x)$. Para qualquer $x \in \mathbb{R}$, a função de distribuição acumulada (f.d.a) de X, denotada por $F_X(x)$, é definida como

$$F_X(x) = P(X \leq x) = \sum_{\substack{x_i \in R_x \\ \forall\ x_i \leq x}} p(x_i) = \sum_{\substack{x_i \in R_x \\ \forall\ x_i \leq x}} P(X = x_i)$$

Função de distribuição acumulada

Ex.: Considere o lançamento de uma moeda duas vezes e X é o número de vezes de caras. A f.m.p. de X é dada por

x	0	1	2
P(X=x)	1/4	1/2	1/4

A f.d.a é dada por

$$F_X(x) = P(X \leq x) = \begin{cases} 0, \text{ se } x < 0 \\ 1/4, \text{ se } 0 \leq x < 1 \\ 3/4, \text{ se } 1 \leq x < 2 \\ 1, \text{ se } x \geq 2 \end{cases}$$

Função de distribuição acumulada

Def.: Seja X uma v.a. contínua que assume valores em R_x e com f.d.p $f_X(x)$. Para qualquer $x \in I\!R$, a função de distribuição acumulada (f.d.a) de X, denotada por $F_X(x)$, é definida como

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)dt, \text{ para } -\infty < x < \infty$$

Como consequência imediata, podemos escrever os dois resultados

- $P(a < X < b) = \int_a^b f_X(x)dx = F_X(b) - F_X(a)$ (Teorema fundamental do cálculo)
- $f_X(x) = \frac{dF_X(x)}{dx}$, se a derivada existir.

Função de distribuição acumulada

Ex.: Para a função densidade dada por

$$f_X(x) = \begin{cases} \frac{x^2}{3}, \text{ se } -1 < x < 2 \\ 0, \text{ c.c.} \end{cases}$$

Determine $F_X(x)$ e use-a para avaliar $P(0 \leq X < 1)$.

Função de distribuição acumulada

Ex.: Para a função densidade dada por

$$f_X(x) = \begin{cases} \frac{x^2}{3}, \text{ se } -1 < x < 2 \\ 0, \text{ c.c.} \end{cases}$$

Determine $F_X(x)$ e use-a para avaliar $P(0 \leq X < 1)$.

$$F_X(x) = \int_{-\infty}^{x} f_X(t)dt = \int_{-1}^{x} \frac{t^2}{3}dt = \frac{t^3}{9}\Big|_{-1}^{x} = \frac{1}{9}(x^3+1)$$

Logo,

$$F_X(x) = P(X \leq x) = \begin{cases} 0, \text{ se } x < -1 \\ \frac{1}{9}(x^3+1), \text{ se } -1 \leq x < 2 \\ 1, \text{ se } x \geq 2 \end{cases}$$

Função de distribuição acumulada

A $P(0 \leq X < 1)$ pode ser calculada por

$$\begin{aligned} P(0 \leq X < 1) &= F_X(1) - F_X(0) \\ &= \frac{(1^3+1)}{9} - \frac{(0^3+1)}{9} \\ &= \frac{2}{9} - \frac{1}{9} = \frac{1}{9} \end{aligned}$$

Propriedades de uma f.d.a

- $F_X(x)$ é uma função contínua
- $F_X(x)$ é uma função monótona não-decrescente
- $0 \leq F_X(x) \leq 1, \forall\, x \in \mathbb{R}$
- $\lim\limits_{x \to -\infty} F_X(x) = 0$ e $\lim\limits_{x \to \infty} F_X(x) = 1$
- $P(X \leq a) = F_X(a)$
- $P(X > a) = 1 - P(X \leq a) = 1 - F_X(a)$
- $P(a < X \leq b) = F_X(b) - F_X(a)$

Função de distribuição acumulada

Ex.: Seja $F_X(x)$ dada por

$$F_X(x) = \begin{cases} 0, \text{ se } x < 0 \\ 1/8, \text{ se } 0 \leq x < 1 \\ 1/2, \text{ se } 1 \leq x < 2 \\ 5/8, \text{ se } 2 \leq x < 3 \\ 1, \text{ se } x \geq 3 \end{cases}$$

a) Calcule $P(1 < X \leq 3)$

Função de distribuição acumulada

Ex.: Seja $F_X(x)$ dada por

$$F_X(x) = \begin{cases} 0, \text{ se } x < 0 \\ 1/8, \text{ se } 0 \leq x < 1 \\ 1/2, \text{ se } 1 \leq x < 2 \\ 5/8, \text{ se } 2 \leq x < 3 \\ 1, \text{ se } x \geq 3 \end{cases}$$

a) Calcule $P(1 < X \leq 3)$

$P(1 < X \leq 3) = P(X = 2) + P(X = 3) = 1/8 + 3/8 = 1/2$

b) $P(X > 2)$

Função de distribuição acumulada

Ex.: Seja $F_X(x)$ dada por

$$F_X(x) = \begin{cases} 0, \text{ se } x < 0 \\ 1/8, \text{ se } 0 \leq x < 1 \\ 1/2, \text{ se } 1 \leq x < 2 \\ 5/8, \text{ se } 2 \leq x < 3 \\ 1, \text{ se } x \geq 3 \end{cases}$$

a) Calcule $P(1 < X \leq 3)$

$P(1 < X \leq 3) = P(X = 2) + P(X = 3) = 1/8 + 3/8 = 1/2$

b) $P(X > 2)$

$P(X > 2) = 1 - P(X \leq 2) = 1 - 5/8 = 3/8$

Função de distribuição acumulada

c) Encontre a $p(x)$.

Função de distribuição acumulada

c) Encontre a $p(x)$.

$P(X = 0) = 1/8; P(X = 1) = 1/2 - 1/8 = 3/8; P(X = 2) = 5/8 - 1/2 = 1/8; P(X = 3) = 1 - 5/8 = 3/8$

$$p(x) = \begin{cases} 1/8, \text{ se } x = 0 \text{ ou } x = 2 \\ 3/8, \text{ se } x = 1 \text{ ou } x = 3 \\ 0, \text{ c.c.} \end{cases}$$

Esperança matemática de uma variável aleatória

Def.: Seja X uma v.a. com f.m.p $p(x)$ (caso discreto) ou f.d.p $f_X(x)$ (caso contínuo). Chamamos de esperança matemática ou valor médio de X o valor

$$\mu_X = E(X) = \sum_{x \in R_x} x\, p(x), \text{ (Caso discreto)}$$

ou

$$\mu_X = E(X) = \int_{R_x} x\, f_X(x) dx, \text{ (Caso contínuo)}$$

desde que o somatório e a integral existam.

Propriedades da Esperança matemática

Considere $a, b \in \mathbb{R}$ constantes:

a) Se a é uma constante, então $E(aX) = aE(X)$

b) Se $X = a$ (constante), então $E(X) = E(a) = a$

c) $E(E(X)) = E(X)$

d) Se a é uma constante, então $E(X \pm a) = E(X) \pm a$

e) Se a, b são constantes, então $E(aX \pm bY) = aE(X) \pm bE(Y)$

Esperança matemática

Ex.: Seja X uma v.a. com f.m.p. dada por

$$p(x) = \frac{\binom{4}{x}\binom{3}{3-x}}{\binom{7}{3}}, \quad x = 0, 1, 2, 3$$

Calcule $E(X)$.

Esperança matemática

Ex.: Seja X uma v.a. com f.m.p. dada por

$$p(x) = \frac{\binom{4}{x}\binom{3}{3-x}}{\binom{7}{3}}, \quad x = 0, 1, 2, 3$$

Calcule $E(X)$.

$$E(X) = \sum_{x \in R_x} x\, p(x) = 0\, P(X = 0) + 1\, P(X = 1) + 2\, P(X = 2) + 3\, P(X = 3)$$

$P(X = 0) = \frac{\binom{4}{0}\binom{3}{3-0}}{\binom{7}{3}} = \frac{1}{35}, P(X = 1) = \frac{12}{35}, P(X = 2) = \frac{18}{35}, P(X = 3) = \frac{4}{35}$

Logo,

$$E(X) = 0\frac{1}{35} + 1\frac{12}{35} + 2\frac{18}{35} + 3\frac{4}{35} = \frac{60}{35} = 1,71$$

Esperança matemática

Resultado: Seja X uma v.a. com f.m.p $p(x)$ ou f.d.p $f_X(x)$. Uma função de X, dita $g(X)$, é também uma v.a. e

$$E(g(X)) = \sum_{x \in R_x} g(x)p(x)$$

ou

$$E(g(X)) = \int_{R_x} g(x)f_X(x)dx$$

Variância de uma v.a.

Def.: Seja X uma v.a. com f.m.p $p(x)$ ou f.d.p $f_X(x)$, com média $\mu_X = E(X)$. Chamamos de variância da v.a. X o valor

$$\sigma_X^2 = Var(X) = E((X - E(X))^2) = E((X - E(X))^2)$$

ou seja,

$$\sigma_X^2 = Var(X) = \sum_{x \in R_x} (x - \mu_X)^2 \, p(x)$$

ou

$$\sigma_X^2 = Var(X) = \int_{R_x} (x - \mu_X)^2 \, f_X(x) dx$$

A raiz quadrada da variância é o desvio-padrão de X, $\sigma_X = DP(X)$.

Variância de uma v.a.

Resultado: Podemos escrever a variância da v.a. X por

$$\sigma^2 = Var(X) = E(X^2) - \{E(X)\}^2$$

Variância de uma v.a.

Resultado: Podemos escrever a variância da v.a. X por

$$\sigma^2 = Var(X) = E(X^2) - \{E(X)\}^2$$

Dem.:

$$\begin{aligned}
Var(X) &= E((X - \mu_X)^2) \\
&= E(X^2 - 2X\mu_X + \mu_X^2) \\
&= E(X^2) - 2\mu_X E(X) + \mu_X^2 \\
&= E(X^2) - 2\mu_X\mu_X + \mu_X^2 \\
&= E(X^2) - \mu_X^2 \\
&= E(X^2) - \{E(X)\}^2
\end{aligned}$$

Propriedades variância de uma v.a.

Considere $a, b \in \mathbb{R}$ constantes:

- Se a é uma constante, então $Var(aX) = a^2 Var(X)$
- Se $X = a$, constante, então $Var(X) = Var(a) = 0$
- Se a é uma constante, então $Var(X \pm a) = Var(X)$
- Se a,b constantes, então $Var(aX \pm b) = a^2 Var(X)$
- Se a,b constantes e X e Y são duas variáveis independentes, então $Var(aX \pm bY) = a^2 Var(X) + b^2 Var(Y)$

Exemplos

Ex1.: Seja X uma v.a. com f.d.p dada por

$$f_X(x) = \frac{x^2}{3}, \quad -1 < x < 2$$

Determine:

a) $E(X)$

Exemplos

Ex1.: Seja X uma v.a. com f.d.p dada por

$$f_X(x) = \frac{x^2}{3}, \quad -1 < x < 2$$

Determine:

a) $E(X)$

$$\begin{aligned} E(X) &= \int_{-1}^{2} x \, \frac{x^2}{3} dx = \frac{1}{3}\frac{1}{4}x^4 \Big|_{-1}^{2} \\ &= \frac{1}{12}(2^4 - (-1)^4) = 1,25 \end{aligned}$$

Exemplos

b) $Var(X)$

Exemplos

b) $Var(X)$

$$Var(X) = E(X^2) - \{E(X)\}^2$$

$$\begin{aligned} E(X^2) &= \int_{-1}^{2} x^2 \, \frac{x^2}{3} dx = \frac{1}{3}\frac{1}{5}x^5 \Big|_{-1}^{2} \\ &= \frac{1}{15}(2^5 - (-1)^5) = 2,2 \end{aligned}$$

Logo,

$$Var(X) = 2,2 - (1,25)^2 = 0,6375$$

Exemplos

c) $E(4X + 3)$

Exemplos

c) $E(4X+3)$

$$E(4X+3) = \int_{-1}^{2} (4X+3)\frac{x^2}{3}dx$$

ou

$$E(4X+3) = 4E(X)+3 = 4(1,25)+3 = 8$$

Exemplos

Ex2.: A demanda semanal de uma certa bebida, em milhares de litros, em uma rede de lojas de conveniência, é uma v.a. contínua $g(x) = X^2 + X - 2$, onde X tem f.d.p. dada por

$$f_X(x) = \begin{cases} 2(x-1), & \text{se } 1 < x < 2 \\ 0, & \text{c.c.} \end{cases}$$

Determine o valor esperado da demanda semanal dessa bebida.

Exemplos

Ex2.: A demanda semanal de uma certa bebida, em milhares de litros, em uma rede de lojas de conveniência, é uma v.a. contínua $g(x) = X^2 + X - 2$, onde X tem f.d.p. dada por

$$f_X(x) = \begin{cases} 2(x-1), & \text{se } 1 < x < 2 \\ 0, & \text{c.c.} \end{cases}$$

Determine o valor esperado da demanda semanal dessa bebida.

Seja $Y = g(X) = X^2 + X - 2$, então

$$E(Y) = E(X^2 + X - 2) = E(X^2) + E(X) - 2$$

$$\begin{aligned} E(X) &= \int_1^2 x\, 2(x-1)dx = \int_1^2 2x^2 dx - \int_1^2 2x dx \\ &= \frac{2}{3}x^3\Big|_1^2 - 2\frac{1}{2}x^2\Big|_1^2 = 1,67 \end{aligned}$$

Exemplos

$$
\begin{aligned}
E(X^2) &= \int_1^2 x^2\, 2(x-1)dx = \int_1^2 2x^3 dx - \int_1^2 2x^2 dx \\
&= \frac{2}{4}x^4\Big|_1^2 - \frac{2}{3}x^3\Big|_1^2 \\
&= \frac{1}{2}(2^4 - 1^4) - \frac{2}{3}(2^3 - 1^3) = 2,83
\end{aligned}
$$

Assim,

$$E(Y) = E(X^2) + E(X) - 2 = 2,83 + 1,67 - 2 = 2,5$$

Portanto, a demanda semanal média dessa loja de conveniência é de 2500 litros de bebida.

Principais Modelos Discretos

Modelos Discretos - Uniforme Discreta

A v.a. assume cada um de seus valores com igual probabilidade.

Def.: A v.a. discreta X, assumindo valores $x_1, \ldots, x_k$ tem distribuição uniforme se, e somente se,

$$p(x) = P(X = x) = \begin{cases} \frac{1}{k}, & \text{se } x = x_1, x_2, \ldots, x_k \\ 0, & \text{c.c.} \end{cases}$$

Notação: $X \sim \mathcal{U}_d(k)$. Temos que

$$\mu_x = E(X) = \sum_{i=1}^{k} x_i P(X = x_i) = \sum_{i=1}^{k} x_i \frac{1}{k} = \frac{1}{k} \sum_{i=1}^{k} x_i$$

$$\sigma_X^2 = \sum_{i=1}^{k} (x_i - \mu_X)^2 P(X = x_i) = \frac{1}{k} \left\{ \sum_{i=1}^{k} x_i^2 - \frac{\left(\sum_{i=1}^{k} x_i \right)^2}{k} \right\}$$

Modelos Discretos - Uniforme Discreta

Ex.: Seja X uma v.a. que indica o n° de pontos marcados na face superior de um dado quando ele é lançado. Portanto, temos uma distribuição uniforme, cuja f.m.p é dada por

Modelos Discretos - Uniforme Discreta

Ex.: Seja X uma v.a. que indica o n° de pontos marcados na face superior de um dado quando ele é lançado. Portanto, temos uma distribuição uniforme, cuja f.m.p é dada por

$$p(x) = \begin{cases} \frac{1}{6}, & \text{se } x = 1, 2, 3, 4, 5, 6 \\ 0, & \text{c.c.} \end{cases}$$

e a $E(X)$ e $Var(X)$ são

$$\mu_x = \sum_{i=1}^{6} x_i P(X = x_i) = (1)\frac{1}{6} + (2)\frac{1}{6} + (3)\frac{1}{6} + (4)\frac{1}{6} + (5)\frac{1}{6} + (6)\frac{1}{6} = 3,5$$

$$Var(X) = E(X^2) - \{E(X)\}^2$$

$$E(X^2) = \sum_{i=1}^{k} x_i^2 P(X = x_i) = \frac{1}{6}(1^2 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2) = 15,17$$

$$Var(X) = 15,17 - (3,5)^2 = 2,92$$

Modelos Discretos - Bernoulli

Considere uma v.a. X assume apenas dois valores: 1, se ocorrer sucesso e 0, se ocorrer fracasso. Indicaremos por p a probabilidade de sucesso, isto é, P(Sucesso) = P(X=1) = p.

Def. A v.a. discreta X que assume apenas os valores 0 e 1 tem distribuição de Bernoulli se, e somente se,

$$p(x) = P(X = x) = \begin{cases} p^x(1-p)^{1-x}, \text{ se } x = 0, 1 \\ 0, \text{ c.c.} \end{cases}$$

Notação: $X \sim Ber(p)$

Temos que

$$E(X) = p$$

e

$$Var(X) = p(1-p)$$

Modelos Discretos - Bernoulli

Ex.: Suponha o lançamento de um dado perfeito e o interesse é ocorrer a face 3. Então,

Modelos Discretos - Bernoulli

Ex.: Suponha o lançamento de um dado perfeito e o interesse é ocorrer a face 3. Então,

$$X = \begin{cases} 1, & \text{se sair a face 3} \\ 0, & \text{se não sair a face 3} \end{cases}$$

A f.m.p é

x	0	1
P(X=x)	5/6	1/6

$$P(X = x) = \left(\frac{1}{6}\right)^x \left(1 - \frac{1}{6}\right)^{1-x}, x = 0, 1$$

Modelos Discretos - Binomial

Considere M ensaios de Bernoulli independentes, todos com a mesma probabilidade de sucesso p. A v.a. que conta o número de sucessos nos M ensaios de Bernoulli é denominada v.a. Binomial com parâmetros M e p.

Def.: A v.a. discreta X, correspondente ao número de sucessos em M ensaios independentes de Bernoulli, tem distribuição Binomial se, e somente, se

$$p(x) = P(X = x) = \begin{cases} \binom{M}{x} p^x (1-p)^{M-x}, \text{ se } x = 0, 1, \ldots, M \\ 0, \text{ c.c.} \end{cases}$$

em que $\binom{M}{p} = \frac{M!}{x!(M-x)!}$. Notação: $X \sim Bin(M, p)$.

$$E(X) = Mp \text{ e } Var(X) = Mp(1-p)$$

Modelos Discretos - Binomial

Ex.: Uma rede varejista compra certo tipo de equipamento eletrônico. O fabricante indica que a taxa de equipamentos em perfeito estado é 97%.

a) Seleciona-se ao acaso 20 itens. Qual a probabilidade de que haja pelo menos um item defeituoso nesses 20 ?

Modelos Discretos - Binomial

Ex.: Uma rede varejista compra certo tipo de equipamento eletrônico. O fabricante indica que a taxa de equipamentos em perfeito estado é 97%.

a) Seleciona-se ao acaso 20 itens. Qual a probabilidade de que haja pelo menos um item defeituoso nesses 20 ?

$M = 20$ e $p = 0,03$

$$\begin{aligned} P(X \geq 1) &= 1 - P(X < 1) \\ &= 1 - P(X = 0) \\ &= 1 - \binom{20}{0}(0,03)^0(1-0,03)^{20} \\ &= 0,4562 \end{aligned}$$

A probabilidade de haver pelo menos um item defeituoso nos 20 equipamentos é 0,4562.

Modelos Discretos - Binomial

b) Selecionando-se aleatoriamente 20 itens em cada um de 10 carregamentos, qual a probabilidade de que haja 3 carregamentos com pelo menos um item defeituoso?

Modelos Discretos - Binomial

b) Selecionando-se aleatoriamente 20 itens em cada um de 10 carregamentos, qual a probabilidade de que haja 3 carregamentos com pelo menos um item defeituoso?

Y= n° de carregamentos com pelo menos um item defeituoso

$$Y \sim Bin(10; 0,4526)$$

$$\begin{aligned} P(Y=3) &= \binom{10}{3}(0,4526)^3(1-0,4526)^{10-3} \\ &= (120)(0,09494)(0,01406) \\ &= 0,160216 \end{aligned}$$

Modelos Discretos - Geométrica

Considere uma sequência de ensaios Bernoulli independentes, com probabilidade de sucesso p $(0 < p < 1)$. Seja a v.a. X o n° de fracassos anteriores ao primeiro sucesso. Similarmente, a v.a. X pode ser vista como o n° de ensaios que precedem o primeiro sucesso.

Def.: A v.a. X tem distribuição geométrica se a sua f.m.p é dada por

$$p(x) = P(X = x) = \begin{cases} p(1-p)^x, \text{ se } x = 0, 1, 2, \ldots \\ 0, \text{ c.c.} \end{cases}$$

Notação: $X \sim Geo(p)$

Temos que

$$E(X) = \frac{1-p}{p} \text{ e } Var(X) = \frac{1-p}{p^2}$$

Modelos Discretos - Geométrica

Observação: Uma v.a. Y pode ser vista como o número de ensaios até a ocorrência do primeiro sucesso. Neste caso, Y tem distribuição geométrica com f.m.p. dada por

$$p(y) = P(Y = y) = \begin{cases} p(1-p)^{y-1}, \text{ se } y = 1, 2, \ldots \\ 0, \text{ c.c.} \end{cases}$$

Obs: $Y = X + 1$. Com isso temos que

$$E(Y) = \frac{1}{p} \text{ e } Var(Y) = \frac{1-p}{p^2}$$

Modelos Discretos - Geométrica

Ex.: Um pesquisador está realizando experimentos quimicos independentes e sabe que a probabilidade de que cada experimento apresente uma reação positiva é $0,3$. Qual é a probabilidade de que menos de 3 reações negativas ocorram antes da primeira positiva?

Modelos Discretos - Geométrica

Ex.: Um pesquisador está realizando experimentos quimicos independentes e sabe que a probabilidade de que cada experimento apresente uma reação positiva é $0,3$. Qual é a probabilidade de que menos de 3 reações negativas ocorram antes da primeira positiva?

$$P(X < 3) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$\begin{aligned}
P(X = x) &= p(1-p)^x \\
P(X = 0) &= 0,3(1-0,3)^0 = 0,3 \\
P(X = 1) &= 0,3(1-0,3)^1 = 0,21 \\
P(X = 2) &= 0,3(1-0,3)^2 = 0,147
\end{aligned}$$

$$P(X < 3) = 0,3 + 0,21 + 0,147 = 0,657$$

Modelos Discretos - Poisson

É largamente empregada quando se deseja contar o n° de eventos de certo tipo que ocorrem em um certo período de tempo ou superfície ou volume.

Exemplos:

- n° de chamadas telefônicas recebidas por uma central telefônica durante 5 min;
- n° de falhas de um computador em um dia de operação;
- n° de defeitos em peças fabricadas;

Modelos Discretos - Poisson

Def.: Uma v.a. X tem distribuição com parâmetro λ, $\lambda > 0$, se

$$p(x) = P(X = x) = \begin{cases} \frac{e^{-\lambda}\lambda^x}{x!}, & \text{se } x = 0, 1, 2, \ldots \\ 0, & \text{c.c.} \end{cases}$$

Notação: $X \sim Poisson(\lambda)$

Temos que

$$E(X) = \lambda \text{ e } Var(X) = \lambda$$

Modelos Discretos - Poisson

Ex.: Uma central telefônica recebe, em média, cinco chamadas por minuto. Supondo que a distribuição Poisson seja adequada nessa situação, obtenha a probabilidade de que a central telefônica receba no máximo duas chamadas durante um intervalo de um minuto.

Modelos Discretos - Poisson

Ex.: Uma central telefônica recebe, em média, cinco chamadas por minuto. Supondo que a distribuição Poisson seja adequada nessa situação, obtenha a probabilidade de que a central telefônica receba no máximo duas chamadas durante um intervalo de um minuto.

$$X \sim Poisson(5)$$

$$P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$\begin{aligned} P(X = 0) &= \frac{e^{-5}5^0}{0!} = 0,0067 \\ P(X = 1) &= \frac{e^{-5}5^1}{1!} = 0,0334 \\ P(X = 2) &= \frac{e^{-5}5^2}{2!} = 0,0842 \end{aligned}$$

$$P(X \leq 2) = 0,0067 + 0,0334 + 0,0842 = 0,1243$$

O processo de Poisson

Suponha que μ seja a média de ocorrência do evento de interesse em t unidades de medida (por exemplo, tempo). Denotamos por λ a taxa média de ocorrência em uma unidade de medida, com $\mu = \lambda t$. Podemos reescrever a f.m.p. por

$$p(x) = P(X = x) = \begin{cases} \frac{e^{-\lambda t}(\lambda t)^x}{x!}, & \text{se } x = 0, 1, 2, \ldots \\ 0, & \text{c.c.} \end{cases}$$

Modelos Discretos - Poisson

Ex.: Considerando o exemplo anterior, qual a probabilidade de que a central telefônica receba no máximo duas chamadas em quatro minutos?

Modelos Discretos - Poisson

Ex.: Considerando o exemplo anterior, qual a probabilidade de que a central telefônica receba no máximo duas chamadas em quatro minutos? Sabemos que $X \sim Poisson(5)$. Logo

$$p(x) = P(X = x) = \begin{cases} \frac{e^{-5t}(5t)^x}{x!}, & \text{se } x = 0, 1, 2, \ldots \\ 0, & \text{c.c.} \end{cases}$$

$$P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$\begin{aligned} P(X = 0) &= \frac{e^{-5(4)}(5(4))^0}{0!} = 2,06 \times 10^{-9} \\ P(X = 1) &= \frac{e^{-5(4)}(5(4))^1}{1!} = 4,12 \times 10^{-8} \\ P(X = 2) &= \frac{e^{-5(4)}(5(4))^2}{2!} = 4.12 \times 10^{-7} \end{aligned}$$

$$P(X \leq 2) = 4,56 \times 10^{-7} \approx 0$$

Resultados Importantes

Resultado 1: Se $X_1, X_2, \ldots, X_n$ são v.a's independentes e $X_i \sim Poisson(\lambda_i)$, então $Y = X_1 + X_2 + \ldots + X_n \sim Poisson(\lambda_1 + \lambda_2 + \ldots + \lambda_n)$

Resultado 2: Se $X \sim Bin(M, p)$, com M grande e p pequeno, pode-se aproximar a distribuição de X pela Poisson com parâmetro $\lambda = Mp$.

Principais modelos contínuos

Modelos Contínuos - Uniforme

Def.: Uma v.a. contínua X tem distribuição Uniforme no intervalo $[\alpha, \beta]$, $\alpha, \beta \in I\!R$, se sua f.d.p é dada por

$$f_X(x) = \begin{cases} \frac{1}{\beta-\alpha}, \text{ se } \alpha \leq x \leq \beta \\ 0, \text{ c.c.} \end{cases}$$

Notação: $X \sim U(\alpha, \beta)$. A f.d.a. da distribuição uniforme é dada por

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)dt = \int_{-\infty}^{x} \frac{1}{\beta - \alpha} dt = \frac{x - \alpha}{\beta - \alpha}$$

$$F_X(x) = \begin{cases} 0, \text{ se } x < \alpha \\ \frac{x-\alpha}{\beta-\alpha}, \text{ se } \alpha \leq x \leq \beta \\ 1, \text{ se } x \geq \beta \end{cases}$$

Modelos Contínuos - Uniforme

Ilustração gráfica da f.d.p. da $U(a, b)$

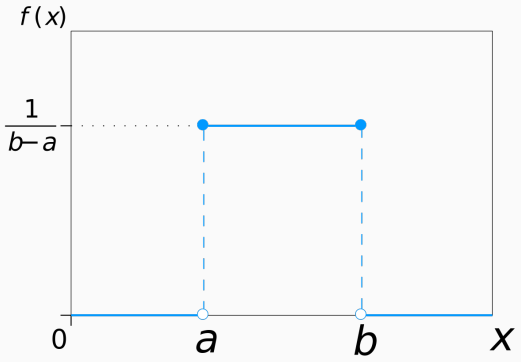

Ilustração gráfica da f.d.a. da $U(a, b)$

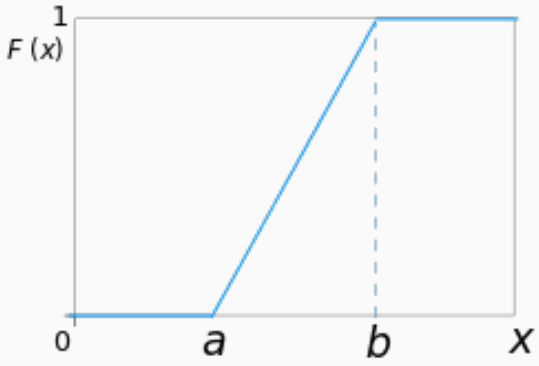

Modelos Contínuos - Uniforme

A média e a variância de X são, respectivamente,

$$E(X) = \frac{\alpha + \beta}{2} \quad \text{se} \quad Var(X) = \frac{(\beta - \alpha)^2}{12}$$

Modelos Contínuos - Uniforme

Ex.: Seja X uma v.a. com distribuição Uniforme $U(-1/2, 1/2)$.
Calcule:
a) $F_X(x)$

Modelos Contínuos - Uniforme

Ex.: Seja X uma v.a. com distribuição Uniforme $U(-1/2, 1/2)$. Calcule:

a) $F_X(x)$

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)dt = \int_{-1/2}^{x} \frac{1}{1/2 - (-1/2)} dt = x + 1/2$$

b) $P(-1/4 < X \leq 1/4)$

Modelos Contínuos - Uniforme

Ex.: Seja X uma v.a. com distribuição Uniforme $U(-1/2, 1/2)$. Calcule:

a) $F_X(x)$

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)dt = \int_{-1/2}^{x} \frac{1}{1/2 - (-1/2)} dt = x + 1/2$$

b) $P(-1/4 < X \leq 1/4)$

$$P(-1/4 < X \leq 1/4) = \int_{-1/4}^{1/4} 1dx$$

ou

$$P(-1/4 < X \leq 1/4) = F_X(1/4) - F_X(-1/4) = (1/4 + 1/2) - (-1/4 + 1/2)$$
$$= 1/2$$

Modelos Contínuos - Uniforme

c) $E(X)$ e $Var(X)$

Modelos Contínuos - Uniforme

c) $E(X)$ e $Var(X)$

$$E(X) = \frac{-1/2 + 1/2}{2} = 0$$

$$Var(X) = \frac{(1/2 + 1/2)^2}{12} = \frac{1}{12}$$

Modelos Contínuos - Exponencial

Def.: Uma v.a. contínua X tem distribuição Exponencial com parâmetro λ, $\lambda > 0$, se sua f.d.p é dada por

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, \text{ se } x \geq 0 \\ 0, \text{ c.c.} \end{cases}$$

Notação: $X \sim Exp(\lambda)$. Uma ilustração gráfica da f.d.p. é

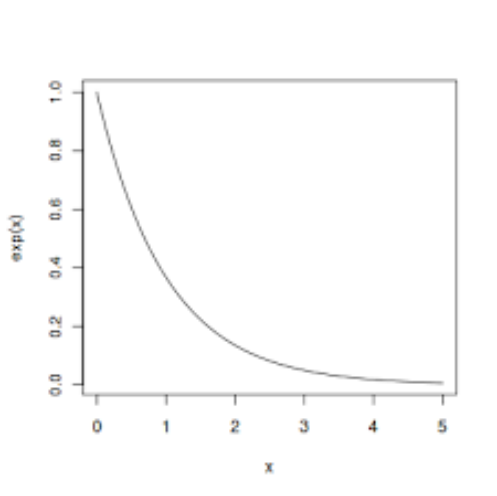

Modelos Contínuos - Exponencial

A f.d.a é dada por

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)dt = \int_{0}^{x} \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}$$

$$F_X(x) = \begin{cases} 0, \text{ se } x < 0 \\ 1 - e^{-\lambda x}, \text{ se } x \geq 0 \end{cases}$$

Modelos Contínuos - Exponencial

A ilustração gráfica da f.d.a é dada por

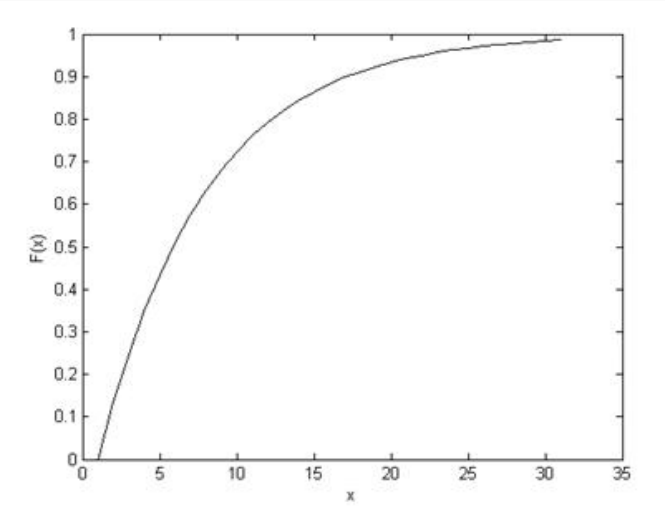

A média e a variância de X são

$$E(X) = \frac{1}{\lambda} \quad \text{e} \quad Var(X) = \frac{1}{\lambda^2}$$

Modelos Contínuos - Exponencial

Prop.: Se $X \sim Exp(\lambda)$, então $P(X > a + b | X > b) = P(X > a)$.

Esta propriedade é conhecida por falta de memória e é a única distribuição contínua com esta propriedade.

Observação: Outra parametrização para a distribuição exponencial.

$$f_X(x) = \begin{cases} \frac{1}{\alpha} e^{-\frac{x}{\alpha}}, & \text{se } x \geq 0 \\ 0, & \text{c.c.} \end{cases}$$

Utilizando essa parametrização, temos que

$$E(X) = \alpha \quad \text{e} \quad Var(X) = \alpha^2$$

Modelos Contínuos - Exponencial

Ex.: Seja X o tempo de vida de um fusível que tem distribuição exponencial com vida média de 100 horas. Qual a probabilidade de um fusível durar mais de 150 horas ?

Modelos Contínuos - Exponencial

Ex.: Seja X o tempo de vida de um fusível que tem distribuição exponencial com vida média de 100 horas. Qual a probabilidade de um fusível durar mais de 150 horas ?

$$X \sim Exp(\lambda)$$

$$E(X) = \frac{1}{\lambda} \Rightarrow \lambda = \frac{1}{100}$$

$$f_X(x) = \begin{cases} \frac{1}{100} e^{-\frac{x}{100}}, \text{ se } x \geq 0 \\ 0, \text{ c.c.} \end{cases}$$

$$P(X > 150) = \int_{150}^{\infty} \frac{1}{100} e^{-\frac{x}{100}} dx = -e^{-\frac{x}{100}} \Big|_{150}^{\infty} = e^{-1,5} = 0,22313$$

Modelos Contínuos - Normal

É o mais importante dos modelos probabilísticos. É também conhecida como distribuição Gaussiana. Sua representação gráfica é conhecida pela curva em forma de sino.

Def.: Uma v.a. contínua X tem distribuição normal com parâmetros μ (média) e σ^2 (variância) se sua f.d.p é dada por

$$f_X(x) = \begin{cases} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, \text{ se } -\infty < x < \infty, -\infty < \mu < \infty, \sigma^2 > 0 \\ 0, \text{ c.c.} \end{cases}$$

Notação: $X \sim \mathcal{N}(\mu, \sigma^2)$.

Modelos Contínuos - Normal

Uma ilustração gráfica da sua f.d.p é

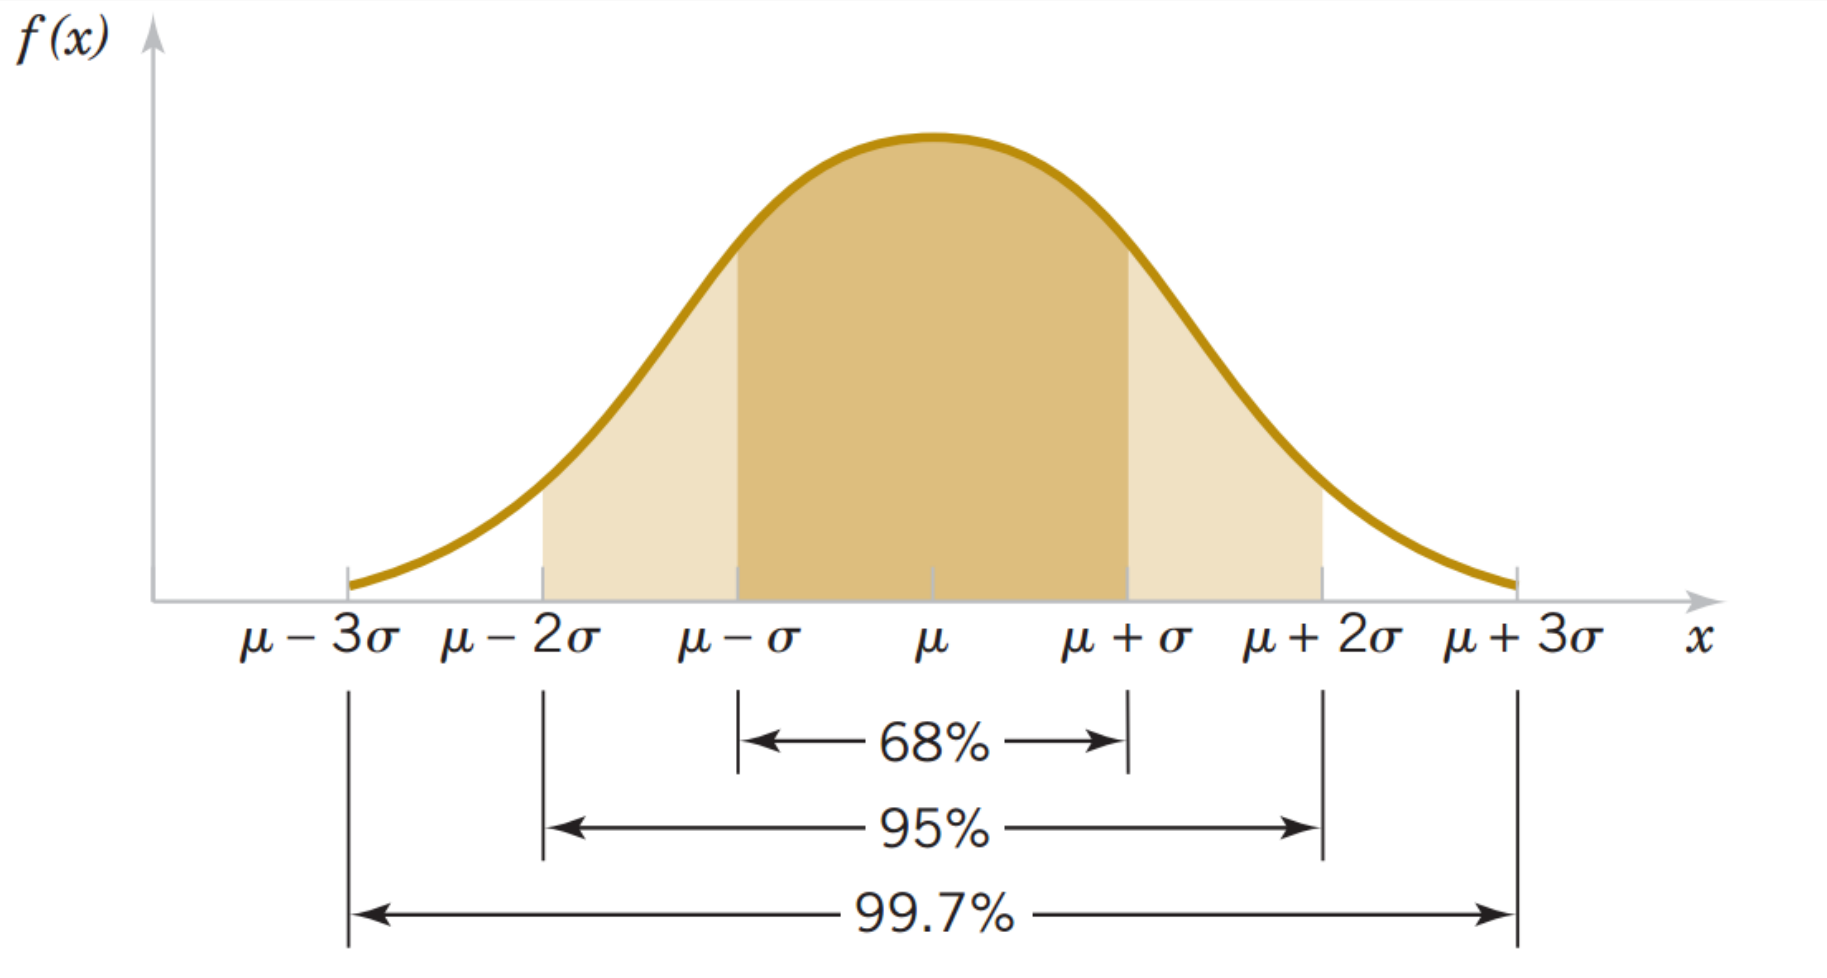

Modelos Contínuos - Normal

A média e a variância de X são

$$E(X) = \mu \quad \text{e} \quad Var(X) = \sigma^2$$

ou seja, a distribuição é parametrizada pela sua média e variância.

Prop.:

1 - A distribuição é simétrica em relação à média. Isto é,

$$f(\mu - x) = f(\mu + x), \forall x \in I\!R$$

2 - Como a área total sob a curva é igual a 1, à esquerda e à direita de μ a área é igual a 0,5.

3 - Distribuição Normal e o Boxplot

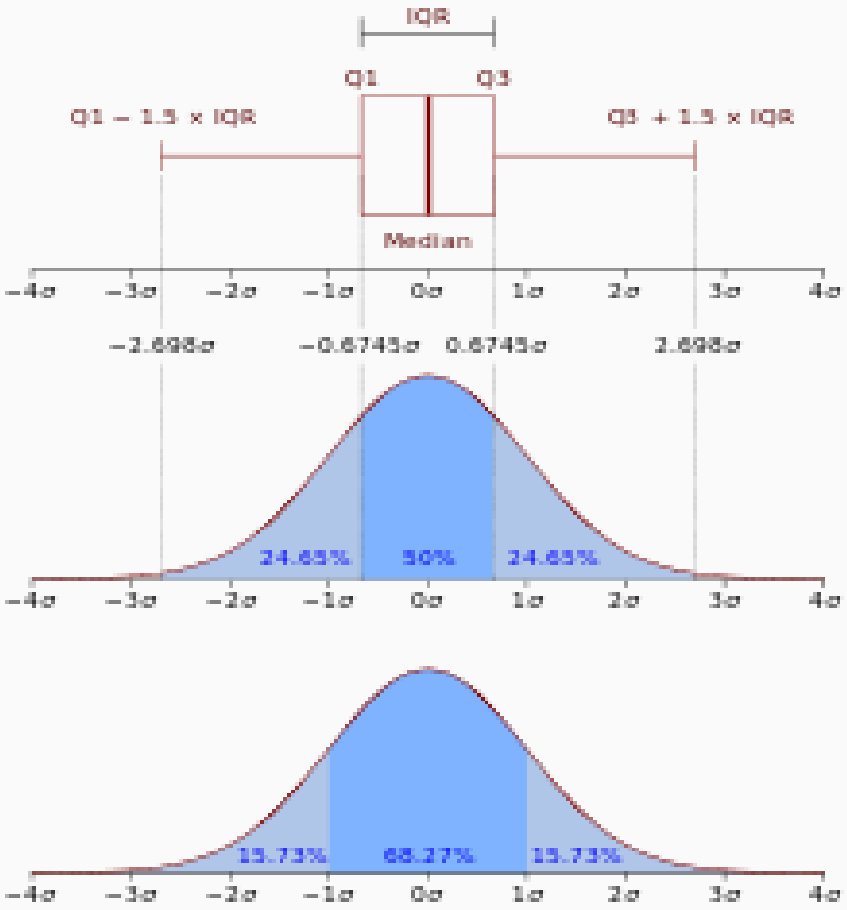

Modelos Contínuos - Normal

A f.d.a. de uma v.a. $X \sim \mathcal{N}(\mu, \sigma^2)$ é

$$F_X(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(t-\mu)^2} dt$$

cuja integral não tem solução analítica.

Pergunta: Como calcular probabilidades ?

Modelos Contínuos - Normal

Def.: Se $X \sim \mathcal{N}(\mu, \sigma^2)$, então a v.a. Z definida por

$$Z = \frac{X - \mu}{\sigma}$$

terá distribuição normal com média 0 e variância 1, $Z \sim \mathcal{N}(0, 1)$, conhecida como distribuição normal-padrão ou reduzida.

Modelos Contínuos - Normal

Table of Standard Normal Probabilities for Negative Z-scores

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
-3.4	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0002
-3.3	0.0005	0.0005	0.0005	0.0004	0.0004	0.0004	0.0004	0.0004	0.0004	0.0003
-3.2	0.0007	0.0007	0.0006	0.0006	0.0006	0.0006	0.0006	0.0005	0.0005	0.0005
-3.1	0.0010	0.0009	0.0009	0.0009	0.0008	0.0008	0.0008	0.0008	0.0007	0.0007
-3.0	0.0013	0.0013	0.0013	0.0012	0.0012	0.0011	0.0011	0.0011	0.0010	0.0010
-2.9	0.0019	0.0018	0.0018	0.0017	0.0016	0.0016	0.0015	0.0015	0.0014	0.0014
-2.8	0.0026	0.0025	0.0024	0.0023	0.0023	0.0022	0.0021	0.0021	0.0020	0.0019
-2.7	0.0035	0.0034	0.0033	0.0032	0.0031	0.0030	0.0029	0.0028	0.0027	0.0026
-2.6	0.0047	0.0045	0.0044	0.0043	0.0041	0.0040	0.0039	0.0038	0.0037	0.0036
-2.5	0.0062	0.0060	0.0059	0.0057	0.0055	0.0054	0.0052	0.0051	0.0049	0.0048
-2.4	0.0082	0.0080	0.0078	0.0075	0.0073	0.0071	0.0069	0.0068	0.0066	0.0064
-2.3	0.0107	0.0104	0.0102	0.0099	0.0096	0.0094	0.0091	0.0089	0.0087	0.0084
-2.2	0.0139	0.0136	0.0132	0.0129	0.0125	0.0122	0.0119	0.0116	0.0113	0.0110
-2.1	0.0179	0.0174	0.0170	0.0166	0.0162	0.0158	0.0154	0.0150	0.0146	0.0143
-2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
-1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
-1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
-1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
-1.6	0.0548	0.0537	0.0526	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
-1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
-1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
-1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823
-1.2	0.1151	0.1131	0.1112	0.1093	0.1075	0.1056	0.1038	0.1020	0.1003	0.0985
-1.1	0.1357	0.1335	0.1314	0.1292	0.1271	0.1251	0.1230	0.1210	0.1190	0.1170
-1.0	0.1587	0.1562	0.1539	0.1515	0.1492	0.1469	0.1446	0.1423	0.1401	0.1379
-0.9	0.1841	0.1814	0.1788	0.1762	0.1736	0.1711	0.1685	0.1660	0.1635	0.1611
-0.8	0.2119	0.2090	0.2061	0.2033	0.2005	0.1977	0.1949	0.1922	0.1894	0.1867
-0.7	0.2420	0.2389	0.2358	0.2327	0.2296	0.2266	0.2236	0.2206	0.2177	0.2148
-0.6	0.2743	0.2709	0.2676	0.2643	0.2611	0.2578	0.2546	0.2514	0.2483	0.2451
-0.5	0.3085	0.3050	0.3015	0.2981	0.2946	0.2912	0.2877	0.2843	0.2810	0.2776
-0.4	0.3446	0.3409	0.3372	0.3336	0.3300	0.3264	0.3228	0.3192	0.3156	0.3121
-0.3	0.3821	0.3783	0.3745	0.3707	0.3669	0.3632	0.3594	0.3557	0.3520	0.3483
-0.2	0.4207	0.4168	0.4129	0.4090	0.4052	0.4013	0.3974	0.3936	0.3897	0.3859
-0.1	0.4602	0.4562	0.4522	0.4483	0.4443	0.4404	0.4364	0.4325	0.4286	0.4247
-0.0	0.5000	0.4960	0.4920	0.4880	0.4840	0.4801	0.4761	0.4721	0.4681	0.4641

Table of Standard Normal Probabilities for Positive Z-scores

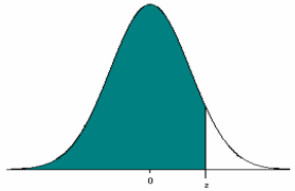

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Note that the probabilities given in this table represent the area to the LEFT of the z-score.
The area to the RIGHT of a z-score = 1 – the area to the LEFT of the z-score

Modelos Contínuos - Normal

Ex.:(Uso da tabela da normal-padrão). Seja $Z \sim \mathcal{N}(0, 1)$, calcule:

a) $P(0 \leq Z \leq 1,65)$

Ex.:(Uso da tabela da normal-padrão). Seja $Z \sim \mathcal{N}(0,1)$, calcule:

a) $P(0 \leq Z \leq 1,65) = P(Z \leq 1,65) - P(Z \leq 0) = 0,9505 - 0,5 = 0,4505$

Table of Standard Normal Probabilities for Positive Z-scores

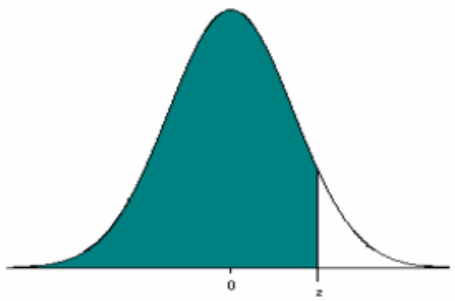

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633

Modelos Contínuos - Normal

b) $P(Z < -1,57)$

Modelos Contínuos - Normal

b) $P(Z < -1,57) = 0,0582$

Table of Standard Normal Probabilities for Negative Z-scores

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
-3.4	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0002
-3.3	0.0005	0.0005	0.0005	0.0004	0.0004	0.0004	0.0004	0.0004	0.0004	0.0003
-3.2	0.0007	0.0007	0.0006	0.0006	0.0006	0.0006	0.0006	0.0005	0.0005	0.0005
-3.1	0.0010	0.0009	0.0009	0.0009	0.0008	0.0008	0.0008	0.0008	0.0007	0.0007
-3.0	0.0013	0.0013	0.0013	0.0012	0.0012	0.0011	0.0011	0.0011	0.0010	0.0010
-2.9	0.0019	0.0018	0.0018	0.0017	0.0016	0.0016	0.0015	0.0015	0.0014	0.0014
-2.8	0.0026	0.0025	0.0024	0.0023	0.0023	0.0022	0.0021	0.0021	0.0020	0.0019
-2.7	0.0035	0.0034	0.0033	0.0032	0.0031	0.0030	0.0029	0.0028	0.0027	0.0026
-2.6	0.0047	0.0045	0.0044	0.0043	0.0041	0.0040	0.0039	0.0038	0.0037	0.0036
-2.5	0.0062	0.0060	0.0059	0.0057	0.0055	0.0054	0.0052	0.0051	0.0049	0.0048
-2.4	0.0082	0.0080	0.0078	0.0075	0.0073	0.0071	0.0069	0.0068	0.0066	0.0064
-2.3	0.0107	0.0104	0.0102	0.0099	0.0096	0.0094	0.0091	0.0089	0.0087	0.0084
-2.2	0.0139	0.0136	0.0132	0.0129	0.0125	0.0122	0.0119	0.0116	0.0113	0.0110
-2.1	0.0179	0.0174	0.0170	0.0166	0.0162	0.0158	0.0154	0.0150	0.0146	0.0143
-2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
-1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
-1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
-1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
-1.6	0.0548	0.0537	0.0526	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
-1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
-1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
-1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823
-1.2	0.1151	0.1131	0.1112	0.1093	0.1075	0.1056	0.1038	0.1020	0.1003	0.0985
-1.1	0.1357	0.1335	0.1314	0.1292	0.1271	0.1251	0.1230	0.1210	0.1190	0.1170
-1.0	0.1587	0.1562	0.1539	0.1515	0.1492	0.1469	0.1446	0.1423	0.1401	0.1379
-0.9	0.1841	0.1814	0.1788	0.1762	0.1736	0.1711	0.1685	0.1660	0.1635	0.1611

Modelos Contínuos - Normal

Ex.: Seja $X \sim \mathcal{N}(90, 100)$. Cacule:

a) $P(80 < X < 100)$

Modelos Contínuos - Normal

Ex.: Seja $X \sim \mathcal{N}(90, 100)$. Cacule:

a) $P(80 < X < 100)$

$$P\left(\frac{80-90}{10} < \frac{X-90}{10} < \frac{100-90}{10}\right) = P(-1 < Z < 1)$$

$$= P(Z < 1) - P(Z < -1) = 0,8413 - 0,1587 = 0,6826$$

b)$P(X \geq 90)$

Modelos Contínuos - Normal

Ex.: Seja $X \sim \mathcal{N}(90, 100)$. Cacule:

a) $P(80 < X < 100)$

$$P\left(\frac{80-90}{10} < \frac{X-90}{10} < \frac{100-90}{10}\right) = P(-1 < Z < 1)$$

$$= P(Z < 1) - P(Z < -1) = 0,8413 - 0,1587 = 0,6826$$

b)$P(X \geq 90)$

$$P\left(\frac{X-90}{10} \geq \frac{90-90}{10}\right) = P(Z \geq 0) = 0,5$$

Modelos Contínuos - t-Student

Def.: Uma variável aleatória contínua X tem distribuição t-Student com ν graus de liberdade se sua f.d.p é dada por

$$f_X(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})}\left(1+\frac{x^2}{\nu}\right)^{-\left(\frac{\nu+1}{2}\right)}, \quad -\infty < x < \infty, \nu > 0$$

Notação: $X \sim t_\nu$

Modelos Contínuos - *t*-Student

Ilustração da sua f.d.p

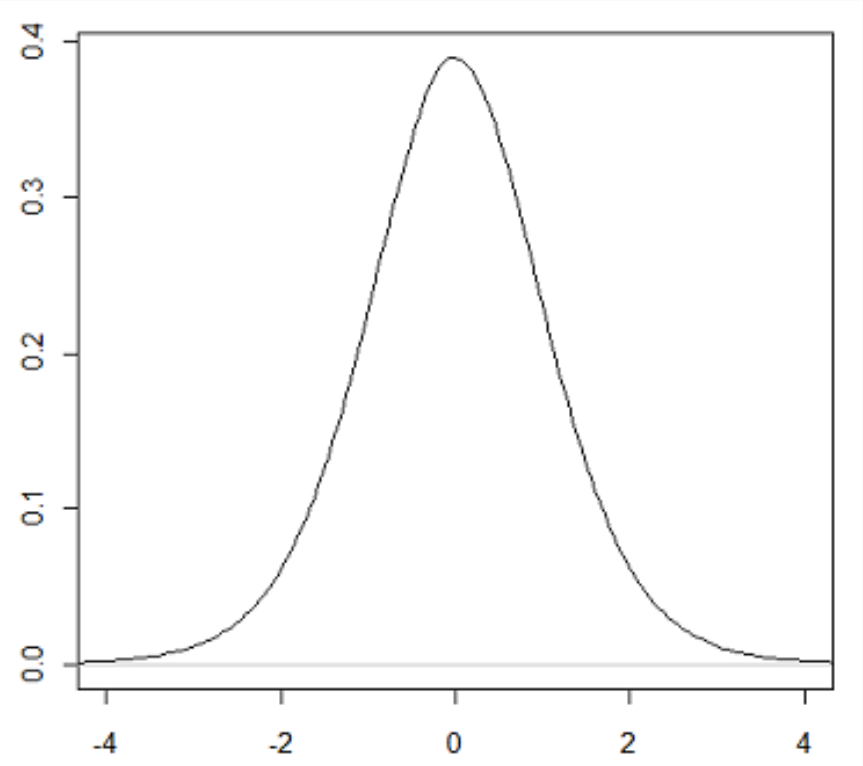

Modelos Contínuos - t-Student

Propriedades:

- A f.d.p tem a mesma forma de sino da distribuição Normal, mas com caudas mais pesadas;
- Quanto maior o grau de liberdade, mais a distribuição t-Student se aproxima da distribuição Normal;
- Considere $X_1, \ldots, X_n$ variáveis aleatórias e com distribuição normal com média μ e desvio padrão σ. Então, a variável

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}}$$

onde s é o desvio padrão amostral, tem distribuição t-Student com $n - 1$ graus de liberdade;
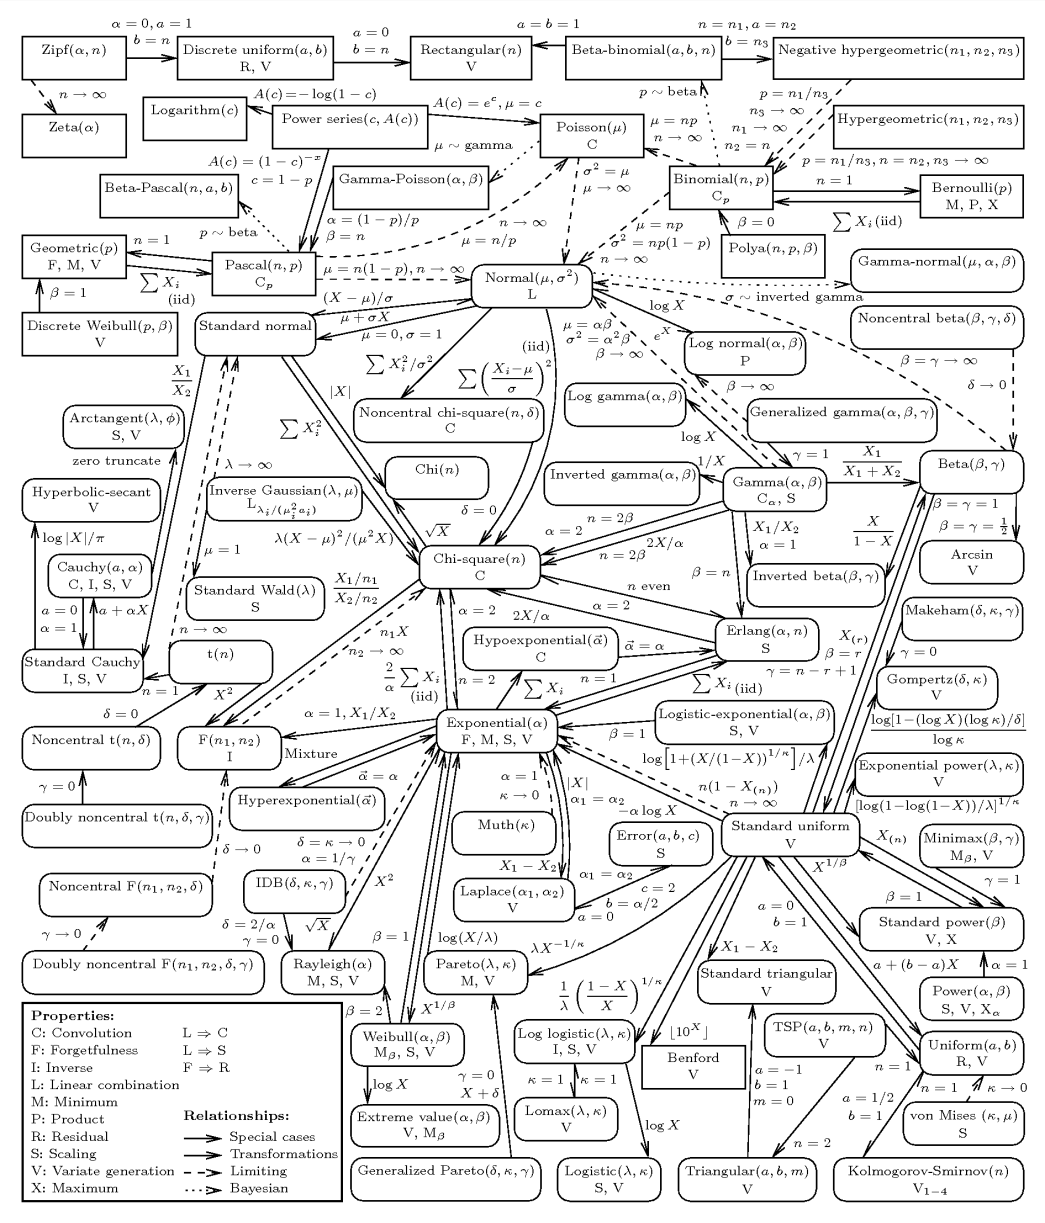
Modelos Probabilísticos